群知能 | 先行研究調査 (2026-10-23)

ACO の系譜と Neural ACO による大規模組合せ最適化

ACO (Ant System→ACS→MMAS) を、①ランタイム・収束の理論、②神経組合せ最適化 (AM・POMO) との接続、③学習・LLM による η 設計の 3 方向から追う。IRIDIA の原理 (AntNet) → MMAS 理論 (Kötzing+→Kergaßner+→Manthey+)、ML-ACO→ (DeepACO) → ReEvo→TIDE 、そして NCO のヒートマップを復号する HeatACO へ。

#	年	論文	発表	系譜
1	1998	AntNet (Di Caro & Dorigo 1998)	JAIR 9 (1998)	原典
2	2011	MMAS on linear functions (Kötzing+ 2011)	FOGA 2011	発展
3	2019	Attention Model (Kool+ 2019)	ICLR 2019	原典
4	2020	POMO (Kwon+ 2020)	NeurIPS 2020	発展
5	2020	ML-ACO (Sun+ 2020)	Computers & OR 2022	発展
6	2024	BACO Markov analysis (Kergaßner+ 2024)	GECCO 2024	最新
7	2024	ReEvo (Ye+ 2024)	NeurIPS 2024	発展
8	2025	Time-dependent ACO (Manthey+ 2025)	ANTS 2026 (LNCS)	最新
9	2026	HeatACO (Lin+ 2026)	arXiv プレプリント 2026	最新
10	2026	TIDE (Chen+ 2026)	arXiv プレプリント 2026	最新

AntNet: Distributed Stigmergetic Control for Communications Networks

Gianni Di Caro, Marco Dorigo（IRIDIA, Université Libre de Bruxelles）| JAIR 1998

1 どんなもの?

Ant System（Dorigo+ 1991/96）のスティグマジー原理を、パケット網の適応ルーティングに移した AntNet を提案。前向き蟻が経路を試し、後ろ向き蟻が確率的ルーティング表を強化する。現実的なシミュレータで 6 手法と比べ、遅延で最良。

2 先行研究と比べてどこがすごい?

OSPF・SPF・Bellman-Ford は推定値を他ノードへ伝播させ、局所的な誤差が全体に広がる。Q-Routing（Boyan & Littman 1994）は TD(0) 型で経路を決定的に選ぶ。AntNet は推定を伝播させず、蟻のモンテカルロ試行の結果だけで確率表を更新する。

3 技術や手法のキモはどこ?

各ノードが確率表 P_nd と旅行時間の統計モデルを持つ。前向き蟻は P_nd にキュー長の補正を加えて次ノードを選ぶ。後ろ向き蟻は逆走しながら強化量 $r \in (0,1]$ で $P_{fd} \leftarrow P_{fd} + r(1-P_{fd})$ と更新し、他の辺は正規化で減衰させる。

4 どうやって有効だと検証した?

SimpleNet（8 ノード）・NSFNET（14）・NTTnet（57）で、OSPF/SPF/BF/Q-R/PQ-R/ 理想解 Daemon と比較した。SimpleNet では AntNet だけが Daemon 並みのスループット（Fig. 8）。NTTnet では 90% 遅延が他手法より 1 桁小さい（Fig. 13–15）。

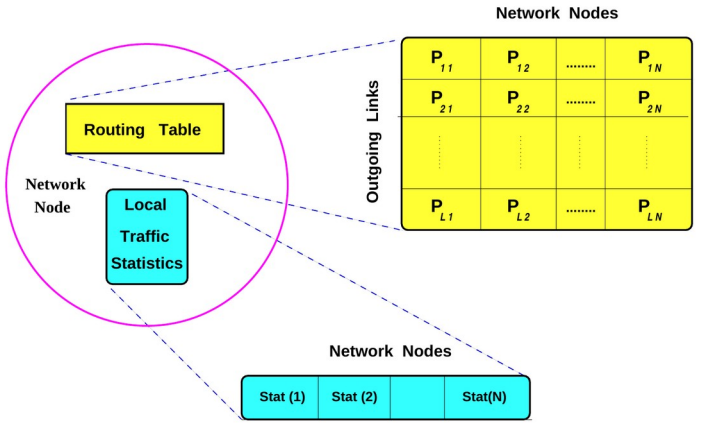
5 議論はある?

著者:ルーティングを分散・非定常の強化学習問題と捉え、Actor-Critic や first-visit MC との対応を論じた。

所感: Neural ACO が ACO を RL や事前分布の学習として扱う視点の起点。組合せ最適化側の原典（AS・ACS）は本文未確認のため、本論文で原理を確かめた。

6 次に読むべき論文は?

- Ant System (Dorigo+ 1996)（未調査:本文未確認）
- Ant Colony System (Dorigo & Gambardella 1997)（未調査:本文未確認）
- DeepACO (Ye+ 2023)（既存: deep-learning-fusion）



出典: AntNet (Di Caro & Dorigo 1998) Fig. 1（各ノードが持つ確率的ルーティング表と局所交通統計）

書誌情報

発表: JAIR 9 (1998)
リンク: https://arxiv.org/abs/1105.5449
系譜: 原典
調査日: 2026-10-23
確認範囲: 全文（問題提起・手法・実験・結果・考察）

Simple Max-Min Ant Systems and the Optimization of Linear Pseudo-Boolean Functions

Timo Kötzing, Frank Neumann, Dirk Sudholt, Markus Wagner（Max Planck Institute for Informatics）| FOGA 2011

1 どんなもの?

MAX-MIN Ant System（MMAS）を簡略化した MMAS/MMAS* について、線形擬似ブール関数での期待最適化時間を厳密に解析した。全線形関数に $O(n^3 \log n/\rho)$、OneMax に $O(n \log n + n/\rho)$ の上界を与え、両者の上界の差 n^2 を解消。

2 先行研究と比べてどこがすごい?

従来の解析（Neumann, Sudholt & Witt; Gutjahr & Sebastiani）は、フェロモンが上下限に張り付く「凍結」を前提とし、上界が関数値の種類数に比例した。BinVal では 2^n 通りあるため指数的な界だった。本論文は凍結を仮定しない解析法を導入した。

3 技術や手法のキモはどこ?

1 ビットごとに 0/1 の 2 辺を持つ構築グラフで、フェロモン = 選択確率とし $[1/n, 1-1/n]$ に制限する。最良解を毎回強化し $\tau' = \min\{(1-\rho)\tau+\rho, 1-1/n\}$。適応度レベル法をフェロモン側に拡張し、重み付きフェロモン和の上昇で進捗を測る。

4 どうやって有効だと検証した?

定理:全線形関数 $O(n^3 \log n/\rho)$（Thm. 2）、OneMax $O(n \log n + n/\rho)$（Thm. 8）、BinVal $O(n^2 + n/\rho)$ ほか（Thm. 12）。実験は n=200 〜 1000、$\rho \in \{1, 0.5, 0.1, 0.05\}$ で 1000 回平均（Fig. 2）。MMAS は ρ=0.1 で ρ=1 より約 30% 速い。

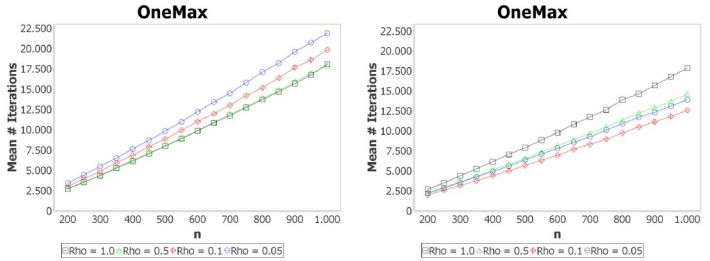
5 議論はある?

著者:一般の上界はまだ緩く、全線形関数で $O(n \log n + n/\rho)$ が成り立つかは未解決。

所感:蟻 1 匹・最良解のみ強化という極端な簡略版で、TSP など実用 ACO との距離は大きい。ただ、ρ と τ の上下限の役割を定量化し、後の理論の土台になった。

6 次に読むべき論文は?

- BACO Markov analysis (Kergaßner+ 2024)（本資料）
- Runtime analysis of a simple ACO algorithm (Neumann & Witt 2009)（未調査:本文未確認）
- MAX-MIN Ant System (Stützle & Hoos 2000)（未調査:本文未確認）



出典: MMAS on linear functions (Kötzing+ 2011) Fig. 2 上段（OneMax での MMAS*（左）と MMAS（右）の平均反復回数。ρ=1.0/0.5/0.1/0.05）

書誌情報

発表: FOGA 2011
リンク: https://arxiv.org/abs/1007.4707
系譜: 発展（← MAX-MIN Ant System (Stützle & Hoos 2000)）
調査日: 2026-10-23
確認範囲: 全文（問題提起・手法・実験・結果・考察）

Attention, Learn to Solve Routing Problems!

Wouter Kool, Herke van Hoof, Max Welling（University of Amsterdam）| ICLR 2019

1 どんなもの?

Transformer 型のエンコーダ・デコーダで巡回路を 1 ノードずつ構築する Attention Model（AM）と、貪欲ロールアウトをベースラインにした REINFORCE を提案。同じハイパラで TSP・CVRP・OP・PCTSP を学習し、TSP100 で gap 2.26% 。

2 先行研究と比べてどこがすごい?

Pointer Network（Vinyals+ 2015; Bello+ 2016）は LSTM のため入力順に依存し、Actor-Critic 学習も不安定。S2V-DQN（Dai+ 2017）は貪欲な挿入に偏る。AM は注意機構で順序不変と並列化を得て、学習則も簡素にした。構築型 NCO の標準形となった。

3 技術や手法のキモはどこ?

3 層の多頭注意（8 ヘッド、d=128）でノード埋込みを作り、デコーダが文脈（グラフ埋込み・始点・直前ノード）から訪問済みをマスクして次を選ぶ。勾配は $\nabla L = E[(L(\pi) - b(s))\nabla \log p_\theta(\pi|s)]$ 、b(s) は最良モデルの貪欲解。

4 どうやって有効だと検証した?

各問題 1 万事例で評価（Table 1）。TSP20/50/100 で貪欲 0.34/1.76/4.53% 、1280 サンプルで 0.08/0.52/2.26% 。Bello+（貪欲 6.90%）や OR Tools（2.90%）を上回る。CVRP100 は LKH3 比 3.72% 。AM とロールアウト基線の両方が効く（Fig. 3）。

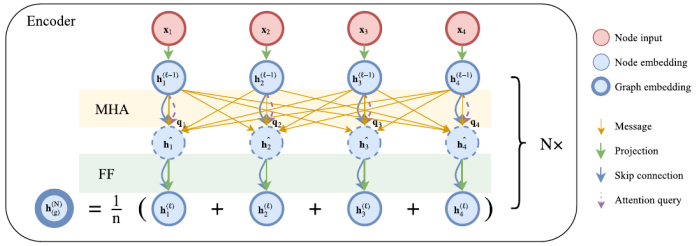
5 議論はある?

著者:大規模化（グラフの疎化）と、マスクで表せない制約（バックトラック）が課題。

所感:学習方策 $p_\theta(\pi|s)$ は、ACO の構築規則 $\tau^\alpha \cdot \eta^\beta$ を 1 回の推論で置き換えたものと読める。反復探索を持たない弱点を、フェロモン更新で補うのが DeepACO の発想。

6 次に読むべき論文は?

- POMO (Kwon+ 2020)（本資料）
- DeepACO (Ye+ 2023)（既存: deep-learning-fusion）
- Pointer Networks (Vinyals+ 2015)（未調査）



出典: Attention Model (Kool+ 2019) Fig. 1（多頭注意によるエンコーダ。グラフ埋込みはノード埋込みの平均）

書誌情報

発表: ICLR 2019
リンク: https://arxiv.org/abs/1803.08475
系譜: 原典
調査日: 2026-10-23
確認範囲: 全文（問題提起・手法・実験・結果・考察）

POMO: Policy Optimization with Multiple Optima for Reinforcement Learning

Yeong-Dae Kwon, Jinho Choo, Byoungjip Kim, Iljoo Yoon ほか (Samsung SDS) | NeurIPS 2020

1 どんなもの?

解の系列表現の対称性 (TSP では始点が任意) を使い、N 個の始点から軌跡を並列に生成して共有ベースラインで学習する POMO を提案。AM と同じネットワークで、TSP100 の gap を 0.14% (約 1 分) まで下げた。

2 先行研究と比べてどこがすごい?

AM (Kool+ 2019) の貪欲ロールアウト基線では、サンプル解のアドバンテージがほぼ常に負になる。START トークンは特定の初手に偏る。POMO は最適解の複数の表現を同時に探索し、低分散で局所解に陥りにくい学習と、多始点・座標変換による推論を導入した。

3 技術や手法のキモはどこ?

各ノードを始点とする N 本の軌跡を並列にサンプルし、$\nabla J \approx (1/N)\Sigma(R(\tau^i)-b(s))\nabla \log p_\theta(\tau^i|s)$。b(s) は N 本の報酬の平均 (共有基線)。推論では多始点の貪欲解と、単位正方形の反転・回転 8 通りの事例拡張から最良を選ぶ。

4 どうやって有効だと検証した?

TSP100 (Table 2) : AM 貪欲 3.51% → POMO 単一軌跡 1.07% → ×8 拡張 0.14% (1 分)。CVRP100 は LKH3 比 0.32% (2 分) で、AM サンプリング (3.09% 、30 分) を大きく上回る。0-1 ナップサック KP100 でも gap 0.006 (Table 4)。

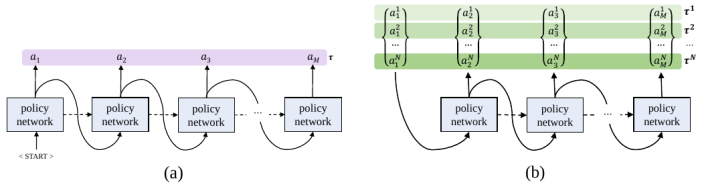
5 議論はある?

著者: CVRP ではすべてのノードが良い始点ではなく、始点を選ぶ別ネットワークは今後の課題。

所感: 同一事例で多数の解を作り平均と比べる学習は、蟻の集団比較に近い。ただし学習は 100 ノード規模で、ReEvo 論文では TSP1000 の gap が 52% (ReEvo Table 3)。

6 次に読むべき論文は?

- Attention Model (Kool+ 2019) (本資料)
- ReEvo (Ye+ 2024) (本資料)
- LEHD (Luo+ 2023) (未調査)



出典: POMO (Kwon+ 2020) Fig. 2 ((a) START トークンによる単一軌跡 (b) 始点を変えた N 本の軌跡の並列生成)

書誌情報

発表: NeurIPS 2020
リンク: https://arxiv.org/abs/2010.16011
系譜: 発展 (← Attention Model (Kool+ 2019))
調査日: 2026-10-23
確認範囲: 全文 (問題提起・手法・実験・結果・考察)

Boosting Ant Colony Optimization via Solution Prediction and Machine Learning

Yuan Sun, Sheng Wang, Yunzhuang Shen, Xiaodong Li ほか(Monash University) | Computers & Operations Research 2022

1 どんなもの?

小規模事例の最適解から「辺が最適解に含まれる確率」を分類器で学習し、ACO のヒューリスティック行列 η やフェロモン初期値に入れる ML-ACO を提案。オリエンテーリング問題で AS・MMAS を一貫して改善し、500 ノードでは MMAS 比 10% 超。

2 先行研究と比べてどこがすごい?

ACO の η は問題知識から手設計し(OP では $\eta = s_j/c_{ij}$)、フェロモンは一様に初期化するのが通例だった。本論文は解予測(Sun+ 2021)を ACO に組み込む最初の試み。後に DeepACO (Ye+ 2023)が「教師あり・特徴量手設計」と指摘する代表例でもある。

3 技術や手法のキモはどこ?

CPLEX で解いた 50 ノードの OP 事例 90 件を使い、各辺を正例 / 負例として 5 特徴(コスト比、得点率 2 種、ランダム解での順位・相関統計)で SVM・LR・GCN を学習。予測確率 p を $\eta = p \cdot s_j/c_{ij}$ (最良)または τ の初期値に使う。

4 どうやって有効だと検証した?

100 ノードでは初回反復の解が平均 50% 超良く、SVM-MMAS は予算 4% で通常 MMAS の最終解を超える(Fig. 4–5)。500 ノードへ汎化し、MMAS 4612 → 5168 (Table 1)。観光の実データで MMAS 比 +1.24%。2-opt 併用で OP 標準問題の平均 gap 0.58% (Table 4)。

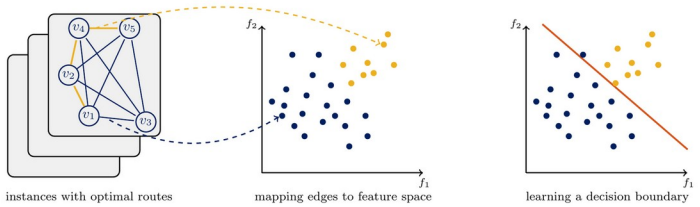
5 議論はある?

著者:辺単位の 2 値分類で、訪問順の予測は扱えていない。線形 SVM が 20 層 GCN よりやや良かった(GCN は未調整)。

所感:深層学習が必須でないこと、事前分布の質が序盤の収束を決めることを示した。厳密解のラベルが要る点が、RL で学ぶ DeepACO との決定的な違い。

6 次に読むべき論文は?

- DeepACO (Ye+ 2023) (既存: deep-learning-fusion)
- HeatACO (Lin+ 2026) (本資料)
- Ant colony optimization theory: a survey (Dorigo & Blum 2005) (未調査:本文未確認)



出典: ML-ACO (Sun+ 2020) Fig. 1 (最適解つき事例の辺を特徴空間に写し、最適解に含まれる辺を分類する学習手順)

書誌情報

発表: Computers & OR 2022
リンク: https://arxiv.org/abs/2008.04213
系譜: 発展(← MAX-MIN Ant System (Stützle & Hoos 2000))
調査日: 2026-10-23
確認範囲: 全文(問題提起・手法・実験・結果・考察)

Markov Chain-based Optimization Time Analysis of Bivalent Ant Colony Optimization for Sorting and LeadingOnes

Matthias Kergaßner, Oliver Keszocze, Rolf Wanka (Friedrich-Alexander-Universität Erlangen-Nürnberg) | GECCO 2024

1 どんなもの?

フェロモンが τ_{min} と τ_{max} の 2 値しか取らない簡略 ACO「BACO」を導入し、マルコフ連鎖で期待最適化時間の厳密な式を導いた。Sorting で $\Theta(n^3)$ の初のタイトな界を示し、LeadingOnes では未解決だった下界を補って $\Theta(n^2)$ を確定。

2 先行研究と比べてどこがすごい?

ACO のランタイム解析は少なく、Neumann & Witt や Kötzing+ 2011 などは主に上界だけだった。LeadingOnes の下界は未解決で、Sorting は解析されていなかった。本論文は改善確率を遷移行列に落とし、上界と下界を同時に得る汎用の道具を示した。

3 技術や手法のキモはどこ?

状態 = 最良解の目的関数値とし、遷移行列 M は上三角。期待時間は $T(n,t) = p(1-M)^{-1}(1-M)^{-1}M(0,\cdots,0,1)^T$ (Thm. 3.1)。比 $M(i,j)/M(i+1,j)$ が行だけに依存すれば逆行列が閉形式になる。鍵はフェロモン比 $t=\tau_{min}/\tau_{max}$ 。

4 どうやって有効だと検証した?

LeadingOnes : $t=c/n^s$ ($s\geq 1$) で $\Theta(n^{s+1})$ 、$s<1$ で超多項式に相転移し、最適は $t=c/n$ の $\Theta(n^2)$ (Table 1)。Sorting (FPP 目的) : $t=c/n^2$ で $\Theta(n^3)$ 、$t=1$ では $\Theta(n!)$ (Table 2)。C++ 実装($n\leq 200$ 、20 回)が理論曲線と一致(Fig. 1–2)。

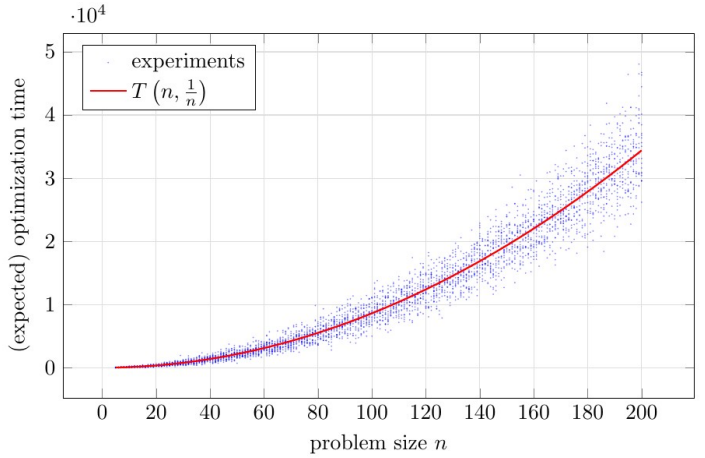
5 議論はある?

著者: Sorting では BACO が (1+1)EA や OnePSO より n/log n 倍遅い。s=2 での相転移の有無は未解決。

所感: τ_{min}/τ_{max} の比が性能を支配し、適切な範囲を外すと指数的に悪化するという結論は、MMAS の上下限や HeatACO の κ 上限設計の理論的な裏付けと読める。

6 次に読むべき論文は?

- MMAS on linear functions (Kötzing+ 2011) (本資料)
- Time-dependent ACO (Manthey+ 2025) (本資料)
- Running time analysis of ACO for shortest path problems (Sudholt & Thyssen 2012) (未調査)



出典: BACO Markov analysis (Kergaßner+ 2024) Fig. 1 (LeadingOnes の実測最適化時間(点)と理論式 T(n,1/n) (赤線))

書誌情報

発表: GECCO 2024
リンク: https://arxiv.org/abs/2405.03353
系譜: 最新(← MMAS on linear functions (Kötzing+ 2011))
調査日: 2026-10-23
確認範囲: 全文(問題提起・手法・実験・結果・考察)

ReEvo: Large Language Models as Hyper-Heuristics with Reflective Evolution

Haoran Ye, Jiarui Wang, Zhiguang Cao, Federico Berto ほか (Peking University) | NeurIPS 2024

1 どんなもの?

LLM でヒューリスティックのコードを生成・進化させる「言語ハイパーヒューリスティクス (LHH)」を定式化し、反省付き進化の ReEvo を提案。ACO の η 関数を 5 問題で生成し、手設計の η や DeepACO を上回った。

2 先行研究と比べてどこがすごい?

従来のハイパーヒューリスティクスは人が定義した探索空間に縛られ、FunSearch・EoH は多くの試行を要した。同じ著者の DeepACO が学習する η は、学習規模の外で劣化する。ReEvo は解釈可能なコードを約 100 回の評価で得て、問題規模を越えて使える。

3 技術や手法のキモはどこ?

LLM に生成器と反省器の 2 役を与える。親 2 個の相対性能を比べる短期反省→交叉、反省を蓄積する長期反省→エリート変異、の 5 段で進化する。反省は「言語的な勾配」として働き、適応度地形を滑らかにする(相関長 0.28→1.28 、Table 4)。

4 どうやって有効だと検証した?

ACO (Fig. 2): TSP/CVRP/OP/MKP/BPP の各 5 規模で手設計 η を一貫して改善。TSP50・OP50・MKP100 では、その規模で学習した DeepACO にも勝つ。規模が離れるほど差が広がる。POMO の TSP1000 gap も 52%→29% に改善 (Table 3)。

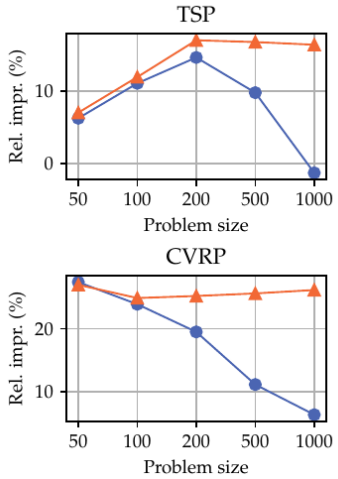
5 議論はある?

著者:評価は 100 回に限定しており、評価数が多いと反省の効果が薄れる可能性。性能の高い LLM ほど反省が効く。

所感: Neural ACO の「 η を学習する」枠組みを、NN の重みからコード探索に置き換えた転換点。GPU 不要で軽い一方、事例ごとの適応はしない。

6 次に読むべき論文は?

- TIDE (Chen+ 2026) (本資料)
- EoH (Liu+ 2024) (既存: ga-hybrid)
- DeepACO (Ye+ 2023) (既存: deep-learning-fusion)



出典: ReEvo (Ye+ 2024) Fig. 2 左上 (TSP・CVRP で手設計 η に対する改善率の規模依存。青: DeepACO 、橙: ReEvo 。両者とも最小規模で学習)

書誌情報

発表: NeurIPS 2024
リンク: https://arxiv.org/abs/2402.01145
系譜: 発展 (← DeepACO (Ye+ 2023))
調査日: 2026-10-23
確認範囲: 全文 (問題提起・手法・実験・結果・考察)

Convergence and Running Time of Time-dependent Ant Colony Algorithms

Bodo Manthey, Jesse van Rhijn, Ashkan Safari, Tjark Vredeveld（University of Twente）| ANTS 2026（LNCS Swarm Intelligence）

1 どんなもの?

Gutjahr の時間依存型 ACO（蒸発率 ρ や下限 τ_{min} を時間とともに下げ、確率 1 で最適解へ収束）の実行時間を初めて解析した。GBAS/tdev の有限時間界を与え、最短路問題では tdev が超多項式、tdlb が多項式時間になると示す。

2 先行研究と比べてどこがすごい?

Gutjahr の GBAS は定数 ρ では最適解を一定確率でしか見つけられない。時間依存版で収束は保証されたが、実行時間は未解決だった。MMAS のランタイム解析（Attiratanasunthron & Fakcharoenphol 、Sudholt & Thyssen）は時間依存性を扱っていない。

3 技術や手法のキモはどこ?

GBAS/tdev は $\rho(k)=\alpha/k$（$\alpha<1/(2L)$）で、最適な歩道を一度も通らない確率を ε 以下に抑える（Thm. 1）。各ノードに蟻を置く n-ANT に、$\rho(m)=\alpha_n/m^{\beta}$ の tdev と、$\tau_{min}(m)=c_n/\ln(m+1)$ の tdlb を組み合わせて比べる。

4 どうやって有効だと検証した?

定理:直列インスタンス（Fig. 1）で n-ANT/tdev は $2^{\Omega(\sqrt{n})}$ サイクルを要する（Thm. 2）。n-ANT/tdlb は期待 $O(n^4 \ln n + (n/\rho)\ln n)$ サイクル（Thm. 3）で、最短路以外の辺のフェロモンは確率 1 で 0 に収束（Cor. 4）。実験はなく純理論。

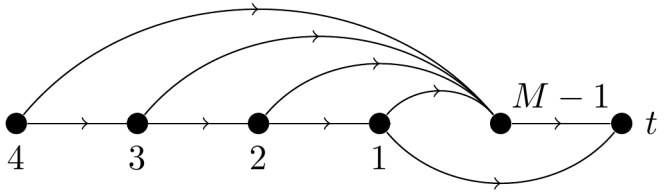
5 議論はある?

著者:汎用の界は個別問題には緩い。対象の SDSP は多項式時間で解ける問題で、TSP への拡張は未解決。

所感:「収束保証のためのスケジュールが実行時間を壊しうる」ことを形式化した点が重要。下限を緩める tdlb の方が安全という結論は、MMAS の実務感覚と合う。

6 次に読むべき論文は?

- A Graph-based Ant System and its convergence (Gutjahr 2000)（未調査:本文未確認）
- BACO Markov analysis (Kergaßner+ 2024)（本資料）
- Running time analysis of ACO for shortest path problems (Sudholt & Thyssen 2012)（未調査）



出典: Time-dependent ACO (Manthey+ 2025) Fig. 1（n=4 の直列インスタンス。誤った辺は重み M−1 の誘引ノードへ向かう）

書誌情報

発表: ANTS 2026 (LNCS)
リンク: https://arxiv.org/abs/2501.10810
系譜: 最新（← Graph-based Ant System (Gutjahr 2000)）
調査日: 2026-10-23
確認範囲: 全文（問題提起・手法・実験・結果・考察）

HeatACO: A Heatmap-Guided Max–Min Ant System for Large-Scale Travelling Salesman Problems

Bo-Cheng Lin, Yi Mei, Mengjie Zhang（Victoria University of Wellington）| arXiv プレプリント 2026

1 どんなもの?

非自己回帰型 NCO（AttGCN・DIMES・UTSP・DIFUSCO）が出す辺の確信度ヒートマップを、MMAS で実行可能な巡回路に復号する HeatACO を提案。再学習も予測器ごとの調整もなしに、TSP500 〜 10K で MCTS 復号より高品質かつ高速。

2 先行研究と比べてどこがすごい?

ヒートマップは巡回路そのものではない。貪欲マージは誤った高確信辺を直せず（TSP1K で gap 13 〜 102%）、MCTS k-opt は高コストで予測器ごとの調整が要る。DeepACO・GFACS と違い、HeatACO は学習をせず外部のヒートマップを受け取るだけ。

3 技術や手法のキモはどこ?

遷移確率 ∝ $\tau^{\alpha} \cdot \eta^{\beta} \cdot e^{\kappa}$。証拠 e_ij は、各ノードで 3 番目に高い確信度（次数 2 の枠を超える水準）を基準とし、それを上回る辺だけを強める。κ は上位 10% の証拠でもフェロモンの動的範囲の半分に収まるよう自動設定し、後でフェロモンが誤りを正せるようにする。

4 どうやって有効だと検証した?

Table 1：TSP1K で DIFUSCO+HeatACO+2-opt が 0.20%・8.4 秒（MCTS 0.53%・100 秒、MMAS+2-opt 0.42%）。局所探索なしでは全予測器・全規模で対応 MMAS に全勝（Table 2）。一方 TSP10K では 2-opt 後に MMAS へ全敗。ATSP や TSPLIB にも転移（Table IV–V）。

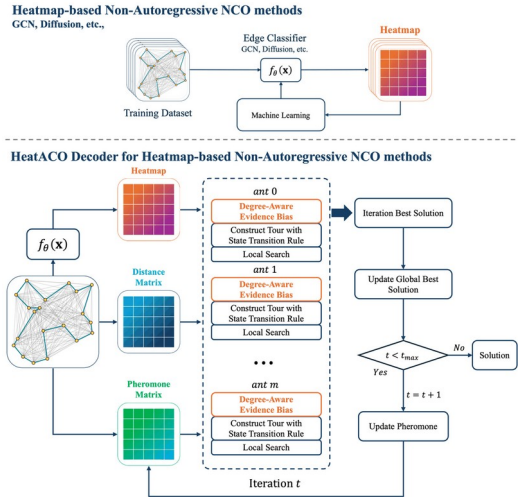
5 議論はある?

著者：分布シフトでヒートマップが密になると逆効果（DIMES の pr2392 で gap 4.08%）。強い局所探索があると寄与は消える。

所感：距離だけの SoftDist でも TSP10K で 0.54%（Table VII）と、学習ヒートマップの付加価値は限定的。ACO を「NCO の出力を検証・修正する層」に再定義した点が新しい。

6 次に読むべき論文は?

- Position: Rethinking Post-Hoc Search-Based Neural Approaches (Xia+ 2024)（未調査：概要のみ）
- DIFUSCO (Sun & Yang 2023)（未調査）
- DyNACO (Tran+ 2026)（既存：deep-learning-fusion）



出典：HeatACO (Lin+ 2026) Fig. 1（上：NCO によるヒートマップ予測、下：ヒートマップを証拠バイアスとして使う MMAS 復号）

書誌情報

発表： arXiv プレプリント 2026
リンク： https://arxiv.org/abs/2601.19041
系譜： 最新（← ML-ACO (Sun+ 2020)）
調査日： 2026-10-23
確認範囲： 全文（問題提起・手法・実験・結果・考察）

TIDE: Tuning-Integrated Dynamic Evolution for LLM-Based Automated Heuristic Design

Chentong Chen, Mengyuan Zhong, Ye Fan, Jialong Shi, Jianyong Sun（Xi'an Jiaotong University）| arXiv プレプリント 2026

1 どんなもの?

LLM による自動ヒューリスティック設計（AHD）で、アルゴリズムの構造（コードの論理）と連続パラメータを分けて共進化させる TIDE を提案。ACO 枠組みでの η 設計を含む 9 問題・5 枠組みで、EoH・ReEvo・HSEvo・MCTS-AHD を概ね上回る。

2 先行研究と比べてどこがすごい?

ReEvo や EoH はコード生成を一括のテキスト生成として扱い、LLM が苦手な定数の値（numerical blindness）のせいで有望な構造を捨ててしまう。反省型は単一の論理に早く収束し、CodeBLEU 等の多様性指標は言い換えと構造の変化を区別できない。

3 技術や手法のキモはどこ?

外側は 6 島の島モデルで、AST 木編集距離（TSED）により構造の近い島にはコードを、遠い島には言語化した知見を移す。内側では UCB で 5 種のプロンプト戦略を選んで論理を生成し、有望な個体だけ差分進化（rand/1）で定数を調整する（LLM トークン不要）。

4 どうやって有効だと検証した?

ACO 枠組み（Table 2）: TSP50/100 で 5.80/8.15（DeepACO 5.84/8.28、ReEvo 5.84/8.32）、OP・MKP も最良。一方 CVRP50/100 は 9.01/15.37 で DeepACO（8.89/14.93）に届かず、BPP も僅差で負ける。

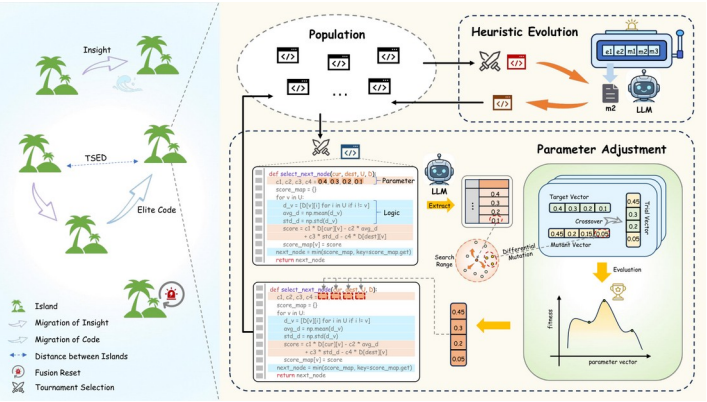
5 議論はある?

著者:今後は多目的最適化と、学んだ構造的知見の問題間転移を扱う。

所感: LLM-AHD は TSP 系では NN 由来の η を超えたが、容量制約のある CVRP では今も DeepACO が強い。ACO は「LLM が設計した部品の評価器」として定番ベンチ化しており、ACO 本体は改良されていない点に注意。

6 次に読むべき論文は?

- ReEvo (Ye+ 2024)（本資料）
- MCTS-AHD (Zheng+ 2025)（未調査）
- HSEvo (Dat+ 2025)（未調査）



出典: TIDE (Chen+ 2026) Fig. 2（左: TSED で制御する島モデル、右: LLM による論理生成と差分進化による定数調整）

書誌情報

発表: arXiv プレプリント 2026
リンク: https://arxiv.org/abs/2601.21239
系譜: 最新（← ReEvo (Ye+ 2024)）
調査日: 2026-10-23
確認範囲: 全文（問題提起・手法・実験・結果・考察）