# DeepLearning・NN との融合

群知能 ×DL/NN の融合を 3 方向で追う。①群知能で NN (構造・重み・ LLM 群) を最適化: IPPSO→Model Swarms→Heterogeneous Swarms 。
②NN/DRL で群知能を学習・強化: DeepACO→GFACS→DyNACO 、GLEET 。③ LLM を群知能の演算子に: LMPSO→SwarmAgentic 。
深層 MARL による群制御 ( Hüttenrauch+ ) も起点として収録。

| # | 年 | 論文 | 発表 | 系譜 |
|---|---|---|---|---|
| 1 | 2018 | IPPSO (Wang+ 2018) | IEEE CEC 2018 | 原典 |
| 2 | 2019 | Mean-Embedding DRL (Hüttenrauch+ 2019) | JMLR 2019 | 原典 |
| 3 | 2023 | DeepACO (Ye+ 2023) | NeurIPS 2023 | 原典 |
| 4 | 2024 | GFACS (Kim+ 2024) | AISTATS 2025 | 発展 |
| 5 | 2024 | GLEET (Ma+ 2024) | GECCO 2024 | 発展 |
| 6 | 2024 | Model Swarms (Feng+ 2024) | ICML 2025 | 発展 |
| 7 | 2025 | Heterogeneous Swarms (Feng+ 2025) | NeurIPS 2025 | 最新 |
| 8 | 2025 | LMPSO (Shinohara+ 2025) | IEEE CEC 2025 | 最新 |
| 9 | 2025 | SwarmAgentic (Zhang+ 2025) | EMNLP 2025 | 最新 |
| 10 | 2026 | DyNACO (Tran+ 2026) | KDD 2026 | 最新 |

# Evolving Deep Convolutional Neural Networks by Variable-length Particle Swarm Optimization for Image Classification

Bin Wang, Yanan Sun, Bing Xue, Mengjie Zhang（Victoria University of Wellington）| IEEE CEC 2018

## 1 どんなもの?

PSO で CNN のアーキテクチャ(層の種類・数・設定)を自動探索する IPPSO を提案。著者らは「PSO で CNN 構造を進化させる初の研究」と位置づけ、群知能による NAS の起点の一つ。MNIST 変種 MDRBI で既存 12 手法より低い誤差を達成。

## 2 先行研究と比べてどこがすごい?

LEIC（Real+ 2017）や EvoCNN（Sun+ 2017）など GA 系の CNN 構造探索は計算が重く、PSO は未使用だった。PSO は固定長の連続ベクトルしか扱えず可変長の CNN 構造を表せない点が障壁で、本論文はこれを符号化の工夫で突破した。

## 3 技術や手法のキモはどこ?

各層を IP アドレス風の 2 バイトで符号化し、サブネット(値域)で層種別 Conv/Pool/FC/Disabled を区別。Disabled 層で層を「隠す」ことで固定長粒子のまま可変長構造を表す。バイトごとの係数 c1[i], c2[i] で PSO 更新し、部分データで 10 エポック学習して適応度を評価。

## 4 どうやって有効だと検証した?

MB・MDRBI・CS（28×28 画像)で 12 手法と比較（Table V）。平均誤差は MB 1.21%（2 位、LDANet-2 が 1.05%）、MDRBI 33%（1 位、次点 TIRBM 35.50%）、CS 12.06%（5 位)。粒子 30・各 30 試行、1 試行約 2.5 時間（GTX1080×2）。

## 5 議論はある?

著者: PSO の近傍トポロジーの影響や RNN への適用が今後の課題。

所感: Table V で MDRBI の平均 33% が最良値 34.50% より良いという不整合がある。データも小規模で、CIFAR/ImageNet 上の現代的 NAS との比較はない。

## 6 次に読むべき論文は?

・psoCNN (Fernandes Junior & Yen 2019)（本文未確認）
・DeepSwarm (Byla & Pang 2019)（参照のみ）
・Model Swarms (Feng+ 2024)（本資料）

| 2.61(C) | 18.143(P) | 2.61(C) | 35.255(D) | 27.255(F) |
|---|---|---|---|---|

| 2 | 61 | 18 | 143 | 2 | 61 | 35 | 255 | 27 | 255 |
|---|---|---|---|---|---|---|---|---|---|

出典: IPPSO (Wang+ 2018) Fig. 2–3（5 層 CNN の IP アドレス列と、それを並べた 10 次元の粒子ベクトル。35.255 は Disabled 層）

## 書誌情報

**発表:** IEEE CEC 2018
**リンク:** https://arxiv.org/abs/1803.06492
**系譜:** 原典
**調査日:** 2026-10-23
**確認範囲:** 全文(問題提起・手法・実験・結果・考察)

# Deep Reinforcement Learning for Swarm Systems

Maximilian Hüttenrauch, Adrian Šošić, Gerhard Neumann（University of Lincoln）| JMLR 2019

## 1 どんなもの?

群ロボットの分散方策を深層強化学習で学ぶため、近傍エージェントの観測集合を平均埋め込み（mean embedding）で表す状態表現を提案。NN 特徴の平均埋め込みで、ランデブー・追跡回避において既存表現より速く高品質な群行動を獲得した。

## 2 先行研究と比べてどこがすごい?

MADDPG（Lowe+ 2017）流の観測連結は入力次元が個体数に比例し、置換不変性もない。画像・ヒストグラム表現は特徴次元に対し指数的に膨らむ。平均埋め込みは個体数可変・順序不変で、学習後に異なる個体数へそのまま転用できる。

## 3 技術や手法のキモはどこ?

近傍 j の観測 o^{i,j} を分布からのサンプルとみなし、$\mu = (1/|O|)\ \Sigma_j\ \phi(o^{i,j})$ を方策入力にする。$\phi$ はヒストグラム・RBF・NN（64 ユニット、end-to-end 学習）を比較。パラメータ共有 TRPO で集中学習・分散実行する。

## 4 どうやって有効だと検証した?

一輪車モデルのランデブー（20 体）と追跡回避（10 体、2 倍速の逃避者）を大域 / 局所観測で評価。NN+ は平均報酬で NN/RBF 比約 10% 改善、定常平均距離は約半分（Fig. 3a, 5a）。20 体で学習し 100 体で実行しても最良（Fig. 5b）。50 対 5 の追跡では連結表現は学習不能（Fig. 10a）。

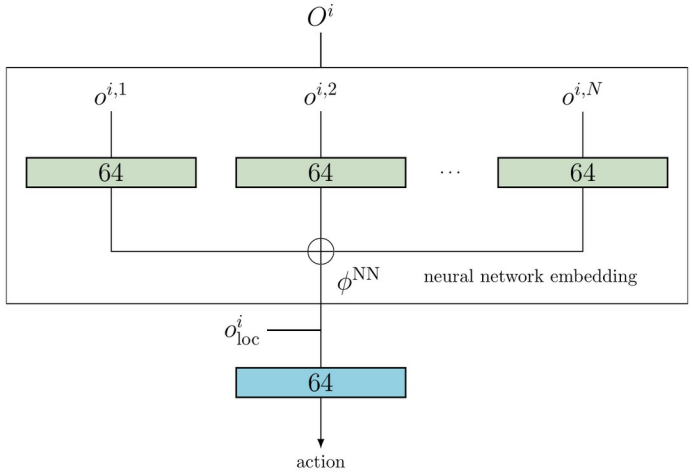
## 5 議論はある?

著者:学習時メモリは O(N(N−1))、20 体で 4 〜 6 時間の学習。推論は約 1ms で実時間実行できる。

所感:古典的な群ルールを DRL 方策で置き換える流れの起点。実機検証はなく、評価はシミュレーション内に留まる。

## 6 次に読むべき論文は?

- Mean Field MARL (Yang+ 2018)（未調査）
- GNN による群ロボット分散制御 (Tolstaya+ 2019)（未調査）
- LLM 駆動の群シミュレーション (Jimenez-Romero+ 2025)（参照のみ）




出典: Mean-Embedding DRL (Hüttenrauch+ 2019) Fig. 1(a)（NN 平均埋め込み方策。緑の層は重み共有、⊕は特徴の平均）

## 書誌情報

**発表:** JMLR 2019
**リンク:** https://arxiv.org/abs/1807.06613
**系譜:** 原典
**調査日:** 2026-10-23
**確認範囲:** 全文（問題提起・手法・実験・結果・考察）

# DeepACO: Neural-enhanced Ant Systems for Combinatorial Optimization

Haoran Ye, Jiarui Wang, Zhiguang Cao, Helan Liang, Yong Li（Soochow University）| NeurIPS 2023

## 1 どんなもの?

ACO のヒューリスティック行列 $\eta$ を GNN で生成し、深層強化学習で学習する DeepACO を提案。単一のアーキテクチャとハイパラで 8 種の組合せ最適化問題すべてで従来 ACO を上回り、TSP 等では問題特化の NCO 手法と同等以上。

## 2 先行研究と比べてどこがすごい?

ACO の $\eta$ は問題ごとに専門家が手設計しており、知識の乏しい問題では作れない。ML-ACO（Sun+）は教師あり学習で特徴も手設計のため汎用性が低い。DeepACO は DRL で $\eta$ を自動設計し、ACO の蓄積(変種・局所探索)とそのまま組み合わせられる。

## 3 技術や手法のキモはどこ?

GNN（異方的メッセージパッシング +edge gating）が事例 $\rho$ から $\eta_\theta(\rho)$ を出力し、蟻は $\tau^{\alpha}\cdot\eta^{\beta}$ に比例して解を構築。損失 E[f(s) + W·f(NLS(s))] を REINFORCE で最小化する。学習 $\eta$ で摂動しつつ 2-opt を挟む Neural-guided LS（NLS）も提案。

## 4 どうやって有効だと検証した?

TSP/CVRP/OP/PCTSP/SOP/SMTWTP/RCPSP/MKP で、AS・Elitist・MMAS のいずれも改善（Fig. 2）。TSP500 で gap 1.84%（ACO 6.16%）、TSP1000 で 3.16%（同 7.87%）（Table 1）。TSPLIB でも一貫して優位（Fig. 5）で、ハイパラ頑健性も向上（Fig. 4）。

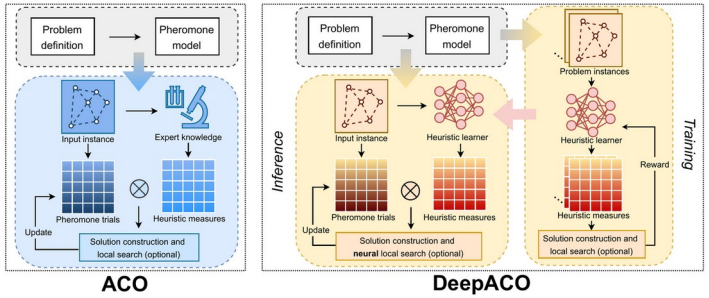
## 5 議論はある?

著者:学習した知識を n×n 行列 1 枚に圧縮するため表現力が限られ、LS なしでは最適近くに届かない。3 次元・動的な $\eta$ が今後の課題。

所感:「NN で群知能を強化」系譜の転換点。$\eta$ が静的である点を後続の GFACS・DyNACO が突いていく。

## 6 次に読むべき論文は?

- GFACS (Kim+ 2024)（本資料）
- DyNACO (Tran+ 2026)（本資料）
- ReEvo (Ye+ 2024)（参照のみ）




出典: DeepACO (Ye+ 2023) Fig. 1（従来 ACO と DeepACO の比較。事例集合で学習した GNN が $\eta$ を生成）

## 書誌情報

**発表:** NeurIPS 2023
**リンク:** https://arxiv.org/abs/2309.14032
**系譜:** 原典
**調査日:** 2026-10-23
**確認範囲:** 全文（問題提起・手法・実験・結果・考察）

# Ant Colony Sampling with GFlowNets for Combinatorial Optimization

Minsu Kim, Sanghyeok Choi, Hyeonah Kim, Jiwoo Son ほか ( Mila / KAIST ) | AISTATS 2025

## 1 どんなもの?

DeepACO の $\eta$ を REINFORCE ではなく GFlowNet で学習し、報酬に比例する多峰的な事前分布を得る GFACS を提案。ACO のフェロモン更新を「事後更新」と捉え、7 種の組合せ最適化で DeepACO・ACO を一貫して上回った。

## 2 先行研究と比べてどこがすごい?

DeepACO ( Ye+ 2023 ) は REINFORCE で期待報酬を最大化するため分布がモード崩壊し、後段のフェロモン探索の伸びしろを潰す。GFACS は多様な高報酬解を覆う事前分布を学習し、ACO の反復探索と相乗させる点が差分。

## 3 技術や手法のキモはどこ?

GNN が出す $\eta(G)$ で構築方策 $P_F$ を定義し、Trajectory Balance 損失で $p(x) \propto \exp(-\beta E(x))$ を学習。局所探索解を使う off-policy 経験収集、LS 後のエネルギーで評価し直す energy reshaping 、事例内平均で正規化する shared energy norm を導入。

## 4 どうやって有効だと検証した?

同一 GNN ・同一 LS で DeepACO と比べ全 7 問題で改善 ( Fig. 4 )。TSP500 で gap 1.56% ( DeepACO 1.77% )、CVRP500 で 1.95% (同 2.43% ) ( Table 2 )。TSPLib 700 ～ 1499 ノードで 3.88% ( ACO 7.01% ) ( Table 1 )。学習は 3 時間未満。

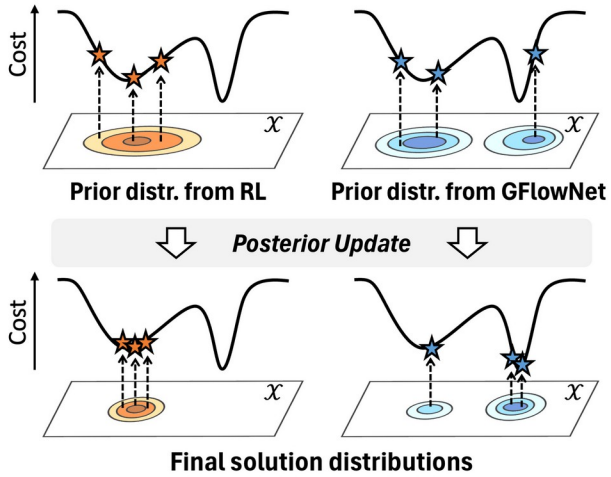
## 5 議論はある?

著者:経験的には改善するが、RL より最適性が良くなる理論保証はない。

所感:差の多くは 1 ポイント未満で、改善は学習法の工夫による。小規模 CVRPLib では素の ACO に劣り、事前分布が静的な点も残る。

## 6 次に読むべき論文は?

- DeepACO (Ye+ 2023) (本資料)
- DyNACO (Tran+ 2026) (本資料)
- GFlowNet Foundations (Bengio+ 2023) (未調査)




出典: GFACS (Kim+ 2024) Fig. 1 ( RL 由来の単峰事前分布と GFlowNet 由来の多峰事前分布、事後更新後の解分布の違い)

## 書誌情報

**発表:** AISTATS 2025
**リンク:** https://arxiv.org/abs/2403.07041
**系譜:** 発展 (← DeepACO (Ye+ 2023) )
**調査日:** 2026-10-23
**確認範囲:** 全文 (問題提起・手法・実験・結果・考察)

# Auto-configuring Exploration-Exploitation Tradeoff in Evolutionary Computation via Deep Reinforcement Learning

Zeyuan Ma, Jiacheng Chen, Hongshu Guo, Yining Ma, Yue-Jiao Gong（South China University of Technology）| GECCO 2024

## 1 どんなもの?

PSO 等の探索・活用バランス（EET）を、Transformer 方策が粒子ごとに動的制御する GLEET を提案。問題クラス単位で一度学習すれば未知問題に転用できる。DMSPSO に適用した GLEET-DMSPSO が CEC2021 拡張ベンチで 8 手法中平均順位 1.09 。

## 2 先行研究と比べてどこがすごい?

DRL-PSO・RLEPSO・DE-DQN 等の先行 DRL 制御は問題ごとに再学習が必要で過学習しやすく、MLP と単純な状態で表現力も乏しい。GLEET は問題集合で学習する汎化可能な MDP と、個体間の関係を扱う注意機構を導入した。

## 3 技術や手法のキモはどこ?

状態は各粒子の進捗・停滞・gBest/pBest との差や距離など 9 次元の特徴。自己注意エンコーダで個体埋め込みを「fully informed」にし、EET 埋め込みを Query とするデコーダが粒子ごとに c1 の正規分布を出す（c2=4−c1）。報酬は gBest 改善量、PPO で学習。

## 4 どうやって有効だと検証した?

CEC2021 の 10 関数を拡張した問題集合で、静的・適応・DRL 系の 7 手法と比較（Table 1）。GLEET-DMSPSO は 10D・10 問題中 9 で 1 位。未学習クラスへのゼロショットでも劣化は数 % 以内（Table 2）、Protein-Docking（12D）でも最良（Table 3）。

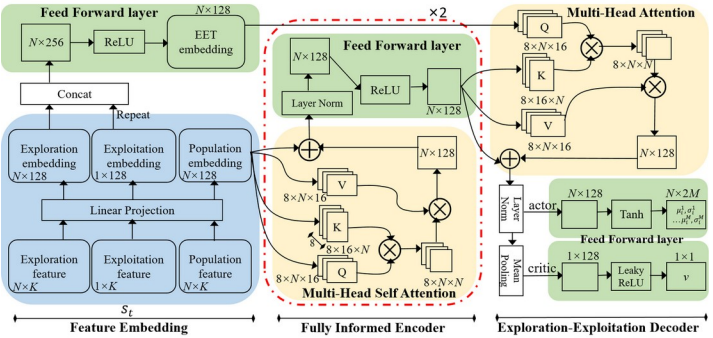
## 5 議論はある?

著者:手設計の景観特徴は高次元で脆い可能性があり、個体数を動的に変えられない。

所感:「学習する群知能」の代表例で、MetaBBO 潮流の中核。制御対象が c1 のみで十分かは疑問で、LLM・GNN 系の後続との比較が見たい。

## 6 次に読むべき論文は?

- MetaBox (Ma+ 2023)（参照のみ）
- Learning to Learn w/o GD by GD (Chen+ 2017)（未調査）
- Symbol (Chen+ 2024)（未調査）




出典: GLEET (Ma+ 2024) Fig. 2（特徴埋め込み・Fully Informed Encoder・探索活用デコーダからなる方策ネットワーク）

## 書誌情報

**発表:** GECCO 2024
**リンク:** https://arxiv.org/abs/2404.08239
**系譜:** 発展（← L2O (Chen+ 2017)）
**調査日:** 2026-10-23
**確認範囲:** 全文（問題提起・手法・実験・結果・考察）

# Model Swarms: Collaborative Search to Adapt LLM Experts via Swarm Intelligence

Shangbin Feng, Zifeng Wang, Yike Wang, Sayna Ebrahimi ほか ( University of Washington / Google Cloud AI Research ) | ICML 2025

## 1 どんなもの?

LoRA で作った複数の LLM エキスパートを粒子とみなし、PSO 風に重み空間を協調移動させて効用関数を最適化する Model Swarms を提案。約 200 事例・勾配学習なしで、12 のモデル合成手法を 9 タスク平均 13.3% 上回った ( Gemma-7B )。

## 2 先行研究と比べてどこがすごい?

learn-to-fuse 系は大量の教師データを要し、Task Arithmetic 等のモデル算術は「どの専門家をどう合成するか」に強い仮定を置く。Model Swarms は任意の「モデル→スカラー」効用だけで探索でき、EvolMerge ( Akiba+ ) の GA より手設計の規則が少ない。

## 3 技術や手法のキモはどこ?

速度 $v \leftarrow (1/C)[r_v\ \phi_v v + r_p\ \phi_p(p-x) + r_g\ \phi_g(g-x) - r_w\ \phi_w(g_w-x)]$ 、$x \leftarrow x + \lambda v$。大域最悪 g_w からの斥力、線形補間による初期粒子の水増し、改善しない粒子の個人最良への再起動、ステップ長の減衰を導入。

## 4 どうやって有効だと検証した?

単一タスク 9 種で全て最良 ( GSM8k test .652 、次点 .622 ) ( Table 1 )。多タスク 4 分野で平均 5.7% 、報酬モデル適合で 6.7% 改善し、PPO/DPO も上回る ( Table 4 )。人手評価の勝率 70.8% 。初期全員不正解の問題の 36 ～ 54% が解けるようになった ( Fig. 2 )。

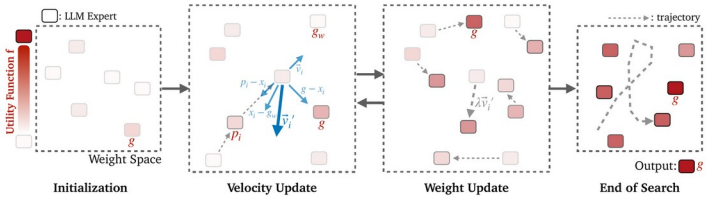
## 5 議論はある?

著者:局所解に留まる可能性、全専門家を毎反復更新する計算コスト、悪意ある効用関数による悪用リスク。

所感: PSO で NN 重みを探す発想自体は古典的だが、LLM 規模・LoRA 空間で実用化した点が新しい。ベースラインの調整の公平性は要確認。

## 6 次に読むべき論文は?

- Heterogeneous Swarms (Feng+ 2025) (本資料)
- Evolutionary Model Merge (Akiba+ 2024) (未調査)
- IPPSO (Wang+ 2018) (本資料)




出典: Model Swarms (Feng+ 2024) Fig. 1 ( LLM 専門家が重み空間で速度更新・重み更新を繰り返し、大域最良 g を出力)

## 書誌情報

**発表:** ICML 2025
**リンク:** https://arxiv.org/abs/2410.11163
**系譜:** 発展 (← IPPSO (Wang+ 2018) )
**調査日:** 2026-10-23
**確認範囲:** 全文 (問題提起・手法・実験・結果・考察)

# Heterogeneous Swarms: Jointly Optimizing Model Roles and Weights for Multi-LLM Systems

Shangbin Feng, Zifeng Wang, Palash Goyal, Yike Wang ほか ( University of Washington / Google Cloud AI Research ) | NeurIPS 2025

## 1 どんなもの?

複数 LLM の協調系を DAG で表し、役割(グラフ構造)と重みの両方を PSO で交互に最適化する Heterogeneous Swarms を提案。12 タスクで役割系・重み系の 17 ベースラインを平均 18.5% 上回り、11 タスクで最良。

## 2 先行研究と比べてどこがすごい?

GPTSwarm や AgentVerse 等の役割最適化は重みが固定、Model Swarms ( Feng+ 2024 ) 等の重み最適化は役割(入出力関係)が固定だった。本手法は両者を同時に適応させ、タスクにより役割と重みの重要度が異なることも示した。

## 3 技術や手法のキモはどこ?

role-step :連続隣接行列の群を G-Decode で離散 DAG に復号し、トポロジカル順に LLM を呼んで効用 f を評価、行列を PSO で更新。weight-step :最良 DAG へ LLM をランダムに割り当て、貢献度 JFK-score (出現頻度で重み付けた効用平均)で重みを PSO 更新。

## 4 どうやって有効だと検証した?

Gemma-7B 由来の 10 専門家で、知識・推論・エージェント等 12 データセットを評価( Table 1 )。GSM8k 0.481 ( Model Swarms 0.459 )、GAIA-text 0.250 (最良ベースライン 0.143 )。協調利得 C-Gain は平均 0.213 で、全員不正解の問題の 18.1% を解いた( Fig. 3 )。

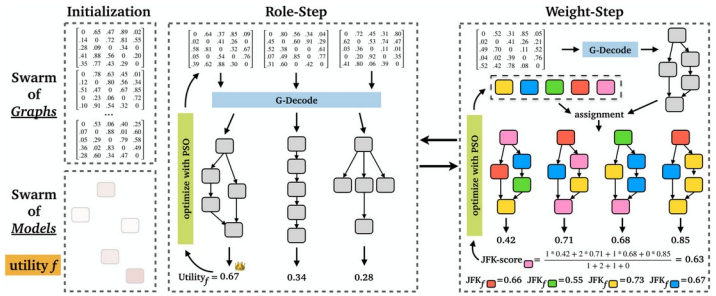
## 5 議論はある?

著者:重み更新は同一アーキテクチャの LLM 群が前提で、最適化・推論とも LLM 呼び出しが多くコストが高い。

所感: PSO が離散グラフ探索の外側ループとして機能する点が面白い。JFK-score は割当てのノイズが大きそうで、試行数 M への感度が気になる。

## 6 次に読むべき論文は?

- Model Swarms (Feng+ 2024) (本資料)
- GPTSwarm (Zhuge+ 2024) (未調査)
- SwarmAgentic (Zhang+ 2025) (本資料)




出典: Heterogeneous Swarms (Feng+ 2025) Fig. 2 (グラフの群とモデルの群を、role-step と weight-step で交互に PSO 最適化)

## 書誌情報

**発表:** NeurIPS 2025
**リンク:** https://arxiv.org/abs/2502.04510
**系譜:**最新(← Model Swarms (Feng+ 2024) )
**調査日:** 2026-10-23
**確認範囲:**全文(問題提起・手法・実験・結果・考察)

# Large Language Models as Particle Swarm Optimizers

Yamato Shinohara, Jinglue Xu, Tianshui Li, Hitoshi Iba（東京大学）| IEEE CEC 2025

## 1 どんなもの?

PSO の「速度」をプロンプトで表し、LLM に次の解を生成させる LMPSO を提案。TSP 、TSP ヒューリスティックの改良、記号回帰で評価し、数式やプログラムのような構造化された系列を解とする問題で特に有効なことを示した。

## 2 先行研究と比べてどこがすごい?

OPRO や LMEA ( Liu+ 2024 ) などの LLM 最適化は GA 的な枠組みが中心で、群知能は未活用だった。また TSP 等への PSO 適用には交換操作など問題固有の速度定義が必要だったが、LMPSO はプロンプトの差し替えだけで多様な解表現に適用できる。

## 3 技術や手法のキモはどこ?

メタプロンプトに問題記述、慣性項(現在位置を生んだ前回の指示 v_i^t )、現在位置 x_i^t 、pbest/gbest を含む新方向 v_i^{t+1} を入れ、LLM が次位置を生成する。制約違反時は再試行・再初期化。Llama-3.1-8B-Instruct 、温度 0.9 。

## 4 どうやって有効だと検証した?

TSP ( 10/20/30 都市)では TSP 用 PSO を全規模で上回るが、20 都市以上では NN・FI 等の構築法に劣る( Table II )。100 都市でのヒューリスティック改良は FI の 0.07 に対し 0.06 で最良 ( Table III )。記号回帰は PMLB の多くで gplearn の GP より高い $R^2$ ( Table IV )。

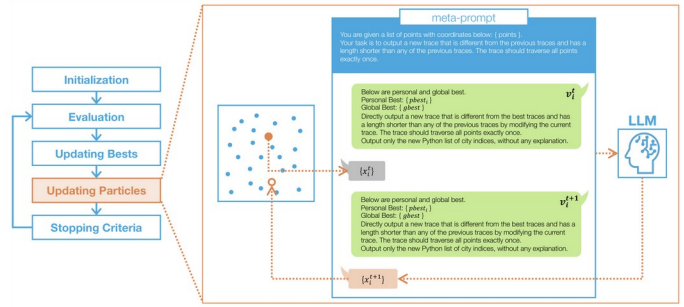
## 5 議論はある?

著者:大規模な解表現の直接最適化は難しく、ヒューリスティック改良への変換が有効。LLM 性能への依存の定量化が課題。

所感: 30 都市 TSP 1 回に約 56 分と高コスト。GA 系 LLM 最適化 ( ReEvo 等)との直接比較がなく、PSO 構造の寄与は未検証。

## 6 次に読むべき論文は?

- OPRO (Yang+ 2024) (未調査)
- ReEvo (Ye+ 2024) (参照のみ)
- SwarmAgentic (Zhang+ 2025) (本資料)




出典: LMPSO (Shinohara+ 2025) Fig. 1 ( TSP 用メタプロンプト。速度 v_i を指示文、位置 x_i を解として LLM が次位置を生成)

## 書誌情報

**発表:** IEEE CEC 2025
**リンク:** https://arxiv.org/abs/2504.09247
**系譜:** 最新(← OPRO / LMEA (2024) )
**調査日:** 2026-10-23
**確認範囲:** 全文(問題提起・手法・実験・結果・考察)

# SwarmAgentic: Towards Fully Automated Agentic System Generation via Swarm Intelligence

Yao Zhang, Chenyang Lin, Shijie Tang, Haokun Chen ほか( LMU Munich )| EMNLP 2025

## 1 どんなもの?

エージェント集合と協調構造を言語で記述したシステムを粒子とし、LLM が速度・位置更新を担う言語版 PSO でエージェント系をゼロから自動生成する SwarmAgentic を提案。TravelPlanner で ADAS 比 +261.8% 、6 タスク全てで最良。

## 2 先行研究と比べてどこがすごい?

ADAS ( Hu+ 2024 )・AFlow・EvoAgent 等は種エージェントやテンプレートに依存し、機能と協調を別々に最適化する。SwarmAgentic はゼロからの生成・機能の自己最適化・協調の自己最適化の 3 条件を満たす唯一の枠組みと主張( Table 1 )。

## 3 技術や手法のキモはどこ?

v^{t+1} = LLM_vel(c_f r_f F(v^t), c_p r_p(p*−x), c_g r_g(g−x)) 。LLM が失敗例から欠陥(担当不在・冗長手順など)を診断し、失敗した過去の更新・個人最良・大域最良との比較からテキストの修正方針を作り、追加・削除・修正・並べ替えで位置を更新。

## 4 どうやって有効だと検証した?

TravelPlanner 、Natural Plan 3 種、Creative Writing 、MGSM で評価(最適化は GPT-4o-mini )。TravelPlanner 最終合格率は GPT-4o 実行で 32.2% ( ADAS 8.9% ) ( Table 2 )。発見した系を Claude-3.5 等へ移しても最良( Table 4 )。失敗駆動調整を除くと 8.8→8.4 ( Table 5 )。

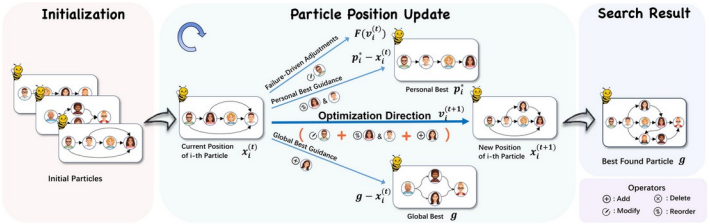
## 5 議論はある?

著者:事前知識を使わないため構造化環境では収束が遅い可能性、幻覚の伝播、テキスト環境限定で身体性がない。

所感:粒子 5・反復 10 と小規模で、PSO は数理より比喩に近い。探索コスト( API 呼び出し数)の報告が乏しい。

## 6 次に読むべき論文は?

- ADAS (Hu+ 2024) (未調査)
- LMPSO (Shinohara+ 2025) (本資料)
- AgentPSO (Hwang+ 2026) (参照のみ)




出典: SwarmAgentic (Zhang+ 2025) Fig. 1 (失敗駆動調整・個人最良・大域最良から言語で最適化方向を作り、エージェント系を更新)

## 書誌情報

**発表:** EMNLP 2025
**リンク:** https://arxiv.org/abs/2506.15672
**系譜:**最新(← LMPSO / ADAS )
**調査日:** 2026-10-23
**確認範囲:**全文(問題提起・手法・実験・結果・考察)

# Beyond Static Priors: Dynamic Neural Guidance for Large-Scale Ant Colony Optimization

Dat Thanh Tran, Van Khu Vu, Yining Ma（VinUniversity / MIT）| KDD 2026

## 1 どんなもの?

神経誘導 ACO が「静的ヒートマップで学習し、反復探索に投入する」という学習・推論の不整合を指摘し、フェロモンと現行解を周期的に観測して誘導を更新する DyNACO を提案。TSP で 10 万ノードまで拡張し、全規模で神経系手法を上回る。

## 2 先行研究と比べてどこがすごい?

DeepACO・GFACS・GTG-ACO は事例の形状から一度だけ事前分布を出し、学習中にフェロモン動態を一度も見ない。また全ノード構築型のため 1 万ノード程度で頭打ち。DyNACO は誘導の動的化と、摂動型 ACO+ 局所修復による大規模化を両立した。

## 3 技術や手法のキモはどこ?

$\log p(j|i) = \alpha \log \tau_{ij} + \beta \log \eta_{ij} + \gamma z_{ij}(S_h)$ :手設計 $\eta$ を残し、GNN の残差ロジット z を加算。semi-MDP として S 反復ごとに状態（フェロモン・現行解）を観測し、全軌跡の平均コストを PPO で最小化。摂動周辺のみ 2-opt する SRR で信用割当てを保つ。

## 4 どうやって有効だと検証した?

TSP-100K で I=10000 時に gap 1.90%・2.86 分（SIL 2.45%・2.6 時間、誘導なし ACO 3.12%）（Table 1）。TSP では誘導なしより 23 ～ 33% 高速。1K で学習したモデルを TSPLIB 33 事例（最大 86K）にゼロショット適用し、誘導なし ACO 比 31% 改善・29/33 勝。

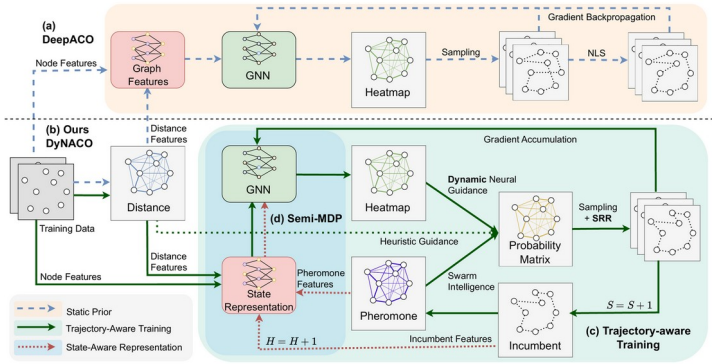
## 5 議論はある?

著者:時間粒度 (H,S) と K 近傍グラフは問題ごとに設定が必要で、学習は固定規模。

所感:学習した誘導が飽和したフェロモン辺を抑えて停滞を防ぐ（Fig. 3）という分析は、群の多様性維持を NN が学ぶ好例。LKH3 との差はまだ大きい。

## 6 次に読むべき論文は?

- DeepACO (Ye+ 2023)（本資料）
- GFACS (Kim+ 2024)（本資料）
- MAX-MIN Ant System (Stützle & Hoos 2000)（未調査）




出典: DyNACO (Tran+ 2026) Fig. 1（(a) DeepACO の静的事前分布と (b) DyNACO の状態依存・軌跡全体での学習の比較）

## 書誌情報

**発表:** KDD 2026
**リンク:** https://arxiv.org/abs/2606.04039
**系譜:** 最新（← GFACS (Kim+ 2024)）
**調査日:** 2026-10-23
**確認範囲:** 全文（問題提起・手法・実験・結果・考察）