エネルギー評価の方法論（理論推定と実機計測の差）

SNN の省エネ主張は Horowitz (2014) の 45nm 単価で MAC と AC の回数を数える推定に支えられてきた。2021 年以降、メモリ・データ移動を含む解析（ Davidson & Furber → Lemaire → Yan ）と HW シミュレータ（ SATA → Bhattacharjee ）で優位は条件付きと判明。
比較相手も 32bit ANN → 量子化 ANN（ Shen, Yan ）、計測も同一 HW ・実チップ（ Xu, Gamage ）へと公平化が進む。

#	年	論文	発表	系譜
1	2021	Davidson & Furber 2021	Frontiers in Neuroscience 2021	原典
2	2022	SATA (Yin+ 2022)	IEEE TCAD 2022	発展
3	2022	Lemaire+ 2022	ICONIP 2022	発展
4	2023	Ottati+ 2023	IEEE JETCAS 2023	発展
5	2024	Bhattacharjee+ 2024	ICASSP 2024	発展
6	2024	Bit Budget (Shen+ 2024)	CVPR 2024	発展
7	2025	SENECA ANN vs SNN (Xu+ 2025)	Neural Networks 2025	発展
8	2025	Höfflin & Wassner 2025	IAA-SPAICE 2025	最新
9	2026	QNN-SNN twin (Yan+ 2026)	IEEE TCAD 2026	最新
10	2026	Loihi 2 vs Jetson 検出 (Gamage+ 2026)	Neurocomputing 2026	最新

Comparison of Artificial and Spiking Neural Networks on Digital Hardware

Simon Davidson, Steve B. Furber（ University of Manchester ）| Frontiers in Neuroscience 2021

1 どんなもの？

レート符号化 SNN と ANN を同一デジタル回路（ SpiNNaker2 の 22FDX 設計値）上の処理パイプラインに分解し、SNN が省エネになる条件を導いた Perspective 。結論は「 1 活性値を平均 1.72 スパイク未満で表せない限り SNN は勝てない」。

2 先行研究と比べてどこがすごい？

従来の「 SNN は乗算不要だから省エネ」という主張は演算単価だけを比べ、重み・膜電位メモリの読み書きを無視していた。変換 SNN （ Rueckauer+ 2017 ）を念頭に、メモリアクセスを含む同一シリコン上の比較を初めて簡潔に定式化。

3 技術や手法のキモはどこ？

1 入力あたりの費用を $E_ANN = E_w + N_t(E_get+E_mul+E_add+E_wr)$ 、$E_SNN = N_spk \cdot E_w + N_spk \cdot N_t(E_get+E_add+E_wr)$ と分解。加算 $E \approx 60fJ$ を単位に乗算 5E ・ SRAM 読出 5E ・書戻し E とし、$12E/7E=1.72$ を損益分岐とする。

4 どうやって有効だと検証した？

実験はなく解析のみ（ Sec. 4, Eq. 1–2 ）。SpiNNaker2 の TSMC 22FDX ポストレイアウト値（ 32bit SRAM 読出 296fJ 、32×8bit MAC 293fJ ）を使用し、放送費用を SNN 有利側に無視しても $N_spk<1.72$ が必要と示した。

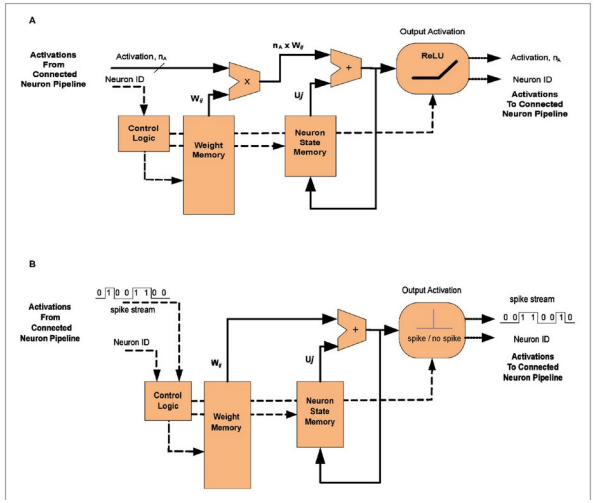
5 議論はある？

著者：プロセス差で比は多少変わるが結論は不変。勝つには時間符号化など情報量の多い符号が必要。

所感：数式数本でメモリ支配を示した原典。データ再利用・スパース性・量子化 ANN は扱わず、後続（ Dampfhoffer, Yan ）がこれを拡張していく。

6 次に読むべき論文は？

- Horowitz ISSCC (2014)（本文未確認）
- Lemaire+ ICONIP (2022)（本資料）
- Dampfhoffer+ TETCI (2023)（本文未確認）
- Yan+ TCAD (2026)（本資料）



出典：Davidson & Furber 2021 Fig. 2（ ANN(A) と SNN(B) のニューロン更新パイプライン。どちらも重み・状態メモリを読み書きする）

書誌情報

発表： Frontiers in Neuroscience 2021
リンク： https://doi.org/10.3389/fnins.2021.651141
系譜： 原典
調査日： 2026-10-23
確認範囲： 全文（問題提起・手法・実験・結果・考察）

SATA: Sparsity-Aware Training Accelerator for Spiking Neural Networks

Ruokai Yin, Abhishek Moitra, Abhiroop Bhattacharjee ほか（Yale University）| IEEE TCAD 2022

1 どんなもの？

BPTT 学習 SNN 向けのスパース性考慮シストリック加速器 SATA と、計算と DRAM/GLB/ スクラッチパッドのデータ移動を数えるエネルギー推定枠組み（SATA-Sim）を提案。Eyeriss 型 ANN 基準と比べ、SNN 学習は 1.27 倍のエネルギーと示した。

2 先行研究と比べてどこがすごい？

既存の SNN アルゴリズム研究は演算数ベースの解析推定で省エネを主張し、HW のデータ移動を無視していた。H2Learn 等の専用設計は SNN に特化しすぎて公平比較に向かない。SATA は汎用 Eyeriss 型を土台に ANN と同条件で比べる基準を与える。

3 技術や手法のキモはどこ？

E_total = Σ N_op(sp)·E_op を順伝播・逆伝播・重み更新の各段で計算と各階層メモリアクセスに分解。スパイク S・発火勾配∇f・膜電位勾配∇U の 3 種のスパース性で N_op を減らし、重みを時間方向に保持するデータフローを採用。

4 どうやって有効だと検証した？

VGG5/CIFAR10（T=8）、65nm 合成＋CACTI。非スパースで SNN は 1.35 倍、スパース込みでも 1.27 倍（計算 1.19 倍・メモリ 1.27 倍）（Fig. 8）。メモリ費用の 96.3% は GLB/DRAM でスパース性では削れない（Fig. 10）。T が大きいと急増。

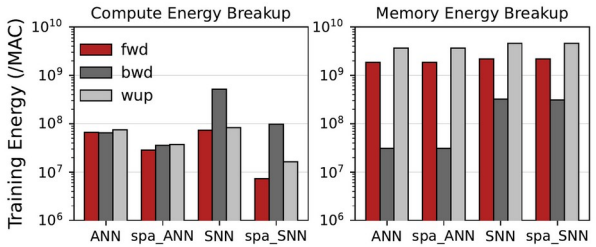
5 議論はある？

著者：制御エネルギー・ゲーティング漏れは無視した理想化比較。∇U のスパース化が鍵。

所感：対象は学習だが、推論評価にも転用される SNN エネルギー推定基盤となった。単位が「MAC 何回分」の正規化値なので絶対値比較には注意。

6 次に読むべき論文は？

- SpinalFlow (Narayanan+ 2020)（本文未確認）
- SpikeSim (Moitra+ 2023)（未調査）
- Bhattacharjee+ ICASSP (2024)（本資料）



出典：SATA Fig. 8（ANN/SNN 学習の計算・メモリエネルギー内訳。spa_ はスパース性利用時）

書誌情報

発表： IEEE TCAD 2022
リンク： https://arxiv.org/abs/2204.05422
系譜： 発展（← Davidson & Furber 2021）
調査日： 2026-10-23
確認範囲： 全文（問題提起・手法・実験・結果・考察）

An Analytical Estimation of Spiking Neural Networks Energy Efficiency

Edgar Lemaire, Loïc Cordone, Andrea Castagnetti ほか（ Université Côte d'Azur, CNRS LEAT ）| ICONIP 2022

1 どんなもの？

SNN と通常の ANN（ FNN ）のエネルギーを、シナプス演算・メモリアクセス・アドレス計算の回数 ×45nm 単価で見積もるハードウェア非依存の解析指標を提案。CIFAR-10・GSC・NCARS の 3 種のデータで SNN が 6 〜 8 倍省エネと推定した。

2 先行研究と比べてどこがすごい？

従来指標は ACC/MAC 回数のみで、膜電位の読み書き、リーク・リセット・バイアス、疎な畳み込みのアドレス計算を無視していた。一方 Davidson & Furber のような特定 HW 前提の結論は一般化しにくいとして、中間の汎用モデルを狙う。

3 技術や手法のキモはどこ？

E = E_mem + E_ops+addr 。入力・重み・膜電位の読出し、出力・膜電位の書込み回数を層ごとに式化し、SNN 側は入力スパイク数 θ に比例させる。単価は加算 0.1pJ ・乗算 3.1pJ 、SRAM は 8kB 10pJ 〜 1MB 100pJ を容量で補間。

4 どうやって有効だと検証した？

VGG-16/CIFAR-10（ T=4 、精度 88.4% vs 95.1% ）、4 層 CNN/GSC（ T=2 ）、Tiny VGG-11/NCARS（ T=5 ）。スパイク率 0.08 〜 0.14 。総エネルギーはメモリが支配し、FNN/SNN 比は 8.19・6.22・8.17 倍（ Table II, Fig. 1 ）。

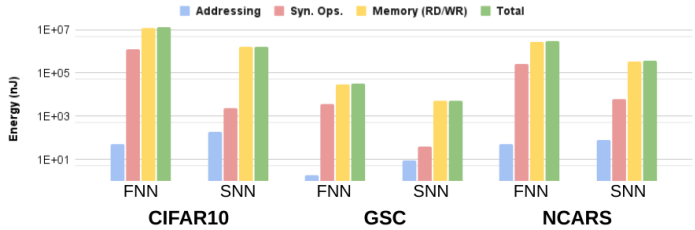
5 議論はある？

著者：今後は自作 HW（ SPLEAT ）での実測と比べ、量子化の影響も調べる。

所感：FNN は 32bit で全特徴マップを SRAM 保持、SNN は 1000 要素 FIFO という SNN 有利な仮定。データ再利用や量子化 ANN を無視しており、後の批判の対象になる。

6 次に読むべき論文は？

- Davidson & Furber (2021)（本資料）
- Lemaire+ ACM TECS (2022)（本文未確認）
- Dampfhoffer+ TETCI (2023)（本文未確認）
- Höfflin & Wassner (2025)（本資料）



出典：Lemaire+ 2022 Fig. 1（ 45nm 単価による推定エネルギーの内訳。メモリ読み書きが支配的）

書誌情報

発表： ICONIP 2022
リンク： https://arxiv.org/abs/2210.13107
系譜： 発展（← Davidson & Furber 2021 ）
調査日： 2026-10-23
確認範囲： 全文（問題提起・手法・実験・結果・考察）

To Spike or Not To Spike: A Digital Hardware Perspective on Deep Learning Acceleration

Fabrizio Ottati, Chang Gao, Qinyu Chen ほか（ Politecnico di Torino / TU Delft ほか）| IEEE JETCAS 2023

1 どんなもの？

ANN と SNN のデジタル加速器を、簡易エネルギーモデルと公表チップの実測値（ ImageNet・VAD・KWS ）で定量比較したレビュー。静的画像では ANN 加速器が SNN 加速器をパレート支配し、SNN の勝機は時系列・イベントセンサとハイブリッドにあると結論。

2 先行研究と比べてどこがすごい？

既存の SNN-HW レビューは SNN 同士の比較に留まり、最先端 ANN 加速器との客観比較が欠けていた。SynOP は定義に合意がなく状態更新も含まないため採用せず、精度と並べた「 1 推論あたりエネルギー」を公平な指標とした。

3 技術や手法のキモはどこ？

45nm 単価（ 8b 加算 0.03pJ・乗算 0.2pJ・8kB SRAM 読出 10pJ/64b ）で畳み込み 1 窓を解析。1 時刻なら SNN 13.1nJ 、ANN 24.1nJ で SNN が 1.84 倍有利に見えるが、$E_{SNN}=13.1\text{nJ}\cdot T\cdot\gamma$ と時刻数 T が掛かるため静的入力では逆転する。

4 どうやって有効だと検証した？

ImageNet で SNN 最良の SNPU'23（ 28nm 、ResNet18 、16 時刻）は 1.95mJ/ 推論・66.8% 、同じ 28nm の ANN（ Mo'21 ）は 0.46mJ・76.9%（ Table II ）。音声 VAD/KWS では SNN チップも ANN 並み（ Table III ）。

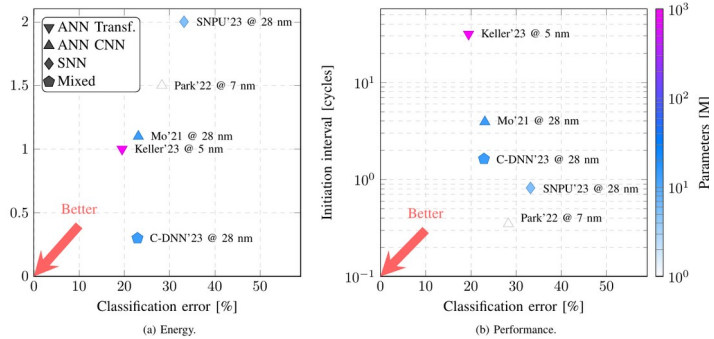
5 議論はある？

著者：時系列では SNN も競争力があり、オンチップ学習は SNN が先行。ハイブリッドが最適解かもしれない。

所感：公表値の横断比較は精度・プロセス・課題が揃わず粗い。それでも「エネルギー / 推論と精度を同時に見る」評価軸を明確化した意義は大きい。

6 次に読むべき論文は？

- Davidson & Furber (2021)（本資料）
- C-DNN (Kim+ 2023)（未調査）
- NeuroBench (Yik+ 2025)（既存：neuromorphic-hardware ）



出典：Ottati+ 2023 Fig. 1（ ImageNet 上の公表加速器のエネルギー / 推論・性能と分類誤差。SNN の SNPU'23 は ANN にパレート支配される）

書誌情報

発表： IEEE JETCAS 2023
リンク： https://arxiv.org/abs/2306.15749
系譜： 発展（← Davidson & Furber 2021 ）
調査日： 2026-10-23
確認範囲： 全文（問題提起・手法・実験・結果・考察）

Are SNNs Truly Energy-efficient? — A Hardware Perspective

Abhiroop Bhattacharjee, Ruokai Yin, Abhishek Moitra, Priyadarshini Panda（Yale University）| ICASSP 2024

1 どんなもの？

近年の SNN アルゴリズム論文の「FLOPs× 時刻 ×(1− スパース率)×E_AC 」による推定省エネを、デジタル系統配列 SATA とアナログ IMC の SpikeSim で再評価。推定の 10 〜 83 倍が SATA 上では 1.3 〜 6.8 倍に縮むことを示した。

2 先行研究と比べてどこがすごい？

BNTT・TDBN 等の SNN 学習研究は FLOPs やスパイク率という原始的指標で効率を主張し、メモリアクセス・データ通信・LIF 回路・クロスバ非理想性を考慮していなかった。SpinalFlow 等の先行 HW 研究も大規模 SNN の実用面を扱いきれていなかった。

3 技術や手法のキモはどこ？

SATA（28nm 、出力 / 重み定常の系統配列）と SpikeSim（65nm RRAM クロスバ）の 2 つの HW ベンチで同一モデルを評価しボトルネックを特定。緩和策として動的時刻削減 DT-SNN 、SNN 向けデータフロー、LIF 共有、非理想性考慮の重み符号化を検討。

4 どうやって有効だと検証した？

CIFAR10 で推定改善 10 〜 83 倍に対し、SATA 実効 1.3 〜 6.8 倍、SpikeSim 2 〜 25 倍（Table II ）。SpikeSim で T=1→4 にすると EDP 10.4 倍、DT-SNN で 2.54 倍削減（Fig. 4 ）。SNN 向けデータフローでデータ移動 62.5% 減、LIF 共有で電力 75.1% 減。

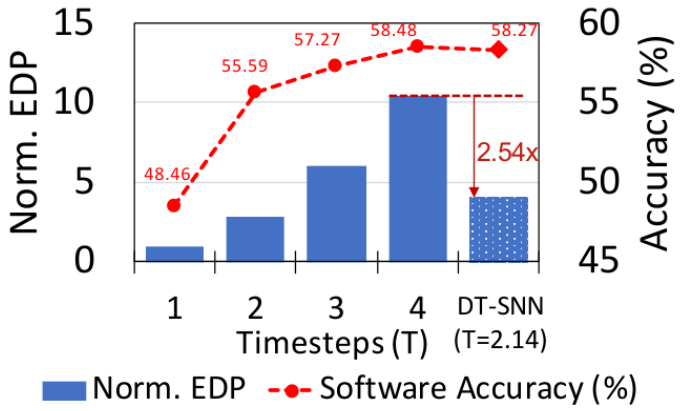
5 議論はある？

著者：時刻反復のデータ移動・LIF 回路・非理想性が主因。HW を意識した SNN アルゴリズム設計が必要。

所感：5 頁の短報だが「推定値と実効値の乖離」を表で示し影響が大きい。ただし実効値もシミュレータ推定で、実チップ計測ではない点に注意。

6 次に読むべき論文は？

- SATA (Yin+ 2022)（本資料）
- SpikeSim (Moitra+ 2023)（未調査）
- DT-SNN (Li+ 2023)（未調査）



出典：Bhattacharjee+ 2024 Fig. 4(a)（SpikeSim 上の VGG16/TinyImageNet 。時刻数とともに EDP が増え、DT-SNN で 2.54 倍削減）

書誌情報

発表： ICASSP 2024
リンク： https://arxiv.org/abs/2309.03388
系譜： 発展（← SATA (Yin+ 2022) ）
調査日： 2026-10-23
確認範囲： 全文（問題提起・手法・実験・結果・考察）

Are Conventional SNNs Really Efficient? A Perspective from Network Quantization

Guobin Shen, Dongcheng Zhao, Tenglong Li ほか（中国科学院自動化研究所 BrainCog Lab ）| CVPR 2024

1 どんなもの？

T 時刻の SNN と T ビット量子化 ANN（ QANN ）は同等の計算複雑さを持つと示し、SynOps に代えて時刻 × 重みビット幅 × スパイクビット幅の「 Bit Budget 」と S-ACE/NS-ACE 指標を提案。量子化を前提にした公平な比較と設計指針を与えた。

2 先行研究と比べてどこがすごい？

従来の SNN 論文は最適化されていない 32bit ANN と比較し、SOPs は発火率と時刻しか見ず重みビット幅を無視していた。本論文は量子化・剪定で効率化した ANN を比較相手に据え、SNN の効率は本当に「本質的」かを問い直す。

3 技術や手法のキモはどこ？

QANN の積和を 2^t·a^(t) のビット分解で T 個の二値行列積に書き換え、SNN の時間方向の和と同型と示す。BB = T·b_w·b_s 、S-ACE = Σ n_{w,s}·BB 、NS-ACE は発火率を掛けたもの。FPGA で BB とシナプスエネルギーの線形関係を確認（ Fig. 3 ）。

4 どうやって有効だと検証した？

ImageNet で Spikformer-8-512（重み 16bit・1bit スパイク・T=4 ）は S-ACE 516G・73.4% に対し、重み 4bit・8bit スパイク・T=1 で 210G・76.8%（ Table 1 ）。静的画像では時刻よりスパイクのビット幅に配分すべきで、DVS では均衡が必要（ Table 3 ）。

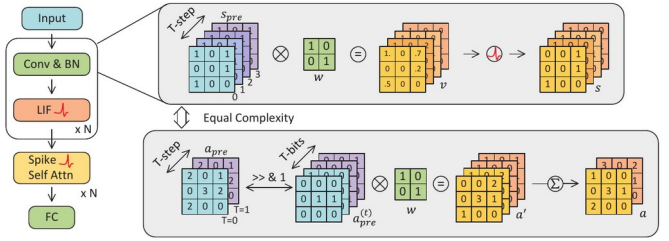
5 議論はある？

著者：ANN 流儀の SNN は活性量子化 ANN と本質的に同じで、スパース性は内在的でなく設計で決まる。

所感：S-ACE は演算複雑度でメモリ費用を含まず、エネルギーそのものではない。「 T=1 ・多ビットスパイク」はほぼ QANN で、SNN の定義自体を揺さぶる結果。

6 次に読むべき論文は？

- Yan+ TCAD (2026)（本資料）
- STEP (Shen+ 2025)（参照のみ）
- Spikformer (Zhou+ 2022)（既存：spiking-transformer ）



出典：Bit Budget (Shen+ 2024) Fig. 1（同じ特徴ビット数なら T 時刻の SNN と T ビット QANN は表現の複雑さが等しい）

書誌情報

発表： CVPR 2024
リンク： https://arxiv.org/abs/2311.10802
系譜： 発展（← Davidson & Furber 2021 ）
調査日： 2026-10-23
確認範囲： 全文（問題提起・手法・実験・結果・考察）

Event-based Optical Flow on Neuromorphic Processor: ANN vs. SNN Comparison based on Activation Sparsification

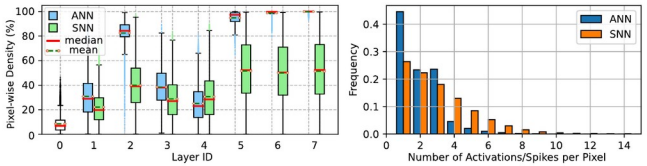
Yingfu Xu, Guangzhi Tang, Amirreza Yousefzadeh ほか（imec Netherlands / TU Delft ほか）| Neural Networks 2025

1 どんなもの？

イベントカメラ光学フローの ANN と SNN を、同じ構造・同程度の活性密度（約 5%）に揃え、両方を同じ処理系で動かせるニューロモルフィックプロセッサ SENECA 上で比較。SNN は時間 62.5%・エネルギー 75.2% に収まり、要因が画素単位の密度にあると特定。

2 先行研究と比べてどこがすごい？

先行比較には ①画像分類で SNN だけ多時刻が要る、② ANN と SNN で別プロセッサ（Lemaire+）や ANN のみ加速（Dampfhoffer+）、③ ANN の活性スパース化を考慮しない、という不公平があった。Horowitz の MAC/AC=5.1 倍に頼る推定も批判する。



出典：Xu+ 2025 Fig. 4（層ごとの画素単位密度（左）と画素あたり活性 / スパイク数の分布（右））

3 技術や手法のキモはどこ？

学習可能閾値の FATReLU（ANN）と閾値学習 LIF（SNN）にスパース化損失を課し、1 回の学習で活性密度を 5% 未満に。SENECA は ANN の活性値もイベントとして扱い、同じ画素の 4 イベントをまとめて膜電位を 1 回だけ読み書きする。

4 どうやって有効だと検証した？

FireNet、56×56 入力、GF22nm ゲートレベル電力解析（signoff 比 ±15%）。SNN 44.9ms/927μJ、ANN 71.8ms/1233μJ（Table 3）。120×120 でも SNN 4174μJ vs ANN 5753μJ。画素密度は ANN 66.5%、SNN 43.5%（Fig. 4）。

5 議論はある？

著者：同じ神経密度でも、活性が画素に集中するほど状態メモリのアクセスが減る。大規模網の写像は今後の課題。

所感：「ANN もスパース化し同一 HW で測る」公平比較の型を示した好例。ただし実チップではなくゲートレベルのシミュレーションで、数フレームのみの評価。

6 次に読むべき論文は？

- Davidson & Furber (2021)（本資料）
- SENECA (Tang+ 2023)（未調査）
- Gamage+ Neurocomputing (2026)（本資料）

書誌情報

発表： Neural Networks 2025
リンク： https://arxiv.org/abs/2407.20421
系譜： 発展（← Lemaire+ 2022）
調査日： 2026-10-23
確認範囲： 全文（問題提起・手法・実験・結果・考察）

Hardware-aware vs. Hardware-agnostic Energy Estimation for SNN in Space Applications

Matthias Höfflin, Jürgen Wassner（ Lucerne University of Applied Sciences and Arts ）| IAA-SPAICE 2025

1 どんなもの？

衛星画像からの 3 次元位置回帰を SNN で解き、同じ SNN/CNN の組にハードウェア非依存の推定（ Lunghi+ 2025 の EMAC ）とハードウェア考慮の推定（ Yan+ の式を LIF へ拡張）を適用。前者は一律 50 〜 60% の省エネ、後者は条件次第と示した。

2 先行研究と比べてどこがすごい？

Lunghi+ や Lemaire+ の手法はシナプス演算以上を数えるが、HW の前提が結論をどれほど左右するかは検証されていなかった。本論文は推定法の選択そのものが「 SNN は省エネか」の答えを変えることを、同一モデルで定量化した。

3 技術や手法のキモはどこ？

E_LIF = T·{N_src(1−s_in)(E_RW+E_ADD) + 状態読出・加算・比較・リーク乗算 + (1−s_out)E_SUB + E_W + N_src(1−s_out)·N_hop·E_hop} 。古典アーキ（ CA ）では内部 / 外部メモリの単価比 MER を 1:100 〜 1:1 で振り、NDA は局所メモリのみと仮定。

4 どうやって有効だと検証した？

MSE は CNN 55.2e-3 、SNN 62.0e-3（ Table 1 ）。非依存法で SNN は CNN の 0.45 〜 0.50 倍。HW 考慮では CA 上の SNN は CNN の約 3 〜 7 倍。NDA 上の SNN は 0.039 〜 0.070 で、MER 1:100 の CNN（ 0.144 ）には勝つが MER 1:1 の CNN（ 0.030 ）には負ける（ Table 2 ）。

5 議論はある？

著者：HW 考慮推定は低レベル単価の選択に強く依存。暗い画素が多いほど SNN の消費は減る。

所感：「 SNN は神経形態 HW でのみ有利」は NDA 上の SNN と CA 上の CNN という異種比較に基づく。単価の仮定一つで結論が反転する脆さ自体が重要な示唆。

6 次に読むべき論文は？

- Lunghi+ Astrodynamics (2025)（参照のみ）
- Yan+ TCAD (2026)（本資料）
- Lemaire+ ICONIP (2022)（本資料）

Test		[5]	This work [rel. energy]						
Seq.	[rel. # of EMAC]		MER 1:100 ([20])		MER 1:50		MER 1:1		-
ρ	CNN	SNN	CNN_{CA}	SNN_{CA}	CNN_{CA}	SNN_{CA}	CNN_{CA}	SNN_{CA}	SNN_{NDA}
0.35	1.000	0.495	0.144	1.000	0.087	0.540	0.030	0.088	0.070
0.51	1.000	0.484	0.144	0.996	0.087	0.535	0.030	0.084	0.058
0.59	1.000	0.470	0.144	0.990	0.088	0.529	0.031	0.078	0.048
0.65	1.000	0.462	0.144	0.987	0.088	0.527	0.031	0.075	0.042
0.69	1.000	0.465	0.146	0.988	0.088	0.527	0.031	0.075	0.045
0.85	1.000	0.456	0.146	0.985	0.088	0.524	0.031	0.073	0.038
0.87	1.000	0.457	0.146	0.985	0.088	0.524	0.031	0.073	0.041
0.90	1.000	0.461	0.147	0.986	0.089	0.526	0.032	0.074	0.045
0.95	1.000	0.456	0.146	0.985	0.088	0.523	0.031	0.073	0.040
0.99	1.000	0.454	0.146	0.984	0.088	0.523	0.031	0.072	0.039

出典：Höfflin & Wassner 2025 Table 2（暗画素率 ρ 別の相対エネルギー。左：HW 非依存、右：MER 別の HW 考慮推定と NDA 上の SNN ）

書誌情報

発表： IAA-SPAICE 2025
リンク： https://arxiv.org/abs/2508.19654
系譜： 最新（← Lemaire+ 2022 ）
調査日： 2026-10-23
確認範囲： 全文（問題提起・手法・実験・結果・考察）

Reconsidering the Energy Efficiency of Spiking Neural Networks Inference from Analytical Perspectives

Zhanglu Yan, Zhenyu Bai, Kaiwen Tang, Weng-Fai Wong（ National University of Singapore ）| IEEE TCAD 2026

1 どんなもの？

レート符号化 SNN（T 時刻）を「log2(T+1)] ビットの容量一致 QNN「双子」と対にし、計算・重み読出し・NoC 上のデータ移動・膜電位アクセスを含む第一原理モデルで比較。典型的な神経形態 HW 条件では T=5 でスパイク率 5.7% 未満が必要と示した。

2 先行研究と比べてどこがすごい？

既存評価は加算と乗算の回数 × 固定単価（Horowitz 値の流用）に偏り、データ移動を無視。比較相手の ANN も 32bit で不公平だった。Dampfhoffer+ や Bhattacharjee+ は個別 HW の事例に留まり、設計空間全体の損益分岐を与えていなかった。

3 技術や手法のキモはどこ？

計算部の条件は $T \cdot s_r \lesssim k(1-\gamma)$（k=E_MAC/E_ACC）。データ移動は疎（イベント 3pJ/bit/hop）と密（0.25pJ/bit/hop）の安い方を選び、ホップ数 k_hop と重み再利用率 R_QNN・R_SNN（SNN は時間方向で最大 T 倍）を変数に損益分岐を閉形式で導く。

4 どうやって有効だと検証した？

22nm 単価。T=4・s_r=0.1 の典型的 SNN は典型 HW で QNN の 1.22 ～ 1.43 倍（Fig. 3）。VGG16 は CIFAR-10 の T=3 で 0.987、T=5 ～ 7 で 1.41 ～ 2.24 倍（Table II）。SST-2 の Transformer は T=15 で 3.76 倍と T/⌈log2(T+1)⌉ に一致。

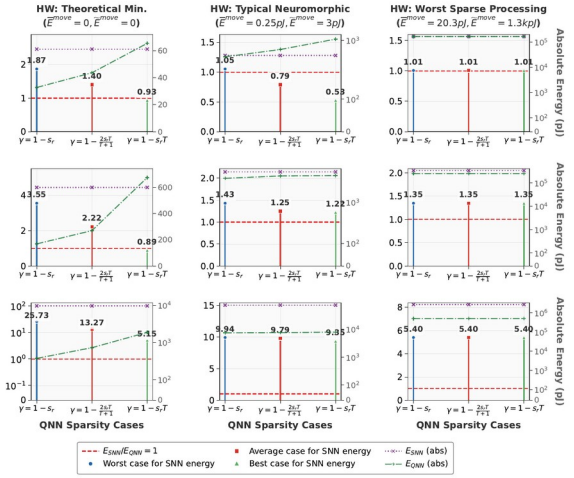
5 議論はある？

著者：制御エネルギーとレイテンシは対象外。疎イベント移動の単価を下げる専用 HW なら SNN 有利域は広がる。

所感：容量一致の双子という比較基準と閉形式の分岐条件が実用的。版を重ね数値が更新（v1 は VGG16, T=6 で 93% 超）されており、引用時は版に注意。

6 次に読むべき論文は？

- Bit Budget (Shen+ 2024)（本資料）
- Dampfhoffer+ TETCI (2023)（本文未確認）
- Kranzlmüller+ (2026)（参照のみ）



出典：Yan+ 2026 Fig. 3（SNN 構成（行）×HW 設定（列）ごとのエネルギー比 E_SNN/E_QNN。1 を超えると QNN が有利）

書誌情報

発表： IEEE TCAD 2026
リンク： https://arxiv.org/abs/2409.08290
系譜： 最新（← Davidson & Furber 2021）
調査日： 2026-10-23
確認範囲： 全文（問題提起・手法・実験・結果・考察）

Real-Time Frame- and Event-based Object Detection with Spiking Neural Networks on Edge Neuromorphic Hardware: Design, Deployment and Benchmark

Udayanga G.W.K.N. Gamage, Yan Zeng, Cesar Cadena ほか（Technical University of Denmark / ETH Zürich）| Neurocomputing 2026

1 どんなもの？

Loihi 2 向けに 3 種の軽量 SNN 物体検出器を設計・展開し、同じ課題の ANN を Jetson Orin Nano・Jetson Nano・Apple M2 で実測比較。Loihi 2 は動的エネルギー / 推論が最小だが、速度と EDP は Orin Nano が上回り、静的電力が動的の 2 〜 5 倍を占める。

2 先行研究と比べてどこがすごい？

SNN 検出の省エネは GPU 上の SOP 推定（SpikeYOLO 等）で語られがちで、実ニューロモルフィックチップでの物体検出の実測は乏しかった。NeuroBench 系の手順に沿い、動的エネルギーと総エネルギー・EDP を分けて報告する。

3 技術や手法のキモはどこ？

各機器でアイドル電力を測り、推論中の総電力との差から動的エネルギーを算出（Loihi 2 はプロファイラ、Jetson は tegrastats で FP16 TensorRT、M2 は powermetrics）。入力は事前にメモリへ載せ I/O を除外。SOP と動的エネルギーの関係も検証。

4 どうやって有効だと検証した？

動的エネルギーで Loihi 2 は Orin Nano の 1.61 〜 3.74 倍、Nano B01 の 10 〜 35 倍効率的（Fig. 8）。総エネルギーは Model-1/evCIVIL-ev で 13.05mJ vs Orin 23.79mJ だが、EDP は 122.3 vs 90.5µJs で Orin が良い（Table 5）。精度は ANN 比 5 〜 15% 低い。

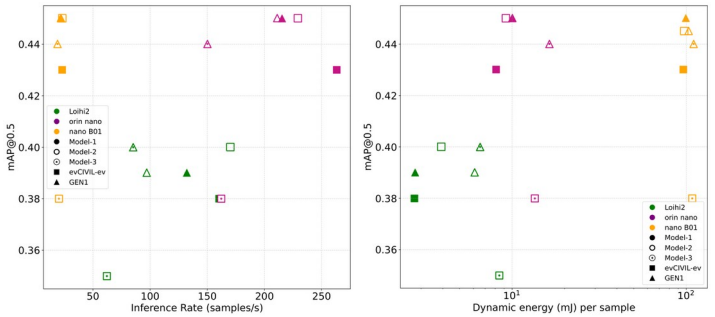
5 議論はある？

著者：SOP 削減は速度と動的エネルギーを改善するが、過度のスパース化は精度を損なう。

所感：ANN は FP16 で INT8 化されず、GAP9 上の ANN は Loihi 2 より 3.7 倍低エネルギーとの記述もある。実測でも比較相手の最適化度と I/O・静的電力の扱いが結論を左右する。

6 次に読むべき論文は？

- NeuroBench (Yik+ 2025)（既存：neuromorphic-hardware）
- Xu+ Neural Networks (2025)（本資料）
- Ottati+ JETCAS (2023)（本資料）



出典：Gamage+ 2026 Fig. 8（イベントデータでの mAP と推論レート（左）・動的エネルギー / サンプル（右）。緑 Loihi 2、紫 Orin Nano、橙 Nano B01）

書誌情報

発表： Neurocomputing 2026
リンク： https://arxiv.org/abs/2605.00146
系譜： 最新（← SENECA ANN vs SNN (Xu+ 2025)）
調査日： 2026-10-23
確認範囲： 全文（問題提起・手法・実験・結果・考察）