イベントベース世界モデルと表現学習

イベントカメラの「変化だけ」の信号から制御に効く表現・予測モデルを学ぶ系譜。コントラスト最大化（自己教師）と EST などのイベント表現、サーベイを原典に、eVAE による RL 用表現、チップ上の夢見学習、機上の自己教師学習へ発展。

2026 年は表現学習と方策探索の分離（ Approximate IL ）、報酬のみの課題整合表現（ FLEET ）、自己回帰の事前学習（ GEP ）、未来イベントを予測する潜在世界行動モデル（ ECHO ）が並び立つ。

#	年	論文	発表	系譜
1	2018	CMax (Gallego+ 2018)	CVPR 2018	原典
2	2019	EST (Gehrig+ 2019)	ICCV 2019	原典
3	2020	Event Vision Survey (Gallego+ 2020)	IEEE TPAMI 2020	原典
4	2021	eVAE (Vemprala+ 2021)	NeurIPS 2021	発展
5	2025	Neuromorphic dreaming (Blakowski+ 2025)	Neuromorphic Comput. Eng. 2025	最新
6	2025	On-Device SSL Depth (Hagenaars+ 2025)	CVPR 2025	最新
7	2026	Approximate IL (Messikommer+ 2026)	CoRL 2026	最新
8	2026	GEP (Cao+ 2026)	CVPR 2026 Findings	最新
9	2026	FLEET (Gottwald+ 2026)	arXiv プレプリント 2026	最新
10	2026	ECHO (Wang+ 2026)	arXiv プレプリント 2026	最新

A Unifying Contrast Maximization Framework for Event Cameras, with Applications to Motion, Depth, and Optical Flow Estimation

Guillermo Gallego, Henri Rebecq, Davide Scaramuzza（University of Zurich / ETH Zurich）| CVPR 2018

1 どんなもの？

イベントを候補の運動で基準時刻へワープし、ワープ後イベント像（IWE）のコントラストを最大化する統一枠組み「コントラスト最大化（CMax）」を提案。ラベルも輝度画像も使わずに、オプティカルフロー・深度・回転運動・平面ホモグラフィを同じ手順で推定した。

2 先行研究と比べてどこがすごい？

従来は、外観情報（輝度画像や地図）と照合するイベント単位のフィルタか、課題ごとのアドホックな集約法しかなかった。CMax は「動くエッジが軌跡に沿ってイベントを出す」という物理だけでデータ対応付けを暗黙に解き、多様な課題を一つの目的関数で扱う。

3 技術や手法のキモはどこ？

① 運動モデルで各イベントを $x' = x - (t - t_{ref})\theta$ のように基準時刻へワープ、②ワープ後のイベント数を画素に積んだ像 H を作る、③その分散 $f(\theta) = \sigma^2(H)$ を勾配法などで最大化。正しい θ ほどエッジが揃って鮮鋭になり、副産物として動き補償済みのエッジ像が得られる。

4 どうやって有効だと検証した？

Event Camera Dataset で評価。回転推定は 1.8 億イベント・最大 670°/s の系列で RMS 誤差約 20°/s（約 3%、Fig. 9）。深度は slider_depth の 100 万イベント（3.4 s）から半密な 3D 再構成（Fig. 7）。平面シーンでは動き補償像が VIO の点群を平らにした（Fig. 11）。

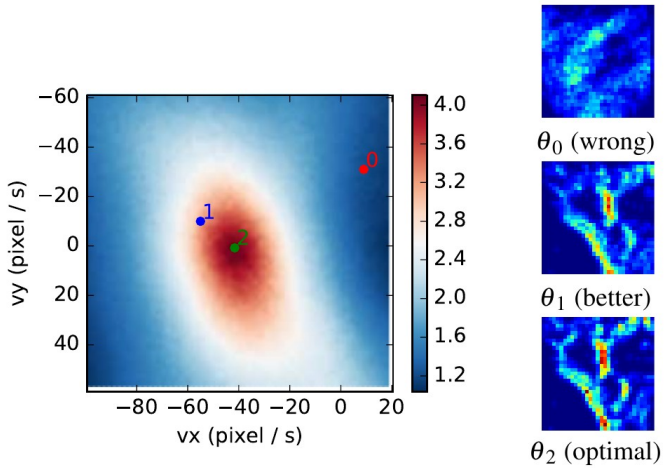
5 議論はある？

著者：外観情報なしで多くの課題を解ける単純さが利点と強調。計算量はワープするイベント数に線形。

所感：数値評価は回転推定に限られ定性的。のちに損失の崩壊（イベントが一点に集まる）が問題化し、正則化が必要になる。ただし「教師なしで運動を学ぶ損失」として以後の自己教師学習の土台になった。

6 次に読むべき論文は？

- Unsupervised Event-based Learning of Optical Flow, Depth, and Egomotion (Zhu+ 2019)（未調査）
- On-Device SSL of Monocular Depth (2025)（本資料）
- Event-based Vision: A Survey (2020)（本資料）



出典：CMax Fig. 3（フロー候補 θ ごとのコントラスト $f(\theta)$ と、ワープ後イベント像の鮮鋭さ）

書誌情報

発表： CVPR 2018
リンク： https://arxiv.org/abs/1804.01306
系譜： 原典
調査日： 2026-10-24
確認範囲： 全文（問題提起・手法・実験・結果・考察）

End-to-End Learning of Representations for Asynchronous Event-Based Data

Daniel Gehrig, Antonio Loquercio, Konstantinos G. Derpanis ほか（University of Zurich / ETH Zurich）| ICCV 2019

1 どんなもの？

イベント列を格子テンソルへ変換する処理を「計測関数・カーネル畳み込み・離散化・射影」の微分可能な演算列として定式化し、既存表現（event frame、voxel grid など）を統一する分類と、カーネルを MLP で課題とともに学ぶ Event Spike Tensor（EST）を提案した。

2 先行研究と比べてどこがすごい？

CNN 用の格子表現は手作りで固定され、どれが最適かは検証されていなかった。EST は表現を課題損失から端から端まで学べるようにし、極性と時間を捨てない 4 次元表現（2×B×H×W）が最も情報を保つことを、物体認識とフローで系統的に示した。

3 技術や手法のキモはどこ？

各イベントに計測値 f（極性・個数・正規化時刻）を割り当て、カーネル k と畳み込んで格子点で標本化：$S_{\pm}[x,y,t_n] = \Sigma f \cdot k(x - x_k, y - y_k, t_n - t_k)$。k を 2 層 MLP にして課題とともに学習し、推論時はルックアップ表に置き換える。

4 どうやって有効だと検証した？

認識は ResNet-34 で N-Cars 0.925、N-Caltech101 0.817。HATS（0.902/0.642）や Voxel grid（0.865/0.785）を上回る（Table 3）。MVSEC のフローでは EV-FlowNet 比で AEE を約 12% 改善し、外れ値率を平均 49% 削減（Table 4）。表現生成は 0.38 ms（Table 6）。

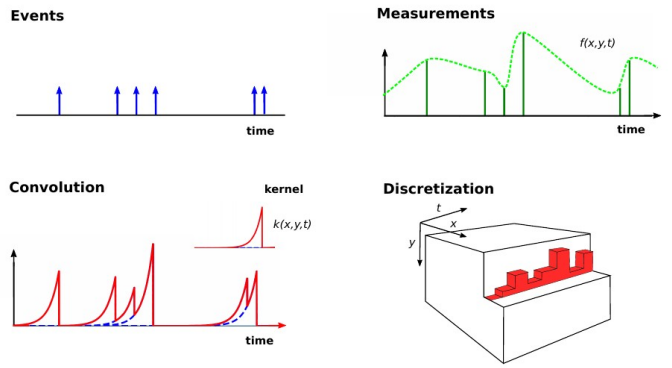
5 議論はある？

著者：非同期処理や低電力では SNN に劣る。ただしバッチ処理なら 146 Hz（ResNet-34）で高速用途に足りる。

所感：時間と極性を残すほど良いという指針は、のちの voxel grid の標準化を後押しした。一方で窓を区切って格子に詰める前提は残り、FLEET などの系列直接処理が批判する対象となった。

6 次に読むべき論文は？

- Event-based Vision: A Survey (2020)（本資料）
- Masked Event Modeling (Klenk+ 2024)（未調査）
- FLEET (2026)（本資料）



出典：EST Fig. 2（イベント→計測→カーネル畳み込み→離散化の枠組み）

書誌情報

発表： ICCV 2019
リンク： https://arxiv.org/abs/1904.08245
系譜： 原典（← Voxel grid (Zhu+ 2019)）
調査日： 2026-10-24
確認範囲： 全文（問題提起・手法・実験・結果・考察）

Event-based Vision: A Survey

Guillermo Gallego, Tobi Delbrück, Garrick Orchard ほか（TU Berlin / UZH・ETH Zurich ほか）| IEEE TPAMI 2020

1 どんなもの？

イベントカメラの動作原理、主要センサ、イベント表現、処理手法（フィルタ・CMax・深層学習・SNN）、低次〜高次の視覚課題、ニューロモルフィック制御とプロセッサまでを網羅した標準サーベイ。分野の共通語彙と未解決課題を整理した。

2 先行研究と比べてどこがすごい？

DVS（Lichtsteiner+ 2008）以降、分野ごとに個別の手法が乱立していた。本サーベイは「イベントは動くエッジが作る、輝度の時間微分の情報」という物理的解釈を軸に、表現と手法を課題横断で体系化し、制御・能動視覚まで射程に入れた点が新しい。

3 技術や手法のキモはどこ？

イベント生成モデル $\Delta L(x_k,t_k)=p_k \cdot C$ と、その線形化 $\Delta L \approx -\nabla L \cdot v \Delta t$ を出発点に、表現を event frame・time surface・voxel grid・3D 点集合・動き補償像・再構成画像に分類。処理法はイベント単位（フィルタ・SNN）とイベント群（CMax・DNN）に分けて整理した。

4 どうやって有効だと検証した？

総説のため新規実験はない。センサ性能を整理：遅延 約 10 µs（実環境はサブミリ秒）、ダイナミックレンジ 120 dB 超（通常 60 dB）、チップ電力 約 10 mW、DVS 画素帯域 約 3 kHz（明所）。主要センサの比較表（Table 1）と表現の図（Fig. 3）を示す。

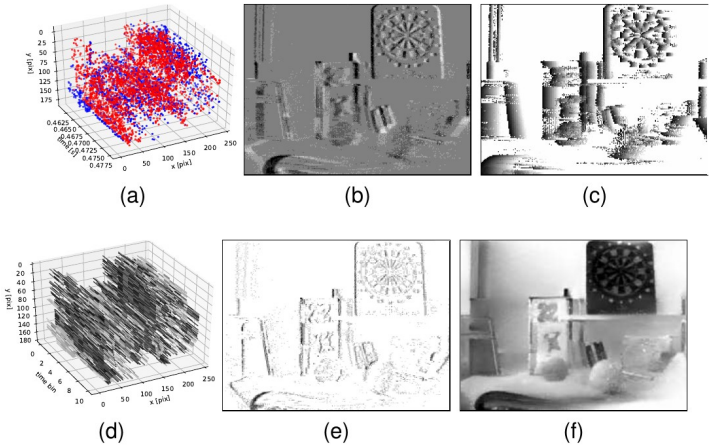
5 議論はある？

著者：最良の表現・手法は課題依存で合意はない。知覚から制御・駆動まで一貫してイベント駆動の系、課題に応じた感覚の変調、速い反射系と遅い熟考系の統合が大きな課題。

所感：「予測・世界モデル」という観点はまだ薄く、表現学習も教師ありが中心の時代の整理である。

6 次に読むべき論文は？

- A 128×128 120 dB 15 µs Latency Asynchronous Temporal Contrast Vision Sensor (2008)（本文未確認）
- EST (2019)（本資料）
- Representation Learning for Event-based Visuomotor Policies (2021)（本資料）



出典：Event Vision Survey Fig. 3（(a) 時空間のイベント (b)event frame (c)time surface (d)voxel grid (e) 動き補償像 (f) 再構成画像）

書誌情報

発表： IEEE TPAMI 2020
リンク： https://arxiv.org/abs/1904.08405
系譜： 原典（← DVS (Lichtsteiner+ 2008)）
調査日： 2026-10-24
確認範囲： 全文（問題提起・手法・実験・結果・考察）

Representation Learning for Event-based Visuomotor Policies

Sai Vemprala, Sami Mian, Ashish Kapoor（Microsoft Research）| NeurIPS 2021

1 どんなもの？

生のイベント列を PointNet 型の集合エンコーダと時刻の正弦波埋め込みで処理し、8 次元の潜在へ圧縮する event VAE（eVAE）を提案。その潜在を観測として PPO で学んだドローン障害物回避方策が、イベント画像＋CNN の端から端までの学習より速く学び、頑健だと示した。

2 先行研究と比べてどこがすごい？

イベント RL の先行研究は、イベントを 2 次元画像に積んで CNN 方策を報酬だけで学んでおり、時間分解能を捨て、疎な入力に弱かった。本研究は知覚と方策を分離し、教師なしで事前学習した表現の上で RL を行う「世界モデル的」な分業をイベントに初めて持ち込んだ。

3 技術や手法のキモはどこ？

Event Context Network：(x,y,p) を共有 MLP で特徴化し、正規化時刻の正弦波埋め込みを加え、max プーリングで順序に依らない文脈ベクトルにする。VAE はこれを潜在 z に写し、時刻で重み付けしたイベント像を復元する。方策は直近 3 つの z を入力とする 2 層 MLP 。

4 どうやって有効だと検証した？

AirSim の 64×64 模擬イベントで評価。学習報酬はイベント画像方策（EIP）や RGB より速く立ち上がる（Fig. 4a）。400 Hz 制御での成功率は eVAE 方策 約 9 割、EIP 約 3 割（40 試行、Fig. 4b、図から読取）。未知の質感・形状で EIP は約 20 m で衝突、eVAE は約 90 m 以上進んだ（Fig. 4c）。

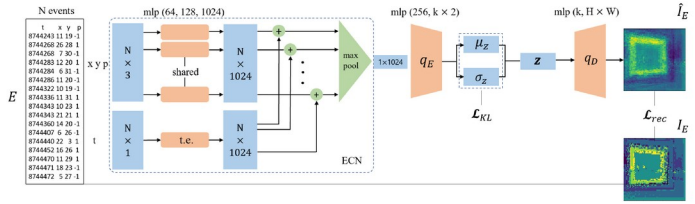
5 議論はある？

著者：大規模・多様なデータや複雑な場面では未検証。イベント模擬の計算コストのため単純な課題に限った。背景ノイズにはやや弱い。

所感：再構成目的なので、制御に不要な見た目まで符号化する。FLEET はこの点を批判した（ただし FLEET はランダム方策のデータで eVAE を事前学習しており、比較条件は厳しい）。

6 次に読むべき論文は？

- FLEET (2026)（本資料）
- Approximate IL (2026)（本資料）
- PlaNet (2019)（既存：world-model/latent-planning）



出典：eVAE Fig. 2（PointNet 型の Event Context Network と時刻埋め込み、VAE によるイベント像復元）

書誌情報

発表： NeurIPS 2021
リンク： https://arxiv.org/abs/2103.00806
系譜： 発展（← EST）
調査日： 2026-10-24
確認範囲： 全文（問題提起・手法・実験・結果・考察）

Neuromorphic dreaming: A pathway to efficient learning in artificial agents

Ingo Blakowski, Dmitrii Zendrikov, Cristiano Capone ほか（INI, UZH・ETH Zurich）| Neuromorphic Comput. Eng. 2025

1 どんなもの？

混合信号ニューロモルフィックチップ DYNAP-SE 上で、方策 SNN と世界モデル SNN を組み、実環境との「覚醒」相と世界モデル内の「夢見」相を交互に回すモデルベース RL を実装した。Atari Pong で、夢見により必要な実プレイが半分未満になった。

2 先行研究と比べてどこがすごい？

SNN の RL は BPTT＋代理勾配など非局所な学習に頼り、チップ実装に向かなかった。e-prop 型の局所則で読み出しだけを学ぶ方式を、世界モデル付き（Capone & Paolucci 2022 の夢見）でアナログ実チップに載せ、サンプル効率の改善を実機で示したのが新しい。

3 技術や手法のキモはどこ？

方策・世界モデルとも、入力をガウス集団符号のスパイク生成器 40 個で与え、固定ランダム結合の LIF 510 個（チップ上）をリザバーにする。PC 上の線形読み出しを局所則で更新：方策は報酬重み付きの方策勾配、世界モデルは次状態 4 変数と報酬の二乗誤差。100 フレーム覚醒＋50 ステップ夢見。

4 どうやって有効だと検証した？

Pong（2000 ゲーム×100 フレーム、10 シード）。夢見ありは平均リターンの立ち上がりが速く、半分未満の実フレームで高得点に達し、低リターンの方策に留まりにくい（Fig. 3）。1 ステップは 18.4 ms（夢見ありは 36.8 ms）で、学習時間は 1.02 h と 3.07 h（3.4 節）。

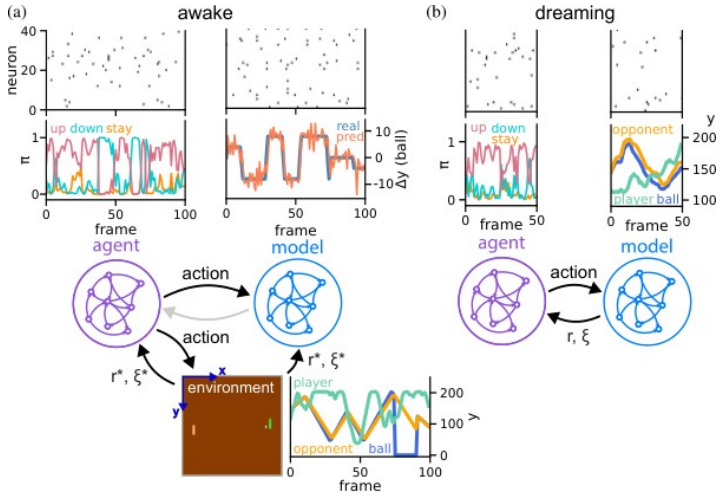
5 議論はある？

著者：短い時間幅のみで学習。コアごとに重みが共有され、入力も 64 本までという制約から、オンチップ学習はできず読み出しのみ PC で学習。チップ個体差・温度で再現性が揺らぐ。

所感：入力はイベントカメラではなくゲーム状態の 4 変数。「イベント視覚の世界モデル」へはまだ距離がある。

6 次に読むべき論文は？

- Towards biologically plausible Dreaming and Planning in recurrent spiking networks (2022)（未調査）
- Training slow silicon neurons to control extremely fast robots (2026)（既存：on-chip-learning）
- e-prop (2020)（既存：snn/training）



出典：Neuromorphic dreaming Fig. 1（(a) 覚醒相：方策と世界モデルが実環境から学ぶ (b) 夢見相：世界モデル内で方策だけを学ぶ）

書誌情報

発表： Neuromorphic Comput. Eng. 2025
リンク： https://arxiv.org/abs/2405.15616
系譜： 最新（← Capone & Paolucci 2022（SNN の夢見と計画））
調査日： 2026-10-24
確認範囲： 全文（問題提起・手法・実験・結果・考察）

On-Device Self-Supervised Learning of Low-Latency Monocular Depth from Only Events

Jesse Hagenaars, Yilun Wu, Federico Paredes-Vallés ほか（TU Delft）| CVPR 2025

1 どんなもの？

コントラスト最大化による自己教師学習（深度＋自己運動→フロー→ IWE の鮮鋭さ）を CUDA で約 100 倍高速化し、Jetson Orin NX を積んだ 800 g のドローン上で、飛行しながら単眼イベント深度をオンライン学習した。障害物回避が事前学習だけより約 30% 改善した。

2 先行研究と比べてどこがすごい？

CMax 系の自己教師学習は真値不要で、テスト環境でそのまま学べるという利点があった。しかし損失計算と逆伝播が重く、機上学習は実現していなかった。Bhattacharya+ 2024 は実データでオフライン微調整した。本研究は飛行中のオンライン微調整を実現した。

3 技術や手法のキモはどこ？

430k パラメータの ConvGRU ネットが深度 D と姿勢 P を出し、$x' \sim KPD(x)K^{-1}x$ からフローを作る。損失は多参照時刻の CMax 損失＋幾何一貫性：$L=L_CM+\lambda L_geo$。イベント単位の並列ワープ・スプラットを CUDA で実装し、パディングを除いて解析勾配を与えた。

4 どうやって有効だと検証した？

MVSEC outdoor_day1（深度上限 10 m）で MAE 2.25 m。イベントのみの自己教師法 Zhu+ 2019（2.72 m）を上回る（Table 1）。損失計算は約 100 倍高速・メモリ 2〜5 分の 1（Fig. 2）。実飛行では約 2 分の学習で深度誤差が下がり、介入間距離は事前学習のみ比で約 30% 伸びた（Fig. 5）。

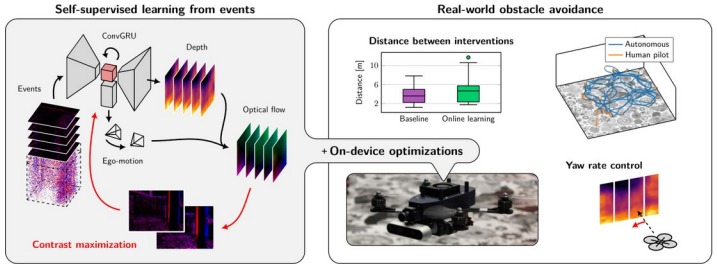
5 議論はある？

著者：解像度の 4 分の 1 しか使わず、模様を付けた環境で飛行。静的シーン仮定のため動く物体の深度は過小評価。深度から yaw を決める制御は隅に引き寄せられる。

所感：予測誤差（ワープの整合）で表現を学ぶ点で、イベント版の自己教師世界モデルに最も近い実機例。行動条件付きの予測ではない。

6 次に読むべき論文は？

- CMax (2018)（本資料）
- Self-supervised learning of event-based optical flow with SNNs (Hagenaars+ 2021)（未調査）
- Monocular Event-Based Vision for Obstacle Avoidance with a Quadrotor (2024)（未調査）



出典：On-Device SSL Depth Fig. 1（CMax による自己教師の深度・自己運動学習と、機上オンライン学習による障害物回避）

書誌情報

発表： CVPR 2025
リンク： https://arxiv.org/abs/2412.06359
系譜： 最新（← CMax）
調査日： 2026-10-24
確認範囲： 全文（問題提起・手法・実験・結果・考察）

Approximate Imitation Learning for Event-based Quadrotor Flight in Cluttered Environments

Nico Messikommer, Jiaxu Xing, Leonard Bauersfeld ほか (University of Zurich) | CoRL 2026

1 どんなもの？

イベント RL・IL のボトルネックである「オンライン学習中のイベント描画」をなくす Approximate IL を提案。オフラインで課題特化の表現空間を学び、状態から同じ特徴を出す「近似学生」で DAgger 微調整する。方策学習時間を 52.44 h から 1.86 h へ 28 倍短縮した。

2 先行研究と比べてどこがすごい？

イベント方策の学習は高フレームレート映像からイベントを模擬する必要があり、DAgger や RL を何百万ステップも回せなかった。Bhattacharya+ 2024 は近似描画に頼った。本研究は表現学習と方策探索を分け、方策探索では状態だけで回すことで描画を完全に不要にした。

3 技術や手法のキモはどこ？

① 一度だけ描画したデータで、イベント学生のエンコーダ F_S と共有行動デコーダ A を教師行動の BC で学習。M3ED 実データで 1 次元距離マップの補助タスクも課す。②状態入力の近似学生を特徴 L1 +行動 MSE で F_S に合わせる。③近似学生で DAgger 、オフライン整合で A を微調整。

4 どうやって有効だと検証した？

Flightmare の森 (Poisson 0.04) で成功率：Approx IL 1.00 、BC 0.80 、オンライン描画の DAgger 0.30 、BC+DAgger 1.00 (Table 1)。M3ED なしは 0.30 (Table 3)。ベクトル化描画は ESIM 比でピーク GPU メモリ 4 分の 1 以下。実機は 5/5 成功、最高 9.8 m/s (VICON 状態使用)。

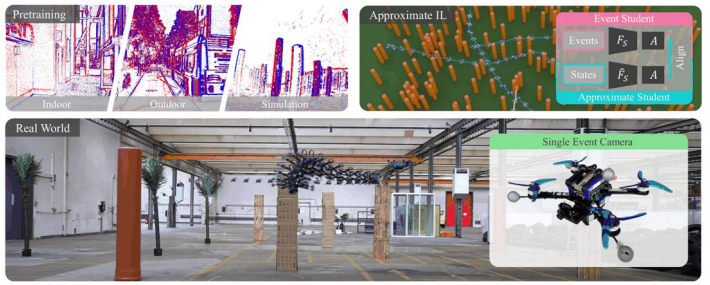
5 議論はある？

著者：高速で墜落すると高価なため、弱いベースラインは実機で比べられない。状態を使わない純視覚版 (成功率 0.5) は外部状態版に劣る。

所感：近似学生は「イベント表現の状態空間モデル」とも読める。ただし表現は BC 目的で固定され、予測 (ダイナミクス) は学ばない。評価は単一シード。

6 次に読むべき論文は？

- Monocular Event-Based Obstacle Avoidance (Bhattacharya+ 2024) (未調査)
- GEP (2026) (本資料)
- DAgger (2011) (未調査)



出典：Approximate IL Fig. 1 (実・模擬イベントでの事前学習、状態入力の近似学生による微調整、単一イベントカメラでの実飛行)

書誌情報

発表： CoRL 2026
リンク： https://arxiv.org/abs/2603.07578
系譜： 最新 (← eVAE / Bhattacharya+ 2024)
調査日： 2026-10-24
確認範囲： 全文 (問題提起・手法・実験・結果・考察)

Generative Event Pretraining with Foundation Model Alignment

Jianwen Cao, Jiaxu Xing, Nico Messikommer ほか (University of Zurich) | CVPR 2026 Findings

1 どんなもの？

イベントエンコーダを凍結 DINOv2 に整合させたうえで、イベントと画像のトークン列を因果 Transformer で自己回帰的に「次の時間片を予測」させる事前学習 GEP を提案。認識・セグメンテーション・深度の 10 指標すべてで従来のイベント事前学習を上回った。

2 先行研究と比べてどこがすごい？

従来のイベント事前学習は、MEM（マスク再構成）や ECDP/ECDDP（対照学習）など静的な画像流の手法の移植で、イベント特有の長期の時間構造を学ばなかった。GEP は VFM の意味を継承しつつ、生成的な系列予測で時間ダイナミクスを学ぶ点が新しい。

3 技術や手法のキモはどこ？

段階 1 :イベント枠を event 側で符号化し、凍結画像特徴との cosine + InfoNCE で整合し、画像入力での保存損失を加える。
段階 2 :整合済みのイベント・画像トークンを交互に並べ、窓 S_{s:s+w} から次の窓を予測する二乗誤差 L_pre で因果 Transformer を学習する。

4 どうやって有効だと検証した？

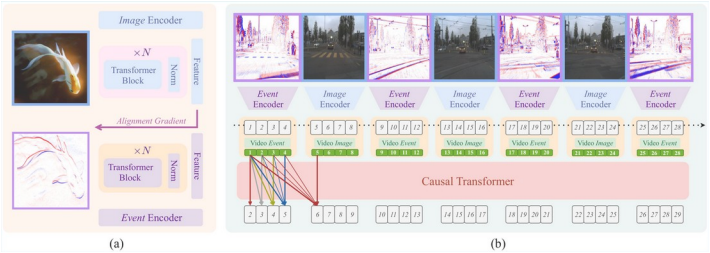
Event-1.8M で 24 エポック事前学習。N-Caltech101 top-1 93.05%（ECDP 87.66%）、DSEC セグメンテーション mIoU 65.22（ECDDP 56.38、Table 2）、MVSEC 深度 Abs 3.85（ECDDP 3.99、Table 3）。整合なしは mIoU 63.27→52.38、自己回帰は MAE 型を +0.94 上回る（Table 6）。

5 議論はある？

著者：限界の節はない。言語モデル型のトークン圧縮は密予測を損なうと指摘する。
所感：「次の潜在を予測する」点は JEPA/ 世界モデルに近い。しかし行動条件がなく、制御課題では未評価。性能の多くは DINOv2 整合由来で、自己回帰の寄与は約 1 mIoU と小さい。

6 次に読むべき論文は？

- Masked Event Modeling (Klenk+ 2024)（未調査）
- TESPEC (Mohammadi+ 2025)（未調査）
- V-JEPA 2 (2025)（既存：world-model/jepa ）



出典：GEP Fig. 2（(a) 凍結 VFM へのイベントエンコーダ整合 (b) イベント・画像トークン列の自己回帰事前学習）

書誌情報

発表： CVPR 2026 Findings
リンク： https://arxiv.org/abs/2603.23032
系譜：最新（← EST / MEM ）
調査日： 2026-10-24
確認範囲：全文（問題提起・手法・実験・結果・考察）

FLEET: Token-Based Feature Extraction for Event Camera-based Reinforcement Learning

Tristan Gottwald, Maximilian Schier, Melanie Schaller ほか（Leibniz University Hannover）| arXiv プレプリント 2026

1 どんなもの？

イベント列を格子に積まず、ランダムフーリエ特徴で埋め込んで Perceiver 型のクロスアテンションで固定数の潜在トークンへ圧縮する RL 用特徴抽出器 FLEET を提案。補助損失なしで報酬だけで学び、Event-CarEnv のレースで最良 CNN 系の約 3.6 倍の収益を得た。

2 先行研究と比べてどこがすごい？

格子化＋ CNN は時間をぼかし、計算量が解像度に比例する。eVAE のような再構成の事前学習は、制御に要らない見た目を符号化し、分布シフトにも弱い。FLEET は系列を直接扱い、課題に整合した表現を端から端まで学ぶことで、両方の欠点を避けた。

3 技術や手法のキモはどこ？

M 個のイベントを等間隔ビンから抽出。座標と時刻を RFF で埋め込み、時刻側のシグモイドゲートで空間埋め込みを変調する。N 個の学習可能クエリでクロスアテンションし、MLP と平均プーリングを経て PPO へ渡す。特徴抽出器は critic の価値損失だけで更新する。

4 どうやって有効だと検証した？

IQM、10 シード（Table 1）：レースで FLEET 46.96、DMRCNN 12.94、RGB NatureCNN 23.89、eVAE 1.13。倒立二重振子で 6390（他のイベント法は 1200 未満、RGB は 8981）。96×64→384×256 でもほぼ一定（Table 2）。Δt=0.025 s でも 41.92 を維持（Table 3）。

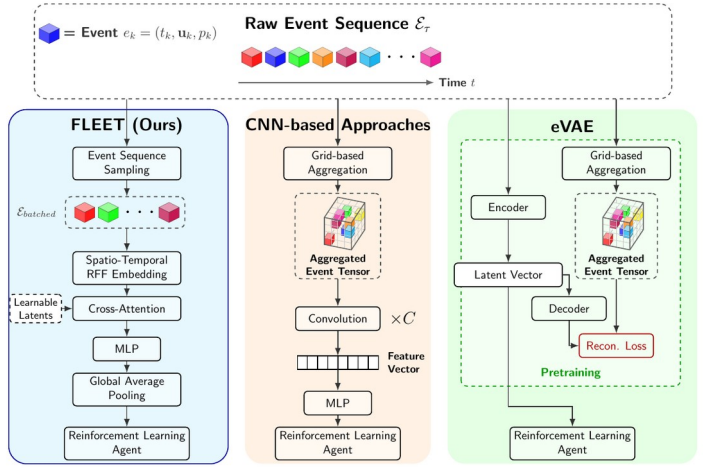
5 議論はある？

著者：今後はイベントの効率的な抽出が課題。実データは教師あり向けしかなく、sim-to-real と実機展開が次の段階。

所感：模擬環境・低解像度のみ。eVAE はランダム方策のデータで事前学習しており、比較は eVAE に不利。予測を学ばない表現なので、世界モデルへの拡張は未着手。

6 次に読むべき論文は？

- eVAE (2021)（本資料）
- Perceiver (Jaegle+ 2021)（未調査）
- Prediction over Reconstruction (2026)（既存：world-model/jepa）



出典：FLEET Fig. 1（FLEET の系列トークン化、格子＋ CNN 方式、再構成で事前学習する eVAE の比較）

書誌情報

発表： arXiv プレプリント 2026
リンク： https://arxiv.org/abs/2608.16523
系譜： 最新（← eVAE）
調査日： 2026-10-24
確認範囲： 全文（問題提起・手法・実験・結果・考察）

ECHO: Event-Augmented Context with Hindsight and Outlook for Wrist-Only Manipulation

Xinyue Wang, Yicheng Jiang, Zesen Gan ほか（The Hong Kong University of Science and Technology）| arXiv プレプリント 2026

1 どんなもの？

手首イベントカメラを、過去（軌跡メモリ）・現在（イベント潜在）・未来（行動区間のイベントを予測する foresight クエリ）にわたる方策モダリティとして π0 に組み込んだ「潜在世界行動モデル」ECHO を提案。手首のみの RLBench で成功率 69.3% を得た。

2 先行研究と比べてどこがすごい？

既存のイベント拡張 VLA（E-VLA、Event-VLA）は、イベントを RGB に融合するか残差で足すだけだった。ECHO はエンコーダ自体を「フレーム間の視覚特徴変化を説明する」潜在世界モデルとして事前学習し、さらに未来イベントの予測を方策の条件に入れた点が新しい。

3 技術や手法のキモはどこ？

事前学習：6 ビンの voxel を 64 トークンに符号化し、凍結 DINOv3 特徴 u_t を warp＋合成で u_{t+Δ} へ写す再構成と、時間反転との対照（MDC）で学ぶ。方策：prefix にイベント・軌跡セル・foresight を並べ、未来イベント潜在への MSE を行動損失に加える。

4 どうやって有効だと検証した？

RLBench 6 課題（各 25 試行）：ECHO 69.3%、π0+event 57.3%、π0 手首のみ 48.7%、前方＋手首 RGB 64.7%。−4 EV では 53.3%（同 42.0/38.7/37.3）。foresight は暗所で 42.7→53.3 に寄与（Table I）。実機 2 課題（各 20 試行）でも暗所 pick-place 80% 対 55%（Table II）。

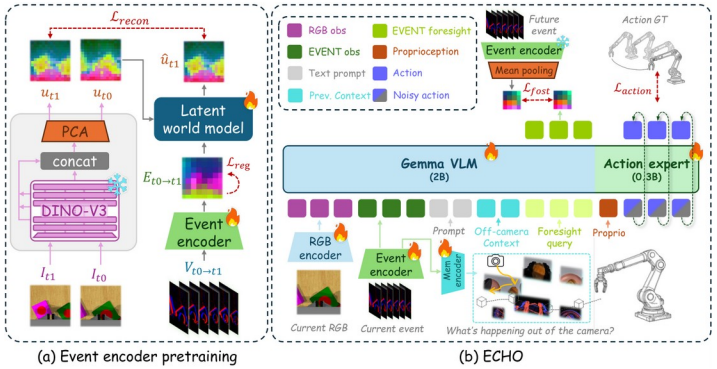
5 議論はある？

著者：限界の節はない。foresight は軌跡文脈がないと逆効果（54.0%）で、action expert 側に置くと 46.0% に落ちる。

所感：イベントの「変化のみ」を潜在行動とみなす設計は、世界モデルとの接続として示唆的。ただし試行数が少なく、シード数の記載もない。模擬イベントは ESIM。

6 次に読むべき論文は？

- GEP (2026)（本資料）
- FLEET (2026)（本資料）
- Event-VLA (2026)（未調査）



(a) Event encoder pretraining　(b) ECHO

出典：ECHO Fig. 2（(a)DINOv3 特徴の変化を説明する潜在世界モデルとしてのイベントエンコーダ事前学習 (b) 軌跡文脈と foresight を持つ方策）

書誌情報

発表： arXiv プレプリント 2026
リンク： https://arxiv.org/abs/2609.34893
系譜： 最新（← GEP / 潜在世界行動モデル）
調査日： 2026-10-24
確認範囲： 全文（問題提起・手法・実験・結果・考察）