SNN と量子化 ANN の公平なベンチマーク

SNN の利点を「同じタスク・同じビット幅・同じ HW 」で問い直す系譜。活性の変化だけを送る Sigma-Delta/Delta Networks（ 2017 ）と、T 時刻 SNN≒ 低ビット ANN とみる B-SNN（ 2020 ）が対抗馬を用意し、He（ 2020 ）・ Iyer（ 2021 ）がデータと学習条件の公平性を問うた。

2025 ～ 26 年は量子化 ANN の SNN 実装（ SDANN ）、時間依存を検査するベンチマーク（ NSA ）、スパイク対イベント駆動 ANN の同一 HW 比較、実機と理論での条件付き優位（ Loihi 2 、Sparsity Ceiling ）へ。

#	年	論文	発表	系譜
1	2017	Sigma-Delta (O'Connor+ 2017)	ICLR 2017	原典
2	2017	Delta Networks (Neil+ 2017)	ICML 2017	原典
3	2020	B-SNN (Lu & Sengupta 2020)	Frontiers in Neuroscience 2020	原典
4	2020	SNN vs RNN (He+ 2020)	Neural Networks 2020	原典
5	2021	N-MNIST 検証 (Iyer+ 2021)	Frontiers in Neuroscience 2021	発展
6	2023	EGRU (Subramoney+ 2023)	ICLR 2023	発展
7	2025	SDANN (Chen+ 2025)	arXiv プレプリント 2025	最新
8	2025	NSA (Chen+ 2025)	IJCAI 2025	最新
9	2026	Spiking/Event SpeechMamba (Ahmed+ 2026)	IJCNN 2026	最新
10	2026	SDNN 変換 on Loihi 2 (Brehove+ 2026)	ICONS 2026	最新
11	2026	Sparsity Ceiling (Wang 2026)	arXiv プレプリント 2026	最新

Sigma Delta Quantized Networks

Peter O'Connor, Max Welling（University of Amsterdam）| ICLR 2017

1 どんなもの？

各層が「活性の変化量」を量子化した整数スパイクだけを次層へ送る Sigma-Delta ネットワークを提案。学習済み ANN を変換でき、出力は丸めネットと一致したまま計算量が入力の変化量に比例する。動画 VGG19 で約 4 〜 11 倍の演算削減。

2 先行研究と比べてどこがすごい？

CNN は似たフレームでも毎回同じ計算を繰り返す。二値化（Courbariaux）や TrueNorth 向け SNN（Esser 2016）は低精度化で節約するが時間冗長性は使わない。本論文はスパイクを「量子化された差分」とみなし、ANN と SNN を同じ関数のまま橋渡しした。

3 技術や手法のキモはどこ？

線形層 w と時間差分 Δ ・積分 Σ が可換であることを使い、Σ∘w∘herd∘Δ の形で丸めネットと同じ出力を得る。herd（離散 Σ-Δ 変調）の出力なら内積は $|s|_1$ 回の加算で済む。層ごとのスケール k を「誤差＋ λ · 加算回数」で最適化する。

4 どうやって有効だと検証した？

Temporal-MNIST（784-200-200-10）では、同じ誤差で Σ-Δ ネットが丸めネットより少ない演算で済む（Fig. 4）。ILSVRC2015 動画上の VGG19 では、静的背景で約 11 倍・動きの多い動画で約 4 倍の計算削減、Top-5 はほぼ一致（Fig. 5）。

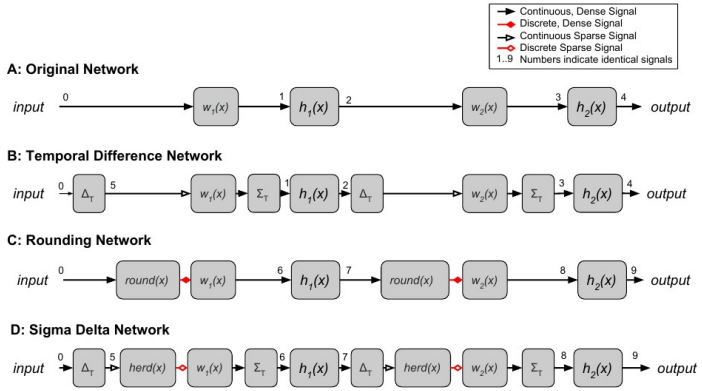
5 議論はある？

著者：利得はデータの時間冗長性次第。命令処理とメモリ移動は無視している。

所感：「SNN の利点＝活性の時間スパース性」を ANN 側に持ち込んだ原典。SNN の比較相手は密 ANN ではなく Σ-Δ 型 ANN であるべき、という論点の出発点。

6 次に読むべき論文は？

- Delta Networks (2017)（本資料）
- Shrestha+ Loihi 2 SDNN (2024)（参照のみ）
- SDNN 変換 on Loihi 2 (2026)（本資料）



出典：Sigma-Delta (O'Connor+ 2017) Fig. 1（元のネット・差分ネット・丸めネット・ Σ-Δ ネット。下 2 つは同一関数）

書誌情報

発表： ICLR 2017
リンク： https://arxiv.org/abs/1611.02024
系譜： 原典
調査日： 2026-10-24
確認範囲： 全文（問題提起・手法・実験・結果・考察）

Delta Networks for Optimized Recurrent Network Computation

Daniel Neil, Jun Haeng Lee, Tobi Delbruck, Shih-Chii Liu（ INI, University of Zurich & ETH Zurich ）| ICML 2017

1 どんなもの?

活性の変化が閾値 Θ を超えたときだけ値を送る RNN「 delta network 」を提案。GRU を差分形式に書き直し delta として学習すると、TIDIGITS で 8 〜 11.9 倍、WSJ 音声認識で 5.7 倍、運転映像の GRU で約 100 倍の演算・重み読出し削減。

2 先行研究と比べてどこがすごい?

低精度化・枝刈りはデータの時間的性質を使わない。RNN は毎時刻状態を読み書きし、重み読出しが支配的（ 45nm で DRAM 2nJ 対乗算 3pJ ）。同時期の Sigma-Delta（ O'Connor 2017 ）が CNN 変換を扱ったのに対し、RNN を delta として直接学習した。

3 技術や手法のキモはどこ?

r_t = W(x_t − x_{t−1}) + r_{t−1} で密な行列ベクトル積を「疎な Δ×W ＋加算」に置換し、占有率 o_c なら演算・読出しは約 1/o_c 。閾値の誤差蓄積は最後に送った値との差で防ぎ、丸め・ノイズ・Δ 上での学習・ L1(Δh) で疎性を高める。

4 どうやって有効だと検証した?

TIDIGITS（ GRU200 ）:そのまま delta 化で 95% ・ 2.2 倍、delta として学習で 98% ・ 8 倍、L1 込み 97% ・ 11.9 倍（ Fig. 4–5 ）。WSJ : WER 10.2→10.8% で 5.5 倍、学習で 5.7 倍（ Fig. 6 ）。comma.ai 操舵: GRU 部で約 100 倍（ Fig. 9 ）。

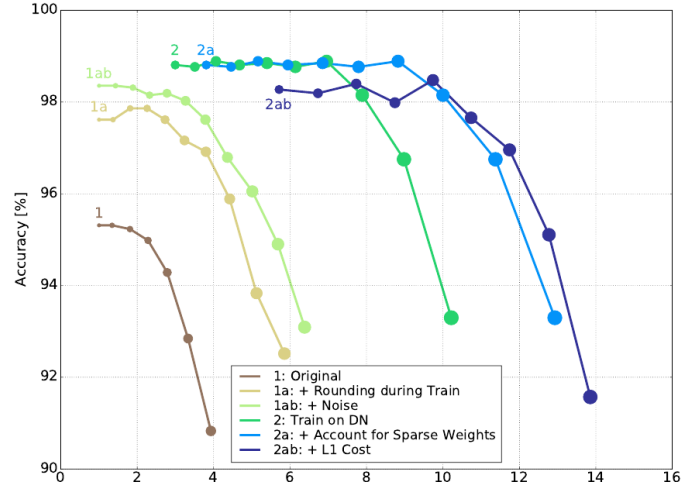
5 議論はある?

著者: CNN は活性数が重み数より多く状態保存で逆にメモリが増えるため RNN 向き。操舵系全体では CNN が支配し節約は 4.2% 。

所感:「活性スパース ANN 」の原典。倍率は演算数ベースで実 HW 計測はなく、後継の EdgeDRNN ・ DeltaKWS で実チップ化された。

6 次に読むべき論文は?

- EGRU (2023)（本資料）
- EdgeDRNN (2020)（未調査）
- DeltaKWS (2024)（未調査）
- Spiking/Event SpeechMamba (2026)（本資料）



出典: Delta Networks (Neil+ 2017) Fig. 5（ TIDIGITS での精度と速度向上倍率。delta として学習した系列 (2, 2a, 2ab) が右上）

書誌情報

発表: ICML 2017
リンク: https://arxiv.org/abs/1612.05571
系譜: 原典
調査日: 2026-10-24
確認範囲: 全文（問題提起・手法・実験・結果・考察）

Exploring the Connection Between Binary and Spiking Neural Networks

Sen Lu, Abhronil Sengupta（The Pennsylvania State University）| Frontiers in Neuroscience 2020

1 どんなもの？

重みを二値化した SNN（B-SNN）を ANN→SNN 変換で作り、BNN 用インメモリ加速器でそのまま動かせると提案。CIFAR-100 で XNOR-Net 47.16% に対し B-SNN 62.07%、ImageNet でも 62.71%（二値重み ANN 65.4%）に達した。

2 先行研究と比べてどこがすごい？

BNN（XNOR-Net）は活性の二値化で精度が大きく落ち、混合精度化は HW を複雑にする。SNN も出力は 0/1 で BNN と同じ HW 原理に乗るのに、両者の接続は未検討だった。本論文は「空間（ビット幅）でなく時間で情報を補う」選択肢として同じ土俵に置いた。

3 技術や手法のキモはどこ？

N 時刻動かした B-SNN は「重み 1bit・活性 $\log_2 N$ bit の離散化 ANN」とみなせる。ただし活性は 0/1 のスパイクなので計算はイベント駆動で、BNN の差動 2 行セルを 1 行に減らせる（Fig. 2）。減算リセット IF・99.7% 分位閾値・早期終了で遅延を削減。

4 どうやって有効だと検証した？

VGG-15、CIFAR-100：全精度 ANN 64.9%、XNOR-Net 47.16%（正規化演算 1）、B-SNN 62.07%（早期終了込み 3.55、平均 62.4 時刻）（Table I）。XNOR-Net と同精度なら 1.49。ImageNet：B-SNN 62.71%、正規化演算 5.09（Fig. 12）。

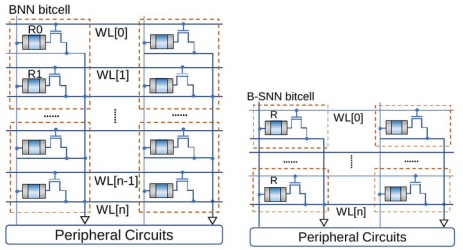
5 議論はある？

著者：計算を時間方向に分散するので瞬時電力は BNN 並み。静止画のみで評価。

所感：「T 時刻 SNN≒$\log_2 T$ ビット活性の QNN」を早期に示し、Bit Budget や Yan+ 2026 の双子比較の前史となった。比較は演算数のみで、膜電位保持やメモリ移動は未計上。

6 次に読むべき論文は？

- Bit Budget (Shen+ 2024)（既存：energy-evaluation）
- QNN-SNN twin (Yan+ 2026)（既存：energy-evaluation）
- SDANN (2025)（本資料）
- BNN×SNN (Datta+ ICLR 2024)（未調査）



(a) BNN RRAM array　(b) B-SNN RRAM array

Input	WL[0]	WL[1]
-1	1	0
+1	0	1

(c) BNN Input Encoding

Input	WL[0]
0	0
1	1

(d) B-SNN Input Encoding

Weight	R0	R1
-1	LRS	HRS
+1	HRS	LRS

(e) BNN Resistor State

Weight	R
-1	HRS
+1	LRS

(f) B-SNN Resistor State

出典：B-SNN (Lu & Sengupta 2020) Fig. 2（BNN と B-SNN の RRAM インメモリ演算アレイ。入力 0/1 なら 1 行 / セル）

書誌情報

発表： Frontiers in Neuroscience 2020
リンク： https://arxiv.org/abs/2002.10064
系譜： 原典
調査日： 2026-10-24
確認範囲： 全文（問題提起・手法・実験・結果・考察）

Comparing SNNs and RNNs on Neuromorphic Vision Datasets: Similarities and Differences

Weihua He, YuJie Wu, Lei Deng ほか（Tsinghua University / UC Santa Barbara）| Neural Networks 2020

1 どんなもの?

イベントカメラデータ上で SNN と RNN（vanilla RNN, LSTM）を、学習則・損失・構造・ハイパラを揃えて初めて系統比較。時間分解能が細かく疎なら SNN が精度で優位、粗ければ LSTM が同等以上、パラメータは LSTM の約 20% と示した。

2 先行研究と比べてどこがすごい?

SNN は神経形態データで評価されるのが通例だが、ML 側からは「RNN も時空間特徴を扱える」と反論できる。RNN の神経形態データでの評価はほぼなく、比較手順も未整備だった。本論文は「feedforward SNN 対 recurrent ANN」を同条件で比べる手順を示した。

3 技術や手法のキモはどこ?

LIF の反復形 $u^t = e^{-dt/\tau}u^{t-1}(1-o^{t-1}) + Wo^{t,n-1}$ を RNN と同じ時空間グラフで表し、膜電位経路が LSTM の忘却ゲートに当たると整理。BPTT・全時刻出力の損失・同一 MLP/CNN・共通ハイパラで揃え、時間分解能 dt を可変にした。

4 どうやって有効だと検証した?

DVS Gesture（CNN）: dt=1ms で SNN 71.5% 対 LSTM 64.6%、dt=25ms で 93.4% 対 92.4%（全時刻損失の LSTM は 93.8%）（Table VIII）。N-MNIST では差が小さい。dt=3ms で学習し 1ms で試験すると SNN −2.2pt、LSTM −20.9pt（Table XII）。

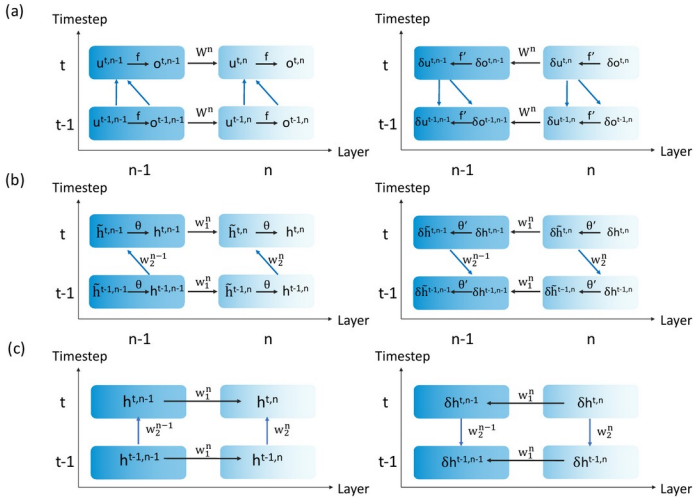
5 議論はある?

著者:細かい時間分解能の DVS 実撮影データなら SNN、粗いなら LSTM を推奨。

所感:損失を揃えるだけで RNN が追いつく点が重要。比較は演算数の次数（SNN は $O(\alpha MN)$ の加算）止まりで、量子化 RNN や活性スパース RNN との比較、エネルギー実測はない。

6 次に読むべき論文は?

- N-MNIST 検証（Iyer+ 2021）（本資料）
- EGRU (2023)（本資料）
- NSA (2025)（本資料）
- Deng+ 2020（本文未確認）



出典: SNN vs RNN (He+ 2020) Fig. 3（SNN・vanilla RNN・LSTM の順伝播と逆伝播の経路）

書誌情報

発表: Neural Networks 2020
リンク: https://arxiv.org/abs/2005.02183
系譜: 原典
調査日: 2026-10-24
確認範囲: 全文（問題提起・手法・実験・結果・考察）

Is Neuromorphic MNIST Neuromorphic? Analyzing the Discriminative Power of Neuromorphic Datasets in the Time Domain

Laxmi R. Iyer, Yansong Chua, Haizhou Li（Institute for Infocomm Research, A*STAR）| Frontiers in Neuroscience 2021

1 どんなもの？

N-MNIST と N-Caltech101 の事象を時間方向に足し合わせた静止画を通常の CNN に学習させるだけで、当時最高の 99.23%/78.01% を達成。教師なし STDP-SNN でもスパイク時刻ではなくレートが効くことを示し、N-MNIST は SNN の時間処理を測れないと結論した。

2 先行研究と比べてどこがすごい？

神経形態データは SNN 固有の利点（スパイク時刻符号）を ANN に対して示せるべきだが、静止画をサッカードで撮り直した N-MNIST 等にその性質があるかは未検証だった。HATS（99.1%）や SNN 各手法の結果が時間情報を使っているかも不明だった。

3 技術や手法のキモはどこ？

2 つの検査。①時間を潰したフレーム（画素ごとの正規化スパイク数）で ANN を学習。②教師なし STDP-SNN で前シナプストレースの時定数を変え、時刻依存（20ms）とレート依存（215ms）の動作領域を比較。後発火時刻の固定や PSTH 由来の STDP でも検証。

4 どうやって有効だと検証した？

時間圧縮フレーム+ CNN：N-MNIST 99.23%、N-Caltech101 78.01%（Table 1–2、HATS の 99.1/64.2 を上回る）。SNN：レート領域 89.87% 対時刻領域 76.25%、後発火時刻固定でも 84.10%、PSTH 由来 STDP 85.45%（Sec. 5–6）。

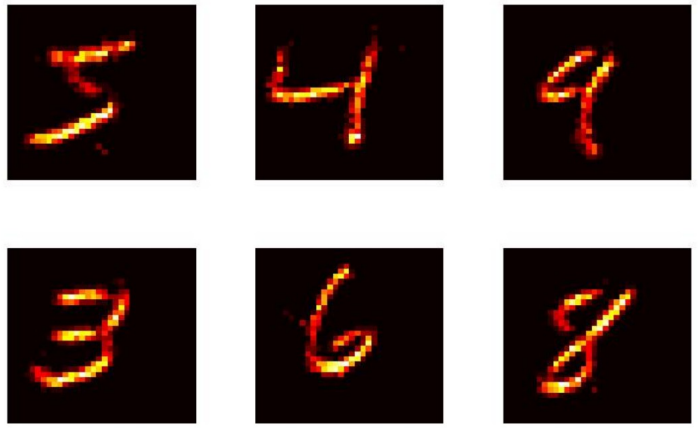
5 議論はある？

著者：静止画由来の変換データは時間に識別情報を持たない。良い神経形態データとは何かは未解決。

所感：「ANN ベースラインで解けるか」を先に確かめるという公平比較の基本手順を示した。SNN 側は教師なし STDP のみで、実撮影データでの同種検証は後続（NSA の STP）に委ねられた。

6 次に読むべき論文は？

- SNN vs RNN (He+ 2020)（本資料）
- NSA (2025)（本資料）
- SHD/SSC (Cramer+ 2020)（未調査）



出典：N-MNIST 検証（Iyer+ 2021）Fig. 2（事象を時間方向に集計した画像。これを CNN に学習させるだけで 99.23%）

書誌情報

発表： Frontiers in Neuroscience 2021
リンク： https://arxiv.org/abs/1807.01013
系譜： 発展（← SNN vs RNN (He+ 2020)）
調査日： 2026-10-24
確認範囲： 全文（問題提起・手法・実験・結果・考察）

Efficient recurrent architectures through activity sparsity and sparse back-propagation through time

Anand Subramoney, Khaleelulla Khan Nazeer, Mark Schöne ほか（Ruhr University Bochum / TU Dresden）| ICLR 2023

1 どんなもの?

GRU に閾値で離散イベントを出す機構を加えた EGRU を提案。ユニットは閾値を超えたときだけ実数値を送り、逆伝播も疎になる。PTB で GRU（66.3）より良いパープレキシティ 57.2 を、約 80% の活性スパース性・実効 MAC 約 1/2.8 で達成。

2 先行研究と比べてどこがすごい?

SNN は神経形態 HW に向くが、言語モデル等の実タスク性能で LSTM/GRU に劣る。Delta Networks（Neil 2017）など既存の活性スパース RNN は推論時だけ疎だった。EGRU は SNN の「イベント通信」を GRU に移植し、学習も疎にして性能を落とさない。

3 技術や手法のキモはどこ?

内部状態 c に対し $y_i = c_i \cdot H(c_i - \vartheta_i)$（閾値 ϑ は学習可能）とし、発火後は c をクリア。H の勾配は $\pm\varepsilon$ 内だけ非零の代理勾配で、閾値から遠いユニットは逆伝播を省く。連続時間極限で順・逆伝播の計算量がイベント数に比例することを adjoint 法で示した。

4 どうやって有効だと検証した?

DVS Gesture：GRU 1024 は 88.1%・実効 MAC 10.6M、EGRU 512 は 88.0%・0.98M（活性スパース性 83.8%）（Table 1）。sMNIST：98.8% 対 98.3% で実効 MAC は 1M 対 226K（Table 2）。PTB：EGRU 57.2、実効 MAC 9.9M 対 GRU 27.6M（Table 3）。

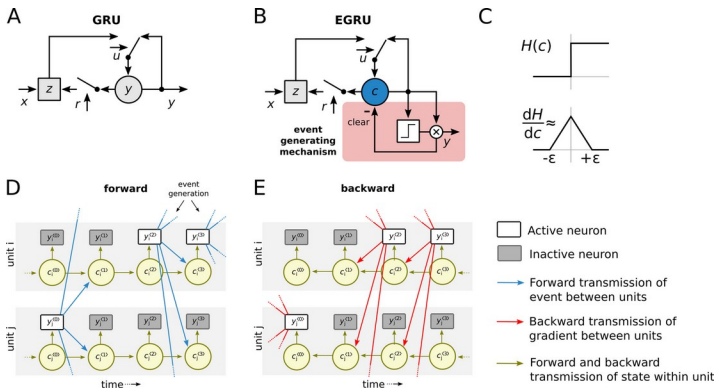
5 議論はある?

著者:オフチップメモリが要る大規模モデルでは重みスパース化との併用が必要。

所感:スパイクでなく実数イベントの ANN で SNN の利点を取り込み、性能でも上回った例。省エネは実効 MAC 数での主張で、実機評価は後続の SpiNNaker2 実装に委ねられた。

6 次に読むべき論文は?

- Delta Networks (2017)（本資料）
- Activity × weight sparsity (Mukherji+ 2023)（参照のみ）
- EGRU on SpiNNaker2 (Nazeer+ 2024)（未調査）
- Spiking/Event SpeechMamba (2026)（本資料）



出典：EGRU (Subramoney+ 2023) Fig. 1（GRU とイベント生成付き EGRU、代理勾配、疎な順・逆伝播）

書誌情報

発表: ICLR 2023
リンク: https://arxiv.org/abs/2206.06178
系譜: 発展（← Delta Networks (Neil+ 2017)）
調査日: 2026-10-24
確認範囲: 全文（問題提起・手法・実験・結果・考察）

Bridging Quantized Artificial Neural Networks and Neuromorphic Hardware

Zhenhui Chen, Haoran Xu, Yangfan Hu ほか（Zhejiang University）| arXiv プレプリント 2025

1 どんなもの？

INT8 量子化 ANN を学習し直さずに神経形態チップ上でスパイク実行する SDANN を提案。活性の各ビットを時刻に割り当てる符号で QANN と完全に同じ精度を保ち、Darwin3 実機で ImageNet 分類（53.6%）と VOC 検出（50.51 mAP）を動かした。

2 先行研究と比べてどこがすごい？

変換 SNN は多数の時刻を要し、直接学習 SNN は代理勾配で精度が落ち学習も重い。どちらも ANN との精度差が残る。SDANN は「SNN を作る」代わりに「QANN を神経形態 HW に写す」ことで、精度の下限を QANN に固定し比較の基準を揃える。

3 技術や手法のキモはどこ？

STEM ニューロン：K ビットの活性を K 時刻の 2 進スパイク列（位相符号）で受け、2^{K−t−1} 倍して加算→ ReLU→ 再び K 時刻の 2 進スパイク列で出力。16bit 制約に合わせバイアス較正と 2 段の縮小積算で桁あふれを防ぎ、低位ビットの間引き（RoT/DRLOs）で発火を削る。

4 どうやって有効だと検証した？

CIFAR10/ImageNet/VOC で INT8 QANN との精度差は 0（Table II）。8 時刻の直接学習 SNN より少ない SOP（Fig. 12）。45nm 単価推定で QANN より大幅に省エネ（Table IX）。Darwin3 実測：Tiny-VGG 22.31mJ 対 RTX 3080 375.69mJ、間引き併用で 20.95mJ（Table X）。

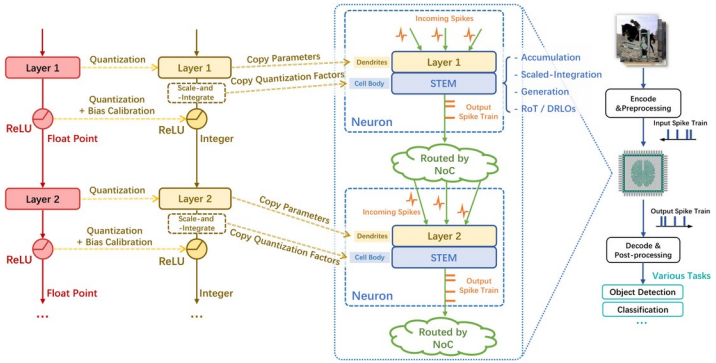
5 議論はある？

著者：間引きの実測削減は SOP 削減と同程度で、差はチップの回路制約による。

所感：SNN の実体が「ビット直列の QANN」になることを明示した。ただし省エネ推定は MAC 0.23pJ 対 AC 0.03pJ を用い、AC 回数が MAC 回数とほぼ同じでも有利と出る。GPU との比較も HW 差が大きい。

6 次に読むべき論文は？

- B-SNN (2020)（本資料）
- Bit Budget (Shen+ 2024)（既存：energy-evaluation）
- STEP (2025)（既存：energy-evaluation、参照のみ）
- Darwin3 (2024)（既存：neuromorphic-hardware）



出典：SDANN (Chen+ 2025) Fig. 3（浮動小数 ANN→ 量子化 ANN→STEM ニューロンへの写像と神経形態 HW での実行）

書誌情報

発表： arXiv プレプリント 2025
リンク： https://arxiv.org/abs/2505.12221
系譜： 最新（← B-SNN (Lu & Sengupta 2020)）
調査日： 2026-10-24
確認範囲： 全文（問題提起・手法・実験・結果・考察）

Neuromorphic Sequential Arena: A Benchmark for Neuromorphic Temporal Processing

Xinyi Chen, Chenxiang Ma, Yujie Wu, Kay Chen Tan, Jibin Wu（The Hong Kong Polytechnic University）| IJCAI 2025

1 どんなもの?

自己位置推定・行動認識・EEG・音源定位・読唇・音声強調・音声認識の 7 タスクからなる SNN 用ベンチマーク NSA を提案。タスクが本当に時間依存を要するかを測る Segregated Temporal Probe（STP）を導入し、10 種のニューロン / 構造を精度・速度・メモリ・エネルギーで比べた。

2 先行研究と比べてどこがすごい?

既存の SNN ベンチマーク（MNIST 系、DVS 変換データ、SHD/GSC）は飽和し、短い時間依存だけで解ける。Iyer（2021）の指摘どおり時間処理能力を測れず、研究間の比較条件や効率指標もばらばら。NSA は時間が要るかを検査してからタスクを採用する。

3 技術や手法のキモはどこ?

STP：同じ SNN を STBP（時間方向の順・逆伝播あり）、SDBP（逆伝播の時間経路を切る）、NoTD（時間経路なし）で学習し、性能差でタスクの時間依存性を定量化。比較ではパラメータ数を揃え、Spiking TCN 等の反復回数を D=1 に統一した。

4 どうやって有効だと検証した?

NSA 全タスクで STBP から SDBP/NoTD へ大きく劣化（例：読唇 17.83→2.47/2.01%、行動認識 81.27→76.29/67.75%、Table 2）。既存 12 データセットでは STBP≈SDBP。PMSN が平均順位 1.9 で最良（Table 3）。LTC は LIF の 268 倍のエネルギー（Table 5）。

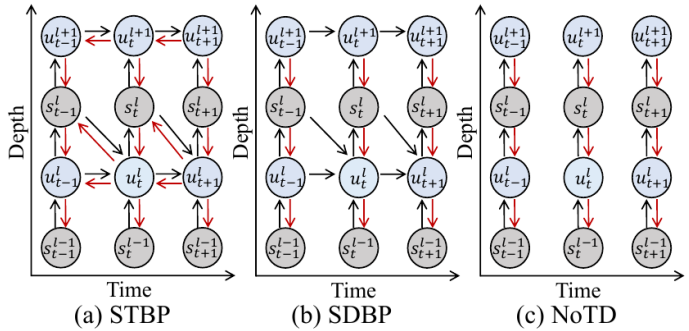
5 議論はある?

著者：高性能な新型ニューロンほどエネルギーとメモリが増え、効率を保つ設計が急務。

所感：時間依存の検査は公平なベンチマーク設計として有用。ただし比較は SNN 同士のみで、同条件の LSTM・量子化 SSM・delta ANN がなく「SNN を使う意味」は測れない。エネルギーも単価推定。

6 次に読むべき論文は?

- N-MNIST 検証（Iyer+ 2021）（本資料）
- PMSN (2024)（既存：parallel-training）
- NeuroBench (2025)（既存：neuromorphic-hardware）



出典：NSA (Chen+ 2025) Fig. 1（STP の 3 つの学習法。STBP・SDBP・NoTD の性能差で時間依存性を測る）

書誌情報

発表: IJCAI 2025
リンク: https://arxiv.org/abs/2505.22035
系譜: 最新（← N-MNIST 検証（Iyer+ 2021））
調査日: 2026-10-24
確認範囲: 全文（問題提起・手法・実験・結果・考察）

Spiking and Event-driven Neuromorphic Mamba Models for Efficient Speech Recognition

Tauseef Ahmed, Tao Sun, Jeronimo Castrillon ほか (Maastricht University / imec) | IJCNN 2026

1 どんなもの?

音声認識モデル SpeechMamba を、① FATReLU で活性を疎にしたイベント駆動版 (E-) と② LIF の二値スパイク版 (S-) に神経形態化し、同じ RISC-V サイクル精度シミュレータで比較。スパース性が高いスパイク版の方が、サイクルとメモリアクセスの削減は小さかった。

2 先行研究と比べてどこがすごい?

音声の神経形態研究は SynOps や理論エネルギーで効率を示すことが多く、不規則なスパース性やデータ移動の実コストを捉えない。Loihi 等の実機はニューロンモデルの制約が強い。本論文は SNN と活性スパース ANN を同じモデル・同じ HW 模型で比べる。

3 技術や手法のキモはどこ?

E- 版: ReLU 挿入→閾値 T を下位分位から掃引して初期化→疎性損失 $\Sigma(\mathrm{FATReLU}(x)+1/T)^2$ で微調整。S- 版: SpikMamba と Spikformer の SSA を使い、発火率に上下限の正則化。シミュレータは原子イベント単位の部分和でデータフローを実行し、サイクルやメモリアクセスを数える。

4 どうやって有効だと検証した?

LibriSpeech test-clean WER : 元 2.32% 、E 3.20% (スパース性 62%)、S 4.71% (72% 、IML-Spikeformer より 30% 少ないパラメータ) (Table I)。基準比のサイクル削減は E 32.3% ・S 19.6% 、メモリアクセス削減は E 17.6% ・S 7.6% 、最適化 E で 46.1%/28.5% (Table II)。

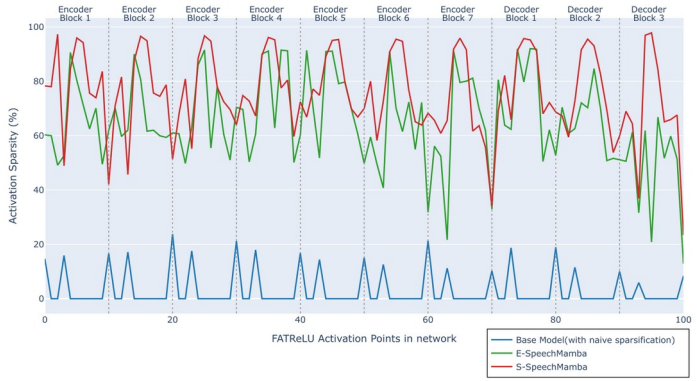
5 議論はある?

著者: LIF の膜電位の読み書きが隠れたコストで、メモリ帯域が制約ならイベント駆動 ANN が有利。

所感: 同一モデル・同一 HW 模型で「スパイク対活性スパース ANN 」を比べた貴重な例。ただし模型は単一 Ibex コアでエネルギーは未報告、ビット幅も FP32 のままで量子化 ANN とは比べていない。

6 次に読むべき論文は?

・SENECA ANN vs SNN (Xu+ 2025) (既存: energy-evaluation)
・EGRU (2023) (本資料)
・Sparsity Ceiling (2026) (本資料)



出典: Spiking/Event SpeechMamba (Ahmed+ 2026) Fig. 3 (活性化点ごとのスパース性。スパイク版 (赤) はイベント版 (緑) より疎)

書誌情報

発表: IJCNN 2026
リンク: https://arxiv.org/abs/2606.01135
系譜: 最新 (← EGRU (Subramoney+ 2023))
調査日: 2026-10-24
確認範囲: 全文 (問題提起・手法・実験・結果・考察)

Sigma-Delta Neural Network Conversion on Loihi 2

Matthew Brehove, Sadia Anjum Tumpa, Espoir Kyubwa ほか（ChromoLogic / Penn State）| ICONS 2026

1 どんなもの？

PyTorch で学習・INT8 量子化した通常の ANN を、Loihi 2 の Σ-Δ ニューロン（整数のグレーデッドスパイク）に変換する手法を提案し、Jetson と同一ネットで比較。PilotNet では 16 倍超の省エネだったが、検出モデル YOLO-KP では 1.2 倍程度にとどまった。

2 先行研究と比べてどこがすごい？

Shrestha+（2024）は Loihi 2 の SDNN を Jetson と比べ大きな利得を示したが、学習は SLAYER（時系列全体を保持し遅い）頼みだった。本論文は標準の量子化ツールと互換にし、学習法の差を除いて「同じ量子化 ANN を 2 つの HW で走らせる」比較に近づけた。

3 技術や手法のキモはどこ？

Σ-Δ ニューロンは Δx·w_q を累積して ReLU とスケーリング（固定小数の乗算＋右シフトのマイクロコード）を施し、前回送信値との差が閾値を超えたときだけ差分をスパイクで送る。閾値 0 で QANN と厳密一致し、閾値を上げると疎になる代わりに精度が下がる。

4 どうやって有効だと検証した？

閾値 0：YOLO-KP（5 チップ）11.73mJ/3.20ms 対 Jetson Xavier 14.10mJ/3.11ms、I/O なしでは逆に 19.89mJ。PilotNet 1.31mJ 対 Jetson 21.94mJ（Table 3）。SynOps は MAC の 0.056 倍でも Loihi の電力は静的電力が支配（Fig. 2）。

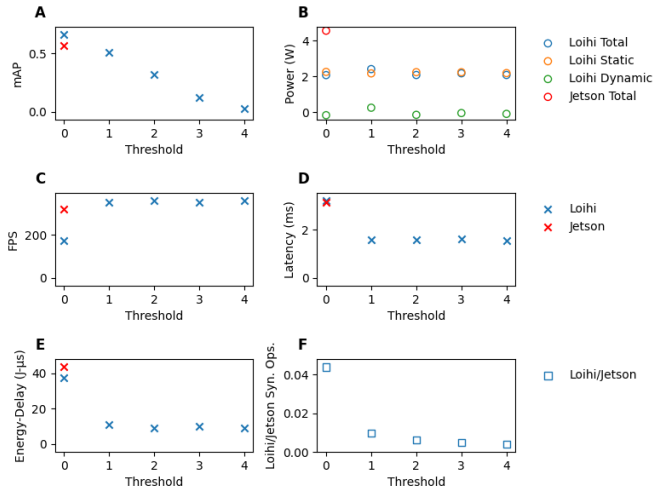
5 議論はある？

著者：Loihi はチップ単体、Jetson は SoC 全体の電力で同一条件ではない。オンチップ SRAM の静的電力はチップ数に比例する。

所感：演算 18 倍減が実エネルギーで 1.2 倍に縮む好例。利得は入力の時間冗長性と静的電力で決まる。精度も FP16 対 INT8 で揃っていない。

6 次に読むべき論文は？

- Sigma-Delta (2017)（本資料）
- Shrestha+ Loihi 2 SDNN (2024)（参照のみ）
- Loihi 2 vs Jetson 検出 (Gamage+ 2026)（既存：energy-evaluation）



出典：SDNN 変換（Brehove+ 2026) Fig. 2（YOLO-KP の閾値別 mAP・電力・FPS・遅延・EDP・演算比）

書誌情報

発表： ICONS 2026
リンク： https://arxiv.org/abs/2505.06417
系譜： 最新（← Sigma-Delta (O'Connor+ 2017)）
調査日： 2026-10-24
確認範囲： 全文（問題提起・手法・実験・結果・考察）

The Sparsity Ceiling: Where Spiking Networks Can and Cannot Trade Activity for Energy

Zeyu Wang（Georgia Institute of Technology）| arXiv プレプリント 2026

1 どんなもの?

構造を固定し隠れユニットだけを連続値と LIF で入れ替える比較と、目標発火率を両側から課すプローブで「どこまで発火を下げられるか」を測定。順伝播 CNN は 5% まで下がるが再帰言語モデルは約 50% で止まる「スパース性の天井」を示し、情報理論的な下界を与えた。

2 先行研究と比べてどこがすごい?

従来研究は単一タスクで精度を最適化し、結果として出た発火率で省エネを推定するだけで、達成可能なスパース性という因果変数を分離していなかった。「発火が少なければ SNN が勝つ」という条件に対し、その発火率自体がタスク構造で決まることを示す。

3 技術や手法のキモはどこ?

H 個のユニットが二値スパイクだけで状態を伝えるとき、M 通りの記憶内容を区別するには $H \cdot H_b(\rho) \geq \log_2 M$、すなわち $\rho \geq H_b^{-1}(\log_2 M / H)$。記憶負荷 $M=S^N$ は系列長に対し指数的に増えるため、再帰モデルでは発火率の下限が上がる。

4 どうやって有効だと検証した?

FashionMNIST：ANN 88.1% 対 SNN 74.7%、5% 目標で 76.6%。演算は ANN 比 0.99 倍（密な入力層の反復が 61%）で、45nm 推定の省エネ 5.05 倍は AC<MAC の単価差由来。WikiText-103 文字 LM：発火 0.63→0.50 止まり、bpc 2.62 対 3.45。Spiking Transformer は 2% まで下がる（Fig. 6）。

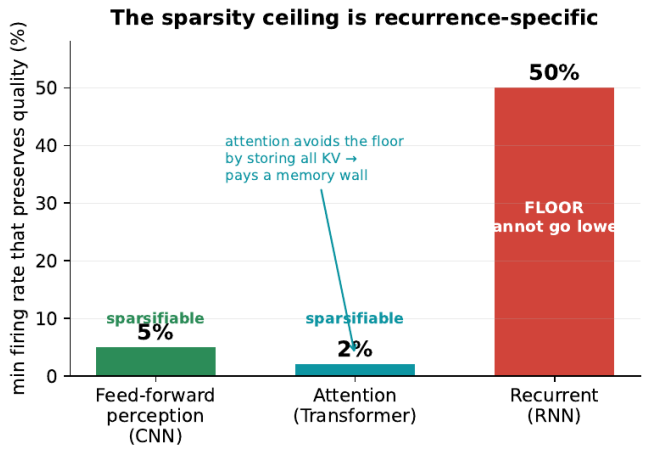
5 議論はある?

著者:知覚はレート符号の代用で、Transformer は小規模、エネルギーは 45nm 推定のみ。

所感:同一構造の比較と下界で「SNN の利得は課題依存」を定式化した点は有用。ただし単著 5 頁の予備的研究で、SNN の精度低下（88→77%）を揃えた等精度比較になっていない。

6 次に読むべき論文は?

- 表現力で正規化した比較（Kranzlmüller+ 2026）（参照のみ）
- Davidson & Furber (2021)（既存: energy-evaluation）
- Time to Spike? (Nguyen+ 2025)（未調査）



出典: Sparsity Ceiling (Wang 2026) Fig. 6（品質を保てる最小発火率。順伝播 5%、Attention 2%、再帰 RNN は 50%）

書誌情報

発表: arXiv プレプリント 2026
リンク: https://arxiv.org/abs/2607.26648
系譜: 最新（← SNN vs RNN (He+ 2020)）
調査日: 2026-10-24
確認範囲: 全文（問題提起・手法・実験・結果・考察）