学会調査 | 先行研究調査( 2026-10-27 )

# GECCO :受賞・注目論文

ACM SIGEVO 主催の進化計算の主要国際会議。フルペーパー採択率は 35 ～ 37% 。Best Paper はトラックごとに 2 ～ 3 本の候補から参加者投票で決まる。
2024 ～ 2026 年は QD と強化学習の融合、学習による最適化器の選択、ベンチマークの見直し、交叉の理論が受賞。2026 年は実応用(全脳モデル)と記号回帰も受賞した。

| # | 年 | 論文 | 発表 | 区分 |
|---|---|---|---|---|
| 1 | 2026 | HICO (Shahrzad+ 2026) | GECCO 2026 | 受賞 |
| 2 | 2026 | QDHUAC (Koohy & Bayne 2026) | GECCO 2026 | 受賞 |
| 3 | 2026 | LH-CC (Qiu+ 2026) | GECCO 2026 | 受賞 |
| 4 | 2026 | GP-GOMEA linkage (Koch+ 2026) | GECCO 2026 | 受賞 |
| 5 | 2026 | 3C-EA (Shahabi Sani+ 2026) | GECCO 2026 | 受賞 |
| 6 | 2026 | Pareto-preserving transforms (Vermetten & Rook 2026) | GECCO 2026 | 受賞 |
| 7 | 2026 | Furthest-parent ($\mu$+1) GA (Opris & Antipov 2026) | GECCO 2026 | 受賞 |
| 8 | 2026 | AutoNumerics-Zero (Real+ 2026) | ICML 2026 | 受賞 |
| 9 | 2025 | Extract-QD / EME (Flageat+ 2025) | GECCO 2025 | 受賞 |
| 10 | 2025 | NE vs RL in transfer (Nisioti+ 2025) | GECCO 2025 | 受賞 |
| 11 | 2024 | JEDi (Templier+ 2024) | GECCO 2024 | 受賞 |

# Evolution With Purpose: Hierarchy-Informed Optimization of Whole-Brain Models

Hormoz Shahrzad, Niharika Gajawelli, Kaitlin Maile ほか（UT Austin / Cognizant AI Lab）| GECCO 2026

## 1 どんなもの？

全脳の Dynamic Mean Field（DMF）モデルの 140 個のパラメータを GA で fMRI データに合わせる。その際、皮質の階層（感覚運動野から連合野へ）の順にパラメータを解放するカリキュラム HICO を提案した実応用論文。

## 2 先行研究と比べてどこがすごい？

従来の進化的フィッティングは個人のデータには良く当てはまるが過学習し、他の被験者への汎化や行動の予測には使えなかった。HICO は同じ計算量で、汎化と行動予測の両方を成立させた。

## 3 技術や手法のキモはどこ？

7 つの安静時ネットワーク（RSN）ごとに 20 個のパラメータを持たせる。まず全脳共通の値を決め、次に Margulies らの主勾配に沿って 5 段階で RSN ごとのブロックだけを動かす。決めたブロックは固定し、世代数は段階ごとに等分する。

## 4 どうやって有効だと検証した？

HCP の 100 人、皮質 400 領域。当てはまりは異質モデル・HICO ・逆順が均質モデルより有意に高い（p≈1e-23 ～ 1e-25）。被験者間の LOO では均質・異質が 0 に崩れ、カリキュラム系は約 0.3（Fig. 3）。行動の予測は HICO だけが有意（Fig. 5, 6）。

## 5 議論はある？

著者：生物学の知識に基づく探索順序は、進化計算の強い帰納バイアスになる。

所感：GA 自体は素朴で、効いているのは時間方向の分解。逆順でも汎化はするので、「階層順」の寄与が見えるのは行動予測だけである点に注意。

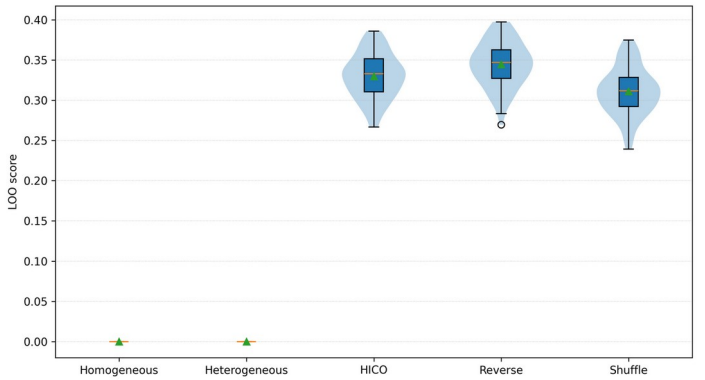
## 6 次に読むべき論文は？

Margulies+ 2016 皮質の主勾配 (PNAS)

Shahrzad & Miikkulainen 2023 Gene Masking (GECCO)

Potter & De Jong 2000 協調共進化 (ECJ)

Deco+ 2009 DMF モデル (PNAS)




出典：HICO (Shahrzad+ 2026) Fig. 3（被験者間 LOO の適応度）

## 書誌情報

**発表：** GECCO 2026

**リンク：** https://arxiv.org/abs/2602.11398

**受賞：** GECCO 2026 Best Paper Award（RWA トラック）

**調査日：** 2026-10-27

**確認範囲：** 全文（問題提起・手法・実験・結果・考察）

# Evolution With Purpose: Hierarchy-Informed Optimization of Whole-Brain Models

Hormoz Shahrzad, Niharika Gajawelli, Kaitlin Maile ほか ( UT Austin / Cognizant AI Lab ) | GECCO 2026

## 詳細

問題設定:全脳 DMF モデルは領域間の構造結合と局所の興奮・抑制ダイナミクスから機能結合 ( FC ) を再現する。パラメータを領域ごとに変えると当てはまりは上がるが、解が個人に過学習し、平均した解は力学的に不安定になる。

手法: elitist GA (集団 100 、エリート 20 、120 世代) で、シミュレーションした FC と実測 FC の相関を最大化する。HICO は全脳共通の段階の後、デフォルトモード・辺縁系、前頭頭頂、注意、視覚、体性運動の順に RSN ごとのパラメータを解放する。比較として逆順とランダム順を用意した。

結果:被験者ごとの当てはまりはランダム順以外のカリキュラムで改善した。平均パラメータで別の被験者を評価する LOO では、カリキュラム無しは 0 に崩れた。流動性知能などの行動指標を ridge 回帰で予測すると、置換検定 ( 1 万回) で有意なのは HICO だけだった。

限界:対象は 100 人で、$R^2$ の大きさは図でしか示されていない。

## 受賞・注目

GECCO 2026 Best Paper Award ( RWA トラック)

## 評価ポイント

・計算神経科学の未解決課題 (汎化と行動予測) に進化計算で答えた (調査者の見立て)

・領域知識を「探索の順序」として入れる、簡単で他にも使える工夫 (調査者の見立て)

・ LOO と置換検定による、実応用として厳しめの評価 (調査者の見立て)

・ Miikkulainen 研と Stanford の脳科学者による分野横断の共同研究 (調査者の見立て)

# Distributional Value Estimation Without Target Networks for Robust Quality-Diversity

Behrad Koohy, Jamie Bayne（Luffy.AI）| GECCO 2026

## 1 どんなもの？

QD と強化学習を組み合わせた QD-RL で、1 ステップあたりの更新回数（UTD 比）を高くして学習できるようにした手法 QDHUAC 。ターゲットネットワークを使わない分布型（C51）critic と Dominated Novelty Search を組み合わせる。

## 2 先行研究と比べてどこがすごい？

PGA-ME や QD-PG は、Polyak 平均で更新するターゲットネットに頼るため UTD≈1 に留まっていた。QD では方策の前線が急に広がるので、この遅れが価値の過小評価を生むと指摘し、ターゲット無しで安定させた。

## 3 技術や手法のキモはどこ？

critic は重み正規化（勾配の大きさを抑える）とバッチ正規化（アーカイブ由来の分布の変化に対応）を重ねた残差ブロックで、損失は分布型の交差エントロピー。方策は SAC 型のエントロピー正則化、リプレイは優先度付き。

## 4 どうやって有効だと検証した？

Brax の 5 タスク・200 万ステップで PGA-ME, QD-PG と比較（Fig. 2）。HalfCheetah の最大適応度は約 8000（基準は 3500）、Humanoid は約 4000 。正規化なしは UTD を上げると最大で約 30% 低下（Fig. 4）。BN だけでは 200 万ステップ後に劣化（Fig. 5）。

## 5 議論はある？

著者：ターゲットへの追従の遅れ（Target Tracking Lag）が QD-RL の主なボトルネック。

所感：Ant と HalfCheetah ではカバレッジが PGA-ME より低く、最大適応度を重視する性格が強い。seed は 5 個で、統計検定の記述は少ない。

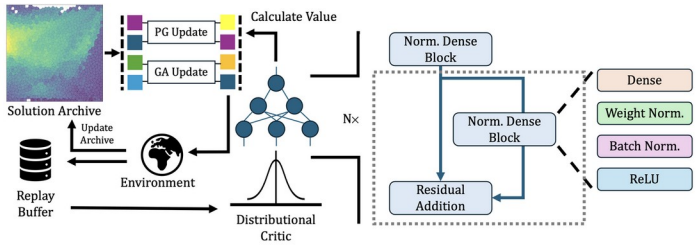
## 6 次に読むべき論文は？

Bhatt+ 2024 CrossQ (ICLR)

Bahlous-Boldi+ 2025 Dominated Novelty Search (GECCO)

Nilsson & Cully 2021 PGA-MAP-Elites (GECCO)

Bellemare+ 2017 C51 分布型強化学習 (ICML)




出典：QDHUAC (Koohy & Bayne 2026) Fig. 1（最適化ループと critic の構造）

## 書誌情報

**発表：** GECCO 2026

**リンク：** https://arxiv.org/abs/2604.20381

**受賞：** GECCO 2026 Best Paper Award（EML トラック）

**調査日：** 2026-10-27

**確認範囲：** 全文（問題提起・手法・実験・結果・考察）

# Distributional Value Estimation Without Target Networks for Robust Quality-Diversity

Behrad Koohy, Jamie Bayne ( Luffy.AI ) | GECCO 2026

## 詳細

問題設定: QD は多様な技能を見つけられるが、移動タスクを解くのに数千万ステップの環境操作が必要になる。強化学習では UTD 比を上げてサンプル効率を高める手法があるが、QD-RL にそのまま入れると価値の推定が発散したり、効果が出なかったりしていた。

手法:アーカイブが生む多様な遷移では価値の分布が多峰になるため、C51 の分布型 critic ( 101 個の原子)を使う。CrossQ と同様に現在の状態と次の状態を同じバッチで正規化し、ターゲットネットを廃止した。集団は格子を使わない DNS で管理し、遺伝的変異、勾配による変異、学習した方策の注入を混ぜる。

結果:多くのタスクで、基準より少ないステップで高い QD スコアと最大適応度に達した。影として持たせたターゲットネットは改善中の方策を過小評価し、偽陰性が多いことを示した( Fig. 3 )。

限界:カバレッジは落ちることがあり、計算コストの比較もない。

## 受賞・注目

GECCO 2026 Best Paper Award ( EML トラック)

## 評価ポイント

・QD-RL のサンプル効率を桁で改善し、実用に近づけた(調査者の見立て)

・ターゲットネットの遅れを測るという、仮説を確かめる分析(調査者の見立て)

・RL の新しい知見( CrossQ 、分布型 RL )を QD に正しく移した(調査者の見立て)

・アブレーションで WN と BN の両方が必要なことを示した(調査者の見立て)

# A Learning-Based Cooperative Coevolution Framework for Heterogeneous Large-Scale Global Optimization

Wenjie Qiu, Zixin Wang, Hongyu Fang, Zeyuan Ma, Yue-Jiao Gong（South China University of Technology）| GECCO 2026

## 1 どんなもの？

部分問題ごとに関数の形も次元（25 ～ 1000）も違う大規模最適化（H-LSGO）を扱う。協調共進化で、各部分問題に使う最適化器を強化学習のエージェントが選ぶ LH-CC と、問題の自動生成器 Auto-H-LSGO を提案した。

## 2 先行研究と比べてどこがすごい？

従来の協調共進化は、分解した後に単一の低次元向け最適化器（CMA-ES など）を使う前提で、H-LSGO では性能も時間も大きく悪化した。MetaBBO の考え方で、最適化器の動的な選択を協調共進化に初めて持ち込んだ。

## 3 技術や手法のキモはどこ？

状態は問題の特徴（次元・分離性・重なり）、集団の特徴、進み具合。行動は高次元用（SEP-CMA-ES など）と低次元用（CMA-ES など）から選び、大きい部分問題では低次元用を禁止する。PPO で学習し、途中で切り替えても続きから探索できるよう状態を保存する。

## 4 どうやって有効だと検証した？

3000 次元・14 部分空間の 14 問題、300 万評価で OEDG-CMAES に 14 勝 0 敗、MMES にも 14 勝（Table 2）。実行時間は約 1000 秒で、OEDG-CMAES（1.3 ～ 1.5 万秒）の約 1/13（Table 3）。学習は 100 万評価・4 関数だけで、未知の問題にも汎化した。

## 5 議論はある？

著者：H-LSGO では、最適化器を動的に切り替えることが鍵になる。

所感：ベンチマークも著者らが作ったもので、実問題（衛星設計など）での検証はまだない。分解は OEDG の結果を事前に計算して使っている。

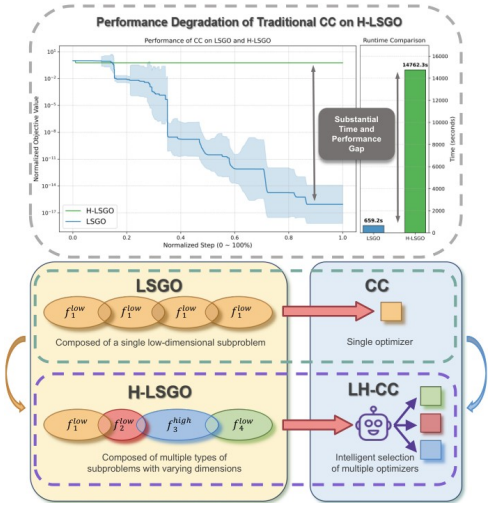
## 6 次に読むべき論文は？

Omidvar+ 2017 DG2 (TEVC)

Tian+ 2024 OEDG (TEVC)

Ma+ 2025 MetaBBO のサーベイ (TEVC)

Xu+ 2023 異質モジュールの大規模ベンチマーク (SWEVO)




出典：LH-CC (Qiu+ 2026) Fig. 1（従来の協調共進化と LH-CC）

## 書誌情報

**発表：** GECCO 2026

**リンク：** https://arxiv.org/abs/2604.01241

**受賞：** GECCO 2026 Best Paper Award（L4EC トラック）

**調査日：** 2026-10-27

**確認範囲：** 全文（問題提起・手法・実験・結果・考察）

# A Learning-Based Cooperative Coevolution Framework for Heterogeneous Large-Scale Global Optimization

Wenjie Qiu, Zixin Wang, Hongyu Fang, Zeyuan Ma, Yue-Jiao Gong（South China University of Technology）| GECCO 2026

## 詳細

問題設定：CEC2013LSGO 以来の大規模最適化は、同じ種類の低次元部分問題の和が前提だった。実問題では、関数の形も次元も違う部分問題が組み合わさる。このとき分解はうまくいっても、単一の最適化器では性能が落ち、時間も大きく増える。

手法：最適化の過程をマルコフ決定過程とし、部分問題ごとの各ステップで最適化器を選ぶメタエージェントを PPO で学習する。報酬は全体の最良値の対数の改善量を正規化したもの。最適化器ごとの内部状態は文脈辞書に保存する。7 種の基本関数・回転・重なりから問題を組み立てる Auto-H-LSGO で学習データを作る。

結果：14 問題すべてで既存の協調共進化と非分解型の手法を上回り、時間も短い。DE と PSO 系の最適化器に入れ替えた LH-CC-G でも優位を保った。ランダム選択や固定選択より良いことを確かめた（Fig. 5）。

限界：分解法は固定で、資源配分は均等。

## 受賞・注目

GECCO 2026 Best Paper Award（L4EC トラック）

## 評価ポイント

・学習による最適化（L4EC）を大規模最適化という難所に適用した（調査者の見立て）

・問題の自動生成器まで含め、分野の土台を作った（調査者の見立て）

・精度と時間の両方で桁違いの差を示した（調査者の見立て）

・最適化器を入れ替えても使える汎用性を示した（調査者の見立て）

# Introns and Templates Matter: Rethinking Linkage in GP-GOMEA

Johannes Koch, Tanja Alderliesten, Peter A.N. Bosman（CWI / TU Delft）| GECCO 2026

## 1 どんなもの？

記号回帰の代表的な手法 GP-GOMEA の、変数間の依存（リンケージ）の学習を見直した。効かないノード（イントロン）を考慮した相互情報量 MI_masked と、テンプレート木の距離だけで決める Node 類似度を提案。

## 2 先行研究と比べてどこがすごい？

固定テンプレートでは、小さい式の余ったノードがイントロンになる。選択圧を受けないその値が相互情報量の推定を乱していた。既存の指標はランダムなリンケージに勝てない設定もあったが、提案は全設定で上回った。

## 3 技術や手法のキモはどこ？

MI_masked は効かないノードを専用のラベルに置き換えてエントロピーを計算する。Node は木の上での最短距離 d を 1−d/(1+max d) で類似度にし、同点の扱いを毎世代ランダムにして連結木を作り直す。学習コストはゼロ。

## 4 どうやって有効だと検証した？

5 データセット・30 run・1000 万評価。木の高さ 5/7 と線形スケーリングの有無の全組合せで、Node が最良、次いで MI_masked（Friedman 検定と Nemenyi 検定で有意 , Fig. 8）。Node は既存手法の最終精度に半分の評価数、約 10 分で到達（Fig. 4）。

## 5 議論はある？

著者：学習された相互情報量の構造はテンプレートの構造に収束し、構造そのものが最良のリンケージになる。

所感：値ではなく表現の構造が依存を決めるという結論は、グレーボックス最適化と GP をつなぐ。問題ごとに重要な部位は捉えにくい。

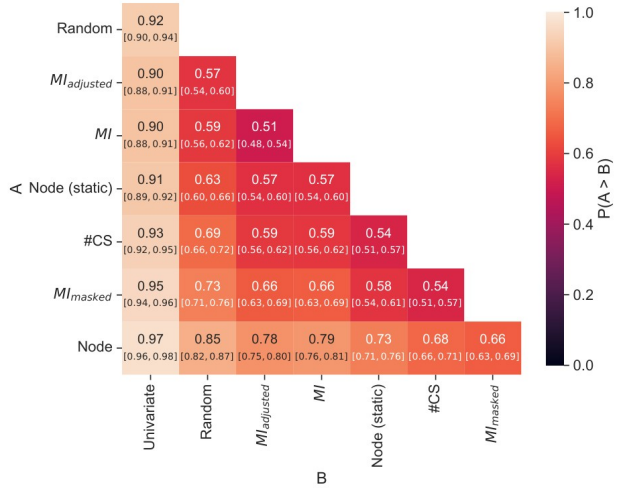
## 6 次に読むべき論文は？

Virgolin+ 2021 GP-GOMEA (TEVC)

Thierens & Bosman 2011 Linkage Tree GA (GECCO)

La Cava+ 2021 SRBench (NeurIPS)

Koza 1992 Genetic Programming




出典：GP-GOMEA linkage (Koch+ 2026) Fig. 10（補足資料：A が B より高い $R^2$ を出す確率）

## 書誌情報

**発表：** GECCO 2026

**リンク：** https://arxiv.org/abs/2602.02311

**受賞：** GECCO 2026 Best Paper Award（GP トラック）

**調査日：** 2026-10-27

**確認範囲：** 全文（問題提起・手法・実験・結果・考察）

# Introns and Templates Matter: Rethinking Linkage in GP-GOMEA

Johannes Koch, Tanja Alderliesten, Peter A.N. Bosman（CWI / TU Delft）| GECCO 2026

## 詳細

問題設定：GOMEA 系の手法は、依存し合う変数をまとめて親から受け継ぐ（GOM）ことで効率よく探索する。GP-GOMEA は式を固定長の木テンプレートに載せ、ノード位置を変数とみなす。小さい式では使われない位置ができ、その値はランダムに漂う。このため、母集団の統計から依存を推定すると信号がノイズに埋もれる。

手法：(1) 使われない位置を「masked」という一つの記号として扱い、相互情報量を計算する。(2) 母集団を見ずに、テンプレート上のノード間の距離で類似度を定義し、UPGMA で連結木を作る。

結果：全設定で既存の MI と、偏りを補正した MI を上回った。毎世代作り直す Node は、一度だけ作る Node(static) より明らかに良かった。世代を追うと、MI_masked で学ばれる依存の形は Node の形に近づいた（Fig. 7）。

限界：対象は 5 つの回帰データで、演算子の組は限られる。

## 受賞・注目

GECCO 2026 Best Paper Award（GP トラック）

## 評価ポイント

・最先端の記号回帰手法の中核を、最小限の変更で大きく改善した（調査者の見立て）

・新しい設定値を増やさない、実装しやすい提案（調査者の見立て）

・「何が学ばれているか」まで可視化した分析（調査者の見立て）

・イントロンの扱いは GP 以外の不活性変数にも使える（調査者の見立て）

# Evolving Multi-Channel Confidence-Aware Activation Functions for Missing Data with Channel Propagation

Naeem Shahabi Sani, Ferial Najiantabriz, Shayan Shafaei, Dean F. Hougen（University of Oklahoma）| GECCO 2026

## 1 どんなもの？

欠損のある表データ向けに、値 x・欠損フラグ m・補完の信頼度 c の 3 入力を受ける活性化関数 f(x,m,c) を遺伝的プログラミングで進化させる 3C-EA。あわせて、m と c を層から層へ伝える ChannelProp を提案した。

## 2 先行研究と比べてどこがすごい？

ReLU や Swish は値しか見ないため、観測値と補完値を区別できない。欠損マスクを入力に足すだけでは、1 層目より先で情報が消える。活性化関数の進化的探索を、多変数で信頼度付きのものに広げた点が新しい。

## 3 技術や手法のキモはどこ？

c は観測値で 1、補完値では max(0.1, 1− 欠損率)。ChannelProp は重みの絶対値を行ごとに正規化した行列で、c と観測度を次の層へ混ぜる（追加パラメータなし）。適応度は検証精度に、使う入力の数への小さな報酬と木の大きさの罰則を加える。

## 4 どうやって有効だと検証した？

UCI の自然欠損データ 7 件と、人工欠損（MCAR/MAR/MNAR 各 20%）を入れた 5 件。30 seed と Wilcoxon 検定。自然欠損 7 件中 6 件で精度が最高（Table 5）。Heart Disease は 0.920 で ReLU より 9 ポイント高い。Glass の MNAR では 52.5%（基準は 40.7 ～ 49.8%, Table 6）。

## 5 議論はある？

著者：信頼度を見る活性化は、欠損率が高いほど効く（Fig. 2）。

所感：データセットごとに GP を回すコストが大きく、MLP と平均値補完に限られる。比較相手は固定の活性化関数だけで、欠損に特化した手法とは比べていない。

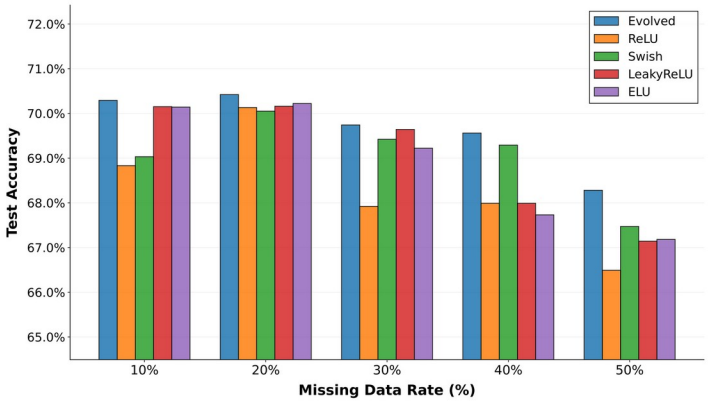
## 6 次に読むべき論文は？

Bingham+ 2020 活性化関数の進化的探索 (GECCO)

Ramachandran+ 2017 Swish の自動探索

Che+ 2018 GRU-D (Sci. Rep.)

Little & Rubin『Statistical Analysis with Missing Data』




出典：3C-EA (Shahabi Sani+ 2026) Fig. 2（PIMA の欠損率別のテスト精度）

## 書誌情報

**発表：** GECCO 2026

**リンク：** https://arxiv.org/abs/2602.13864

**受賞：** GECCO 2026 Best Paper Award（NE トラック）

**調査日：** 2026-10-27

**確認範囲：** 全文（問題提起・手法・実験・結果・考察）

# Evolving Multi-Channel Confidence-Aware Activation Functions for Missing Data with Channel Propagation

Naeem Shahabi Sani, Ferial Najiantabriz, Shayan Shafaei, Dean F. Hougen（University of Oklahoma）| GECCO 2026

## 詳細

問題設定：欠損値を平均などで埋めると、ネットワークは本物の観測値と推測値を同じように扱ってしまう。欠損マスクを特徴として加えても、非線形変換そのものはデータの信頼性に反応しない。

手法：GP の終端記号を x, m, c と定数とし、tanh やソフトプラスなどの単項演算と、四則・min・max の二項演算で木を作る。候補ごとに 3 チャネルの MLP を短時間学習し、検証精度で評価する（1 run で 3000 候補）。ChannelProp は線形層の重みの大きさに比例して、欠損と信頼度の情報を出力側へ配分する。

結果：MAR の Glass では精度 58.0%・AUC 0.778 、PIMA では再現率 0.493 など、少数クラスの取りこぼしが減った。アブレーション（MNAR 40%）では、信頼度・フラグ・ChannelProp のどれを外しても多くの場合で低下した。進化した関数の例 f=min(x·m, x)+x は、補完値を 2 倍にする。

限界：信頼度はヒューリスティックで、CNN や Transformer への拡張は今後の課題。

## 受賞・注目

GECCO 2026 Best Paper Award（NE トラック）

## 評価ポイント

・神経進化の探索空間を「データの信頼性」へ広げた新しい発想（調査者の見立て）

・医療などの欠損が多い表データという実務的な課題（調査者の見立て）

・進化した式を読んで解釈できる（調査者の見立て）

・欠損の 3 つの仕組みすべてで系統的に評価した（調査者の見立て）

# Exploration of Pareto-preserving Search Space Transformations in Multi-objective Test Functions

Diederick Vermetten, Jeroen Rook（Sorbonne Université, LIP6 / Paderborn University）| GECCO 2026

## 1 どんなもの？

多目的のベンチマーク（ZDT, DTLZ, MMF）に、目的空間の形を変えずに探索空間だけを変える 2 種類の全単射変換を加えた。代表的な多目的進化アルゴリズムがどれだけ影響を受けるかを調べた論文。

## 2 先行研究と比べてどこがすごい？

単目的の BBOB では回転や平行移動によるインスタンスが標準だが、箱型制約の多目的問題ではパレート集合が壊れるため使えなかった。問題の式を書き換えずに使える「パレート保存」の変換を示した。

## 3 技術や手法のキモはどこ？

(1) 座標ごとに Beta 分布の CDF を掛けて密度を歪める（$\alpha$, $\beta$ の 25 通り）。(2) 超立方体を一度超球に写し、回転してから戻す sphered rotation（変数間に依存が入る）。同じ Beta-CDF を目的空間にも掛けて比べた。

## 4 どうやって有効だと検証した？

NSGA-II, SMS-EMOA, MOEA/D とランダム探索を 10 run・5000 評価で比較。2 次元 DTLZ1 を回転すると、MOEA/D はランダム探索より悪くなった（Fig. 5）。10 次元 ZDT の回転で、相対 HV は 0.57 ～ 0.61 に下がった（Fig. 10）。

## 5 議論はある？

著者：既存のベンチマークは、軸に沿った変異（多項式変異）を暗黙に優遇してきた可能性がある。

所感：軸のバイアスは約 20 年前から指摘されていたが、問題によらない道具にした意義が大きい。変換の種類と強さの選び方は未解決。

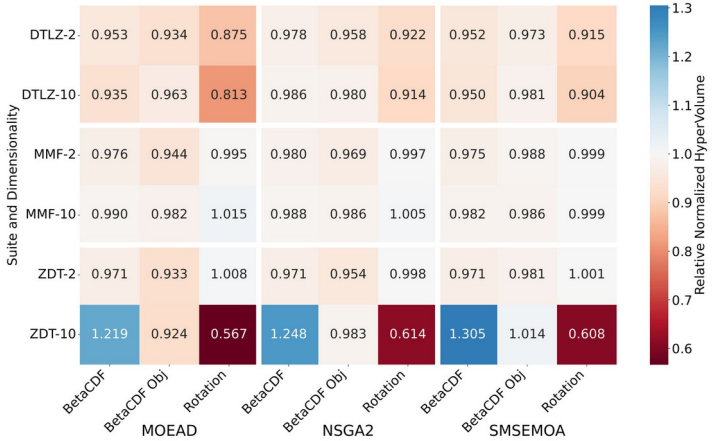
## 6 次に読むべき論文は？

Huband+ 2006 WFG toolkit (TEVC)

Iorio & Li 2006 回転した多目的テスト問題 (GECCO)

Hansen+ 2021 COCO (OMS)

Vermetten+ 2025 MA-BBOB (TELO)




出典：Pareto-preserving transforms (Vermetten & Rook 2026) Fig. 10（変換別の相対 HV）

## 書誌情報

**発表：** GECCO 2026

**リンク：** https://arxiv.org/abs/2604.08173

**受賞：** GECCO 2026 Best Paper Award（BBSR–ENUM 共同枠）

**調査日：** 2026-10-27

**確認範囲：** 全文（問題提起・手法・実験・結果・考察）

# Exploration of Pareto-preserving Search Space Transformations in Multi-objective Test Functions

Diederick Vermetten, Jeroen Rook ( Sorbonne Université, LIP6 / Paderborn University ) | GECCO 2026

## 詳細

問題設定:多目的ベンチマークの設計は、パレートフロントの形など目的空間の性質に集中してきた。探索空間の性質(最適解の位置、軸に沿った構造)は十分に検討されていない。アルゴリズムがベンチマークの意図しない構造を利用していないかを確かめる手段もなかった。

手法:全単射なので、到達できる目的値の集合は変わらない。Beta-CDF は軸に沿った構造を保ったまま領域の密度を変え、sphered rotation は軸に沿った構造を壊す。変換の強さは、ランダムな点どうしの距離分布の Wasserstein 距離で測った( Fig. 3 )。目的空間への変換は、元の空間に戻してから HV を計算し、公平に比べた。

結果: Beta-CDF はランダム探索には大きく効くが、進化アルゴリズムは比較的安定していた。回転は 3 手法とも明確に悪化させ、MOEA/D が最も影響を受けた。同じ強さの変換なら、探索空間の変換のほうが目的空間の変換より影響が大きいこともあった。

限界: 2 目的・箱型制約の問題に限られ、変換の組合せは未検討。

## 受賞・注目

GECCO 2026 Best Paper Award ( BBSR–ENUM 共同枠)

## 評価ポイント

・ベンチマークの偏りという、分野全体に関わる問題を突いた(調査者の見立て)

・問題式を書き換えずに多目的版のインスタンスを作れる道具(調査者の見立て)

・探索空間と目的空間の難しさを分けて分析できる(調査者の見立て)

・ IOHexperimenter による再現性の高い実験設計(調査者の見立て)

# Parent Selection Mechanisms in Elitist Crossover-Based Algorithms

Andre Opris, Denis Antipov（University of Passau / Sorbonne Université, LIP6）| GECCO 2026

## 1 どんなもの？

(μ+1) GA で交叉の親に「最も離れた 2 個体」を優先して選ぶと、Jump_k 問題を期待 O(k·4^k·n log n) 時間で解けることを証明した理論論文。交叉が多様性を作り、保つ仕組みを初めて示した。

## 2 先行研究と比べてどこがすごい？

通常の (μ+1) GA で知られた上界は O(n^{k−1}) 程度で、多様性は変異が作り、交叉は壊すと考えられてきた。親の選び方を変えるだけで、強い多様性維持の仕組みに近い速さを得た。

## 3 技術や手法のキモはどこ？

新しい多様性の指標：集団内の最大ハミング距離 d と、その距離にある互いに素なペアの数 m（最大マッチング）。変異が d を上げ、交叉が同じ距離のペアを増やして d の低下を防ぐ。ギャンブラーの破産問題と負のドリフト定理で解析した。

## 4 どうやって有効だと検証した？

定理 3.6：μ ≥ c·4^r(k−r)ln n/(p_c p_fu) のとき、全個体がプラトー上にある状態から O(4^r n^{k−r}/(p_c p_fu)) 評価で最適解に達する。系 4.3 で全体は O(4^k n log n)（r=k−1）。プラトーに着くまでも遅くならない。

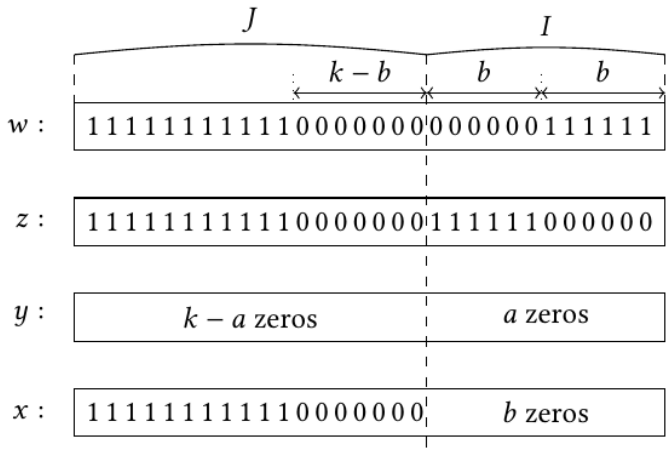
## 5 議論はある？

著者：同じような動きは通常の (μ+1) GA でも起きていると考えられる（Doerr らの実験と合う）。

所感：一様な選択では条件 p_fu を満たせない点が要。解析は Jump_k だけで、実験による定数の確認はない。

## 6 次に読むべき論文は？

Jansen & Wegener 2002 交叉が有効な例 (Algorithmica)
Dang+ 2018 交叉と自然に生じる多様性 (TEVC)
Opris+ 2024 O(4^k/p_c) の上界 (GECCO)
Opris+ 2025 O(4^k) の上界と多様性 (Algorithmica)




出典：Furthest-parent (μ+1) GA (Opris & Antipov 2026) Fig. 1（補題 3.4 の構成）

## 書誌情報

**発表：** GECCO 2026
**リンク：** https://arxiv.org/abs/2604.04083
**受賞：** GECCO 2026 Best Paper Award（GA–THEORY 共同枠）
**調査日：** 2026-10-27
**確認範囲：** 全文（問題提起・手法・実験・結果・考察）

# Parent Selection Mechanisms in Elitist Crossover-Based Algorithms

Andre Opris, Denis Antipov（University of Passau / Sorbonne Université, LIP6）| GECCO 2026

## 詳細

問題設定：Jump_k は、最適解から距離 k 以内がすべて 2 番目に良い局所最適（プラトー）になる関数である。変異だけでは Θ(n^k) かかる。交叉で 2 つの局所最適を組み合わせれば速く解けるが、そのためには集団に十分な多様性が要る。これまでの解析は、交叉を「最悪の子を作るもの」として悲観的に扱っていた。

手法：交叉時に最も離れたペアを選ぶ確率の下限 p_fu を仮定する（距離で順位付けしたトーナメントやべき乗則の選択で満たせる）。交叉で同じ距離のペアを増やすと、最大距離 d は m 個の個体が消えない限り下がらない。この性質を不公平なランダムウォークとして扱う。

結果：d が下がる前に、d の増加か最適解の生成が起きる確率が高いことを示し、典型的な挙動に基づいて上界を出した。山登りの段階でも、交叉が大きな集団による遅れを補う。

限界：対象は単一のベンチマーク関数で、局所最適のネットワークを持つ問題への一般化は予想にとどまる。

## 受賞・注目

GECCO 2026 Best Paper Award（GA–THEORY 共同枠）

## 評価ポイント

・「交叉が多様性を作る」という通説に反する結果を厳密に示した（調査者の見立て）

・新しい多様性の指標は、他の解析にも使える道具になる（調査者の見立て）

・親の選択という実務的な設計に理論の根拠を与えた（調査者の見立て）

・Jump_k の最良の上界 O(4^k) 級に迫る（調査者の見立て）

# AutoNumerics-Zero: Automated Discovery of State-of-the-Art Mathematical Functions

Esteban Real, Mirko Rossini, Connal de Souza ほか( Google DeepMind / Google ) | ICML 2026

## 1 どんなもの?

空のプログラムから記号回帰(遺伝的プログラミングと CMA-ES )で、指数関数や cos などの超越関数を近似するプログラムを、数学の事前知識なしに発見する AutoNumerics-Zero 。2026 年の Humies 金賞(二次情報)。

## 2 先行研究と比べてどこがすごい?

テイラー、パデ、チェビシェフ、ミニマックスなどの伝統的な手法は任意の精度を目指す。float32 など有限の精度で十分という前提に切り替え、同じ演算数で既知の近似を大きく上回るプログラムを見つけた。

## 3 技術や手法のキモはどこ?

外側は分散・非同期版の NSGA-II (精度と演算数の 2 目的)で、計算グラフに挿入・削除・つなぎ替えの変異を加える。内側は CMA-ES で係数を最適化する。中間値を再利用できるプログラム表現。最良解は区間演算で誤差の上界を証明した。

## 4 どうやって有効だと検証した?

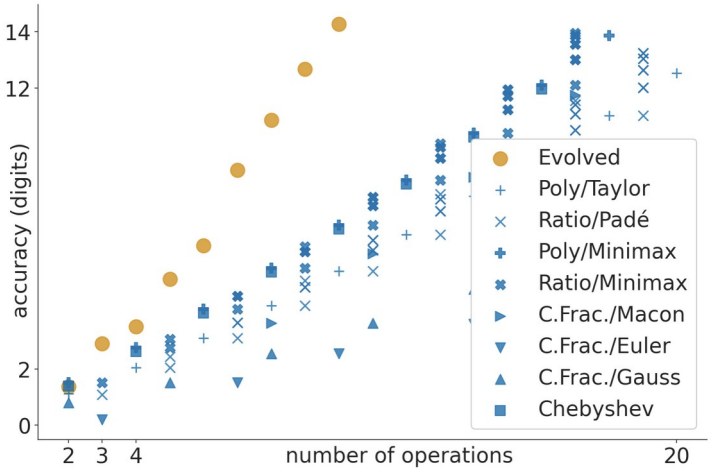
2^x を 10 演算で 14 桁の精度で計算(同じ規模の既知の近似より 6 桁以上高い。最大相対誤差 5.4e-15 を証明 , Fig. 4, 5 )。ハードウェアに特化した版は、最良の基準より 3 倍以上速く、誤差は 1 ULP 未満( Fig. 7 )。他の CPU 5 世代でも最低 80% 速い。

## 5 議論はある?

著者:有限の精度を狙えば、進化的探索は人手の数値解析を超えうる。
所感:誤差関数では高精度の領域でパデ近似に負けるなど、万能ではない。探索に 100 ～ 1 万プロセスを数日回すコストと、範囲縮小( range reduction )への依存が残る。

## 6 次に読むべき論文は?

Schmidt & Lipson 2009 データからの法則発見 (Science)
Real+ 2020 AutoML-Zero (ICML)
Fawzi+ 2022 AlphaTensor (Nature)
Mankowitz+ 2023 AlphaDev (Nature)




出典: AutoNumerics-Zero (Real+ 2026) Fig. 4 ( 2^x 近似の演算数と精度)

## 書誌情報

**発表:** ICML 2026
**リンク:** https://arxiv.org/abs/2312.08472
**受賞:** 23rd Humies ( 2026 ) Gold Award ( GECCO 2026 で発表、二次情報)
**調査日:** 2026-10-27
**確認範囲:** 全文(問題提起・手法・実験・結果・考察)

# AutoNumerics-Zero: Automated Discovery of State-of-the-Art Mathematical Functions

Esteban Real, Mirko Rossini, Connal de Souza ほか ( Google DeepMind / Google ) | ICML 2026

## 詳細

問題設定:計算機は超越関数を四則演算の組合せで近似するしかない。既存の数値解析の手法は、精度を上げれば演算が増える級数展開が中心である。実際には float32 の精度を超える正確さは捨てられる。そこで「有限だが高い精度」を最少の演算で達成するプログラムを探す。

手法:プログラムは係数の定義と四則演算の命令列で、空のプログラムから始める。変異は完全にランダムで、数学の知識を入れない。100 ～ 1 万のワーカーで非同期に進化させ、子ごとに CMA-ES で係数を合わせる。最終候補は未知の入力で検査し、区間演算 ( IBEX ) で誤差の上界を証明する。

結果:指数関数・cos・Bessel・Airy の各関数で、多くの演算数において基準を上回った。$\sqrt{\ }$ を演算に加えると、Bessel 関数の原点付近の振る舞いも扱える。ハード特化の探索では、コンパイラの珍しい最適化経路を引き出すコードが見つかった。

限界:誤差関数では高精度でパデ近似が上で、範囲縮小は人手の既存手法に頼る。

## 受賞・注目

23rd Humies ( 2026 ) Gold Award ( GECCO 2026 で発表、二次情報)

## 評価ポイント

・人間の数値解析の成果を上回る「人間に匹敵する結果」の典型例(調査者の見立て)

・誤差の上界を数学的に証明し、主張を検証可能にした(調査者の見立て)

・速度という実用上の指標でも 3 倍超の改善を示した(調査者の見立て)

・受賞の根拠は SIGEVOlution の予定稿(二次情報)で、公式の受賞一覧は未確認

# Extract-QD Framework: A Generic Approach for Quality-Diversity in Noisy, Stochastic or Uncertain Domains

Manon Flageat, Johann Huber, François Helenon ほか（Imperial College London）| GECCO 2025

## 1 どんなもの？

評価にノイズがある Quality-Diversity（不確実 QD）の既存手法を、抽出や深さ付きコンテナなどのモジュールで統一する EQD Framework を提案。その実装として Extract-MAP-Elites（EME）も示した。

## 2 先行研究と比べてどこがすごい？

固定回数の再評価、Archive-Sampling 、Deep-Grid などはそれぞれ制約があり、どれを使えばよいか分かりにくかった。EME は、どのタスクでも最良の手法と同等以上になる「最初の一手」を目指した。

## 3 技術や手法のキモはどこ？

毎世代の評価の 25% を、アーカイブ内のエリートの再評価に回す。選ばれたエリートは一度アーカイブから抜き出し、新しい個体と同じ規則で戻す。各セルに深さ 8 の控えを持ち、上位ほど指数的に再評価されやすい。

## 4 どうやって有効だと検証した？

Arm・Hexapod・Walker・Ant の 4 系統、10 seed 、1 世代 1024 評価。補正した QD スコアで各タスクの最良手法と同等、Ant では全手法を上回った（p<1e-3, Fig. 4）。PGA-ME に組み込んだ EPGA は、3 タスクで PGA を上回った（p<5e-3, Fig. 6）。

## 5 議論はある？

著者：EME を最初の一手として、EQD Framework を手法設計の道具箱として使ってほしい。

所感：扱ったのは性能を正しく推定する問題だけで、再現性の最大化や性能とのトレードオフは今後の課題。

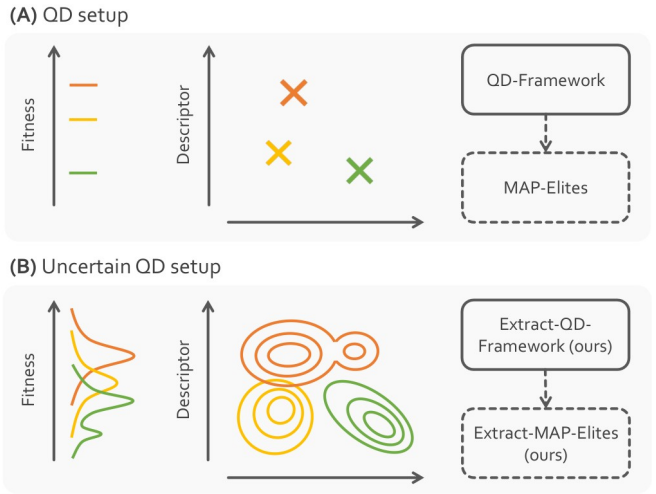
## 6 次に読むべき論文は？

Flageat & Cully 2023 Uncertain QD (TELO)

Justesen+ 2019 Adaptive Sampling による MAP-Elites

Nilsson & Cully 2021 PGA-MAP-Elites (GECCO)

Cully & Demiris 2018 QD Framework (TEVC)




出典：Extract-QD / EME (Flageat+ 2025) Fig. 1（QD と不確実 QD の設定）

## 書誌情報

**発表：** GECCO 2025

**リンク：** https://arxiv.org/abs/2502.06585

**受賞：** GECCO 2025 Best Paper Award（CS＋NE 共同枠）

**調査日：** 2026-10-27

**確認範囲：** 全文（問題提起・手法・実験・結果・考察）

# Extract-QD Framework: A Generic Approach for Quality-Diversity in Noisy, Stochastic or Uncertain Domains

Manon Flageat, Johann Huber, François Helenon ほか（Imperial College London）| GECCO 2025

## 詳細

問題設定：QD は 1 回の評価で適応度と行動記述子が決まると仮定している。ノイズがあると、たまたま良く見えた「幸運な」解がセルを占領し、多様性も質も見かけだけになる。不確実 QD には、性能の推定、再現性の最大化、両者のトレードオフという 3 つの下位問題がある。

手法：EQD Framework は、QD Framework の選択とコンテナに加え、変異、抽出、深さ付きコンテナ、深さ内の順位付け、初回のサンプル数をモジュールとして明示する。既存の 10 以上の手法を表で対応づけた（Table 1）。EME は、世代あたりの評価予算を固定したまま再評価を混ぜるので並列化しやすく、アーカイブの大きさにもよらない。

結果：真の値（512 回再評価の中央値）で作り直したアーカイブで比べると、どのタスクでも上位に入った。Archive-Sampling は大きなアーカイブでは使えなかった。

限界：再現性に関わる 2 つの下位問題は実験していない。

## 受賞・注目

GECCO 2025 Best Paper Award（CS＋NE 共同枠）

## 評価ポイント

・乱立していた不確実 QD の手法を一つの枠組みに整理した（調査者の見立て）

・タスクを選ばず使える既定の手法を示した（調査者の見立て）

・追加の評価コストなしで既存の QD-RL を改善した（調査者の見立て）

・QDax 上の実装で、実務で使いやすい（調査者の見立て）

# When Does Neuroevolution Outcompete Reinforcement Learning in Transfer Learning Tasks?

Eleni Nisioti, Joachim Winther Pedersen, Erwan Plantec, Milton L. Montero, Sebastian Risi（IT University of Copenhagen）| GECCO 2025

## 1 どんなもの？

難しさが段階的に上がる課題で、前の段階の技能を次に持ち越せるかを比べた。論理回路のベンチマーク stepping gates と、Brax を拡張したロボットのベンチマーク ecorobot を作り、神経進化と強化学習を比較した。

## 2 先行研究と比べてどこがすごい？

神経進化が強化学習に勝る場面として、勾配の近似・局所解の回避・頑健性に加え、「転移学習」を示した。構造探索の有無、直接／間接の符号化、多様性重視の有無という 3 つの軸で違いを整理した。

## 3 技術や手法のキモはどこ？

N-parity と Simple ALU（9 段階）は、今のレベルを解くと次に進むカリキュラム。ecorobot は踏み石のある迷路と、高さが増していく障害物。NEAT, HyperNEAT, CMA-ES, MAP-Elites, PPO, 目標条件付き PPO を 10 試行で比較した。

## 4 どうやって有効だと検証した？

CMA-ES は両方の回路の全レベルを解き、NEAT は parity を全部・ALU はレベル 5 まで解いた。PPO は最初のレベルで止まった（Fig. 3）。ただしカリキュラム無しで 6-parity を直接解かせると PPO は完答した（Fig. 4）。迷路では NEAT が 7 個中平均 5 個の踏み石に達した（Fig. 5）。

## 5 議論はある？

著者：転移には直接符号化が有利で、間接符号化は局所解の回避に強い。

所感：ロボットを Ant に替えると NEAT も最初の踏み石で止まり、複雑な身体と転移の両立は未解決。強化学習側は、転移向けの手法と比べていない。

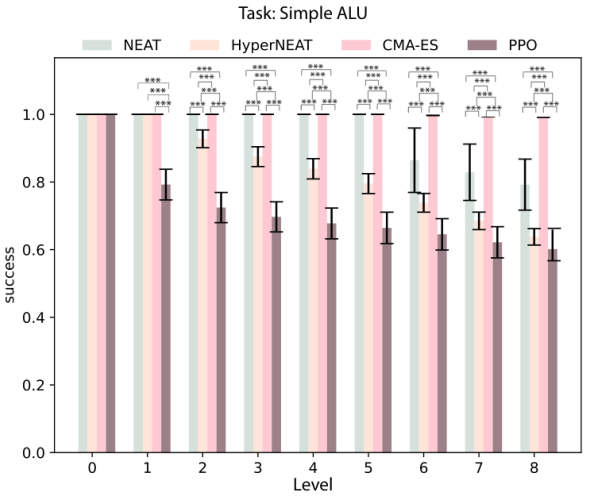
## 6 次に読むべき論文は？

Stanley & Miikkulainen 2002 NEAT (ECJ)

Wang+ 2024 TensorNEAT (GECCO)

Such+ 2017 Deep Neuroevolution

Salimans+ 2017 ES as a Scalable Alternative to RL




出典：NE vs RL in transfer (Nisioti+ 2025) Fig. 3 下段（Simple ALU のレベル別成功率）

## 書誌情報

**発表：** GECCO 2025

**リンク：** https://arxiv.org/abs/2505.22696

**受賞：** GECCO 2025 Best Paper Award（BBSR＋ENUM 共同枠）

**調査日：** 2026-10-27

**確認範囲：** 全文（問題提起・手法・実験・結果・考察）

# When Does Neuroevolution Outcompete Reinforcement Learning in Transfer Learning Tasks?

Eleni Nisioti, Joachim Winther Pedersen, Erwan Plantec, Milton L. Montero, Sebastian Risi（ IT University of Copenhagen ）| GECCO 2025

## 詳細

問題設定：強化学習は課題が変わると脆く、以前に学んだことを忘れやすい。神経進化は構造探索や集団による多様性を持つため、技能の積み上げに向く可能性があるが、系統的に調べられていなかった。

手法：stepping gates はレベルが進むほど入力ビットや論理演算が増え、前の解を部品として再利用できる。ecorobot は Brax に壁・障害物・餌・距離センサを加え、ロボットの体と課題を自由に組み合わせられる。どちらも JAX で書かれ、GPU 上で一貫して学習できる。

結果：直接符号化（ CMA-ES, NEAT ）は回路と迷路でレベルを積み上げた。HyperNEAT はレベルが上がると性能が落ちた。MAP-Elites は迷路全体を探索したが、踏み石を正しい順に通れず報酬は低かった。HalfCheetah の障害物課題で、PPO は速いが転倒を繰り返し、障害物を「無視する」方策を学んでいた。

限界：PPO 系以外の強化学習や、ハイパーパラメータの大規模な調整は扱っていない。

## 受賞・注目

GECCO 2025 Best Paper Award（ BBSR ＋ ENUM 共同枠）

## 評価ポイント

・NE と RL の比較に「転移」という新しい切り口を持ち込んだ（調査者の見立て）

・2 つの公開ベンチマークを作り、今後の研究の土台を用意した（調査者の見立て）

・カリキュラム有無のアブレーションで、差の原因を突き止めた（調査者の見立て）

・手法の弱点（ Ant での失敗）も隠さず報告した（調査者の見立て）

# Quality with Just Enough Diversity in Evolutionary Policy Search

Paul Templier, Luca Grillotti, Emmanuel Rachelson ほか（ISAE-SUPAERO）| GECCO 2024

## 1 どんなもの？

最良の 1 方策を求める進化戦略（ES）に、QD が使う行動記述子の情報を「必要なだけ」取り入れる JEDi 。行動と適応度の関係をガウス過程で学び、有望な行動を目標にして ES を走らせる。

## 2 先行研究と比べてどこがすごい？

MAP-Elites はすべての行動を均等に磨くため評価が分散し、ES は一つの解き方に固まって騙されやすい。JEDi はその中間で、迷路と大規模な方策の制御の両方で最大適応度を上げた。

## 3 技術や手法のキモはどこ？

評価回数で重み付けしたガウス過程で、行動から最大適応度を予測する。予測の平均と分散のパレート前線から目標の行動を選ぶ。目標ごとに ES を走らせ、目標への近さと適応度の重み付き和（WTFS, $\alpha$ ）で順位を付ける。

## 4 どうやって有効だと検証した？

Kheperax の迷路 4 種と Brax（HalfCheetah, Walker2D, AntMaze; 2×256 の MLP ）。Walker2D の最大適応度は MAP-Elites 2118 、ES 3988 に対し JEDi 5535（Fig. 1 ）。迷路 A・B・Quad B で最良、Brax では勾配を使わない QD に $p \le 0.02$ で勝った。

## 5 議論はある？

著者：JEDi は QD の置き換えではなく、最良の解を求める用途で行動の情報を使う方法。

所感：迷路 C では CMA-MAE に負け、結果のばらつき（二峰性）も大きい。$\alpha$ を 0.8 から 0 へ線形に下げるスケジュールが実用上の鍵。

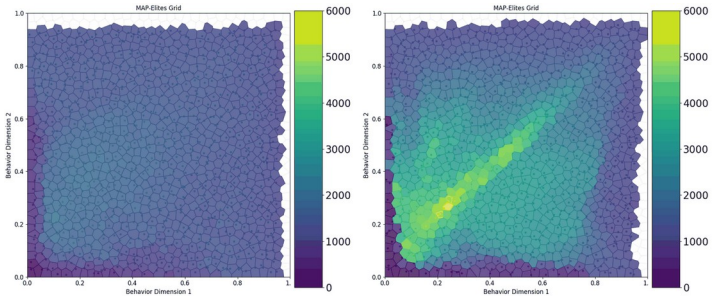
## 6 次に読むべき論文は？

Fontaine & Nikolaidis 2023 CMA-MAE (GECCO)

Fontaine+ 2020 CMA-ME (GECCO)

Colas+ 2020 ME-ES (GECCO)

Cully+ 2015 Robots that can adapt like animals (Nature)




出典：JEDi (Templier+ 2024) Fig. 1（Walker2D のアーカイブ：左 MAP-Elites 、右 JEDi ）

## 書誌情報

**発表：** GECCO 2024

**リンク：** https://arxiv.org/abs/2405.04308

**受賞：** GECCO 2024 Best Paper Award（CS＋L4EC 共同枠）

**調査日：** 2026-10-27

**確認範囲：** 全文（問題提起・手法・実験・結果・考察）

# Quality with Just Enough Diversity in Evolutionary Policy Search

Paul Templier, Luca Grillotti, Emmanuel Rachelson ほか（ISAE-SUPAERO）| GECCO 2024

## 詳細

問題設定：人は歩き方を学ぶとき、すべての歩き方を極めるのではなく、有望な方法に絞って磨く。QD は多様性のために予算を使いすぎ、ES は行動の情報を使わないので欺瞞的な課題で行き詰まる。

手法：アーカイブの各セルを、評価回数を重みとするデータ点にしてガウス過程に学習させる。これにより、全セルが埋まった後も「どれだけ調べたか」で不確かさが変わる。平均（活用）と分散（探索）の両方を最大化するパレート前線から、複数の目標を並列に選ぶ。各 ES は目標に最も近い既存の解から始め、評価したすべての解をアーカイブに戻す。

結果：迷路では QD が先に目標へ着くが頭打ちになり、JEDi は改善を続けた。AntMaze では ES と JEDi が壁を跳び越える意外な解を見つけた。アブレーションでは、重み付きガウス過程が重みなしより良かった。

限界：PGA-ME のような RL の勾配は使っておらず、組合せは今後の課題。

## 受賞・注目

GECCO 2024 Best Paper Award（CS＋L4EC 共同枠）

## 評価ポイント

・QD と ES の役割分担を「必要なだけの多様性」として定式化した（調査者の見立て）

・ベイズ最適化の考え方を行動空間での目標選びに使った（調査者の見立て）

・大きな方策ネットワークでも勾配なしで高い性能（調査者の見立て）

・QD の「目的」を問い直す概念的な貢献（調査者の見立て）