GNN による物理シミュレーション・世界モデル

物理系を「物体・粒子・メッシュ要素とその相互作用」のグラフとして学ぶ系譜。IN（2016）と GN（2018）を原典に、物体中心の C-SWM、粒子の GNS、メッシュの MeshGraphNets、対称性の EGNN を経て、GraphCast が実天気予報に到達。
2025 〜 2026 年は拡散（DGN）・Transformer（ParticleFormer、メッシュ Transformer）との比較と、長期ロールアウトの安定性（IGNS）が焦点。

#	年	論文	発表	系譜
1	2016	Interaction Networks (Battaglia+ 2016)	NIPS 2016	原典
2	2018	Graph Networks (Battaglia+ 2018)	arXiv プレプリント 2018	原典
3	2020	C-SWM (Kipf+ 2020)	ICLR 2020	発展
4	2020	GNS (Sanchez-Gonzalez+ 2020)	ICML 2020	発展
5	2021	MeshGraphNets (Pfaff+ 2021)	ICLR 2021	発展
6	2021	EGNN (Satorras+ 2021)	ICML 2021	発展
7	2023	GraphCast (Lam+ 2023)	Science 2023	発展
8	2025	Diffusion Graph Networks (Lino+ 2025)	ICLR 2025	最新
9	2025	ParticleFormer (Huang+ 2025)	CoRL 2025	最新
10	2025	Mesh Transformer (Garnier+ 2025)	arXiv プレプリント 2025	最新
11	2026	IGNS (Hoang+ 2026)	ICLR 2026	最新

Interaction Networks for Learning about Objects, Relations and Physics

Peter W. Battaglia, Razvan Pascanu, Matthew Lai ほか（Google DeepMind）| NIPS 2016

1 どんなもの？

物体をノード・関係をエッジとするグラフを入力に、関係モデル f_R と物体モデル f_O を分けて学習する Interaction Network（IN）を提案。n 体・剛体衝突・バネ紐で、1 ステップ学習のみから数千ステップのロールアウトを実現した最初の汎用学習型物理エンジン。

2 先行研究と比べてどこがすごい？

CNN は固定の局所近傍、MLP は全入力を平坦化するため、物体数や関係の構造が変わると対応できない。IN は関係を明示的に入力し f_R・f_O を全関係・全物体で共有するので、物体数の異なる系へそのまま汎化する。比較は MLP・等速度・関係なし IN 。

3 技術や手法のキモはどこ？

相互作用項 b_k=[o_i; o_j; r_k] に f_R を適用して効果 e_k を求め、受信物体ごとに和で集約（順序不変）。外力 x_j と結合して f_O で次の速度を出す。e_k の L2 正則化と入力ノイズで長期のドリフトを抑える。

4 どうやって有効だと検証した？

自作物理エンジンの 2000 シーン ×1000 ステップで学習。次ステップ速度の MSE は n 体 0.25（MLP 79）、ボール 0.0020（0.072）、紐 0.0011（0.016）と桁違いに小さい（Table 2）。6 体→ 3・12 体、15 質点→ 5・30 質点へも汎化（Table 3）。

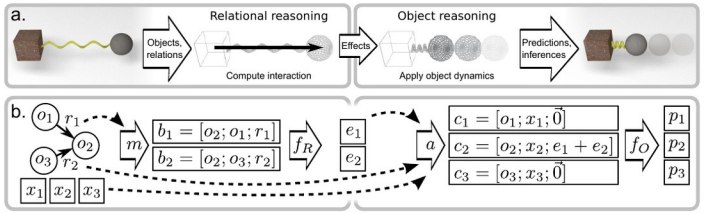
5 議論はある？

著者：大規模系での相互作用の間引き、知覚フロントエンドの付加、確率モデル化が課題。

所感：位置・速度が既知という前提で、「グラフはどこから来るか」は未解決。カオス系では軌道が一致せず、評価は見た目の妥当性に頼っている。

6 次に読むべき論文は？

- Graph Networks (Battaglia+ 2018)（本資料）
- GNS (Sanchez-Gonzalez+ 2020)（本資料）
- NPE (Chang+ 2017)（未調査）



出典：Interaction Networks Fig. 1（a: 関係推論と物体推論の分離、b: m・f_R・a・f_O による計算の流れ）

書誌情報

発表： NIPS 2016
リンク： https://arxiv.org/abs/1612.00222
系譜： 原典
調査日： 2026-10-27
確認範囲： 全文（問題提起・手法・実験・結果・考察）

Relational inductive biases, deep learning, and graph networks

Peter W. Battaglia, Jessica B. Hamrick, Victor Bapst ほか（DeepMind・Google Brain・MIT・エディンバラ大）| arXiv 2018

1 どんなもの？

組合せ汎化を AI の最優先課題とする立場から、IN・MPNN・NLNN・Deep Sets などを辺・ノード・グローバルの 3 つの更新関数と 3 つの集約関数で統一する Graph Network（GN）ブロックを提案した総説兼ポジション論文。graph_nets ライブラリも公開。

2 先行研究と比べてどこがすごい？

MLP・CNN・RNN の関係的帰納バイアス（全結合・局所性・逐次性）を整理し、どれも集合やグラフ構造を自然に扱えないと指摘。GNN（Scarselli+ 2009）や MPNN（Gilmer+ 2017）を特殊ケースとして含み、グラフ→グラフの共通インタフェースで積み重ね可能にした。

3 技術や手法のキモはどこ？

各辺で e'_k=ϕ^e(e_k, v_rk, v_sk, u)、受信ノードごとに ρ^{e→v} で集約して v'_i=ϕ^v(ē'_i, v_i, u)、最後にグローバル u' を更新。ρ は置換不変（和・平均・最大）。encode-process-decode 構成で M 回のメッセージパッシングを重ねる。

4 どうやって有効だと検証した？

新しい実験はなく、既存研究の整理で主張を裏づける。1 ステップ学習の IN が数千ステップに伸び物体数が半分・倍の系へゼロショット転移した例、関節数の異なる系に汎化した GN 順モデル（2018）などを組合せ汎化の証拠に挙げる（Sec. 5.1）。

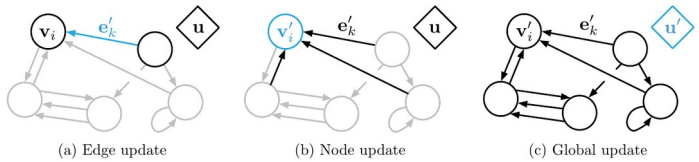
5 議論はある？

著者：WL テストで区別できないグラフがあり、再帰や制御フローは表しにくい。感覚入力からグラフを得る方法、破断時のノード分割など動的なグラフ変更は未解決。

所感：後の GNS・MGN・GraphCast はすべてこの型の上に建っている。

6 次に読むべき論文は？

- GNS (Sanchez-Gonzalez+ 2020)（本資料）
- MPNN (Gilmer+ 2017)（未調査）
- GN as Learnable Physics Engines (Sanchez-Gonzalez+ 2018)（未調査）



出典：Graph Networks Fig. 3（GN ブロック内の辺・ノード・グローバルの順の更新）

書誌情報

発表： arXiv プレプリント 2018
リンク： https://arxiv.org/abs/1806.01261
系譜： 原典（← Interaction Networks）
調査日： 2026-10-27
確認範囲： 全文（問題提起・手法・実験・結果・考察）

Contrastive Learning of Structured World Models

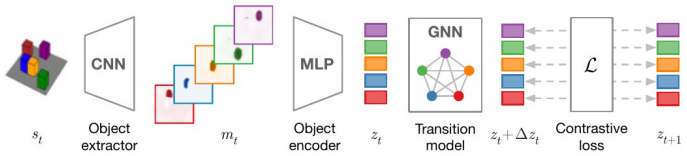
Thomas Kipf, Elise van der Pol, Max Welling（アムステルダム大）| ICLR 2020

1 どんなもの？

画素観測から物体ごとの潜在状態を教師なしで取り出し、GNN で物体間相互作用を含む行動条件付き遷移を学ぶ C-SWM を提案。画素を再構成せず対照損失だけで学び、ブロック押し環境の 10 ステップ予測で H@1 ほぼ 100% を達成。

2 先行研究と比べてどこがすごい？

物体発見の既存手法や World Models（Ha & Schmidhuber 2018）は画素再構成損失に頼るため、小さいが重要な物体を無視したり背景に容量を割く。C-SWM は知識グラフ埋め込み TransE に倣い、本物と偽の状態遷移をエネルギーで識別する。



出典：C-SWM Fig. 1（CNN 物体抽出器、MLP 物体符号化器、GNN 遷移モデル、物体ごとの対照損失）

3 技術や手法のキモはどこ？

CNN の K 枚の特徴マップを物体スロットとし MLP で z^k に符号化。全結合グラフ上の GNN が行動つきで Δz を予測。正例のエネルギー H=(1/K)Σ_k d(z^k+Δz^k, z^k_{t+1}) と負例のヒンジで L=H+max(0, γ−H̃) を最小化。

4 どうやって有効だと検証した？

2D Shapes・3D Blocks・Atari 2 種・3 体重力を潜在空間の順位指標 H@1/MRR で評価。3D Blocks の 10 ステップで H@1 99.9%、AE 型 World Model は 4.0%。GNN を MLP に替えると 2D Shapes で 89.7% に低下。3 体系は 75.5% 対 67.9%（Table 1）。

5 議論はある？

著者：同じ見た目の物体を区別できず、決定論的でマルコフ性を仮定している。

所感：GNN 遷移を物体中心世界モデルの標準部品にした。ただし Atari では分散が大きくスロット数 K に敏感で、現実画像への適用は後続に委ねられた。

6 次に読むべき論文は？

- Slot Attention (Locatello+ 2020)（未調査）
- SlotFormer (Wu+ 2023)（未調査）
- ParticleFormer (2025)（本資料）

書誌情報

発表： ICLR 2020
リンク： https://arxiv.org/abs/1911.12247
系譜： 発展（← Graph Networks）
調査日： 2026-10-27
確認範囲： 全文（問題提起・手法・実験・結果・考察）

Learning to Simulate Complex Physics with Graph Networks

Alvaro Sanchez-Gonzalez, Jonathan Godwin, Tobias Pfaff, Rex Ying ほか（DeepMind・スタンフォード大）| ICML 2020

1 どんなもの？

粒子をノード、近傍半径内の粒子対をエッジとするグラフ上の学習メッセージパッシングで加速度を予測する Graph Network-based Simulator（GNS）を提案。水・砂・粘性体と剛体が混ざる系を、最大約 2 万粒子・数千ステップで同じ構造のまま模擬した。

2 先行研究と比べてどこがすごい？

DPI（Li+ 2018）は剛体を保つ専用の階層機構が必要で、CConv（Ummenhofer+ 2020）は流体に特化していた。GNS は同じハイパーパラメータで全領域を学び、6 領域すべてで最良設定の CConv よりロールアウト誤差が小さい（Fig. 4m）。

3 技術や手法のキモはどこ？

encode-process-decode で、エッジに相対変位と距離を入れて並進不変にし、非共有の GN を M=10 段重ねて加速度を出し、オイラー積分する。学習時に入力速度へランダムウォークノイズ（σ=3e-4）を加え、自己予測による誤差蓄積に強くする。

4 どうやって有効だと検証した？

SPH・MPM・PBD で作った十数データセット（Table 1）。WaterRamps で学習したモデルを 32 倍の領域・34 倍の 8.5 万粒子・8 倍の 5000 ステップに適用しても妥当な流れを生成。ノイズ量、メッセージパッシング段数、接続半径が性能を左右（Fig. 4）。

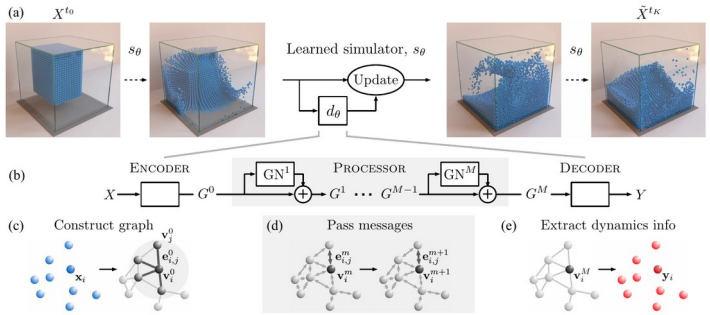
5 議論はある？

著者：メッシュへの拡張、ハミルトン力学や対称性など物理知識の導入、高速化、逆問題への応用が今後の課題。

所感：評価は見た目と粒子 MSE が中心。カオス的な長期挙動が統計的に正しいかは問われていない。

6 次に読むべき論文は？

- MeshGraphNets (2021)（本資料）
- IGNS (2026)（本資料）
- DPI-Net (Li+ 2019)（未調査）



出典：GNS Fig. 2（学習シミュレータ s_θ と encode-process-decode、グラフ構築・メッセージパッシング・動力学の取り出し）

書誌情報

発表： ICML 2020
リンク： https://arxiv.org/abs/2002.09405
系譜： 発展（← Graph Networks）
調査日： 2026-10-27
確認範囲： 全文（問題提起・手法・実験・結果・考察）

Learning Mesh-Based Simulation with Graph Networks

Tobias Pfaff, Meire Fortunato, Alvaro Sanchez-Gonzalez, Peter W. Battaglia（DeepMind）| ICLR 2021

1 どんなもの？

シミュレーションのメッシュをグラフとし、メッシュ空間とワールド空間の 2 種のエッジで学習メッセージパッシングを行う MeshGraphNets を提案。布・弾性体・非圧縮流・圧縮性の翼周り流を同じ枠組みで学び、元の解法より 1 ～ 2 桁速く推論した。

2 先行研究と比べてどこがすごい？

GNS（2020）は粒子を固定半径でつなぐので布の静止形状を持てず、不規則なメッシュでは発散する。格子 CNN（UNet）は翼端の細かい後流を解像できず、GCN（Belbute-Peres+ 2020）はエッジでメッセージを計算しないため翼周り流でロールアウトが安定しない。

3 技術や手法のキモはどこ？

メッシュエッジに参照座標の相対ベクトル u_ij と世界座標の x_ij を、ワールドエッジに x_ij を入れ、15 段の非共有 GN ブロックで更新し、出力を積分する。さらにサイジング場を予測し、汎用リメッシャで次ステップのメッシュを適応的に作り直す。

4 どうやって有効だと検証した？

6 データセットで 1 ステップと全ロールアウトの RMSE を報告（Table 1）。FlagDynamic で解法 26199 ms/step に対し 837 ms 。2 千ノードの旗で学習し 2 万ノードの吹き流しへ汎化。ワールドエッジを外すとロールアウト誤差が 51%・92% 増える。

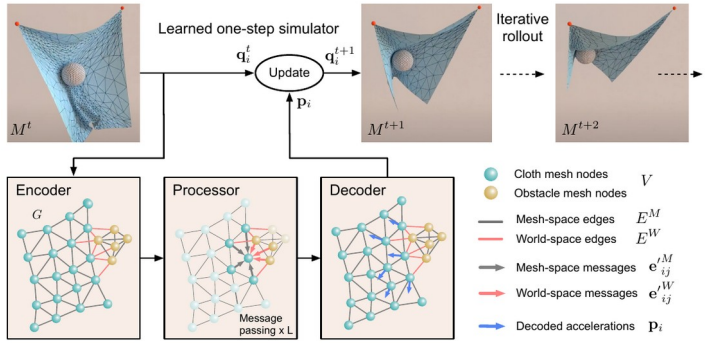
5 議論はある？

著者：物理に基づく補助損失、エネルギー保存型の積分、予測精度を直接最適化する離散化の学習が今後の課題。

所感：Airfoil の全ロールアウト RMSE は大きく、長期誤差は残る。後の Transformer 型や階層型の比較基準になった。

6 次に読むべき論文は？

- Training Transformers for Mesh-Based Simulations (2025)（本資料）
- MultiScale MeshGraphNets (Fortunato+ 2022)（未調査）
- IGNS (2026)（本資料）



出典：MeshGraphNets Fig. 1（布と球の例での encode-process-decode と 2 種のエッジ）

書誌情報

発表： ICLR 2021
リンク： https://arxiv.org/abs/2010.03409
系譜： 発展（← GNS）
調査日： 2026-10-27
確認範囲： 全文（問題提起・手法・実験・結果・考察）

E(n) Equivariant Graph Neural Networks

Victor Garcia Satorras, Emiel Hoogeboom, Max Welling（アムステルダム大）| ICML 2021

1 どんなもの？

辺関数に座標の距離の二乗だけを入れ、座標は相対ベクトルの重み付き和で更新することで、回転・並進・反射・置換に等変な EGNN を提案。球面調和関数を使わず高次元にも拡張でき、n 体の位置予測で次点より誤差を 32% 下げた。

2 先行研究と比べてどこがすごい？

TFN（Thomas+ 2018）や SE(3)-Transformer（Fuchs+ 2020）は球面調和関数による高次表現が必要で、計算が重く 3 次元に限られる。Radial Field（Köhler+ 2019）は等変だが特徴 h を伝えない。EGNN は普通の GNN の柔軟さと等変性を両立する。

3 技術や手法のキモはどこ？

$m_{ij}=\phi_e(h_i, h_j, \|x_i-x_j\|^2, a_{ij})$、$x_i \leftarrow x_i + C\sum_j (x_i-x_j)\phi_x(m_{ij})$、$h_i \leftarrow \phi_h(h_i, \sum_j m_{ij})$。距離は E(n) 不変、相対ベクトルの和は等変なので、層を重ねても等変性が保たれる（付録 A で証明）。速度を扱う拡張もある。

4 どうやって有効だと検証した？

3 次元の荷電 5 粒子系で 1000 ステップ後の位置を予測し、MSE 0.0071（GNN 0.0107、Radial Field 0.0104、TFN 0.0155、SE(3)-Tr. 0.0244、Table 2）。推論も TFN より速い。グラフ自己符号化と QM9 分子物性でも高い性能（Table 3）。

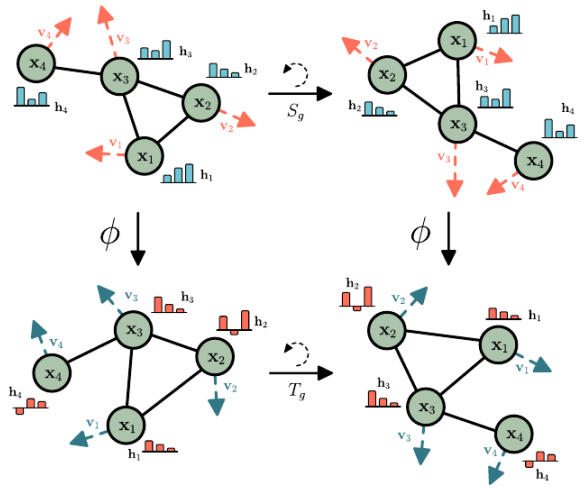
5 議論はある？

著者：計算が軽く実装が簡単なので、創薬・タンパク質・材料への応用を期待。

所感：力学の検証は 5 粒子のみで、ロールアウトでなく一括予測。大規模なメッシュや粒子のシミュレータで等変性がどこまで効くかは別途確かめる必要がある。

6 次に読むべき論文は？

- NequIP (Batzner+ 2022)（未調査）
- SEGNN (Brandstetter+ 2022)（未調査）
- PIEGraph (Orozco+ 2026)（参照のみ）



出典：EGNN Fig. 1（入力を回転してから GNN を通しても、GNN の出力を回転しても同じになる等変性の例）

書誌情報

発表： ICML 2021
リンク： https://arxiv.org/abs/2102.09844
系譜： 発展（← Graph Networks）
調査日： 2026-10-27
確認範囲： 全文（問題提起・手法・実験・結果・考察）

GraphCast: Learning skillful medium-range global weather forecasting

Remi Lam, Alvaro Sanchez-Gonzalez, Matthew Willson ほか（Google DeepMind・Google Research）| Science 2023

1 どんなもの？

0.25° 格子（約 104 万点、227 変数）の大気状態から 6 時間後を予測する GNN を自己回帰で回し、10 日予報を TPU 1 台で 1 分以内に出す GraphCast を提案。ECMWF の決定論予報 HRES を、検証した 1380 項目の 90.3% で上回った。

2 先行研究と比べてどこがすごい？

数値予報は計算資源で精度が伸びるが、過去データから直接は改善できない。既存の機械学習予報（Keisler 2022 の GNN、FourCastNet、Pangu-Weather）が HRES に迫るのは一部変数・7 日程度まで。Pangu-Weather には 252 項目中 99.2% で勝る。

3 技術や手法のキモはどこ？

格子→メッシュの 1 層エンコーダ、正二十面体を 6 回細分した 4 万 962 ノードのマルチメッシュ（全解像度の辺を同時に持ち、長距離を少ない段数で伝える）上の 16 層プロセッサ、メッシュ→格子のデコーダ。学習時の自己回帰ステップを 1→12 に増やす。

4 どうやって有効だと検証した？

ERA5（1979–2017）で学習し 2018 年で評価。z500 の RMSE スキルで HRES より 7 ～ 14% 良い（Fig. 2）。熱帯低気圧の進路、大気の川、極端高温も改善（Fig. 3）。マルチメッシュを外すと 5 日以内の z500 で HRES に勝てない（Supp. 7.3.1）。

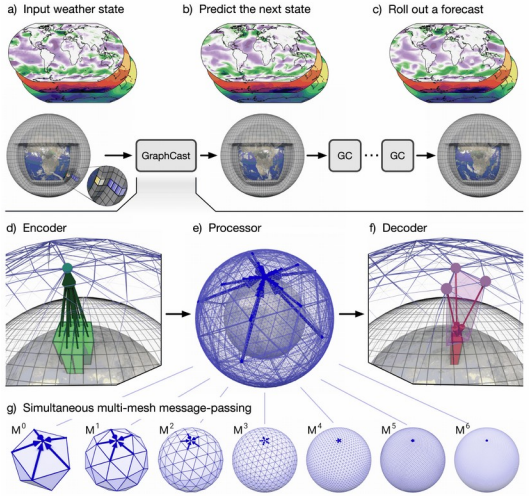
5 議論はある？

著者：MSE 学習のため長いリードタイムで予報がぼやけ、決定論的で不確実性を扱えない。アンサンブル化が次の課題。

所感：GNN シミュレータが実世界の基幹業務で勝った転換点。ぼやけの問題が拡散型（GenCast）への移行を促した。

6 次に読むべき論文は？

- GenCast (Price+ 2024)（未調査）
- Diffusion Graph Networks (2025)（本資料）
- Pangu-Weather (Bi+ 2023)（未調査）



出典：GraphCast Fig. 1（入力→次状態の予測→ロールアウト、エンコーダ・プロセッサ・デコーダと M0 ～ M6 のマルチメッシュ）

書誌情報

発表： Science 2023
リンク： https://arxiv.org/abs/2212.12794
系譜： 発展（← MeshGraphNets）
調査日： 2026-10-27
確認範囲： 全文（問題提起・手法・実験・結果・考察）

Learning Distributions of Complex Fluid Simulations with Diffusion Graph Networks

Mario Lino, Tobias Pfaff, Nils Thuerey（ミュンヘン工科大・ Google DeepMind ）| ICLR 2025

1 どんなもの？

メッシュと物理パラメータを条件に、流れ場の統計的平衡状態を拡散モデルで直接サンプリングする Diffusion Graph Networks（ DGN ）と潜在版 LDGN を提案。短い軌跡だけで学習しても全分布を再現し、3D 翼の乱流の圧力場を解法より 4 〜 5 桁速く生成した。

2 先行研究と比べてどこがすごい？

従来の GNN 代理モデルは平均流や軌跡を予測するが、長いロールアウトでは不安定になる。流れ場の拡散モデル（ Lienen+ 2024 など）は CNN で格子に限られる。単一スケールの GNN 拡散は受容野が足りず、大きいメッシュでは解を生成できない（ Fig. 15 ）。

3 技術や手法のキモはどこ？

ノイズを予測する DDPM のデノイザを encode-process-decode の GNN とし、Guillard の粗視化で作った多段グラフ上の U-Net 型で大域的に除去する。LDGN は変分グラフ自己符号化器の粗い潜在メッシュ上で拡散し、高周波ノイズを抑える。

4 どうやって有効だと検証した？

楕円周りの 2D 層流と、DES で作った 3D 翼の乱流で評価。翼の W2graph は LDGN 1.95 、DGN 2.12 、混合ガウス GNN 4.32（ Table 9 ）。3000 サンプルの生成は GPU で 2.43 分、解法は 2989 分。LDGN は DGN より 8 倍速い。

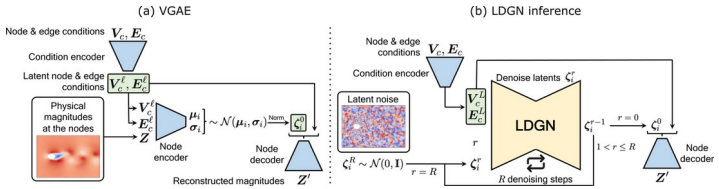
5 議論はある？

著者：生成サンプルに時間相関がなく、物理制約の導入やフローマッチングでの高速化が今後の課題。

所感：自己回帰をやめて分布を直接学ぶことで長期の不安定さを避けた。一方、時間発展を問う世界モデルとしては使えない。

6 次に読むべき論文は？

- GraphCast (2023)（本資料）
- Fluid-DiT (Mo & Ke 2026)（参照のみ）
- PDE-Refiner (Lippe+ 2023)（未調査）



出典：DGN Fig. 2（ a: 条件エンコーダ付き変分グラフ自己符号化器、b: 潜在空間でノイズ除去する LDGN の推論）

書誌情報

発表： ICLR 2025
リンク： https://arxiv.org/abs/2504.02843
系譜：最新（← MeshGraphNets ）
調査日： 2026-10-27
確認範囲：全文（問題提起・手法・実験・結果・考察）

ParticleFormer: A 3D Point Cloud World Model for Multi-Object, Multi-Material Robotic Manipulation

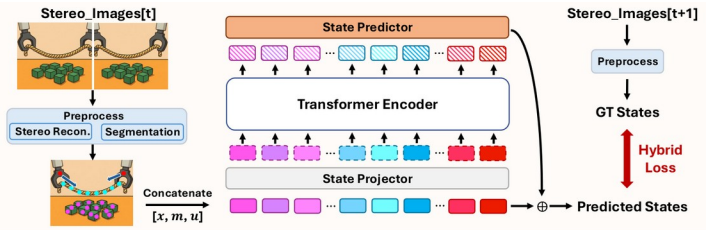
Suning Huang, Qianzhong Chen, Xiaohan Zhang ほか（スタンフォード大・ RAI Institute ）| CoRL 2025

1 どんなもの？

ロボットが操作する物体を点群の粒子で表し、GNN の代わりに Transformer の自己注意で粒子間の相互作用を学ぶ 3D 世界モデル ParticleFormer を提案。剛体・布・ロープ・粒状体が混ざる場面で予測誤差を下げ、実機の MPC でも GNN 型より目標に近づけた。

2 先行研究と比べてどこがすごい？

RoboCraft や AdaptiGraph などのグラフ型粒子ダイナミクス（ GBND ）は近傍半径や最大近傍数 TopK に敏感で、多材質の接触の伝わりが苦手。学習には動的 Gaussian Splatting による粒子追跡も要る。DINO-WM など 2D 世界モデルは 3D 構造を捉えにくい。



出典：ParticleFormer Fig. 2（ステレオ画像から粒子状態を作り、Transformer で次状態を予測、混合損失で学習）

3 技術や手法のキモはどこ？

ステレオ画像から点群を再構成・分割し、各粒子の位置・材質・動作を埋め込み、3 層の Transformer エンコーダで全粒子どうしを注意させて変位を予測。対応点不要の Chamfer 距離と微分可能 Hausdorff 距離の混合損失で 5 ステップ自己回帰学習する。

4 どうやって有効だと検証した？

FleX シミュレーション 6 種と実機 3 種で評価。粒子 MSE は Cloth Gathering 0.0023（ GBND 0.0076 ）、Rope Sweeping 0.0008（ 0.0029 ）。CD+HD も DINO-WM より大幅に小さい（ Table 1 ）。GBND は TopK を 5→15 と増やしても及ばない（ Fig. 4 ）。

5 議論はある？

著者：シーンごとの学習で、多様な環境への汎化は未確認。外部の分割モデルの失敗が伝搬する。

所感：全粒子の全結合注意は大規模化で計算量が問題になる。近傍半径という「関係の手設計」に GNN が依存することへの反論として読める。

6 次に読むべき論文は？

- C-SWM (2020)（本資料）
- AdaptiGraph (Zhang+ 2024)（未調査）
- PIEGraph (Orozco+ 2026)（参照のみ）

書誌情報

発表： CoRL 2025
リンク： https://arxiv.org/abs/2506.23126
系譜： 最新（← C-SWM ）
調査日： 2026-10-27
確認範囲： 全文（問題提起・手法・実験・結果・考察）

Training Transformers for Mesh-Based Simulations

Paul Garnier, Vincent Lannelongue, Jonathan Viquerat, Elie Hachem（Mines Paris - PSL, CEMEF）| arXiv 2025

1 どんなもの？

隣接行列をそのまま注意のマスクに使う Transformer でメッシュ上の流体を学習し、MeshGraphNet（MGN）と体系的に比べた。最小モデルは 7 倍速く 6 倍小さいまま MGN と同等、最大モデル（5100 万パラメータ）は従来最良を平均 38.8% 上回った。

2 先行研究と比べてどこがすごい？

メッセージパッシング型（MGN、BSMS-GNN、マルチグリッド）は受容野を広げるため階層化や K-hop で複雑になり、層や幅を増やすと辺上の逆伝播でメモリが尽きる。GATv2 や TransformerConv など注意つき GNN とも比較し、単純な構成で上回ることを示す。

3 技術や手法のキモはどこ？

$\mathrm{Attention}(Z)=A\odot\mathrm{softmax}(QK^{T}/\sqrt{d})V$ とし、エッジ特徴は使わずノード座標を位置情報とする。A を A^2（膨張）・ランダム辺 20% ・グローバルノード 1% で拡張して受容野を広げる。マスク事前学習ののち微調整し、60 超のモデルでスケーリング則を求めた。

4 どうやって有効だと検証した？

Cylinder・Plate・Airfoil・2D/3D 動脈瘤（最大 30 万ノード）で評価。3D-Aneurysm の全ロールアウト RMSE は 4825、MGN は 13747（Table 1）。最適なモデル規模は N∝C^0.75（Fig. 3）。ランダム辺は訓練時間 15% 増で誤差 15% 減（Fig. 4）。

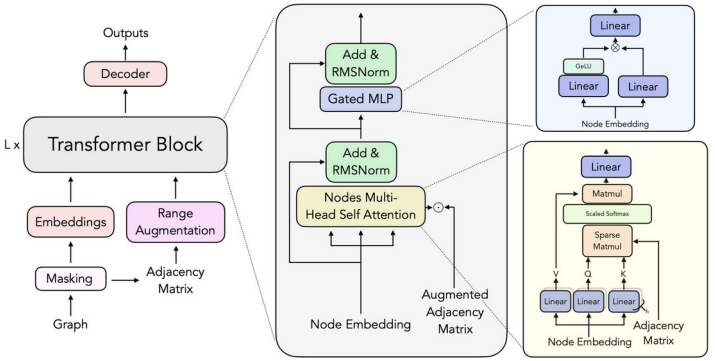
5 議論はある？

著者：接触とワールドエッジが重要な Plate では従来最良に届かない。座標を直接入れるので並進・回転に不変でない。

所感：査読前のプレプリントで、基準値には自前の再現値も含む。MGN との差がどこまで構造由来かは慎重に読みたい。

6 次に読むべき論文は？

- MeshGraphNets (2021)（本資料）
- MeshGraphNet-Transformer (Iparraguirre+ 2026)（参照のみ）
- Transolver (Wu+ 2024)（未調査）



出典：Mesh Transformer Fig. 7（隣接行列を拡張して注意マスクにする Transformer ブロックの構成）

書誌情報

発表： arXiv プレプリント 2025
リンク： https://arxiv.org/abs/2508.18051
系譜： 最新（← MeshGraphNets）
調査日： 2026-10-27
確認範囲： 全文（問題提起・手法・実験・結果・考察）

Improving Long-Range Interactions in Graph Neural Simulators via Hamiltonian Dynamics

Tai Hoang, Alessandro Trenta, Alessio Gravina ほか（カールスルーエ工科大・ピサ大）| ICLR 2026

1 どんなもの？

ポートハミルトン力学を潜在の時間発展とするグラフニューラルシミュレータ IGNS を提案。情報が散逸しないので遠いノードへ信号が届き、多段損失で真の軌道に沿わせて誤差の蓄積を抑える。衝撃が伝わる板の課題で MGN の誤差を約 45 分の 1 にした。

2 先行研究と比べてどこがすごい？

MGN など従来の GNS は 1 ステップ損失で学び自己回帰で回すため誤差が蓄積し、メッセージパッシングは過平滑化・過圧縮で長距離の依存を失う。多段損失（Lienen & Günnemann 2022）も GNN が不安定で短い窓に限られていた。A-DGN・GraphCON とも比較。

3 技術や手法のキモはどこ？

状態を一般化座標 q と運動量 p に分け、ẋ=J∇H − 減衰 + 外力 r_θ をシンプレクティック・オイラー法で積分する。H は近傍和の形で学習し、外力項が幾何情報を担う。開始前に l 回のウォームアップ伝搬を行い、窓 T 全体の多段損失で学習する。

4 どうやって有効だと検証した？

6 課題で評価。Impact Plate の MSE は IGNS 67.9、MGN 3096、HCMT 647（Table 1, 2）。Wave Balls は 0.37e-3 対 MGN 1.78e-3。多段損失を外すと誤差が約 94 倍、外力項を外すと大きく悪化（Table 3）。T=200 の長い窓でも安定（Fig. 3c）。

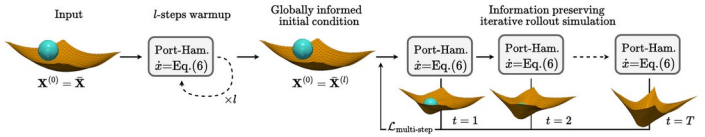
5 議論はある？

著者：開ループの設定で、観測によるフィードバックがない。逆設計や制御への展開は今後。

所感：Plate Def. では MGN がわずかに良く、Cylinder Flow は分割を変えた条件。訓練と評価の窓 T が同じで、窓を超える外挿は未検証。

6 次に読むべき論文は？

- GNS (2020)（本資料）
- MeshGraphNets (2021)（本資料）
- GraphCON (Rusch+ 2022)（未調査）



出典：IGNS Fig. 1（l 回のウォームアップで大域情報を持たせた初期状態から、ポートハミルトン動力学で展開し多段損失で学習）

書誌情報

発表： ICLR 2026
リンク： https://arxiv.org/abs/2511.08185
系譜： 最新（← MeshGraphNets）
調査日： 2026-10-27
確認範囲： 全文（問題提起・手法・実験・結果・考察）