階層的・多時間スケール生成モデル

予測符号化（Rao & Ballard 1999）、Friston の階層動的モデル、谷の MTRNN（2008）を原典に、
確率的 RNN（PV-RNN）、状態 - 行動階層（APC）、くりこみ生成モデル（RGM）へ発展。
2025–26 年は Habitat での階層 AIF、SR による状態 / 行動抽象の学習、RGM の再現実装、精度の自律調整が進む。

#	年	論文	発表	系譜
1	1999	予測符号化 (Rao & Ballard 1999)	Nature Neuroscience 1999	原典
2	2008	階層動的モデル HDM (Friston 2008)	PLoS Comput. Biol. 2008	原典
3	2008	MTRNN (Yamashita & Tani 2008)	PLoS Comput. Biol. 2008	原典
4	2019	PV-RNN (Ahmadi & Tani 2019)	Neural Computation 2019	発展
5	2022	APC (Rao+ 2022)	arXiv 2022 / Neural Comput. 2024	発展
6	2024	RGM (Friston+ 2024)	Front. Netw. Physiol. 2025	発展
7	2025	階層 AIF の移動マニピュレーション (Pezzato+ 2025)	IWAI 2025	最新
8	2026	SR による階層 AIF (Rangarajan & Rao 2026)	Neural Computation 2026	最新
9	2026	RGM の導出と検証済み実装 (Zaghw+ 2026)	IWAI 2026	最新
10	2026	メタ事前分布の自律調整 (Oyama+ 2026)	arXiv プレプリント 2026	最新

Predictive coding in the visual cortex: a functional interpretation of some extra-classical receptive-field effects

Rajesh P. N. Rao, Dana H. Ballard（Salk Institute）| Nature Neuroscience 1999

1 どんなもの？

視覚野の階層を「上位が下位の活動を予測し（フィードバック）、下位は予測誤差だけを上へ送る（フィードフォワード）」生成モデルとして定式化した予測符号化の原典。自然画像で学習した 3 層網が単純細胞様の受容野と端点抑制を再現した。

2 先行研究と比べてどこがすごい？

端点抑制など古典的受容野の外の効果は、曲率・遮蔽の検出など個別の機能で説明されてきた。本論文はそれらを「上位の予測が当たると誤差ニューロンが黙る」という一つの原理（網膜・LGN の予測符号化の皮質への拡張）から導いた。

3 技術や手法のキモはどこ？

各階層の予測推定器（PE）が生成モデル $I=f(Ur)+n$ を持ち、入力の誤差と上位予測 r_{td} との誤差の精度重み付き二乗和を勾配降下して r を推論、遅い時間スケールで基底 U を Hebb 則で学習する。上位ほど受容野が広がる。

4 どうやって有効だと検証した？

5 枚の自然画像のパッチで 3 層網を学習（Fig. 2）。誤差ニューロン 32 個中 28 個が端点抑制（50% 超）を示し、上位からのフィードバックを切ると 5 個に減った（82% 減 , Fig. 5）。周辺に同方位格子で応答 85.3% 抑制、方位コントラストで +19.1%（Fig. 6）。

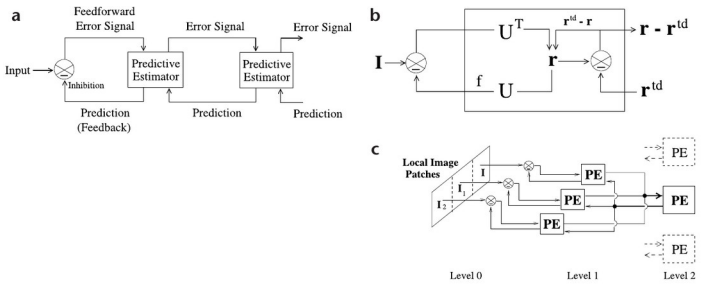
5 議論はある？

著者：横方向抑制や除算正規化でも同様の効果は出うる。MT・IT への一般化は今後。

所感：階層は空間スケールだけで、時間階層と行動はまだない。誤差を局所的に計算する点は、誤差を大域 BPTT で流す後の PV-RNN との大きな違いとして残る。

6 次に読むべき論文は？

- Hierarchical Models in the Brain (Friston 2008)（本資料）
- Active Predictive Coding (Rao+ 2022)（本資料）
- Predictive coding under the free-energy principle (Friston & Kiebel 2009)（未調査）



出典：Rao & Ballard 1999 Fig. 1（階層的予測符号化網と PE モジュール）

書誌情報

発表： Nature Neuroscience 1999
リンク： https://doi.org/10.1038/4580
系譜： 原典
調査日： 2026-10-24
確認範囲： 全文（問題提起・手法・実験・結果・考察）

Hierarchical Models in the Brain

Karl Friston（University College London）| PLoS Computational Biology 2008

1 どんなもの？

状態空間モデルを積み重ね「上位の出力が下位の原因（入力）になる」階層動的モデル（HDM）を提案。PCA・ICA・カルマンフィルタ・ブラインド逆畳み込みまでを単一の変分推論（DEM）で反転できることを示し、皮質の予測誤差伝播網として書き下した。

2 先行研究と比べてどこがすごい？

従来の状態空間モデルは揺らぎを白色（マルコフ）と仮定し高次の運動を捨てていた。本論文は一般化座標（位置・速度・加速度…）で滑らかな揺らぎを扱い、階層が「構造的な経験的事前分布」を、一般化運動が「動的な事前分布」を与えると整理した。

3 技術や手法のキモはどこ？

各層は v^(i−1)=g(x^(i),v^(i))+z 、ẋ^(i)=f(x^(i),v^(i))+w 。状態・パラメータ・精度を時間スケールで分けた平均場で最適化し、精度重み付き予測誤差が上へ、予測が下へ流れる。誤差を表層、予測を深層の錐体細胞に対応づけた。

4 どうやって有効だと検証した？

定量ベンチマークはない。因子分析や線形畳み込みモデル（原因 1・隠れ状態 2・出力 4）の模擬データで、状態・パラメータ・精度の三重推定が真値をおおむね 90% 信用区間に収めることを示した（Fig. 4–6）。EKF との比較は先行論文に委ねている。

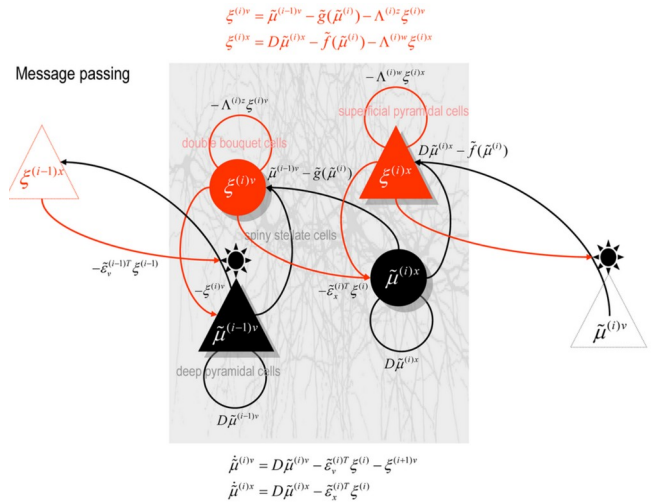
5 議論はある？

著者：ラプラス近似のため単峰の事後に限られ、大量の実証検証が必要と明言。

所感：連続時間・知覚中心で行動選択はまだない。だが「階層＝経験的事前分布、上位ほど遅い」という骨格は RGM まで一貫しており、この系譜の背骨になる論文。

6 次に読むべき論文は？

- Deep temporal models and active inference (Friston+ 2017)（readme 参照）
- From pixels to planning (Friston+ 2024)（本資料）
- A hierarchy of time-scales and the brain (Kiebel+ 2008)（未調査）



出典：Friston 2008 Fig. 8（1 階層ぶんの誤差ユニットと状態ユニットの回路対応）

書誌情報

発表： PLoS Comput. Biol. 2008
リンク：
https://doi.org/10.1371/journal.pcbi.1000211
系譜：原典（← 予測符号化（Rao & Ballard 1999））
調査日： 2026-10-24
確認範囲：全文（問題提起・手法・実験・結果・考察）

Emergence of Functional Hierarchy in a Multiple Timescale Neural Network Model: A Humanoid Robot Experiment

Yuichi Yamashita, Jun Tani（理化学研究所 脳科学総合研究センター）| PLoS Computational Biology 2008

1 どんなもの？

時定数の異なる 2 種の文脈ニューロン（速い τ=5、遅い τ=70）を持つ連続時間 RNN「MTRNN」を提案。明示的なモジュールなしに、速い層が再利用できる運動プリミティブ、遅い層がその順序を担う機能階層が自己組織化することを人型ロボットで示した。

2 先行研究と比べてどこがすごい？

MOSAIC など局所モジュールをゲートで切り替える階層モデルは、似た系列で汎化と分節が衝突し、上下の学習を実験者がサブゴールで分ける必要があった。MTRNN は空間的な階層構造ではなく「時間スケールの差」だけで階層を創発させる。

3 技術や手法のキモはどこ？

各ユニットは $\tau_i\, du_i/dt = -u_i + \Sigma_j\, w_ij\, x_j$ に従い、τ が大きいほど履歴を長く保つ。入力は遅い層に直結させず、遅い層の初期状態でタスク目標を指定。固有感覚 8 次元と視覚 2 次元の次時刻予測を BPTT で学習し、予測を目標関節角として出力する。

4 どうやって有効だと検証した？

小型人型ロボットで物体操作 5 種 × 物体位置 5 か所を学習し、実環境での再現成功率は平均 99.05%（Table 1）。遅い層の結合だけを追加学習して新しいプリミティブの組合せも再現（Fig. 7）。τ 比 1・2 では誤差が有意に悪化（$p<0.01$, Fig. 9）。

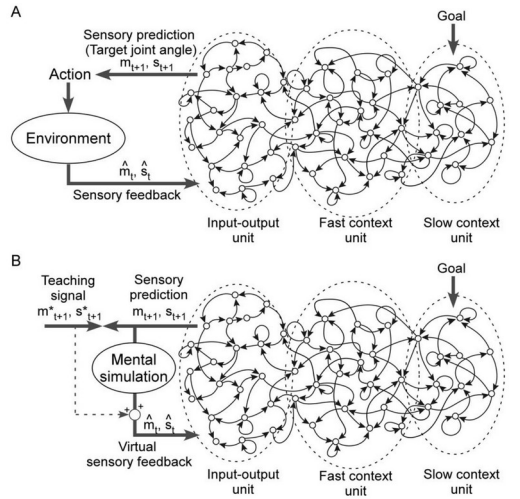
5 議論はある？

著者：初期状態の与え方や、入力と遅い層を結合しない制約も階層の創発に寄与しうる。

所感：決定論的 RNN で不確実性を表せず、行動も教示軌道の再生にとどまる。それでも Fujii & Murata（2025）の slow/fast 世界モデルまで直接受け継がれる設計。

6 次に読むべき論文は？

- PV-RNN (Ahmadi & Tani 2019)（本資料）
- Fujii & Murata (2025)（既存：deep-active-inference）
- CW-VAE (Saxena+ 2021)（既存：world-model/hierarchical）



出典：MTRNN Fig. 3（行動生成モードと学習モード、速い / 遅い文脈ユニット）

書誌情報

発表： PLoS Comput. Biol. 2008
リンク：
https://doi.org/10.1371/journal.pcbi.1000220
系譜：原典
調査日： 2026-10-24
確認範囲：全文（問題提起・手法・実験・結果・考察）

A Novel Predictive-Coding-Inspired Variational RNN Model for Online Prediction and Recognition

Ahmadreza Ahmadi, Jun Tani（沖縄科学技術大学院大学）| Neural Computation 2019

1 どんなもの？

MTRNN の各層に確率的潜在変数を加えた変分 RNN「PV-RNN」を提案。KL 項の重み（メタ事前分布 w）で決定論的カオスから確率過程までを連続的に切り替えられ、中間の w で系列の確率的構造を最もよく抽出・汎化することを示した。

2 先行研究と比べてどこがすごい？

VRNN など従来の変分 RNN は入力を順伝播で与えるため潜在変数が無視されやすく、未来の情報を事後分布に渡すには逆向き RNN が要った。PV-RNN は入力を使わず、予測誤差の BPTT だけで適応ベクトル A を更新して両方の問題を避ける。

3 技術や手法のキモはどこ？

損失は予測誤差と w·KL[q(Z)‖p(Z|d)] の和（重み付き ELBO）。テスト時は直近の時間窓の A を予測誤差で繰り返し最適化する「誤差回帰」で潜在状態を推論し未来を予測する。上位層ほど時定数が大きい MTRNN 構造で多時間スケールを表す。

4 どうやって有効だと検証した？

確率的有限状態機械の系列で、w 大は丸暗記、w 小はランダムな生成になった（Table 1）。手描きプリミティブ列では w0=0.25 が 3 プリミティブ先の予測で 59.4% と最良（w0=1.0 は 40.6%, Table 4）。ロボット同期模倣の 5 歩先 MSE は 0.0047（VRNN 0.0094, Table 5）。

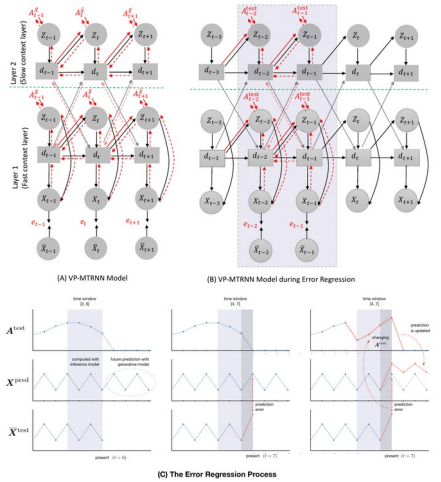
5 議論はある？

著者：最適な w は格子探索頼みで、学習させると収束しない。誤差回帰は 1 歩 205 ms で実時間に間に合わない。

所感：w は事前分布の精度にあたり、自閉症の「強すぎる事前」仮説とつながる。精度のオンライン調整は Oyama+（2026, 本資料）で扱われる。

6 次に読むべき論文は？

- Predictive-Coding-Based Autonomous Regulation … (Oyama+ 2026)（本資料）
- Fujii & Murata (2025)（既存：deep-active-inference）
- Variational Recurrent Neural Network (Chung+ 2015)（未調査）



出典：PV-RNN Fig. 1（2 層 MTRNN 上の生成 / 推論モデルと誤差回帰）

書誌情報

発表： Neural Computation 2019
リンク： https://arxiv.org/abs/1811.01339
系譜： 発展（← MTRNN (Yamashita & Tani 2008)）
調査日： 2026-10-24
確認範囲： 全文（問題提起・手法・実験・結果・考察）

Active Predictive Coding: A Unified Neural Framework for Learning Hierarchical World Models for Perception and Planning

Rajesh P. N. Rao, Dimitrios C. Gklezakos, Vishwas Sathish（ワシントン大学）| arXiv 2022（改訂版は Neural Computation 2024 ）

1 どんなもの？

上位の状態・行動の埋め込みベクトルがハイパーネットで下位の状態遷移 RNN と方策 RNN を生成する 2 層の「能動的予測符号化（ APC ）」を提案。同じ枠組みで画像の部分 - 全体階層の解析と、部屋型迷路の階層計画（オプション学習）を解いた。

2 先行研究と比べてどこがすごい？

従来の予測符号化は知覚の階層表現にとどまって行動を扱わず、階層 RL のオプション研究は状態抽象と行動抽象を同時に学ぶ点が手薄だった。APC は Hinton の部分 - 全体、Hawkins の入れ子の参照枠、状態 - 行動階層の 3 問題を一つのモデルで扱う。

3 技術や手法のキモはどこ？

上位状態 R_t が θ_s=H_s(R_t) で下位の遷移関数（局所参照枠）を、上位行動 A_t が θ_a=H_a(A_t) で下位方策（オプション）を生成する。下位はグリンプスの予測誤差で状態を更新し、一定ステップ後に上位へ要約を返す。状態網は自己教師、行動網は REINFORCE で学習。

4 どうやって有効だと検証した？

画像再構成 MSE で 2 層の APC-2 が 1 層やランダム視線を上回った（ MNIST 0.0085 vs 0.0114/0.0120, Table 1 ）。未学習の Omniglot 文字への転移でも最良（ 0.0226 ）。迷路では上位 3 手で計画でき、目標変更後も RL と違ってすぐ適応した（ Fig. 10 ）。

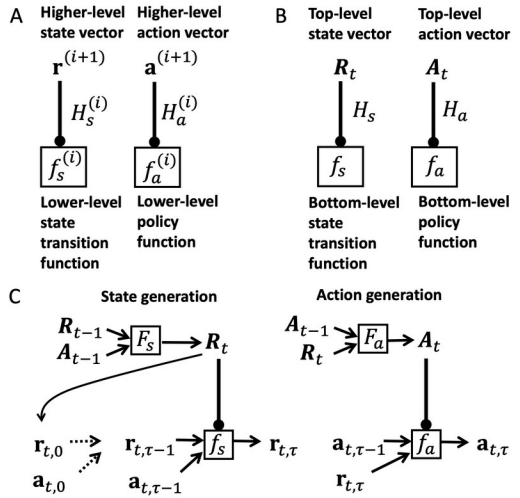
5 議論はある？

著者：各レベルの実行ステップ数が固定で、階層は 2 層だけ。

所感：計画は上位でのランダムシューティング MPC で、自由エネルギーや認識的価値は使っていない。能動的推論との接続は後継の Rangarajan & Rao（ 2026 ）で果たされる。

6 次に読むべき論文は？

- Hierarchical Active Inference using Successor Representations (2026)（本資料）
- Director (Hafner+ 2022)（既存：world-model/hierarchical ）
- The Option-Critic Architecture (Bacon+ 2017)（未調査）



出典：APC Fig. 1（ハイパーネットで状態 / 行動の下位関数を生成するモジュール）

書誌情報

発表： arXiv 2022 / Neural Comput. 2024
リンク： https://arxiv.org/abs/2210.13461
系譜：発展（← 予測符号化 (Rao & Ballard 1999) ）
調査日： 2026-10-24
確認範囲：全文（問題提起・手法・実験・結果・考察）

From pixels to planning: scale-free active inference

Karl Friston, Conor Heins, Tim Verbelen ほか（University College London / VERSES）| arXiv 2024（Frontiers in Network Physiology 2025）

1 どんなもの？

POMDP に「経路（path）」を潜在変数として加え、上位の状態が下位の群の初期状態と経路を生成する「くりこみ生成モデル（RGM）」を提案。同じ構造学習と推論で、画像分類、動画・音楽の圧縮と生成、Atari 風ゲームの計画を一つの離散モデルで扱った。

2 先行研究と比べてどこがすごい？

離散状態の能動的推論は状態と方策の数が爆発し、小規模な問題に限られていた。RGM は繰り込み群のブロック変換で空間と時間を粗視化し、上位ほど遅く広い原因を表すスケール不変な階層を「データから自動で組み立てる」点が新しい。

3 技術や手法のキモはどこ？

下位を近傍ごとにまとめ、出現した局所パターンを一つの状態として尤度 D・経路 E・遷移 B を作る（高速構造学習）。各状態の子は重ならないため、階層は条件付き独立で小さな行列の和積で反転できる。行動は期待自由エネルギー最小の経路予測を反射で実現する。

4 どうやって有効だと検証した？

MNIST は各数字 13 枚で 4 層の RGM を組み 1 万枚で能動学習、テスト 1000 枚で正解率 95.1%、尤度の高い半分では 99.8%（Fig. 8）。Pong は乱択 2.1 万フレームから報酬間の 1024 枚だけを選んで約 18 秒で構造学習し、233 事象に圧縮してミスなくプレイ（Fig. 26–27）。

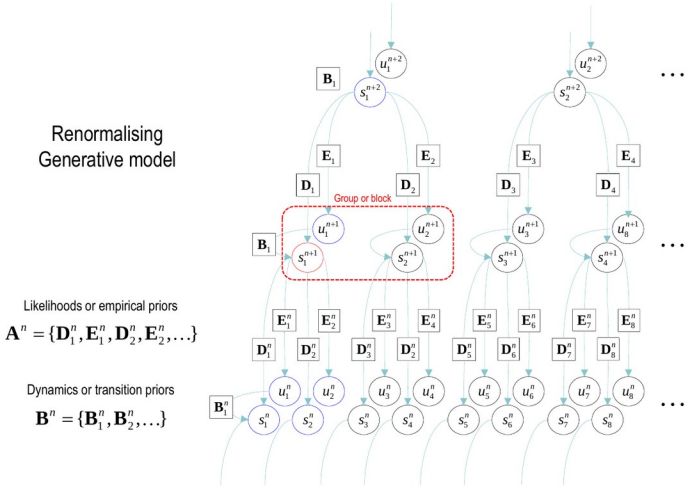
5 議論はある？

著者：性能ベンチマークは意図的に行わず、最小構造ゆえ未経験の事象には脆い。

所感：構造学習は「報酬で選んだデータの圧縮記憶」に近く、汎化性能や Dreamer などとの比較がない。後続の Zaghw+（2026）も定量評価を今後の課題としている。

6 次に読むべき論文は？

- Renormalising Generative Models for Active Inference (Zaghw+ 2026)（本資料）
- Deep temporal models and active inference (Friston+ 2017)（readme 参照）
- AXIOM (Heins+ 2025)（既存：deep-active-inference）



出典：RGM Fig. 3（状態と経路を群ごとに生成するくりこみ生成モデルの構造）

書誌情報

発表： Front. Netw. Physiol. 2025
リンク： https://arxiv.org/abs/2407.20292
系譜： 発展（← HDM (Friston 2008)）
調査日： 2026-10-24
確認範囲： 全文（問題提起・手法・実験・結果・考察）

Mobile Manipulation with Active Inference for Long-Horizon Rearrangement Tasks

Corrado Pezzato, Ozan Çatal, Toon Van de Maele ほか（VERSES AI Research Lab）| IWAI 2025（CCIS, 2026）

1 どんなもの？

離散 POMDP の上位能動的推論がスキル（移動・把持・配置・引出しや冷蔵庫の操作）を選び、連続の階層的能動的推論による全身制御器がそれを実行する完全階層型エージェントを構築。Habitat の長期再配置 3 タスクで最先端の RL 手法を上回った。

2 先行研究と比べてどこがすごい？

能動的推論は 2D 課題や眼球運動の模擬が中心で、現代のロボティクスベンチマークで最先端と互角以上を示した例はなかった。強力な基線 MM（Gu+ 2022）は技能ごとに 1 億ステップの学習を要するが、本手法はオフライン学習なしで動く。

3 技術や手法のキモはどこ？

上位の行動が下位の選好（目標）になる「普遍的生成モデル」。失敗時の再試行モデルが接近方向を切り替え、最下層は関節角（内在）と手先姿勢（外在）の信念を予測誤差で更新し、腕の誤差を台車にも伝えて全身で自由エネルギーを下げる（式 12）。

4 どうやって有効だと検証した？

Fetch ロボットで TidyHouse・PrepareGroceries・SetTable を評価。最終段の成功率は 72.5/77/50% で、MM 基線の 71/64/29% を上回り、3 タスク平均は 66.5% vs 54.7%（Fig. 4、5 シード）。モノリシック RL は大きく劣った。

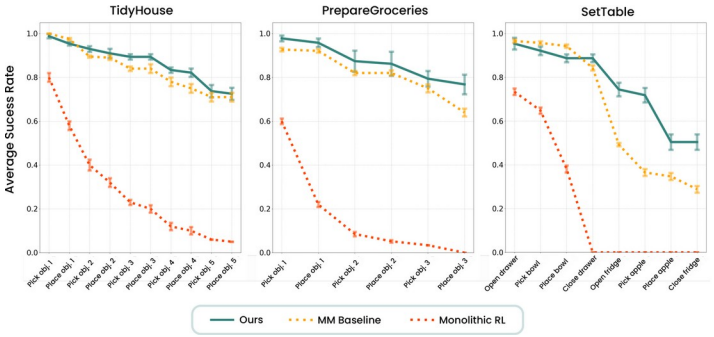
5 議論はある？

著者：床地図や関節物体の状態など特権情報に依存し、スキルは固定の目標列を手で調整。

所感：階層の各層は手設計で、状態・行動の抽象は学習していない。RGM や SR 階層のような自動抽象化と組み合わせられるかが次の焦点。

6 次に読むべき論文は？

- Deep kinematic inference … (Priorelli+ 2023)（未調査）
- Hierarchical Active Inference using Successor Representations (2026)（本資料）
- Multi-skill Mobile Manipulation (Gu+ 2022)（未調査）



出典：Pezzato+ 2025 Fig. 4（Habitat 3 タスクの段階別成功率）

書誌情報

発表： IWAI 2025
リンク： https://arxiv.org/abs/2507.17338
系譜： 最新（← HDM (Friston 2008)）
調査日： 2026-10-24
確認範囲： 全文（問題提起・手法・実験・結果・考察）

Hierarchical Active Inference using Successor Representations

Prashant Rangarajan, Rajesh P. N. Rao（ワシントン大学）| Neural Computation 2026

1 どんなもの？

下位で学習した後続表現（SR）行列をスペクトルクラスタリングして「マクロ状態」を作り、ボトルネック状態へ向かう下位方策を能動的推論で学んで「マクロ行動」とし、上位でも SR と集約した EFE で計画する階層的能動的推論を提案した。

2 先行研究と比べてどこがすごい？

能動的推論は方策の組合せ爆発で大規模化が難しく、Friston 系の階層モデルは階層を人手の因子分解で与えていた。本手法は状態抽象と行動抽象（options）の両方を SR から学習し、FEP 系の脳理論でこれを示したのは初めてと著者は主張する。

3 技術や手法のキモはどこ？

SR $M=(I-\gamma T)^{-1}$ を TD 学習し、報酬の代わりに 1 ステップの EFE を使った $\nu(s)=\Sigma\, M(s,s')G(s')$ で行動を選ぶ（Millidge & Buckley 2023 の拡張）。マクロ状態の EFE は所属するミクロ状態の和とし、上位 SR で ν が最大のマクロ状態へ向かうマクロ行動を選ぶ。

4 どうやって有効だと検証した？

Gridworld で平坦 AIF は階層版の約 10 倍のエピソードを要し、R-stability は 0.281（平坦 0.677、Q 学習 0.526, Fig. 6）。Mountain Car の計画ステップは 8 対 105（Fig. 17）、PointMaze UMaze は 4 対 135。到達ゴール数は階層 5/5・5/5・6/6、平坦 5/5・2/5・0/6（Fig. 23）。

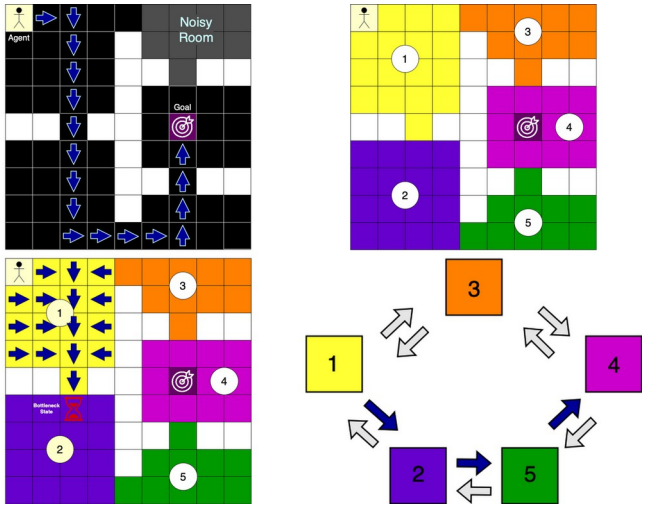
5 議論はある？

著者：連続空間は離散化が必要で、深層化（特徴ベース SR）と 3 層以上は今後。

所感：POMDP 版で雑音の多い部屋を避ける「不確実性と報酬の折衷」が EFE から出る（Fig. 13–15）のは能動的推論らしい。ただしクラスタ数は事前に固定で、抽象の粒度自体は選んでいない。

6 次に読むべき論文は？

- Active Predictive Coding (Rao+ 2022)（本資料）
- Successor Representation Active Inference (Millidge & Buckley 2023)（未調査）
- From pixels to planning (Friston+ 2024)（本資料）



出典：Rangarajan & Rao Fig. 1（五部屋環境、SR 由来のマクロ状態・マクロ行動・上位計画）

書誌情報

発表： Neural Computation 2026
リンク： https://arxiv.org/abs/2604.15679
系譜： 最新（← APC (Rao+ 2022)）
調査日： 2026-10-24
確認範囲： 全文（問題提起・手法・実験・結果・考察）

Renormalising Generative Models for Active Inference: Foundations, Derivations, and Verification

Karim Zaghw, Andrew Pashea, Marc Pritsch ほか（テュービンゲン大学）| IWAI 2026

1 どんなもの？

RGM の生成モデル・推論・計画・能動学習・高速構造学習を局所的な変分メッセージとして一から導き直し、SPM（MATLAB）の参照実装を Python に翻訳してオラクルテストで一致を検証した再現研究。公開コードで RGM の参入障壁を下げる。

2 先行研究と比べてどこがすごい？

原論文（Friston+ 2024）は数式が圧縮的で、参照実装は SPM の手続き的なコードに埋もれていた。本論文は固定点方程式と実際に動くアルゴリズムの違い（E[log A] と log E[A]、フィルタ型の更新、硬い要約の上方伝達）を初めて明示した。

3 技術や手法のキモはどこ？

上位状態は D で下位の初期状態、E で初期経路の経験的事前分布を与え、下位の事後要約が上位の観測になる。構造学習は、相互情報量行列の主固有ベクトルでサイトを群にまとめ、繰り返す局所パターンを状態、遷移の分岐を経路とする操作として定式化した。

4 どうやって有効だと検証した？

SPM の Drone VI と Atari III（Pong 型）などの実演を Python で再現し、MATLAB 出力と相対誤差 10^{-7}・絶対誤差 10^{-12} の許容で全テストに合格（付録 Table 1）。RG の群分けは 58 群中 51 群が一致し、エージェントの挙動は保たれた。

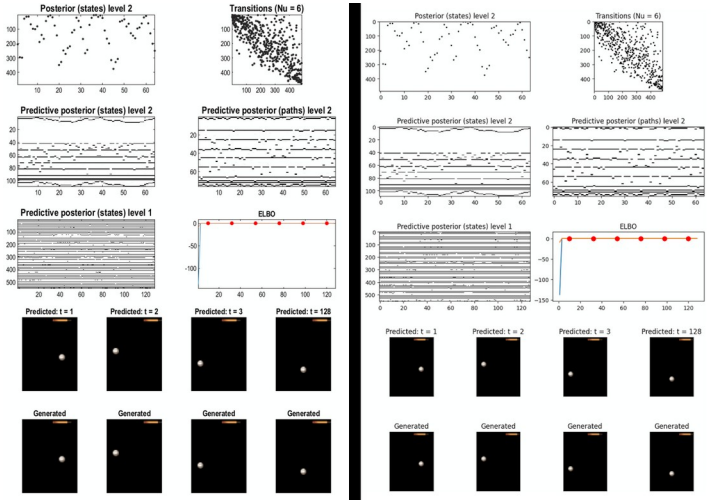
5 議論はある？

著者：検証は SPM 実装への忠実さであって RGM 自体の有効性ではなく、対象も 3 つの実演に限られる。

所感：性能評価のない基盤論文。この実装を土台に、深層世界モデル（Dreamer 系）と定量比較できるかが RGM 系譜の正念場になる。

6 次に読むべき論文は？

- From pixels to planning (Friston+ 2024)（本資料）
- Gradient-free de novo learning (Friston+ 2025)（未調査）
- AXIOM (Heins+ 2025)（既存：deep-active-inference）



出典：Zaghw+ 2026 Fig. 1（Atari III の MATLAB 出力〈左〉と Python 再現〈右〉）

書誌情報

発表： IWAI 2026
リンク： https://arxiv.org/abs/2608.09512
系譜： 最新（← RGM (Friston+ 2024)）
調査日： 2026-10-24
確認範囲： 全文（問題提起・手法・実験・結果・考察）

Predictive-Coding-Based Autonomous Regulation of Internally Generated and Externally Coupled Processing in Human-Robot Interaction

Henrique Oyama, Hiroki Sawada, Jun Tani（沖縄科学技術大学院大学）| arXiv プレプリント 2026

1 どんなもの？

2 層の PV-RNN（時定数 3 と 6 ）で、直近 100 ステップの再構成誤差の蓄積に応じてメタ事前分布 w を高（事前分布に従う内部生成的処理）と低（感覚に結合した処理）の間で確率的に切り替える機構を提案し、人型ロボットとの物理的インタラクションで検証した。

2 先行研究と比べてどこがすごい？

PV-RNN 系の研究は w を固定するか外から切り替えるだけで、事前の予測と感覚証拠の釣り合い（精度）をいつ変えるかを系自身が決めることはできなかった。本研究は自分の推論の不一致履歴を、次の推論条件を決める高次の信号として使う。

3 技術や手法のキモはどこ？

誤差回帰で窓内の事後を更新したあと、窓平均の再構成誤差 $\bar{E}$ を計算し、閾値 2 つ（ヒステリシス）と温度つきシグモイドで w_H=1.0 ⇔ w_L=0.01（課題 3 は 0.001 ）の遷移確率を決める。学習済みの生成モデルのパラメータは固定し、推論の条件だけを調整する。

4 どうやって有効だと検証した？

Torobo で 3 課題を 4 モデルで評価。固定プリミティブ課題では低 w で再構成誤差 0.0287→0.0094 、1 歩先予測誤差 0.328→0.115 、過剰トルク 6.86→3.57 N·m（ Fig. 4 ）。自由な課題 3 でも予測誤差 0.432→0.345 、トルク 13.1→10.9 N·m（ Fig. 6 ）。

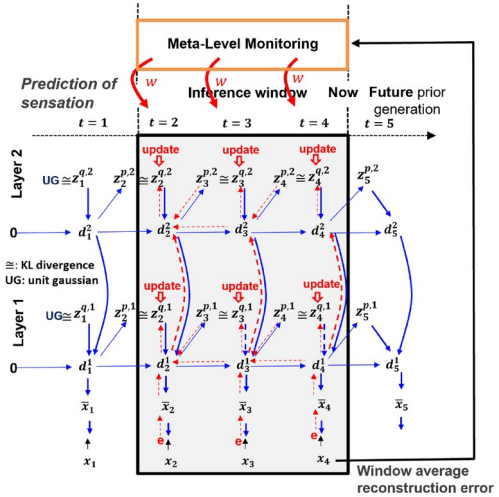
5 議論はある？

著者：切替規則と閾値は手設計で、w 固定の基線との比較はまだ。再構成誤差は感覚の信頼性を区別できない。

所感：精度を「推論の推論」で決める点は能動的推論の精度最適化そのもの。上位層と下位層で別の w を自律調整できれば階層の意味が深まる。

6 次に読むべき論文は？

- PV-RNN (Ahmadi & Tani 2019)（本資料）
- Free-Energy-Gated Plasticity … (Sawada & Tani 2026)（未調査）
- Modeling Autonomous Shifts … Mind-Wandering (Oyama+ 2025)（未調査）



出典：Oyama+ 2026 Fig. 1（ 2 層 PV-RNN と誤差履歴によるメタ事前分布の調整）

書誌情報

発表： arXiv プレプリント 2026
リンク： https://arxiv.org/abs/2609.06888
系譜： 最新（← PV-RNN (Ahmadi & Tani 2019) ）
調査日： 2026-10-24
確認範囲： 全文（問題提起・手法・実験・結果・考察）