# 言語から報酬・目標を生成する行動獲得

言語で書かれた課題を報酬・成功判定に変え、行動デモなしに新しい行動を強化学習で獲得する研究の系譜。
LEARN（言語→形状報酬）から、LLM が報酬コードを書く系（L2R→Eureka→RDA・BIRD）と、VLM が観測を採点する系（VLM-RMs→RL-VLM-F→RoboReward・SOLE-R1・Demo2Reward）に分かれた。
2026 年は未学習課題への汎化と報酬ハッキングの評価が焦点。

| # | 年 | 論文 | 発表 | 系譜 |
|---|---|---|---|---|
| 1 | 2019 | LEARN (Goyal+ 2019) | IJCAI 2019 | 原典 |
| 2 | 2023 | Language to Rewards (Yu+ 2023) | CoRL 2023 | 発展 |
| 3 | 2023 | Eureka (Ma+ 2023) | ICLR 2024 | 発展 |
| 4 | 2023 | VLM-RMs (Rocamonde+ 2023) | ICLR 2024 | 発展 |
| 5 | 2024 | RL-VLM-F (Wang+ 2024) | ICML 2024 | 発展 |
| 6 | 2026 | RoboReward (Lee+ 2026) | arXiv プレプリント 2026 | 最新 |
| 7 | 2026 | SOLE-R1 (Schroeder+ 2026) | arXiv プレプリント 2026 | 最新 |
| 8 | 2026 | Demo2Reward (Gumbsch+ 2026) | arXiv プレプリント 2026 | 最新 |
| 9 | 2026 | RDA (Lee+ 2026) | RLC 2026 | 最新 |
| 10 | 2026 | BIRD (Bhamidipaty+ 2026) | arXiv プレプリント 2026 | 最新 |

# Using Natural Language for Reward Shaping in Reinforcement Learning

Prasoon Goyal, Scott Niekum, Raymond J. Mooney（The University of Texas at Austin）| IJCAI 2019

## 1 どんなもの？

自然言語の指示と過去の行動列から「指示に沿っているか」を判定する LEARN を学習し、その確率を形状報酬として RL に加える。Montezuma's Revenge の 15 課題で、同じ相互作用数での成功回数が言語なしより平均 60% 増えた。

## 2 先行研究と比べてどこがすごい？

報酬整形（Ng+ 1999）は効くが設計が難しい。Williams+ 2017 らの言語→報酬は事前定義の物体・関係に依存し、AGILE（Bahdanau+ 2018）は RL 中に報酬モデルを同時学習する。LEARN は（軌跡，言語）対からオフラインで対応を学ぶ。

## 3 技術や手法のキモはどこ？

行動頻度ベクトル f と指示 I から RELATED/UNRELATED を分類（負例は言語の差し替えとランダムな f）。ポテンシャル $\phi = p_R - p_U$ から $R_lang = \gamma\,\phi(f_t) - \phi(f_\{t-1\})$ を作り、最適方策を変えずに外的報酬に足す。

## 4 どうやって有効だと検証した？

人のプレイ 20 軌跡を 3 秒クリップに切り、AMT で 6,870 文を収集。PPO 50 万ステップで成功回数は Ext+Lang 1529 vs ExtOnly 903（Fig. 4）。AUC は 15 課題中 11 で有意に改善、1 課題で悪化した。

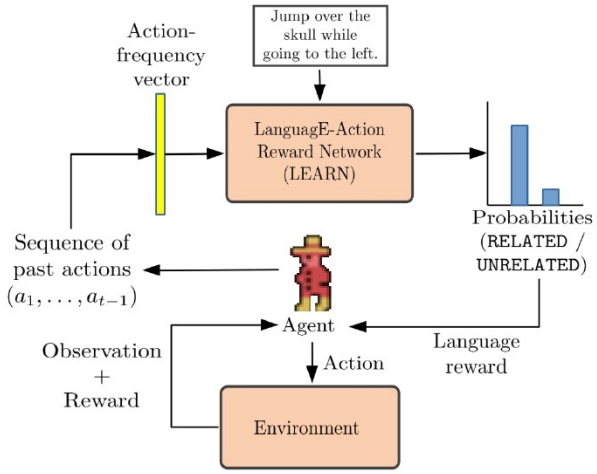
## 5 議論はある？

著者：行動頻度だけを見るため、物体を指す指示・時間順序・複数段の指示は扱えない。「jump」を含む指示の接地は雑音が多い。

所感：外的報酬は別途必要で、言語は探索の補助に留まる。本テーマの出発点。

## 6 次に読むべき論文は？

- AGILE (Bahdanau+ 2018)（未調査）
- Language to Rewards (Yu+ 2023)（本資料）
- VLM-RMs (Rocamonde+ 2023)（本資料）




出典：LEARN Fig. 2（行動頻度ベクトルと指示から言語報酬を出し、環境報酬に加える枠組み）

## 書誌情報

**発表：** IJCAI 2019
**リンク：** https://arxiv.org/abs/1903.02020
**系譜：** 原典
**調査日：** 2026-10-25
**確認範囲：** 全文（問題提起・手法・実験・結果・考察）

# Language to Rewards for Robotic Skill Synthesis

Wenhao Yu, Nimrod Gileadi, Chuyuan Fu ほか（Google DeepMind）| CoRL 2023

## 1 どんなもの？

GPT-4 に言語指示から報酬関数のパラメータを書かせ、MuJoCo MPC で実時間に最適化して動作を合成する。四脚ロボットと器用な手の 17 課題の 90% を解き、プリミティブを呼び出す Code-as-Policies（50%）を上回った。

## 2 先行研究と比べてどこがすごい？

SayCan や Code-as-Policies は LLM を既存プリミティブの組合せ役に留め、新しい低レベル技能は作れない。LLM は関節指令を直接出せない。LEARN など言語→報酬の先行研究は対応付けの学習データを要した。

## 3 技術や手法のキモはどこ？

2 段の Reward Translator：Motion Descriptor が指示を定型テンプレートの動作記述に展開し、Reward Coder が報酬 API 呼び出しのコードに変える。報酬は $R=-\Sigma\ w_i\ n_i(r_i(s,a,\phi_i))$ で、LLM が重み $w$ と目標値 $\phi$ を決める。

## 4 どうやって有効だと検証した？

四脚 9 課題、Franka + Shadow Hand 8 課題。各課題 10 回生成 ×50 回試行。17 中 11 課題で有意に高く、Motion Descriptor を外すと引出し開けなどで失敗（Fig. 4）。対話修正でムーンウォーク、実機で押し・把持も示した。

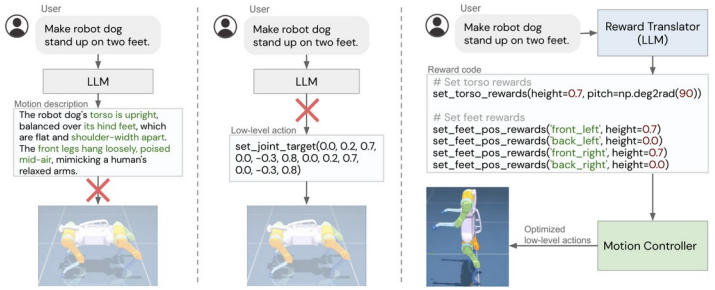
## 5 議論はある？

著者：ロボットごとのテンプレートは手作業。「優雅に歩く」など言語化しにくい課題は苦手で、事前定義の報酬項に縛られ時変報酬も書けない。

所感：学習なしで即座に結果が見えるのが強み。報酬項の設計が実質の事前知識。

## 6 次に読むべき論文は？

- Eureka (Ma+ 2023)（本資料）
- Text2Reward (Xie+ 2023)（未調査）
- Code as Policies (Liang+ 2023)（未調査）




出典：Language to Rewards Fig. 1（LLM は動作記述や関節指令を直接実行できないが、報酬コードを介せば MPC が動作を合成できる）

### 書誌情報

**発表：** CoRL 2023
**リンク：** https://arxiv.org/abs/2306.08647
**系譜：** 発展（← LEARN (Goyal+ 2019)）
**調査日：** 2026-10-25
**確認範囲：** 全文（問題提起・手法・実験・結果・考察）

# Eureka: Human-Level Reward Design via Coding Large Language Models

Yecheng Jason Ma, William Liang, Guanzhi Wang ほか（NVIDIA / University of Pennsylvania）| ICLR 2024

## 1 どんなもの？

環境のソースコードと課題文だけを GPT-4 に渡して報酬コードを書かせ、RL の結果で進化的に改良する Eureka 。10 種のロボット・29 課題の 83% で専門家の報酬を上回り（平均正規化改善 52% ）、Shadow Hand のペン回しを初めて実現した。

## 2 先行研究と比べてどこがすごい？

L2R は課題別テンプレートと報酬 API に縛られ、高次元の器用な操作で伸びない。従来の進化的報酬探索（ Niekum+ 2010 など）もテンプレート内のパラメータ探索だった。Eureka は自由形式の報酬プログラムを一から書く。

## 3 技術や手法のキモはどこ？

① 環境コードを文脈に入れ、実行可能な報酬を零ショット生成。② 各反復 K=16 個を IsaacGym で並列に RL 評価し、最良を変異させる進化探索。③報酬の各成分と適合度の学習中の推移を文章化した reward reflection を次のプロンプトに渡す。

## 4 どうやって有効だと検証した？

Isaac 9 課題・Dexterity 20 課題で、Isaac 全課題と Dexterity 15 課題で人の報酬以上、L2R は高次元で大差（ Fig. 4 ）。reflection を外すと正規化スコア 28.6% 減。人の文章フィードバックで、より安定な走りを 20 人中 15 人が選んだ（ Fig. 9 ）。

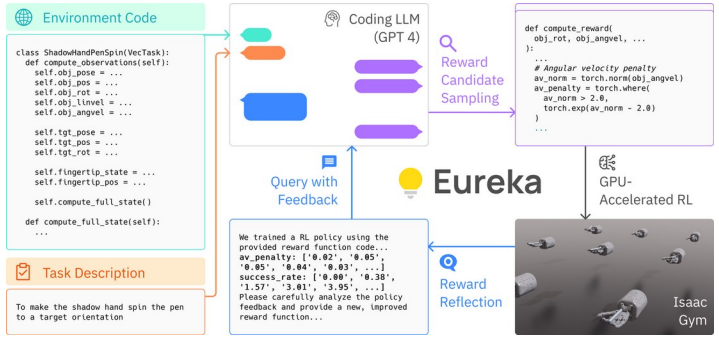
## 5 議論はある？

著者：適合度関数 F（成否判定）を人が定義できる前提で、「安定した歩き方」のような課題は書けない。動画を VLM に見せるフィードバックを今後の方向とする。

所感：成否は人の書いた F が支える。ここが RDA・BIRD の論点になる。

## 6 次に読むべき論文は？

- DrEureka (Ma+ 2024)（未調査）
- RDA (Lee+ 2026)（本資料）
- BIRD (Bhamidipaty+ 2026)（本資料）
- ReEvo (Ye+ 2024)（既存：swarm-intelligence/metabbo ）




出典：Eureka Fig. 2（環境コードと課題文から報酬候補を生成→ GPU 並列 RL で評価→ reward reflection で改良）

## 書誌情報

**発表：** ICLR 2024
**リンク：** https://arxiv.org/abs/2310.12931
**系譜：**発展（← Language to Rewards (Yu+ 2023) ）
**調査日：** 2026-10-25
**確認範囲：**全文（問題提起・手法・実験・結果・考察）

# Vision-Language Models are Zero-Shot Reward Models for Reinforcement Learning

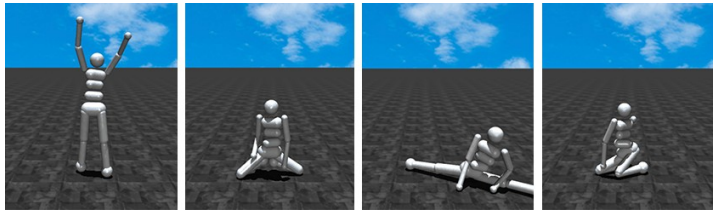
Juan Rocamonde, Victoriano Montesinos, Elvis Nava, Ethan Perez, David Lindner（FAR AI / ETH Zurich ほか）| ICLR 2024

## 1 どんなもの？

CLIP の画像埋め込みと一文の課題文の cos 類似度をそのまま報酬にする VLM-RM 。MuJoCo の人型に「ひざまずく」「蓮華座」「開脚」などを報酬設計なしで学ばせ、8 課題中 5 課題で成功率 100%（人手評価）を得た。

## 2 先行研究と比べてどこがすごい？

VLM で報酬を作る先行研究は CLIP の微調整（Mahmoudieh+ 2022 ）や成功判定器の学習（Du+ 2023 ）など、課題固有のデータや複雑な手順を要した。本研究は微調整なしで、正解報酬のない姿勢課題まで学習できると示した。



出典：VLM-RMs Fig. 1（CLIP 報酬だけで学んだ人型：腕上げ・蓮華座・開脚・ひざまずき）

## 3 技術や手法のキモはどこ？

報酬 R=cos(CLIP_L(l), CLIP_I(φ(s))) 。任意で「a humanoid robot」のような基準文 b を与え、状態埋め込みを b→g 方向へ射影する Goal-Baseline 正則化（強さ α ）で無関係な成分を除く。SAC/DQN の報酬だけを差し替える。

## 4 どうやって有効だと検証した？

CartPole と質感付き MountainCar は成功率 100% 、質感なしでは失敗（Fig. 2 ）。人型は 100 軌跡の人手評価（Table 1 ）。CLIP が大きいほど EPIC 距離が対数線形に改善し、ひざまずきは最大の ViT-bigG-14 だけが成功、他は 0% （Fig. 4 ）。

## 5 議論はある？

著者：一文で意図を伝えきれない複雑な課題では報酬が誤指定になりやすく、独立した監視が要る。腕組みなどの微妙な姿勢は区別できない。

所感：背景の質感やカメラ位置の調整が成否を分けた。報酬ハッキングへの耐性は未検証。

## 6 次に読むべき論文は？

- RoboCLIP (Sontakke+ 2023)（未調査）
- LAMP (Adeniji+ 2023)（未調査）
- RL-VLM-F (Wang+ 2024)（本資料）

## 書誌情報

**発表：** ICLR 2024
**リンク：** https://arxiv.org/abs/2310.12921
**系譜：** 発展（← LEARN (Goyal+ 2019) ）
**調査日：** 2026-10-25
**確認範囲：** 全文（問題提起・手法・実験・結果・考察）

# RL-VLM-F: Reinforcement Learning from Vision Language Foundation Model Feedback

Yufei Wang, Zhanyi Sun, Jesse Zhang ほか（Carnegie Mellon University / USC）| ICML 2024

## 1 どんなもの？

課題の一文と画像観測だけで、VLM（Gemini-Pro・GPT-4V）に「どちらの画像が目標に近いか」を答えさせ、その選好から報酬モデルを学ぶ RL-VLM-F 。布の対角折りなど 7 課題で全ベースラインを上回り、6 課題で正解報酬由来の選好と同等以上だった。

## 2 先行研究と比べてどこがすごい？

Eureka や Text2Reward は環境コードと低次元の真の状態を前提とし、変形物体には書きにくい。Motif は状態の文章記述が要る。CLIP 類似度（VLM-RMs）や RoboCLIP の生スコアは分散が大きく雑音が多い。

## 3 技術や手法のキモはどこ？

生スコアを出させず、画像の対比較で選好ラベル $y \in \{0,1,-1\}$ を得て Bradley-Terry 損失で報酬 $r_\phi$ を学ぶ（PEBBLE 上で SAC と交互更新）。VLM には「分析→ラベル付け」の 2 段プロンプトを全課題共通で与える。

## 4 どうやって有効だと検証した？

CartPole 、MetaWorld 3 課題、SoftGym 3 課題（布・ロープ・水運び）、5 seeds 。CLIP/BLIP-2 スコアは CartPole しか解けず、VLM の直接スコアも全課題で劣る（Fig. 4）。画像間の進捗差が大きいほど選好の正答率が上がる（Fig. 6）。

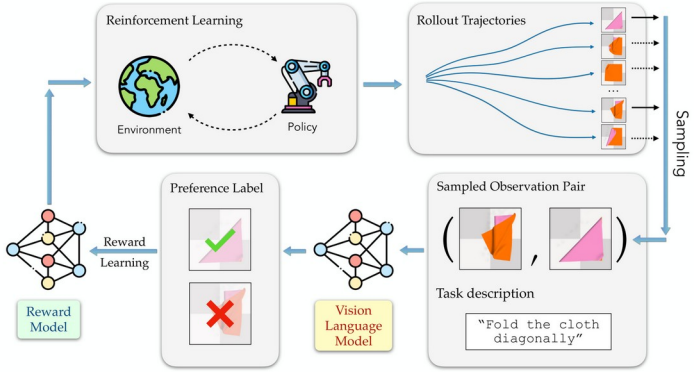
## 5 議論はある？

著者：1 枚の画像で成否が分かる課題が前提。長期課題は部分課題への分解が要る。VLM の偏りは方策に引き継がれる。

所感：MetaWorld ではロボットを透明にして描画しており、実機には工夫が要る。ハッキング耐性も直接は評価していない。

## 6 次に読むべき論文は？

- RoboReward (Lee+ 2026)（本資料）
- Motif (Klissarov+ 2023)（既存：world-model/foundation-world-model ）




出典：RL-VLM-F Fig. 1（観測画像の対を VLM が課題文に照らして比較し、選好ラベルから報酬モデルを学ぶ）

## 書誌情報

**発表：** ICML 2024
**リンク：** https://arxiv.org/abs/2402.03681
**系譜：** 発展（← VLM-RMs (Rocamonde+ 2023)）
**調査日：** 2026-10-25
**確認範囲：** 全文（問題提起・手法・実験・結果・考察）

# RoboReward: General-Purpose Vision-Language Reward Models for Robotics

Tony Lee, Andrew Wagenmaker, Karl Pertsch, Percy Liang, Sergey Levine, Chelsea Finn（Stanford / UC Berkeley）| arXiv プレプリント 2026

## 1 どんなもの？

実ロボット動画と指示から終端の進捗（1 ～ 5）を出す汎用報酬 VLM（RoboReward 4B/8B）と、人手検証済みの RoboRewardBench を構築。8B は 22 モデル中で MAE 最小（0.665）で、実機 RL では Gemini Robotics-ER 1.5 より大きく方策を改善した。

## 2 先行研究と比べてどこがすごい？

VLM-RMs や RL-VLM-F などの VLM 報酬は主にシミュレーションで評価され、実機で十分な精度かは不明だった。OXE などの大規模データは成功デモに偏り、失敗を見分ける報酬モデルの学習・評価に向かない。

## 3 技術や手法のキモはどこ？

「逆 HER」型の負例拡張：成功動画はそのままに、VLM・LLM で「部分成功／失敗になる別の指示」を作る反実仮想ラベル付けと、動画を途中で切る clipping。5 段階ルーブリックで VLM が検証。課題文が分割間で重ならないよう分けて Qwen3-VL を微調整。

## 4 どうやって有効だと検証した？

Robomimic で進捗型報酬は二値より速く収束し、報酬精度と RL 性能の相関 r=0.83（Fig. 3）。2,831 件の Bench で 8B は GPT-5 mini 0.691、GPT-5 0.811 を上回る（Table 1）。WidowX の未学習 2 課題で成功率 5→50%、10→80%（人手報酬 75%・90%, Table 2）。

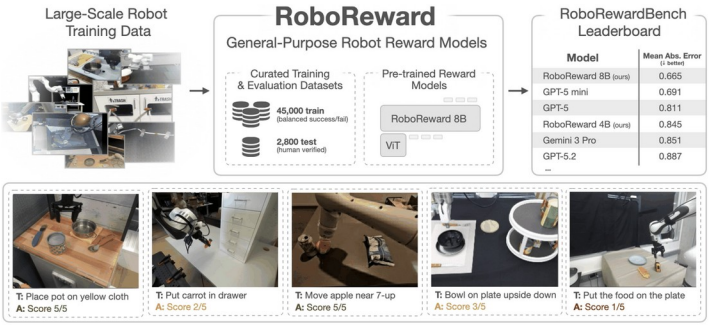
## 5 議論はある？

著者：最先端 VLM も機体・視点ごとに精度がばらつく。長期・多段課題が今後の課題。

所感：負例拡張を外すと MAE 0.845→1.45 と大きく悪化し、データ設計が鍵。終端 1 回の評価で密な報酬ではなく、実機 RL も BC 方策の改善に限られる。

## 6 次に読むべき論文は？

- GVL (Ma+ 2024)（未調査）
- Robometer (Liang+ 2026)（未調査）
- SOLE-R1 (Schroeder+ 2026)（本資料）




出典：RoboReward Fig. 1（4.5 万件の学習データ、2,800 件の人手検証テスト、MAE によるリーダーボードと採点例）

## 書誌情報

**発表：** arXiv プレプリント 2026
**リンク：** https://arxiv.org/abs/2601.00675
**系譜：** 最新（← RL-VLM-F (Wang+ 2024)）
**調査日：** 2026-10-25
**確認範囲：** 全文（問題提起・手法・実験・結果・考察）

# SOLE-R1: Video-Language Reasoning as the Sole Reward for On-Robot Reinforcement Learning

Philip Schroeder, Thomas Weng, Karl Schmeckpeper ほか（MIT / RAI Institute）| arXiv プレプリント 2026

## 1 どんなもの？

動画と言語の目標だけから、時刻ごとに思考連鎖（CoT）で進捗を推論して密な報酬を出す SOLE-R1（Qwen3-VL-8B）。デモも正解報酬もなしに乱数方策から RL し、40 課題中 24 の未学習課題で成功率 50% 以上（GPT-5 は 7、Gemini は 5）。

## 2 先行研究と比べてどこがすごい？

GPT-5 などの汎用 VLM を報酬にすると、部分観測と分布シフトのもとで方策が知覚の誤りを突き、「成功に見える」行動を学ぶ。RoboReward・Robometer・LRM は専門家軌跡が中心で推論過程を持たず、ゼロからのオンライン RL で検証されていない。

## 3 技術や手法のキモはどこ？

入力は目標・初期フレーム・直近 K フレーム・前回の進捗。出力は変化の説明（think）と進捗 p_t∈[−100,100]（answer）。専門家軌跡に乱数動作や逆再生を挟んで後退を含む動画を合成し、CoT 120 万件で SFT、進捗誤差を報酬に GRPO で仕上げる。

## 4 どうやって有効だと検証した？

RoboSuite・ManiSkill・Meta-World・LIBERO・実機の 40 課題で DrQ-v2 を乱数初期化から学習（Fig. 3）。汎用 VLM の失敗は「体感成功は高く真の成功は低い」報酬ハッキング型、SOLE-R1 は信号不足型が中心（Fig. 4）。CoT を外すと報酬が平坦化（Fig. 5）。

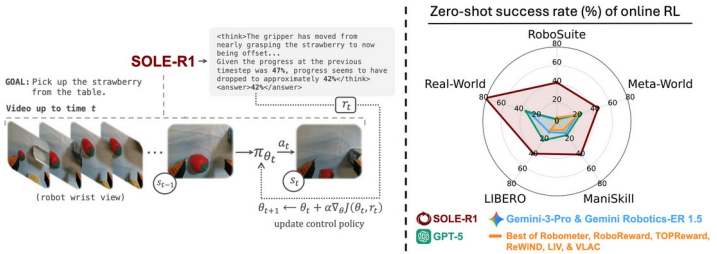
## 5 議論はある？

著者：短い出来事、遮蔽、曖昧な見えでは報酬が平坦・雑音化し、分布シフト下で誤りを突かれる余地は残る。実機には外部の安全機構が必須。

所感：訓練課題の種類が増えるほど解ける課題が増え（Fig. 6）、ここが汎化の鍵。実機は 1 seed のみ。

## 6 次に読むべき論文は？

- RoboReward (Lee+ 2026)（本資料）
- GVL (Ma+ 2024)（未調査）
- ReWiND (Zhang+ 2025)（未調査）
- TOPReward (Chen+ 2026)（未調査）




出典：SOLE-R1 Fig. 1（時刻ごとの CoT と進捗推定を報酬に方策を更新／5 環境での零ショット RL 成功率）

## 書誌情報

**発表：** arXiv プレプリント 2026
**リンク：** https://arxiv.org/abs/2603.28730
**系譜：** 最新（← RoboReward (Lee+ 2026)）
**調査日：** 2026-10-25
**確認範囲：** 全文（問題提起・手法・実験・結果・考察）

# From Demonstrations to Rewards: Test-Time Prompt Optimization for VLM Reward Models

Christian Gumbsch, Leonardo Barcellona, Lennard Schünemann ほか（University of Amsterdam / Toyota）| arXiv プレプリント 2026

## 1 どんなもの？

3 〜 10 本のデモを使い、VLM 成功判定器への言語指示だけを方策学習の前に自動で書き直す Demo2Reward 。再学習も学習中の追加計算もなしに偽陽性を抑え、MetaWorld で成功率を最大 40 ポイント改善、実機でも正解報酬並みに学習した。

## 2 先行研究と比べてどこがすごい？

VLM を零ショット成功判定器に使うと、把持した時点で「成功」とするなど偽陽性が多く、方策がそれを突いて真の成功に届かない（Fig. 2）。詳しいプロンプトの手作りは報酬設計の手間を戻してしまう。RoboReward は大規模な微調整を要する。

## 3 技術や手法のキモはどこ？

デモを接頭辞の部分動画に分け、時点ごとの成否ラベル付きデータにする。メタ批評役の VLM が誤判定例を見て指示 p を改訂し、$\hat{O}(p)=TNR(p)+\lambda TPR(p)$（$\lambda=0.01$）が上がるときだけ採用。退化解（常に 0 ）を避けるため初期値とメタ VLM を変えて K 回探索。

## 4 どうやって有効だと検証した？

Qwen3-VL-8B 、IBRL/RLPD 。PickPlace-Can で偽陽性率 26.1%→0%（Table 1–2）。MetaWorld 4 課題で RoboReward・GVL・RoboCLIP ・零ショット判定を上回る（Fig. 5, 10 seeds ）。実機の蓋閉め（デモ 20 本）で正解報酬並み、零ショットより約 20% 高い（Fig. 7 ）。

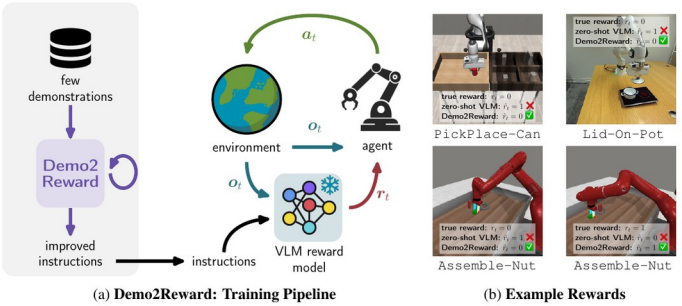
## 5 議論はある？

著者：デモ収集時と学習時で見え方が変わると過適合しうる。二値の成否に限られ、最初の指示は人が与える。

所感：最適化後の指示に青い棒を「赤い棒」と書くなど、VLM の知覚の癖に合わせる。人が読める仕様としての言語とのトレードオフ。

## 6 次に読むべき論文は？

- RoboReward (Lee+ 2026)（本資料）
- GVL (Ma+ 2024)（未調査）
- SENSEI (Sancaktar+ 2025)（既存：world-model/intrinsic-reward ）




出典：Demo2Reward Fig. 1（少数デモで指示を最適化→ VLM 報酬で方策学習／零ショット判定の偽陽性・偽陰性の例）

## 書誌情報

**発表：** arXiv プレプリント 2026
**リンク：** https://arxiv.org/abs/2606.00083
**系譜：** 最新（← RoboReward (Lee+ 2026) ）
**調査日：** 2026-10-25
**確認範囲：** 全文（問題提起・手法・実験・結果・考察）

# RDA: Reward Design Agent for Reinforcement Learning

Hojoon Lee, Ajay Subramanian, Ben Abbatematteo ほか（Meta）| RLC 2026

## 1 どんなもの？

Eureka 型の報酬コード探索に、VLM による動画の視覚診断を組み込んだエージェント RDA 。指示を部分課題に分け、ロールアウトを部分課題ごとに採点して失敗要因を要約し、報酬を直す。HumanoidBench で指示整合度を Eureka の 0.47 から 0.70 に高めた。

## 2 先行研究と比べてどこがすごい？

Eureka は成功率と報酬成分の統計だけで振り返るため、「荷物を押す」課題を投げて解くような指示違反を見分けられない（Fig. 1）。VLM で危険な候補を除く手法や CLIP 整合報酬の追加は、誤りを検出しても直し方を示さない。

## 3 技術や手法のキモはどこ？

GPT-5 が指示を部分課題列 T に分け、各部分課題に対応する成分の重み付き和で報酬コード候補を生成。候補ごとに SAC を学習し、K 本の動画を部分課題ごとに 0 〜 1 で採点・理由を要約、最良を選んで部分課題記述と報酬コードを改訂（5 反復）。

## 4 どうやって有効だと検証した？

ManiSkill 12 課題で整合 0.95・成功 0.90（Eureka 0.87/0.87 、人手の密報酬 0.68/0.74 ）、PlugCharger は RDA のみ成功。HumanoidBench 4 課題で整合 0.70 vs 0.47 、成功 0.42 vs 0.52（Fig. 4 ）。動画診断の追加だけで整合 0.31→0.82（Fig. 7 ）。

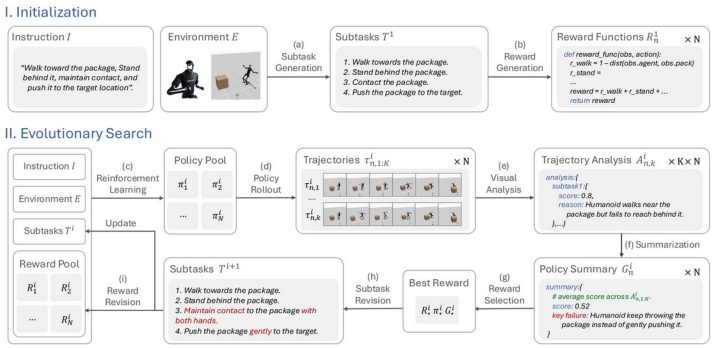
## 5 議論はある？

著者：候補ごとに RL 学習が要り高コスト。VLM の文脈長と細かな視覚推論に制約され、前後の部分課題の報酬が衝突すると失敗する。

所感：整合度を測るのも VLM（GPT-4.1 ）で、探索側の VLM と偏りを共有しうる。BIRD の人手評価と突き合わせたい。

## 6 次に読むべき論文は？

- Eureka (Ma+ 2023)（本資料）
- BIRD (Bhamidipaty+ 2026)（本資料）
- Prompt-to-Policy (Chung+ 2026)（未調査）




出典：RDA Fig. 2（部分課題分解→報酬生成→ RL→ 動画の視覚分析→要約→部分課題と報酬の改訂、の進化ループ）

## 書誌情報

**発表：** RLC 2026
**リンク：** https://arxiv.org/abs/2606.01672
**系譜：**最新（← Eureka (Ma+ 2023) ）
**調査日：** 2026-10-25
**確認範囲：**全文（問題提起・手法・実験・結果・考察）

# A Bird's-Eye View of Iterative Reward Design

Logan M. Bhamidipaty, Lauren Robson, Linda Petrini ほか ( Anthropic Fellows Program / Anthropic ) | arXiv プレプリント 2026

## 1 どんなもの？

LLM による反復報酬設計 ( IRD ) の 14 手法を共通ループの設定として実装し、同一予算で比べる BIRD を構築。30 の設計選択の大半は効果が不明確で、単純な選択を重ねた ERA-S/ERA-U が既存手法を上回った。一方、高得点でも不自然・有害な挙動が残った。

## 2 先行研究と比べてどこがすごい？

Eureka 、Text2Reward 、RDA 、RF-Agent 、REvolve などは実装・フィードバックの前提・評価環境がばらばらで、どの工夫が効くのか比べられなかった。「ベンチマーク得点が高い＝意図どおり」かも検証されていなかった。

## 3 技術や手法のキモはどこ？

IRD を 生成→検証→方策学習→評価→選択 の 5 段に分け、各手法を YAML の設定で表す（同じ選択は同じ実装を共有）。評価は教師あり（ベンチの得点）と教師なし ( VLM の達成評価）を区別し、Bradley–Terry で順位付けする。

## 4 どうやって有効だと検証した？

MuJoCo・Meta-World MT10・Assistax・HumanoidBench の 21 課題。6 手法の比較では REvolve が概ね最強で他は僅差 ( Fig. 4 )。明確に効いた選択は 4 つだけ ( Fig. 5 )。人の達成評価とベンチ得点の相関は MT10 0.78 、HumanoidBench 0.26 ( Table 2 )。

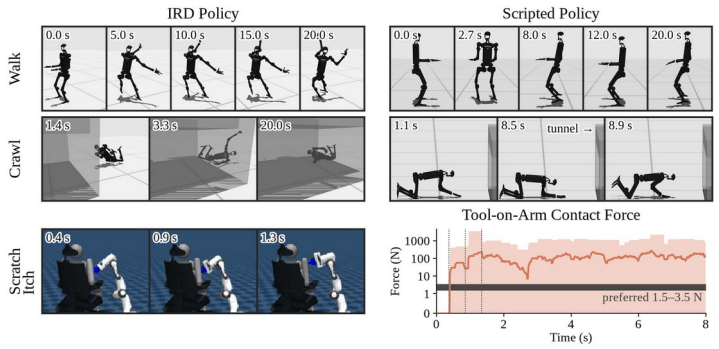
## 5 議論はある？

著者：評価者は著者 2 名のみで、生成・判定モデルの影響は未検証。HumanoidBench の参照報酬は後ろ向きに跳ねても稼げ、背中掻き課題では 3 kN の力を加える方策も高得点だった。

所感：言語で「何を」しか伝えない設定の弱点を示した重要な負の結果。

## 6 次に読むべき論文は？

- Eureka (Ma+ 2023)（本資料）
- RDA (Lee+ 2026)（本資料）
- REvolve (Hazra+ 2025)（未調査）
- RF-Agent (Gao+ 2026)（未調査）




出典：BIRD Fig. 8（参照報酬では高得点だが不自然な IRD 方策・台本方策と、患者の腕に過大な力をかける背中掻き方策）

## 書誌情報

**発表：** arXiv プレプリント 2026
**リンク：** https://arxiv.org/abs/2610.04364
**系譜：** 最新（← Eureka (Ma+ 2023) ）
**調査日：** 2026-10-25
**確認範囲：** 全文（問題提起・手法・実験・結果・考察）