動画からの潜在行動学習と世界モデル内の方策学習

行動ラベルのない動画から潜在行動を学ぶ系譜(ILPO → LAPO → LAPA・LAOM → 自然動画・大規模比較)と、世界モデルの中で方策を学ぶ系譜(MOPO の不確実性罰則 → 動画世界モデル内 RL の WMPO → 幻覚を罰する HaWMPO 、選好でモデルを直す RENEW)を追う。
両者は、潜在行動世界モデル内でのオフライン RL (LAWM)で合流する。

#	年	論文	発表	系譜
1	2019	ILPO (Edwards+ 2019)	ICML 2019	原典
2	2020	MOPO (Yu+ 2020)	NeurIPS 2020	原典
3	2024	LAPO (Schmidt & Jiang 2024)	ICLR 2024	発展
4	2025	LAPA (Ye+ 2025)	ICLR 2025	発展
5	2025	LAOM (Nikulin+ 2025)	ICML 2025	発展
6	2025	WMPO (Zhu+ 2025)	ICLR 2026	最新
7	2025	LAWM (Alles+ 2025)	arXiv プレプリント 2025	最新
8	2026	In-the-Wild LAM (Garrido+ 2026)	ICML 2026	最新
9	2026	RENEW (Bhamidipaty+ 2026)	RLC 2026 ワークショップ	最新
10	2026	What Matters (Bu+ 2026)	arXiv プレプリント 2026	最新
11	2026	HaWMPO (Chen+ 2026)	arXiv プレプリント 2026	最新

Imitating Latent Policies from Observation

Ashley D. Edwards, Himanshu Sahni, Yannick Schroecker ほか (Georgia Institute of Technology) | ICML 2019

1 どんなもの?

行動ラベルのない専門家の状態系列から「潜在行動」と潜在方策を先に学び、少数の環境操作で実行動に対応付ける模倣学習 ILPO を提案。CartPole・Acrobot では 100 ステップ未満の操作で専門家並みになった。

2 先行研究と比べてどこがすごい?

BCO (Torabi+ 2018) など観察からの模倣は、逆動力学モデルを環境との大量の相互作用で学ぶ必要があった。ILPO は動力学全体ではなく「潜在行動→実行動」の対応だけを環境で学ぶので、必要な相互作用が少ない。

3 技術や手法のキモはどこ?

離散潜在行動 z ごとに次状態の差分を出す生成器 G を、最も近い予測だけ罰する $L_{min} = \min_z \| \Delta_t - G(s_t, z) \|^2$ で学び、方策 $\pi(z|s)$ は期待次状態の誤差で学ぶ。次に観測遷移に最も近い z を推定し、$\pi(a|s, z)$ を分類で学ぶ。

4 どうやって有効だと検証した?

古典制御 3 種と CoinRun (128×128 画像、7 行動) で BC (行動あり)・BCO と比較 (Fig. 2, 5)。CartPole・Acrobot は 100 ステップ未満で専門家・BC 並み。Mountain Car と CoinRun は専門家に届かないが、どちらも BCO を上回る。

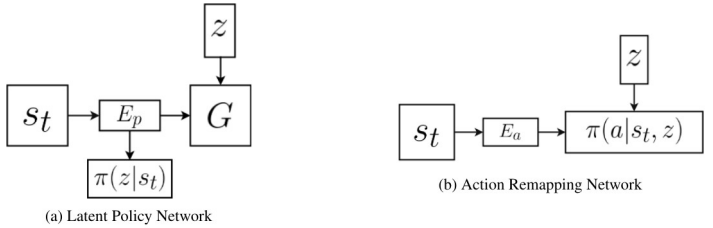
5 議論はある?

著者:離散行動・決定的遷移の仮定、確率的な実演が必要などの限界を挙げる。

所感:「潜在行動を学び、後で実行動に対応付ける」という後続全体の骨格を作った原典。ただし LAPO は手続き生成の多レベル環境で ILPO が崩壊すると報告している。

6 次に読むべき論文は?

- LAPO (2024) (本資料)
- BCO (2018) (未調査)
- Genie (2024) (既存: foundation-world-model)



出典: ILPO Fig. 1 (潜在方策ネットワークと行動再対応ネットワーク)

書誌情報

発表: ICML 2019
リンク: https://arxiv.org/abs/1805.07914
系譜: 原典
調査日: 2026-10-24
確認範囲: 全文 (問題提起・手法・実験・結果・考察)

MOPO: Model-based Offline Policy Optimization

Tianhe Yu, Garrett Thomas, Lantao Yu ほか (Stanford University / UC Berkeley) | NeurIPS 2020

1 どんなもの?

オフライン MBRL で、学習モデルの不確実性 u(s,a) を報酬から差し引く MOPO を提案。真の MDP での収益の下界を最大化することを示し、D4RL と、データの外への汎化が必要な課題で既存手法を上回った。

2 先行研究と比べてどこがすごい?

BEAR・BRAC などモデルフリーのオフライン RL は方策をデータの支持内に縛るため、データ外の状態へ汎化できない。素の MBPO はオフラインでも強いが、モデル誤差を方策が悪用するのを防ぐ機構がなかった。

3 技術や手法のキモはどこ?

罰則つき報酬 $\tilde{r}(s,a) = r(s,a) - \lambda u(s,a)$ の MDP で MBPO (Dyna 型の短いロールアウト)を回す。u はガウス出力アンサンブルの最大標準偏差。$\eta_M(\hat{\pi}) \geq \sup_\pi \{\eta_M(\pi) - 2\lambda \varepsilon_u(\pi)\}$ を保証する。

4 どうやって有効だと検証した?

D4RL 12 データセット(Table 1)で mixed 全部と medium-expert の多くで最良(hopper-mixed 67.5 、MBPO 49.8)。データ外の課題(Table 2)で halfcheetah-jump 4016.6 、ant-angle 2530.9 とバッチ内の最大値を超えた。

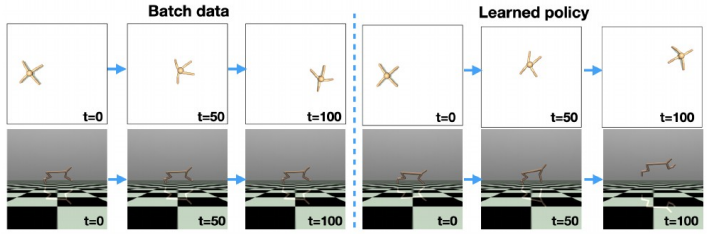
5 議論はある?

著者:行動の多様性が乏しい medium データでは弱い。u は理論保証のない発見的推定で、λ は手で決める。

所感:「世界モデルの中で方策を学ぶときの保守性」の原点。動画世界モデルでは u を何で測るかが、本テーマの最新論文の争点になっている。

6 次に読むべき論文は?

- MOReL (2020) (未調査)
- RENEW (2026) (本資料)
- HaWMPO (2026) (本資料)
- Exploitable WM (2026) (既存: latent-planning)



出典: MOPO Fig. 2 (ant-angle と halfcheetah-jump 。データの外へ出る必要がある課題)

書誌情報

発表: NeurIPS 2020
リンク: https://arxiv.org/abs/2005.13239
系譜: 原典
調査日: 2026-10-24
確認範囲: 全文(問題提起・手法・実験・結果・考察)

Learning to Act without Actions

Dominik Schmidt, Minqi Jiang（Weco AI / FAIR at Meta）| ICLR 2024

1 どんなもの?

行動ラベルのない動画だけから、IDM と FDM の予測の整合で潜在行動を学ぶ LAPO を提案。Procgen 16 ゲームで潜在行動空間が真の行動構造を再現し、潜在方策は 4M ステップの微調整で専門家性能を回復した。

2 先行研究と比べてどこがすごい?

VPT（Baker+ 2022）など IDM で疑似ラベルを付ける手法は、行動ラベル付きデータが必要だった。ILPO は離散潜在を列挙するため崩壊しやすい。LAPO はラベル不要で、連続潜在と VQ の情報ボトルネックを使う。

3 技術や手法のキモはどこ?

IDM が (o_t, o_{t+1}) から z_t を出し、FDM が (o_t, z_t) から o_{t+1} を予測する誤差 $\| \hat{o}_{t+1} - o_{t+1} \|^2$ を同時に最小化。z_t を VQ で量子化して次フレームの丸写しを防ぐ。その後 z を BC し、デコーダで実行動へ戻す。

4 どうやって有効だと検証した?

Procgen 16 ゲーム、約 8M フレームの専門家動画（Fig. 3）。PPO 単独は 4M ステップで専門家の 44% にとどまるが、LAPO は専門家性能を回復し、9/16 で上回る。256 未満のラベル付き遷移によるオフライン復号で PPO 4M ステップに並ぶ（Fig. 4）。

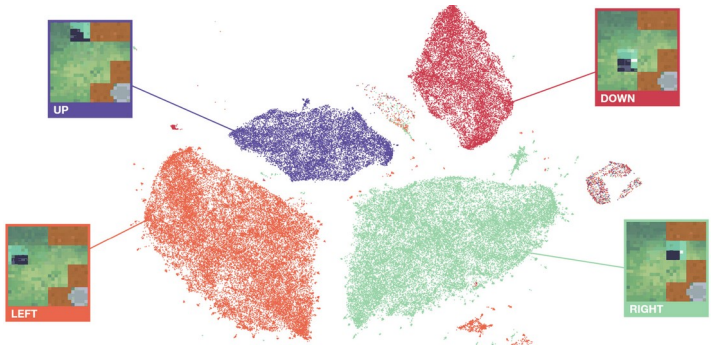
5 議論はある?

著者:遅れて効く行動、強い確率性、Web 規模への拡大が課題。VQ を外すと性能が落ちる。

所感:部分観測のゲームでは潜在行動が画面外の情報まで符号化している（Fig. 5）。これは後の「汚染（distractor）」問題の予兆といえる。

6 次に読むべき論文は?

- LAPA (2025)（本資料）
- LAOM (2025)（本資料）
- Genie (2024)（既存: foundation-world-model）
- VPT (2022)（未調査）



出典: LAPO Fig. 1（Miner の潜在行動の UMAP。色は真の行動で、学習には使っていない）

書誌情報

発表: ICLR 2024
リンク: https://arxiv.org/abs/2312.10812
系譜: 発展（← ILPO）
調査日: 2026-10-24
確認範囲: 全文（問題提起・手法・実験・結果・考察）

Latent Action Pretraining from Videos

Seonghyeon Ye, Joel Jang, Byeongguk Jeon ほか (KAIST / University of Washington / Microsoft Research / NVIDIA) | ICLR 2025

1 どんなもの?

人やロボットの動画から VQ-VAE で離散潜在行動を学び、7B の VLM に予測させて事前学習し、少量のロボット軌跡で実行動に対応付ける LAPA を提案。行動ラベルで事前学習した OpenVLA を実機で上回った。

2 先行研究と比べてどこがすごい?

OpenVLA など既存の VLA はテレオペの行動ラベル付きデータで事前学習するため、規模が限られる。UniPi (動画生成+IDM) や VPT (IDM の疑似ラベル) と比べ、ラベル不要で、環境や身体の違いにも強い。

3 技術や手法のキモはどこ?

①Genie 型の潜在行動量子化モデル (C-ViViT 系、NSVQ) で (x_t, x_{t+H}) から離散 z_t を得る。② LWM-7B に指示文と画像から z_t を予測させる (BC) 。③潜在ヘッドを捨て、課題あたり 150 軌跡程度で実行動ヘッドを微調整。

4 どうやって有効だと検証した?

Language Table (Table 1) で VPT・UniPi を上回る (cross-env 33.6% 、VPT 18.0%) 。Franka 実機 3 課題 (Table 2) で Open-X 事前学習時 50.1% 、OpenVLA 43.9% 。人の動画 (SSv2) だけでも 34.0% と、Bridge 版 OpenVLA の 30.8% を上回る。

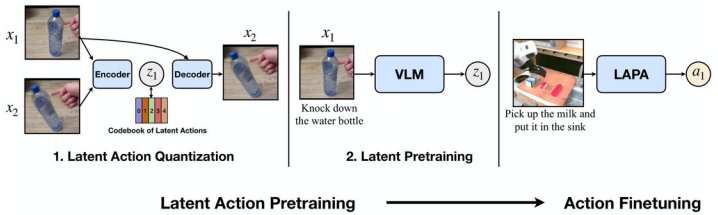
5 議論はある?

著者:把持など細かい動作で劣る (早すぎる把持) 。推論遅延がある。カメラの動きも潜在行動に入る。

所感:「潜在→実行動」を小さなヘッドの微調整で済ませる設計が VLA 系の定番になった。ただし把持の失敗は、潜在行動の粒度が足りないことを示している。

6 次に読むべき論文は?

- LAOM (2025) (本資料)
- What Matters (2026) (本資料)
- UniVLA (2025) (未調査)
- OpenVLA (2024) (未調査)



出典: LAPA Fig. 2 (潜在行動の量子化 → 潜在事前学習 → 実行動での微調整)

書誌情報

発表: ICLR 2025
リンク: https://arxiv.org/abs/2410.11758
系譜: 発展 (← LAPO / Genie)
調査日: 2026-10-24
確認範囲: 全文 (問題提起・手法・実験・結果・考察)

Latent Action Learning Requires Supervision in the Presence of Distractors

Alexander Nikulin, Ilya Zisman, Denis Tarasov ほか (AIRI / dunnolab.ai) | ICML 2025

1 どんなもの?

背景動画やカメラの揺れなど、行動と相関する妨害 (distractor) があると LAPO の潜在行動が壊れることを示した。改良版 LAOM で潜在行動の質を 8 倍にし、全体の 2.5% の行動ラベルで監督すると下流性能が平均 4.2 倍になると報告。

2 先行研究と比べてどこがすごい?

LAPO・LAPA・Genie は、背景が静的で妨害のないデータで評価してきた。Web 動画では行動と無関係な変化の方が次フレームをよく説明するため、再構成目的は妨害を潜在行動に符号化してしまう (Misra+ 2024 の指摘を実証)。

3 技術や手法のキモはどこ?

LAOM :量子化を外す、多段 IDM (o_t と o_{t+k} 、k≤10)、潜在次元を 8192 に拡大、画素の再構成をやめ潜在空間で次状態を予測、データ拡張。さらに少数の真の行動を潜在から線形予測する損失を同時に課す (LAOM+supervision)。

4 どうやって有効だと検証した?

Distracting Control Suite 4 課題、各 5000 軌跡。線形プローブ MSE は LAPO 22.09 → LAOM 2.74 (Fig. 6)。ラベル付き軌跡 2 ～ 128 本の全条件で LAOM+supervision が全基準を上回り、正規化スコア 0.44 (Fig. 1, 8)。IDM より未知の妨害に汎化 (Fig. 9a)。

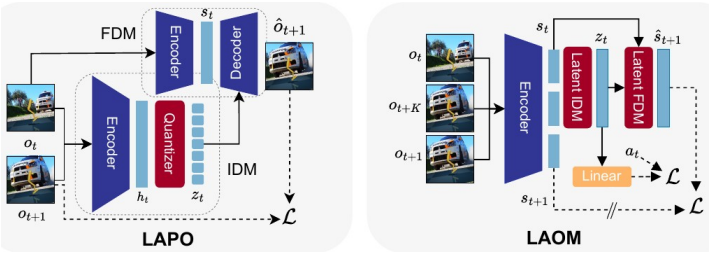
5 議論はある?

著者:妨害がなくても量子化は質を下げる。身体をまたぐ事前学習では、監督つきでも少数ラベルの BC と同程度にとどまる。

所感:「LAM を先に学び、後で復号する」という定番の 3 段階手順への反証。完全にラベルなしという前提を緩める現実解を示した。

6 次に読むべき論文は?

- MaskLAM (2026) (未調査)
- What Do LAMs Actually Learn? (2025) (未調査)
- Why Latent Actions Fail (2026) (未調査)
- In-the-Wild LAM (2026) (本資料)



出典: LAOM Fig. 4 (LAPO と LAOM の構造。LAOM は潜在空間で予測し、少数の行動で監督する)

書誌情報

発表: ICML 2025
リンク: https://arxiv.org/abs/2502.00379
系譜: 発展 (← LAPO)
調査日: 2026-10-24
確認範囲: 全文 (問題提起・手法・実験・結果・考察)

WMPO: World Model-based Policy Optimization for Vision-Language-Action Models

Fangqi Zhu, Zhengyang Yan, Zicong Hong ほか(HKUST / ByteDance Seed)| ICLR 2026

1 どんなもの?

画素空間の行動条件付き動画世界モデルの中だけで、VLA (OpenVLA-OFT)を on-policy の GRPO で強化学習する WMPO を提案。実ロールアウト 128 本の予算で、実環境で直接 GRPO・DPO するより成功率を大きく上げた。

2 先行研究と比べてどこがすごい?

実機での RL は試行が高価で、従来の MBRL (Dreamer 系)は抽象的な潜在空間で学ぶため、Web 画像で事前学習された VLA の視覚特徴と合わない。WMPO は画素を生成し、VLA をそのまま想像の中で動かす。

3 技術や手法のキモはどこ?

OXE で事前学習した拡散動画世界モデルを、方策自身の実ロールアウト(失敗を含む)で微調整する(Policy Behavior Alignment)。ノイズ付き条件フレームとフレーム単位の行動条件を加え、VideoMAE の成否判定器で軌跡全体に 0/1 報酬を与える。

4 どうやって有効だと検証した?

Mimicgen 4 課題(Table 1)。平均成功率は基本方策 33.6% → P=128 で 47.1% (GRPO 33.2% 、DPO 37.3%)、P=1280 で 57.6% 。報酬モデルの F1 は 0.95 超。未知の配置・背景・質感で平均 29.6% (Table 2)。実機の挿入課題で 53→70% 。

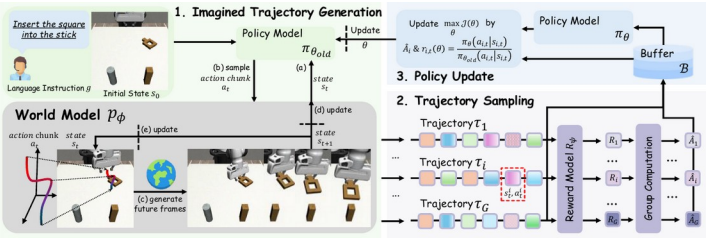
5 議論はある?

著者:短い地平線の報酬は報酬ハッキングを招くため、試行全体を生成して結果で判定する。離散化行動の VLA に限定。

所感:幻覚で「成功」が生成された場合の誤報酬は F1 だけでは測れない。後続の WoVR・HaWMPO がこの問題を正面から扱う。

6 次に読むべき論文は?

- HaWMPO (2026) (本資料)
- WoVR (2026) (未調査)
- Ctrl-World (2025) (既存: foundation-world-model)



出典: WMPO Fig. 2 (想像軌跡の生成、報酬モデルによる判定、GRPO による更新)

書誌情報

発表: ICLR 2026
リンク: https://arxiv.org/abs/2511.09515
系譜:最新(← Ctrl-World (既存))
調査日: 2026-10-24
確認範囲:全文(問題提起・手法・実験・結果・考察)

Latent Action World Models for Control with Unlabeled Trajectories

Marvin Alles, Xingyuan Zhang, Patrick van der Smagt ほか (Technical University of Munich / Volkswagen Group) | arXiv プレプリント 2025

1 どんなもの?

少数の行動付き軌跡と大量の行動なし軌跡を、共通の潜在行動空間で 1 つの世界モデルに学習させ、その中でオフライン RL により潜在行動方策を学ぶ LAWM を提案。行動ラベル 5% で、全ラベル時並みの成績を出した。

2 先行研究と比べてどこがすごい?

潜在行動の研究 (LAPO・LAPA) は BC に使うだけで RL と結びつかず、オフライン RL (TD3+BC・C-LAP) は行動付きデータに依存していた。両者を潜在行動世界モデルで橋渡しする。

3 技術や手法のキモはどこ?

潜在状態 s_t と潜在行動 u_t を持つ生成モデル p(o_t|s_t)p(a_t|s_t,u_t)p(u_t|s_t)p(s_t|s_{t−1},a_{t−1}) を変分推論で学ぶ。行動ありは q(u_t|s_t,a_t) 、なしは q(u_t|s_t,o_{t+1}) (IDM) で推論。方策は潜在行動の事前分布内に制約する。

4 どうやって有効だと検証した?

DMC 3 環境 ×4 データセット (Table 1 、状態入力) 。行動 5% で平均 62.4 (TD3+BC 33.5 、C-LAP 45.9 、IDM-TD3+BC 43.8) 。全ラベルを使う C-LAP Oracle の 63.3 に匹敵する。walker の plan2explore データでは 81.9 (Oracle 69.2) 。

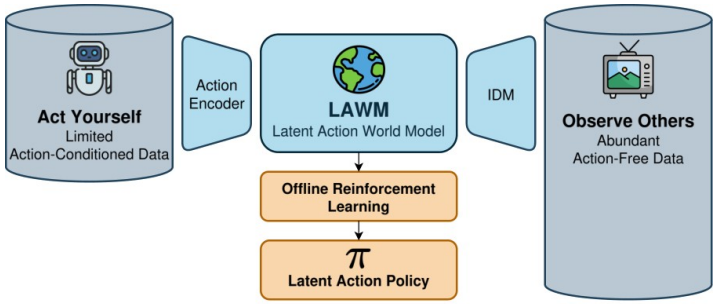
5 議論はある?

著者:多様な挙動を 1 つの IDM と潜在行動表現に統合するのが今後の課題。

所感:潜在行動の事前分布が、MOPO の不確実性罰則に代わる「支持制約」として働く点が本テーマの結節点。ただし実験は状態入力のみで、画像・動画は未検証の短い予稿。

6 次に読むべき論文は?

- C-LAP (2024) (未調査)
- MOPO (2020) (本資料)
- LAPO (2024) (本資料)
- AdaWorld (2025) (未調査)



出典: LAWM Fig. 1 (行動付き・行動なしのデータを潜在行動で統合し、オフライン RL へ)

書誌情報

発表: arXiv プレプリント 2025
リンク: https://arxiv.org/abs/2512.10016
系譜: 最新 (← LAPO / MOPO)
調査日: 2026-10-24
確認範囲: 全文 (問題提起・手法・実験・結果・考察)

Learning Latent Action World Models In The Wild

Quentin Garrido, Tushar Nagarajan, Basile Terver ほか (FAIR at Meta) | ICML 2026

1 どんなもの?

YouTube などの自然動画 (YT-Temporal-1B) だけで、凍結した V-JEPA 2 の表現空間上に潜在行動世界モデルを学習。連続でスパースまたはノイズ付きの潜在行動が複雑な行動を捉え、軽量コントローラで既知の行動に対応付けて計画できることを示した。

2 先行研究と比べてどこがすごい?

従来の LAM はゲーム (Genie) や机上操作 (LAPA・UniVLA) など狭い領域で学び、自然動画は全体の約 5% にとどまっていた。自然動画では環境ノイズに加え、動画間で共通の身体がないことが問題になる。

3 技術や手法のキモはどこ?

IDM g_φ(s_t, s_{t+1}) で z_t を推論し、予測器 p_φ (ViT-L、AdaLN-zero) で s_{t+1} を予測する L1 損失で学ぶ。z の情報量をスパース性 (VICReg 型の正則化)、VAE 型のノイズ、VQ の 3 通りで制限して比較。既知の行動 → z のコントローラは後から学ぶ。

4 どうやって有効だと検証した?

VQ は容量を上げても予測誤差がほぼ下がらない (Fig. 4)。場面転換で誤差が 2 倍以上になり、次フレームの丸写しは起きていない (Table 1)。DROID での計画は Δxyz 0.10 m (ノイズ・高容量)で V-JEPA 2-AC の 0.15 m 以上。RECON では RPE 0.40 で NoMaD 0.52 を上回る (Table S1, S2)。

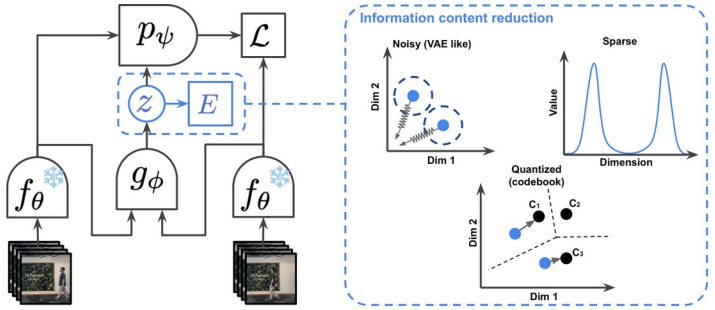
5 議論はある?

著者:共通の身体がないため、潜在行動はカメラ相対で空間的に局在した変換になる。情報制約の係数は固定。

所感: DROID を少し混ぜるだけで計画が大きく改善する (Table S3)。自然動画だけで十分かどうかには、まだ疑問が残る。

6 次に読むべき論文は?

- V-JEPA 2 (2025) (既存: jepa)
- AdaWorld (2025) (未調査)
- OneLA (2026) (未調査)
- LAOM (2025) (本資料)



出典: In-the-Wild LAM Fig. 2 (潜在行動世界モデルと 3 種類の情報量制限)

書誌情報

発表: ICML 2026
リンク: https://arxiv.org/abs/2601.05230
系譜: 最新 (← LAPO / Genie)
調査日: 2026-10-24
確認範囲: 全文 (問題提起・手法・実験・結果・考察)

RENEW: Towards Learning World Models and Repairing Model Exploitation from Preferences

Logan Mondal Bhamidipaty, Mykel Kochenderfer, Subramanian Ramamoorthy（Univ. of Edinburgh / Stanford）| RLC 2026 WS

1 どんなもの？

オフライン MBRL のモデル悪用を、保守的な罰則ではなく「どちらの想像軌跡が物理的にもっともらしいか」という選好でモデル自体を直す DLHF として定式化した。認識的不確実性で問い合わせ先を選ぶ RENEW で効率化した。

2 先行研究と比べてどこがすごい？

従来は MOPO・MOReL の不確実性罰則（汎化を損なう）か、追加の実演収集（高価で危険）で対処していた。RLHF 型の「課題の良さ」の選好は、壁を抜けて速くゴールする軌跡を好み、悪用をかえって強める。

3 技術や手法のキモはどこ？

軌跡区間の対数尤度 $\ell_\theta(\sigma) = \Sigma \log \hat{T}_\theta(s_{t+1}|s_t, a_t)$ を Bradley–Terry の報酬の代わりに使い、$P(\sigma^0 \succ \sigma^1) = \text{logistic}(\ell_\theta(\sigma^0) - \ell_\theta(\sigma^1))$ を交差エントロピーで学ぶ。アンサンブルの不一致に比例して開始状態を選び、選好を集める。

4 どうやって有効だと検証した？

Jumanji 等の小環境（合成オラクル）。素の DLHF は 1M 選好で 1K 教師遷移並み（Table 1）。100K 選好で Sliding 3×3 の誤差 0.419 → 0.207（Table 2）。1600 選好で 10×10 迷路の遷移正解率 87.6 → 97.2%（素の微調整は 93.2%、Table 3）。

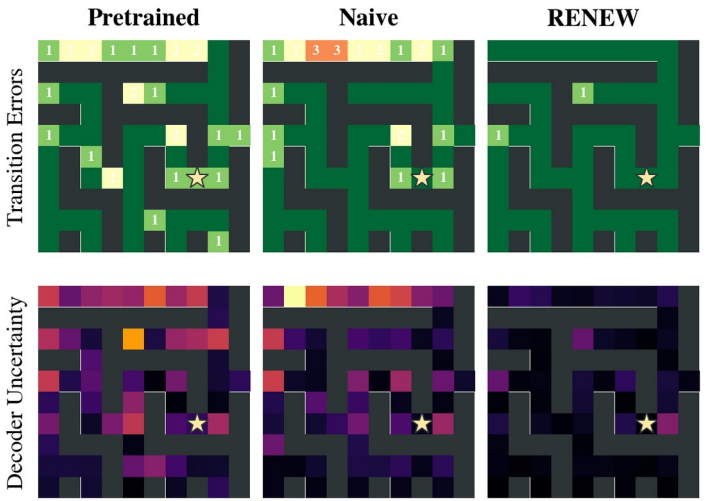
5 議論はある？

著者：本物の人間ではなく合成オラクルを使い、小さな離散環境でのみ評価。素の DLHF は事前学習の正しい遷移を忘れる。

所感：動画世界モデルの幻覚に人の直観で対処する発想は魅力的だが、画素レベルの大規模モデルへの拡張は未検証。

6 次に読むべき論文は？

- Exploitable WM (2026)（既存：latent-planning）
- MOPO (2020)（本資料）
- Deep RL from Human Preferences (2017)（未調査）



出典：RENEW Fig. 4（10×10 迷路の遷移誤差と不確実性。RENEW は両方を減らす）

書誌情報

発表： RLC 2026 ワークショップ
リンク： https://arxiv.org/abs/2607.14180
系譜： 最新（← MOPO）
調査日： 2026-10-24
確認範囲： 全文（問題提起・手法・実験・結果・考察）

What Matters for Latent Actions in Robot Learning

Xizhou Bu, Qingda Hu, Lei Zhou ほか (Fudan University / Xiaomi EV) | arXiv プレプリント 2026

1 どんなもの?

潜在行動モデル (LAM) の設計を共通の自己符号化の枠組みに統一し、41 通りの設計を LIBERO・LIBERO-Plus・RoboTwin2.0 で比較した初の大規模実証研究。原典の LAPO が依然強い基準で、潜在次元は 32 が最良と結論した。

2 先行研究と比べてどこがすごい?

LAM 研究は手法ごとに設定がばらばらで、どの設計が下流の操作性能を決めるのか不明だった。線形プローブなどの代理指標 (LAPO・LAOM が使用) が下流性能を予測できるかも検証されていなかった。

3 技術や手法のキモはどこ?

① 潜在行動の作り方 (IDM-FDM 型: LAPO・LAOF・CoMo ／差分の自己符号化: ΔRGB・ΔDINO ・光学流)、② 正則化 (AE・VAE・VQ ・スパース・ SIGReg) とその強度、③ VLM への統合 (DAP・LAP・JAP ほか) を、700M の LAM と Qwen3-VL-4B で比較。

4 どうやって有効だと検証した?

3 ベンチ平均で LAPO 0.733 、ΔDINO 0.728 、CoMo 0.717 の順で、光学流は最下位 (Table 1)。VQ は LIBERO-Plus のゼロショットで 0.517 と最良。FDM 再構成系の代理指標がプローブより下流性能と相関 (Fig. 4)。Franka 実機で 64.75 → 79.25% (Fig. 7)。

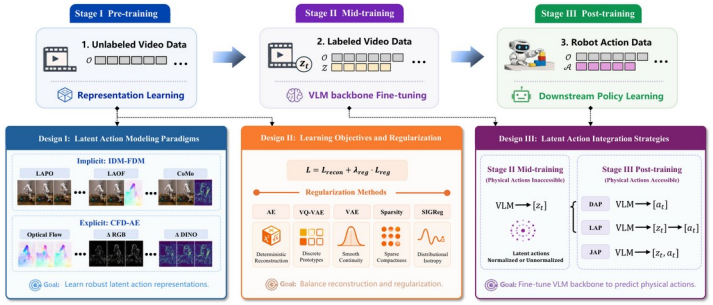
5 議論はある?

著者:代理指標は粗い選別向きで、最終的な選択には下流評価が必要。正則化は種類より強度が効く。

所感:評価は妨害の少ないシミュレータが中心で、LAOM が示した妨害下の結論とは単純に比べられない。VQ の評価も先行研究と食い違う。

6 次に読むべき論文は?

- LAPO (2024) (本資料)
- LAOF (2025) (未調査)
- CoMo (2026) (未調査)
- In-the-Wild LAM (2026) (本資料)



出典: What Matters Fig. 1 (3 段階の学習手順と、比較した 3 つの設計軸)

書誌情報

発表: arXiv プレプリント 2026
リンク: https://arxiv.org/abs/2608.19613
系譜: 最新 (← LAPO / LAOM)
調査日: 2026-10-24
確認範囲: 全文 (問題提起・手法・実験・結果・考察)

HaWMPO: Hallucination-Aware World Model-based Policy Optimization for Generalist Robot Policy

Zengjue Chen, Peidong Liu, Jiawei Li, Qi Wang (JD Joy Future Academy / Jilin University) | arXiv プレプリント 2026

1 どんなもの?

動画世界モデルの中で VLA を GRPO で学習するとき、生成の幻覚が偽の報酬を生む問題に対し、行動条件付きの幻覚推定器 HAM のスコアで報酬を割り引く HaWMPO を提案。LIBERO で WMPO を 6.9pt 上回った。

2 先行研究と比べてどこがすごい?

WMPO は世界モデルの軌跡をすべて同等に扱い、WoVR は初期化の工夫と共進化で幻覚を減らす。HaWMPO は幻覚を明示的に推定して報酬に反映する。MOPO の不確実性罰則を動画世界モデルに移した形といえる。

3 技術や手法のキモはどこ?

HAM は生成 8 フレーム・行動・現フレーム・初期画像を DINOv3 と融合 Transformer で処理し、DINO 類似度・深度・光学流軌跡・MUSIQ の合成指標を回帰する。Reward-Soft : $\hat{R} = (1 - \alpha H) \cdot R$ で割り引いた報酬からグループ相対アドバンテージを計算。

4 どうやって有効だと検証した?

LIBERO (1 軌跡 SFT の OpenVLA-OFT から)で平均 48.7 → 63.7% (WMPO 56.8% 、WoVR* 60.9% 、Table 1)。人手ラベルに対する HAM の AUROC 0.94 (Table 3)。HAM を外すと Spatial で − 8.0pt (Table 4)。G1 実機 2 課題で 67.5 → 80.0% (Table 2)。

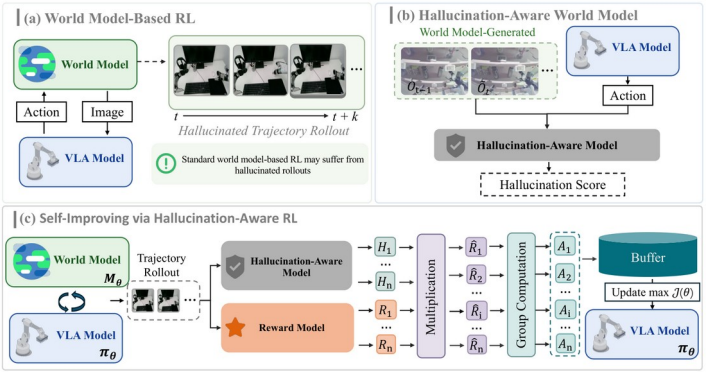
5 議論はある?

著者:幻覚の教師信号は手作りの指標で、短い課題でのみ評価。HAM と世界モデルは別々に学習している。

所感:最適な α が課題で異なり、Goal では統一 α だと HAM なしに劣る。WoVR* は共進化を省いた再現で、比較の公平性に注意が必要。

6 次に読むべき論文は?

- WoVR (2026) (未調査)
- MOPO (2020) (本資料)
- Hallucination in WMs (2026) (既存:foundation-world-model)



出典: HaWMPO Fig. 1 (世界モデル内 RL、幻覚推定モデル、Reward-Soft による GRPO)

書誌情報

発表: arXiv プレプリント 2026
リンク: https://arxiv.org/abs/2609.09941
系譜: 最新(← WMPO / MOPO)
調査日: 2026-10-24
確認範囲: 全文(問題提起・手法・実験・結果・考察)