群知能 | 先行研究調査 (2026-10-24)

学習型群知能と、学習器・古典的探索の役割分担

DE・ACO・MCTS の制御則やヒューリスティックを学習するとき、どこを学習器に任せ、どこを古典的探索に残すか。

DE の演算子・アルゴリズム選択 (DE-DDQN→RL-DAS→RLDE-AFL) と、ヒートマップ＋ MCTS (Att-GCN→DIMES→DIFUSCO/UTSP) を追う。2024 年以降は、SoftDist 、GT-Prior 、同予算の静的調整との比較で、学習の寄与が再評価されている。

#	年	論文	発表	系譜
1	2019	DE-DDQN (Sharma+ 2019)	GECCO 2019	原典
2	2021	Att-GCN+MCTS (Fu+ 2021)	AAAI 2021	原典
3	2022	DIMES (Qiu+ 2022)	NeurIPS 2022	発展
4	2023	DIFUSCO (Sun & Yang 2023)	NeurIPS 2023 (Spotlight)	発展
5	2023	UTSP (Min+ 2023)	NeurIPS 2023	発展
6	2024	RL-DAS (Guo+ 2024)	IEEE TSMC: Systems 2024	発展
7	2024	SoftDist / Position (Xia+ 2024)	ICML 2024 (Position)	最新
8	2025	RLDE-AFL (Guo+ 2025)	GECCO 2025	最新
9	2025	Beyond the Heatmap (Pan+ 2025)	ICLR 2026	最新
10	2026	When does learning pay off? (Mencaroni+ 2026)	arXiv プレプリント 2026	最新

Deep Reinforcement Learning Based Parameter Control in Differential Evolution

Mudita Sharma, Alexandros Komninos, Manuel López-Ibáñez, Dimitar Kazakov（University of York）| GECCO 2019

1 どんなもの？

DE の変異戦略 4 種のどれを使うかを、オフライン学習した Double DQN が世代・個体ごとに選ぶ DE-DDQN を提案。未知の関数で固定戦略とランダム選択に有意に勝ち、平均順位は IPOP-CMA-ES に次ぐ 2 位だった。

2 先行研究と比べてどこがすごい？

従来の RL 型の適応的演算子選択（PM-AdapSS 、F-AUC 、Q 学習、SARSA ）は、少数の特徴を使い実行中に学ぶ。本研究は多数の DE 実行から方策をオフラインで学び、未知の問題に持ち込む。後の MetaBBO の原型。

3 技術や手法のキモはどこ？

状態は 99 次元：適応度の統計、残り予算、停滞、親と参照解の距離、演算子ごとの成功率・改善量の履歴。行動は変異戦略の選択で、F=0.5・CR=1.0 は固定。報酬 R2（最良更新 10 ／親より改善 1 ／他 0 ）が最良。

4 どうやって有効だと検証した？

CEC2005 の 16 関数 ×{10,30} 次元で学習し、未使用の 5 関数 ×2 次元で試験。平均順位は IPOP 2.3 、DDQN2 3.3 、RecPM 4.4 、Random 10.5（Table 4 ）。有意差は固定戦略・ランダムに対してだけ（Table 5 ）。学習に約 6×10^8 評価を使った。

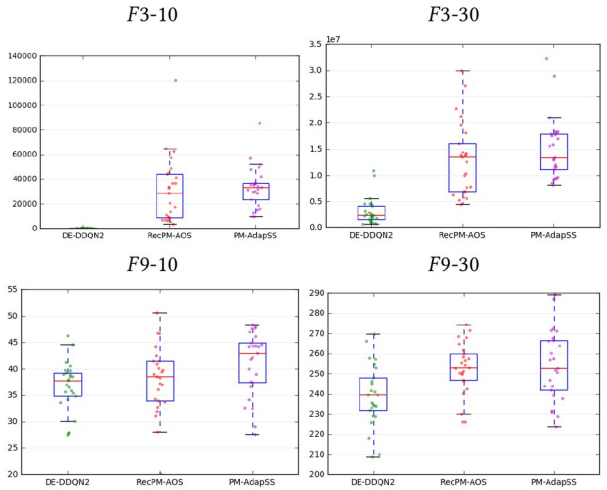
5 議論はある？

著者：F16・F23 の 30 次元では解がばらつき、高次元の多峰関数で NN が迷う。再起動の導入が課題。

所感：既存 AOS とは有意差がなく、試験は 10 問のみ。学習に任せたのは演算子選択だけで、F・CR・再起動は手設計のまま。

6 次に読むべき論文は？

- RL-DAS (Guo+ 2024)（本資料）
- LDE: Learning Adaptive DE (Sun+ 2021)（未調査）
- GLEET (Ma+ 2024)（既存：deep-learning-fusion ）



出典：DE-DDQN (Sharma+ 2019) Fig. 1（一部：F3・F9 の 10/30 次元。25 試行の誤差を DE-DDQN2・RecPM-AOS・PM-AdapSS で比較）

書誌情報

発表： GECCO 2019
リンク： https://arxiv.org/abs/1905.08006
系譜： 原典
調査日： 2026-10-24
確認範囲： 全文（問題提起・手法・実験・結果・考察）

Generalize a Small Pre-trained Model to Arbitrarily Large TSP Instances

Zhang-Hua Fu, Kai-Bin Qiu, Hongyuan Zha（CUHK-Shenzhen・AIRS）| AAAI 2021

1 どんなもの？

小規模 TSP で教師あり学習した Att-GCRN を部分グラフに繰り返し適用し、辺のヒートマップを合成する。それを事前分布にして k-opt の MCTS で巡回路を改善する「ヒートマップ＋ MCTS 」の起点。TSP10000 で LKH3 比 4.39% 。

2 先行研究と比べてどこがすごい？

教師あり学習（Joshi+ 2019 の GCN ＋ビームサーチ）は訓練と違う規模に汎化せず、大規模の正解ラベルも高価。AM（Kool+ ）など RL 構築法は TSP1000 で gap 85% 超。学習は小規模に限り、規模の壁は探索側で越える。

3 技術や手法のキモはどこ？

kNN で部分グラフを抽出し、座標を正規化して部分ヒートマップを作り、重なり回数で平均する（P<1e-4 の辺は除外）。MCTS は完全巡回路を状態とし、k-opt 行動を $Z=W/\Omega+\alpha\sqrt{(\ln(M+1)/(Q+1))}$ で選んで、改善時に W を強化する。

4 どうやって有効だと検証した？

TSP20/50/100 の gap は 0.00/0.01/0.04% 、TSP200 ～ 1000 は 0.88 ～ 3.22% で既存の学習法すべてに勝つ（Table 1–2 ）。TSP10000 で 4.39%（AM 系は 80% 超）。全辺等確率の MCTS 単独は gap 108 ～ 2074%（Table 4 ）。

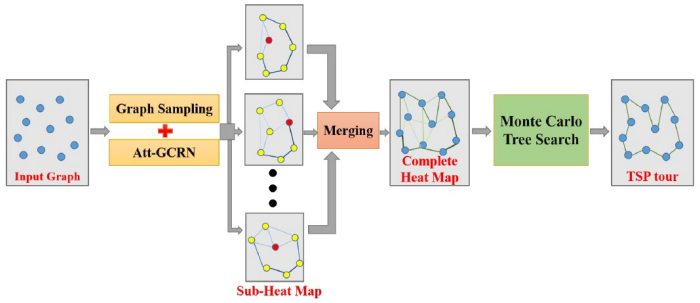
5 議論はある？

著者：学習ベースなので LKH3 に厳密に勝つことは狙わず、α-nearness・POPMUSIC などの手設計規則も避けた。

所感：Table 4 の「ヒートマップなし」は全辺を候補にしており、k 近傍の候補集合という古典的前提まで外している。後の SoftDist・GT-Prior はこの比較の甘さを突いた。

6 次に読むべき論文は？

- DIMES (Qiu+ 2022)（本資料）
- Position: Rethinking Post-Hoc Search (Xia+ 2024)（本資料）
- Targeted sampling MCTS for TSP (Fu+ 2019)（未調査）



出典：Att-GCN+MCTS (Fu+ 2021) Fig. 1（部分グラフのサンプリング→ Att-GCRN→ ヒートマップ統合→ MCTS ）

書誌情報

発表： AAAI 2021
リンク： https://arxiv.org/abs/2012.10658
系譜： 原典
調査日： 2026-10-24
確認範囲： 全文（問題提起・手法・実験・結果・考察）

DIMES: A Differentiable Meta Solver for Combinatorial Optimization Problems

Ruizhong Qiu, Zhiqing Sun, Yiming Yang（UIUC・Carnegie Mellon University）| NeurIPS 2022

1 どんなもの？

解の分布を辺ごとの連続パラメータ θ（ヒートマップ）で表し、REINFORCE と MAML 型のメタ学習で GNN を訓練する DIMES を提案。ラベルなしで TSP10000 まで直接学習でき、RL+AS+MCTS で TSP500/1000/10000 の gap は 1.76/2.46/3.19% 。

2 先行研究と比べてどこがすごい？

自己回帰型の構築 RL（AM 、POMO ）は、復号コストと疎な報酬のため数百ノードが限界。Fu+ 2021 は教師ありで、大規模ラベルが高価。DIMES は並列サンプリングで REINFORCE の分散を下げ、大規模グラフで直接訓練する。

3 技術や手法のキモはどこ？

p_θ(f)∝exp(Σf_iθ_i) を、一様な始点と θ_ij の softmax で逐次サンプルする補助分布 q で近似し、∇ E_q[c]=E_q[(c−b)∇log q] で学習する。メタ学習では、事例ごとの微調整（active search ）に向く初期値を学ぶ。

4 どうやって有効だと検証した？

TSP500/1000/10000（Fu+ の試験集合）の gap は、RL+G で 14.4/15.0/20.4% 、RL+MCTS で 1.93/2.64/3.98%（Table 1 ）。TSP1000 で MCTS に渡すヒートマップを替えると、長さは一様乱数 25.52 、近傍順位 1/(r+1) 24.14 、Att-GCN 23.86 、DIMES 23.69（Table 2d ）。

5 議論はある？

著者：θ を一度に生成するため推論力が限られ、MIS では LwD に負ける。多値変数（MIP ）への拡張は自明でない。

所感：学習単体（G ）の gap は 14% 台で、品質の大半は MCTS が生む。近傍順位だけのヒートマップとの差は約 2% で、後の SoftDist 論争の伏線になった。

6 次に読むべき論文は？

- DIFUSCO (Sun & Yang 2023)（本資料）
- UTSP (Min+ 2023)（本資料）
- Learning TSP Requires Rethinking Generalization (Joshi+ 2022)（未調査）

(a) On meta-learning ($T = 10$).

Inner updates	Fine-tuning	Length ↓
		27.11
✓		26.58
	✓	25.68
✓	✓	**24.91**

(b) On fine-tuning parts ($T = 5$).

Part	Length ↓
Cont. Param.	27.73
MLP	26.75
GNNOut+MLP	**26.49**
GNN+MLP	26.81

(c) On inner update steps T.

T	0	4	8	10	12	14
Length ↓	25.79	25.28	25.08	25.08	24.97	24.91

(d) On heatmaps for MCTS.

Heatmap	Length ↓
Unif(0, 1)	25.52
$1/(r_i + 1)$	24.14
Att-GCN	23.86
DIMES (ours)	**23.69**

出典：DIMES (Qiu+ 2022) Table 2（TSP-1000 のアブレーション。(d) は MCTS に渡すヒートマップの比較）

書誌情報

発表： NeurIPS 2022
リンク： https://arxiv.org/abs/2210.04123
系譜：発展（← Att-GCN+MCTS (Fu+ 2021) ）
調査日： 2026-10-24
確認範囲：全文（問題提起・手法・実験・結果・考察）

DIFUSCO: Graph-based Diffusion Solvers for Combinatorial Optimization

Zhiqing Sun, Yiming Yang（ Carnegie Mellon University ）| NeurIPS 2023

1 どんなもの？

組合せ最適化の解を {0,1} ベクトルとし、異方性 GNN の離散拡散モデルでヒートマップを生成する DIFUSCO を提案。MCTS と組み合わせて、TSP500/1000/10000 の gap を 1.76→0.46% 、2.46→1.17% 、3.19→2.58% に縮めた。

2 先行研究と比べてどこがすごい？

自己回帰型は逐次復号のため大規模化できない。従来のヒートマップ型は変数間の条件付き独立を仮定し、多峰な解分布を表せない。DIFUSCO は DIMES の RL と違い、教師ありの雑音除去で安定に学び、反復で多峰性を扱う。

3 技術や手法のキモはどこ？

Bernoulli 雑音の離散拡散 $q(x_t|x_{t-1})=\mathrm{Cat}(x Q_t)$ の逆過程を、x_0 を予測する GNN で学習する。推論は cosine スケジュールで約 50 ステップに間引き、最終確率をヒートマップとして貪欲復号＋ 2-opt か MCTS に渡す。大規模では k 近傍に疎化。

4 どうやって有効だと検証した？

Table 2：TSP500 の gap は貪欲 10.85%→ ＋ 2-opt 1.49%→MCTS 0.46% 、TSP10000 は 36.75%→3.10%→2.58% 。離散拡散は連続拡散より一貫して良い（ Fig. 1 ）。TSP50 で学習したモデルが 10000 都市でも機能する（ Fig. 3 ）。MIS の SATLIB で gap 0.21% 。

5 議論はある？

著者：ER グラフの MIS では振るわない（辺ベース GNN の帰納バイアスのため）。今後は等変 GNN と高速推論。

所感：2-opt だけで gap が 1/7 になる。学習と探索の寄与は分けて評価すべき。LKH-3 でのラベル作成や、TSP10000 で 28 分かかる生成時間も、後に争点になった。

6 次に読むべき論文は？

- Position: Rethinking Post-Hoc Search (Xia+ 2024)（本資料）
- Beyond the Heatmap (Pan+ 2025)（本資料）
- HeatACO (Lin+ 2026)（既存：aco-neural ）

Algorithm	Type	TSP-500 Length↓	TSP-500 Gap↓	TSP-500 Time↓	TSP-1000 Length↓	TSP-1000 Gap↓	TSP-1000 Time↓	TSP-10000 Length↓	TSP-10000 Gap↓	TSP-10000 Time↓
Concorde	Exact	16.55*	—	37.66m	23.12*	—	6.65h	N/A	N/A	N/A
Gurobi	Exact	16.55	0.00%	45.63h	N/A	N/A	N/A	N/A	N/A	N/A
LKH-3 (default)	Heuristics	16.55	0.00%	46.28m	23.12	0.00%	2.57h	71.77*	—	8.8h
LKH-3 (less trails)	Heuristics	16.55	0.00%	3.03m	23.12	0.00%	7.73m	71.79	—	51.27m
Farthest Insertion	Heuristics	18.30	10.57%	0s	25.72	11.25%	0s	80.59	12.29%	6s
AM	RL+G	20.02	20.99%	1.51m	31.15	34.75%	3.18m	141.68	97.39%	5.99m
GCN	SL+G	29.72	79.61%	6.67m	48.62	110.29%	28.52m	N/A	N/A	N/A
POMO+EAS-Emb	RL+AS+G	19.24	16.25%	12.80h	N/A	N/A	N/A	N/A	N/A	N/A
POMO+EAS-Tab	RL+AS+G	24.54	48.22%	11.61h	49.56	114.36%	63.45h	N/A	N/A	N/A
DIMES	RL+G	18.93	14.38%	0.97m	26.58	14.97%	2.08m	86.44	20.44%	4.65m
DIMES	RL+AS+G	17.81	7.61%	2.10h	24.91	7.74%	4.49h	80.45	12.09%	3.07h
Ours (DIFUSCO)	SL+G†	18.35	10.85%	3.61m	26.14	13.06%	11.86m	98.15	36.75%	28.51m
Ours (DIFUSCO)	SL+G†+2-opt	**16.80**	**1.49%**	**3.65m**	**23.56**	**1.90%**	**12.06m**	**73.99**	**3.10%**	**35.38m**
EAN	RL+S+2-opt	23.75	43.57%	57.76m	47.73	106.46%	5.39h	N/A	N/A	N/A
AM	RL+BS	19.53	18.03%	21.99m	29.90	29.23%	1.64h	129.40	80.28%	1.81h
GCN	SL+BS	30.37	83.55%	38.02m	51.26	121.73%	51.67m	N/A	N/A	N/A
DIMES	RL+S	18.84	13.84%	1.06m	26.36	14.01%	2.38m	85.75	19.48%	4.80m
DIMES	RL+AS+S	17.80	7.55%	2.11h	24.89	7.70%	4.53h	80.42	12.05%	3.12h
Ours (DIFUSCO)	SL+S	17.23	4.08%	11.02m	25.19	8.95%	46.08m	95.52	33.09%	6.59h
Ours (DIFUSCO)	SL+S+2-opt	**16.65**	**0.57%**	**11.46m**	**23.45**	**1.43%**	**48.09m**	**73.89**	**2.95%**	**6.72h**
Att-GCN	SL+MCTS	16.97	2.54%	2.20m	23.86	3.22%	4.10m	74.93	4.39%	21.49m
DIMES	RL+MCTS	16.87	1.93%	2.92m	23.73	2.64%	6.87m	74.63	3.98%	29.83m
DIMES	RL+AS+MCTS	16.84	1.76%	2.15h	23.69	2.46%	4.62h	74.06	3.19%	3.57h
Ours (DIFUSCO)	SL+MCTS	**16.63**	**0.46%**	**10.13m**	**23.39**	**1.17%**	**24.47m**	**73.62**	**2.58%**	**47.36m**

出典：DIFUSCO (Sun & Yang 2023) Table 2（大規模 TSP 。G= 貪欲、S= サンプリング、+2-OPT 、MCTS で復号を変えた比較）

書誌情報

発表： NeurIPS 2023（ Spotlight ）
リンク： https://arxiv.org/abs/2302.08224
系譜：発展（← DIMES (Qiu+ 2022) ）
調査日： 2026-10-24
確認範囲：全文（問題提起・手法・実験・結果・考察）

Unsupervised Learning for Solving the Travelling Salesman Problem

Yimeng Min, Yiwei Bai, Carla P. Gomes（Cornell University）| NeurIPS 2023

1 どんなもの？

ラベルも報酬サンプリングも使わず、代理損失だけで GNN（SAG）を訓練してヒートマップを作り、ヒートマップ誘導の局所探索で解く UTSP を提案。パラメータ約 10%、訓練事例約 0.2%（2000 件）で、TSP200/500/1000 の gap は 0.09/0.84/1.18%。

2 先行研究と比べてどこがすごい？

教師あり（Fu+、DIFUSCO）は大規模の最適解ラベルが高価で、RL（DIMES、AM）は疎な報酬で学習が不安定。UTSP は解を復号せず、微分可能な損失で学ぶ。低域通過の GCN は過平滑化し、区別のつかないヒートマップになることも示した。

3 技術や手法のキモはどこ？

列 softmax の行列 T から巡回置換型の H=Σ_t p_t p_{t+1}^T を作り、L=λ1Σ_i(Σ_j T_ij−1)^2+λ2Σ_i H_ii+Σ D_ij H_ij を最小化する。上位 M 辺に絞り、ヒートマップか M 近傍を候補とする best-first k-opt 探索で H を更新する。

4 どうやって有効だと検証した？

TSP20 ～ 100 は最適解と一致（Table 1–2）。TSP500/1000 の gap は 0.84/1.18%（DIFUSCO 0.46/1.17%、Att-GCN 2.54/3.22%、Table 3）。TSP100 では上位 10 辺が最適辺の 99.76% を覆い、候補は 4950→583 辺に減った。GCN は 33.9% しか覆わない（Fig. 4）。

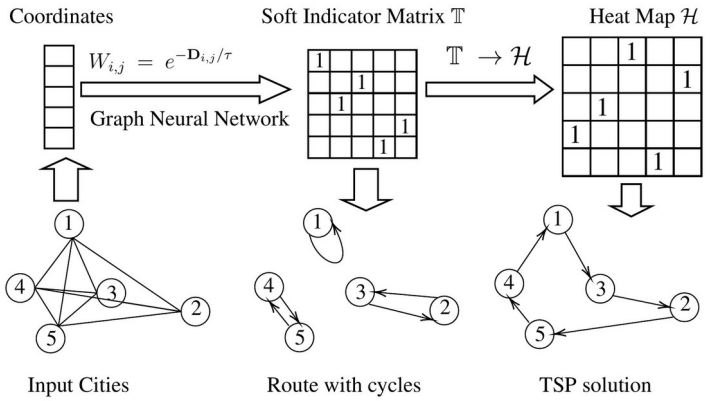
5 議論はある？

著者：代理損失が解の質を測るという理論保証はない。今後は辺特徴を持つ GNN や別の損失を試す。

所感：探索は候補集合をヒートマップと M 近傍の間で乱数で切り替えるため、学習の寄与だけを分離できない。規模ごとの探索設定と時間計測の扱いは、Xia+ と Min の論争点になった。

6 次に読むべき論文は？

- On Size and Hardness Generalization in UL for TSP (Min & Gomes 2024)（未調査）
- Position: Rethinking Post-Hoc Search (Xia+ 2024)（本資料）
- Comment on SoftDist (Min 2024)（参照のみ）



出典：UTSP (Min+ 2023) Fig. 1（GNN が出す軟らかい指示行列 T を T→H 変換してハミルトン閉路のヒートマップにする）

書誌情報

発表： NeurIPS 2023
リンク： https://arxiv.org/abs/2303.10538
系譜： 発展（← Att-GCN+MCTS (Fu+ 2021)）
調査日： 2026-10-24
確認範囲： 全文（問題提起・手法・実験・結果・考察）

Deep Reinforcement Learning for Dynamic Algorithm Selection: A Proof-of-Principle Study on Differential Evolution

Hongshu Guo, Yining Ma, Zeyuan Ma, Jiacheng Chen ほか（South China University of Technology）| IEEE TSMC: Systems 2024

1 どんなもの？

CEC2021 上位の 3 つの DE（JDE21 、MadDE 、NL-SHADE-RSP ）を部品とし、2500 評価ごとにどれを走らせるかを PPO の方策が選ぶ RL-DAS を提案。拡張 CEC2021 の 10D・20D で、各単体と事例ごとの最良選択（AS* ）を上回った。

2 先行研究と比べてどこがすごい？

静的アルゴリズム選択は 1 問題に 1 手法を割り当てるだけで、探索途中の補完性を使えない。DE-DDQN・LDE など RL 支援 DE は 1 つの DE 内の演算子や係数の制御にとどまり、試験関数も少なかった。RL-DAS は熟練の手設計アルゴリズムを丸ごと選ぶ。

3 技術や手法のキモはどこ？

状態はランドスケープ特徴 9 個（FDC 、分散差、NSC など）と、各アルゴリズムが最良・最悪個体を動かした平均シフトベクトル。報酬はコスト減少率 ×(MaxFEs/ 終了 FEs) 。切替時は各 DE の適応パラメータやアーカイブを文脈メモリから復元する。

4 どうやって有効だと検証した？

CEC2021 の 10 関数をシフト・回転で各 2048 事例に拡張（Table 2–3 ）。10D ではランダム切替に 7 勝 4 分 0 敗、AS* に 7 勝 3 分 1 敗、DE-DDQN・LDE に 9 勝 2 分 0 敗。ただし混合クラス C11 の降下率は RL-DAS 93.94% 、ランダム切替 93.69% 、MadDE 93.71% と僅差。

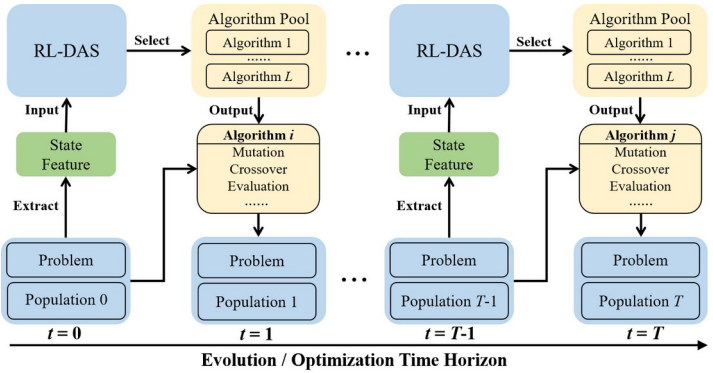
5 議論はある？

著者：状態表現は手設計で、複雑なアルゴリズムの組込みも難しい。切替は 2500 評価ごとが最適で、毎世代の切替は大きく悪化（Fig. 4 ）。

所感：ランダム切替でも単体 DE に勝つ。性能の多くは古典 DE の補完性と文脈復元から来ている。学習器を指揮役に限った分担は一つの答え。

6 次に読むべき論文は？

- RLDE-AFL (Guo+ 2025)（本資料）
- ConfigX (Guo+ 2024)（未調査）
- MetaBox-v2 (Ma+ 2025)（既存：metabbo ）



出典：RL-DAS (Guo+ 2024) Fig. 1（状態特徴から方策がアルゴリズムプールの 1 つを選び、区間ごとに集団を進める）

書誌情報

発表： IEEE TSMC: Systems 2024
リンク： https://arxiv.org/abs/2403.02131
系譜： 発展（← DE-DDQN (Sharma+ 2019) ）
調査日： 2026-10-24
確認範囲： 全文（問題提起・手法・実験・結果・考察）

Position: Rethinking Post-Hoc Search-Based Neural Approaches for Solving Large-Scale Traveling Salesman Problems

Yifan Xia, Xianliang Yang, Zichuan Liu, Zhihao Liu, Lei Song, Jiang Bian（Nanjing University・Microsoft Research Asia）| ICML 2024

1 どんなもの？

ヒートマップ＋ MCTS（Att-GCN 、DIMES 、UTSP 、DIFUSCO ）を再評価したポジション論文。距離行列に softmax をかけただけの SoftDist（パラメータは τ のみ）が多くの学習ヒートマップに勝ち、同じ条件では MCTS が LKH-3 に大きく劣ると示した。

2 先行研究と比べてどこがすごい？

既存手法は、MCTS を含まない代理損失（教師あり・教師なし・RL ）でヒートマップを学ぶ。訓練と試験の目的がずれ、本当に MCTS を助けるかは未検証だった。MCTS（C++・CPU ）と LKH-3 を同じ条件で比べた研究もなかった。

3 技術や手法のキモはどこ？

SoftDist：Φ_ij=exp(−d_ij/τ)/Σ_k exp(−d_ik/τ)。τ だけを、MCTS 込みの真の目的（巡回路長）で格子探索する。評価指標 Score=Gap_LKH3/Gap_MCTS は、同じハードウェア・同じ時間での LKH-3 に対する相対効率を表す。

4 どうやって有効だと検証した？

既定 MCTS（Table 1 ）での gap：SoftDist 1.44/2.20/3.13%（TSP500/1000/10000 ）。Att-GCN 1.64/2.37/3.80% 、DIMES 1.77/2.44/3.23% に勝ち、DIFUSCO（0.51/1.18/2.77% ）とはパレート上で並ぶ。Score は 0.35 ～ 33.8%（Table 2 ）。全 0 のヒートマップでも TSP1000 で 1.85%（Table 3 ）。

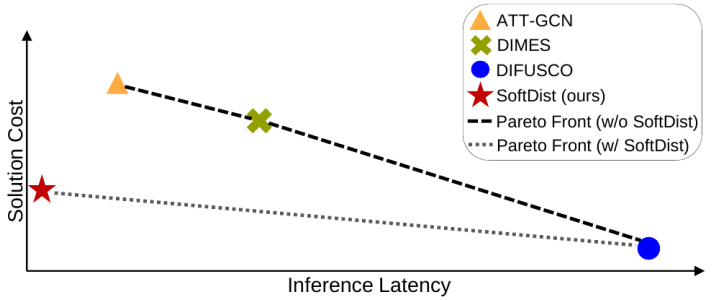
5 議論はある？

著者：MCTS のような問題特化の後処理に頼るのは、汎用・自律的な解法という ML の目的に反する。

所感：Min 2024 の反論は、同じ時間なら UTSP が SoftDist に勝つ（1.65 vs 1.73% ）と時間計測の不公平を指摘した。学習器と探索器を同条件で比べるという論点を立てた点が貢献。

6 次に読むべき論文は？

- Beyond the Heatmap (Pan+ 2025)（本資料）
- Comment on SoftDist (Min 2024)（参照のみ）
- HeatACO (Lin+ 2026)（既存：aco-neural ）



出典：Position (Xia+ 2024) Fig. 1（ヒートマップ生成時間と解コストのパレート。SoftDist を加えると前線が下がる）

書誌情報

発表： ICML 2024（Position ）
リンク： https://arxiv.org/abs/2406.03503
系譜：最新（← DIFUSCO (Sun & Yang 2023) ）
調査日： 2026-10-24
確認範囲：全文（問題提起・手法・実験・結果・考察）

Reinforcement Learning-based Self-adaptive Differential Evolution through Automated Landscape Feature Learning

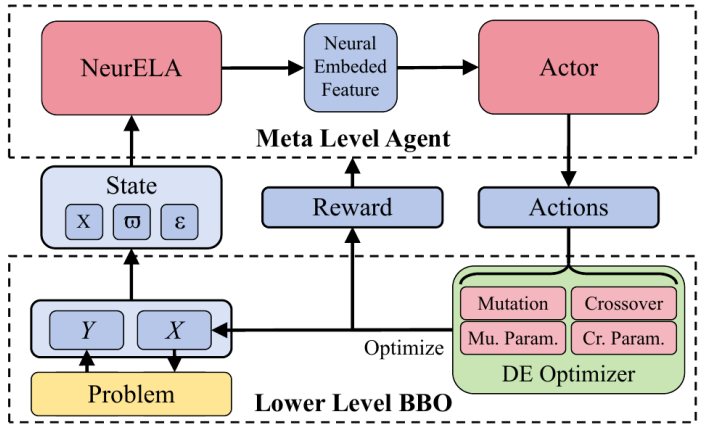
Hongshu Guo, Sijie Ma, Zechuan Huang ほか（South China University of Technology）| GECCO 2025

1 どんなもの？

手設計の状態特徴をやめ、集団と評価値から注意機構（NeurELA）で特徴を学ぶ。そのうえで、14 の変異・3 の交叉演算子とそのパラメータを個体ごとに PPO で同時制御する RLDE-AFL を提案。BBOB 16 関数で、従来 DE と RL 型 DE の 11 手法を上回った。

2 先行研究と比べてどこがすごい？

既存の MetaBBO（DE-DDQN の 99 次元、RL-DAS のランドスケープ特徴、GLEET）は状態設計に専門知識が要り、追加評価を使うものもある。演算子プールも小さく、選択か係数制御の片方だけだった。本手法は特徴設計と構成空間の両方を学習側へ移す。



出典：RLDE-AFL (Guo+ 2025) Fig. 1（NeurELA の特徴から方策が変異・交叉とそのパラメータを決める 2 層構造）

3 技術や手法のキモはどこ？

観測は次元ごとの (x, 仮数, 指数)。評価値を仮数・指数で表し、問題間のスケール差を吸収する。解方向と次元方向の 2 段の自己注意で個体ごとの埋め込みを作り、アクターが変異・交叉の種類（カテゴリ分布）とパラメータ（正規分布）を出す。

4 どうやって有効だと検証した？

BBOB 24 関数（10D）のうち 8 関数で学習し、残り 16 関数で試験（Table 1）。勝 / 負 / 分は NL-SHADE-LBC に 9/4/3、DE-DDQN に 8/6/2、ランダム行動に 13/2/1。20D、評価 2000 回、タンパク質ドッキングにもゼロショットで転移し、GLEET と同等以上（Fig. 4）。

5 議論はある？

著者：特徴抽出器と方策を同時に学ぶことが鍵。GLEET の手設計特徴に替えると性能が下がる（Table 3）。

所感：その差は累積報酬 0.9645 対 0.9512 と小さく、NL-SHADE-LBC に 4 関数で負ける。ランダムに演算子を混ぜても素の DE に勝つので、学習とプール多様性の寄与を分けたい。

6 次に読むべき論文は？

- Neural Exploratory Landscape Analysis (Ma+ 2024)（未調査）
- MetaBox-v2 (Ma+ 2025)（既存：metabbo）
- When does learning pay off? (Mencaroni+ 2026)（本資料）

書誌情報

発表： GECCO 2025
リンク： https://arxiv.org/abs/2503.18061
系譜： 最新（← RL-DAS (Guo+ 2024)）
調査日： 2026-10-24
確認範囲： 全文（問題提起・手法・実験・結果・考察）

Beyond the Heatmap: A Rigorous Evaluation of Component Impact in MCTS-Based TSP Solvers

Xuanhao Pan, Chenguang Wang, Chaolong Ying, Ye Xue, Tianshu Yu（CUHK-Shenzhen）| ICLR 2026

1 どんなもの？

ヒートマップ＋ MCTS の性能を決めるのは、ヒートマップの複雑さか MCTS の設定かを検証した評価研究。MCTS を手法ごとに調整すると、k 近傍の統計だけで作る GT-Prior（パラメータ不要）が学習ヒートマップと同等以上で、規模・分布の変化にも頑健。

2 先行研究と比べてどこがすごい？

Fu+ 2021 以降の研究はヒートマップ生成（DIMES、DIFUSCO、UTSP）の高度化に集中し、MCTS は既定設定のまま比べられてきた。SoftDist（Xia+ 2024）は単純なヒートマップの強さを示したが、MCTS 側の寄与は定量化していなかった。

3 技術や手法のキモはどこ？

MCTS の 6 パラメータ（α、β、最大 k、候補数、シミュレーション数、候補をヒートマップで作るか）をヒートマップ・規模ごとに格子探索し、SHAP で重要度を分解する。GT-Prior は最適巡回路で k 番目近傍が選ばれる頻度 P̂_N(k) をそのまま辺確率にする。

4 どうやって有効だと検証した？

同じヒートマップでも、MCTS 設定で gap は DIMES の TSP10000 で 4.86 ～ 91.31% と変わる（Fig. 2）。調整後の TSP500/1000/10000：GT-Prior 0.50/0.85/2.13%、DIFUSCO 0.33/0.53/2.36%、Zero 0.66/1.16/3.79%（Table 1）。TSP500 で学習した場合、10000 で DIFUSCO は 5.27% に劣化（Table 2）。

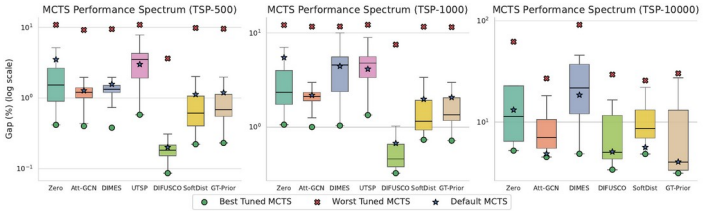
5 議論はある？

著者：最適巡回路の辺は 94% 超が上位 5 近傍に入る。重要なのは候補数と最大深さ。調整のコストは学習と同程度。

所感：同規模では DIFUSCO が今も最良で、学習の価値は分布内の上積みに限られる。探索器を調整してから学習器を比べる手順は標準にすべき。

6 次に読むべき論文は？

- Position: Rethinking Post-Hoc Search (Xia+ 2024)（本資料）
- HeatACO (Lin+ 2026)（既存：aco-neural）
- Connected by Construction / C2TSP (Sun+ 2026)（参照のみ）



出典：Beyond the Heatmap (Pan+ 2025) Fig. 2（ヒートマップ別・規模別の gap 分布。緑 = 最良調整、赤 × = 最悪調整、星 = 既定 MCTS）

書誌情報

発表： ICLR 2026
リンク： https://arxiv.org/abs/2411.09238
系譜： 最新（← SoftDist / Position (Xia+ 2024)）
調査日： 2026-10-24
確認範囲： 全文（問題提起・手法・実験・結果・考察）

When does learning pay off? A study on DRL-based dynamic algorithm configuration for carbon-aware scheduling

Andrea Mencaroni, Robbert Reijnen, Yingqian Zhang, Dieter Claeys（Ghent University）| arXiv プレプリント 2026

1 どんなもの？

炭素考慮フローショップ用メメティックアルゴリズムの 7 パラメータを、PPO で毎世代制御する DRL-DAC を作った。同じ 12 事例・400 万反復の予算で静的チューニングと比べ、学習が得になる条件を調べた。既知型では差がなく、未知の大規模型でだけ最大 3.2% 勝った。

2 先行研究と比べてどこがすごい？

DRL-DAC の研究（DE-DDQN、LDE など）は CEC 関数で既存手法を上回ったという報告が多く、同じ予算の静的チューニングとの比較や、いつ効くかの分析が欠けていた。先行する Reijnen+ の FJSP 研究では、静的 GA と有意差がなかった。

3 技術や手法のキモはどこ？

状態は最良・平均適応度、変動係数、残り予算、停滞の 5 次元で、事例に依存しないよう正規化する。行動は交叉・変異の頻度や強さなど 7 次元の連続値。報酬は後半の改善を重く見る二乗正規化改善量。静的側は Optuna（TPE）と irace で同じ予算を使って調整。

4 どうやって有効だと検証した？

既知型 4 データセット（各 50 事例 ×10 試行）では 3 手法がほぼ同じで、M1T1 の差は 0.04%（Table 4）。未知型 6 データセットでは、M5T3 で +0.3%、M10T3 で +3.2%、M15T3 で +2.3%（Table 5）。最も易しい M5T1 では既定設定が最良。学習は約 55 時間、調整は約 3 日。

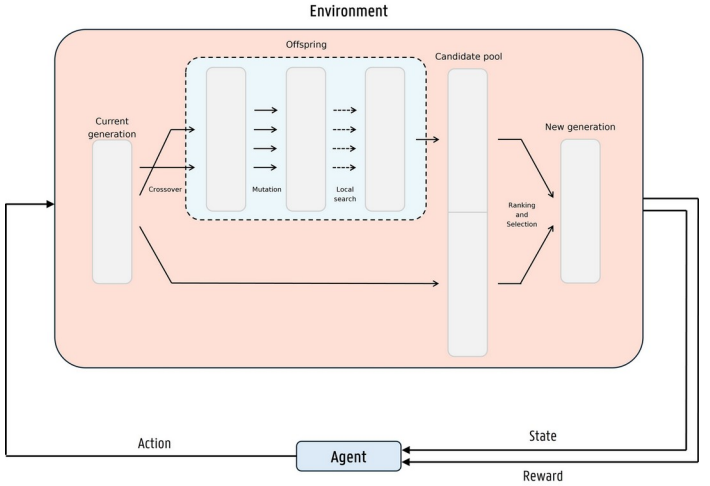
5 議論はある？

著者：類似度は記述的なもので、学習が効くかを事前に予測する基準ではない。方策は最初の約 20 世代だけ交叉パラメータを動かし、後はほぼ静的になる（Fig. 6）。

所感：動的制御の実体は序盤のスケジュールで、学習の価値は分布外への汎化にあった。

6 次に読むべき論文は？

- Reijnen+ 2023 DRL-based DAC for FJSP（未調査）
- Dynamic Algorithm Configuration (Biedenkapp+ 2020)（未調査）
- MetaBox-v2 (Ma+ 2025)（既存：metabbo）



出典：When does learning pay off? (Mencaroni+ 2026) Fig. 2（メメティックアルゴリズムを環境とし、エージェントが毎世代パラメータを決める）

書誌情報

発表： arXiv プレプリント 2026
リンク： https://arxiv.org/abs/2604.01886
系譜： 最新（← DE-DDQN (Sharma+ 2019)）
調査日： 2026-10-24
確認範囲： 全文（問題提起・手法・実験・結果・考察）