LLM 駆動の進化的探索と自己改善エージェント

LLM を交叉・変異演算子、課題の生成器、自己改変器として使い、探索を止めない系の系譜。
LMX・OMNI・Promptbreeder（2023）→ OMNI-EPIC・DGM（アーカイブ＝踏み石）→ ShinkaEvolve・HGM・Hyperagents・AI Scientist（2025–26）。
各論文のアブレーションではアーカイブ・非貪欲な親選択・新奇性棄却が効くが、2026 年の大規模比較は「万能のハーネスはない」と示した。

#	年	論文	発表	系譜
1	2023	LMX (Meyerson+ 2023)	ACM TELO 2024	原典
2	2023	OMNI (Zhang+ 2023)	ICLR 2024	原典
3	2023	Promptbreeder (Fernando+ 2023)	ICML 2024	発展
4	2024	OMNI-EPIC (Faldor+ 2024)	ICLR 2025	発展
5	2025	Darwin Gödel Machine (Zhang+ 2025)	ICLR 2026	発展
6	2025	ShinkaEvolve (Lange+ 2025)	ICLR 2026	最新
7	2025	HGM (Wang+ 2025)	ICLR 2026	最新
8	2026	Hyperagents / DGM-H (Zhang+ 2026)	arXiv プレプリント 2026	最新
9	2026	The AI Scientist, Nature 版 (Yamada+ 2026)	Nature 2026	最新
10	2026	No Universal Harness (Gupta+ 2026)	arXiv プレプリント 2026	最新

Language Model Crossover: Variation through Few-Shot Prompting

Elliot Meyerson, Mark J. Nelson, Herbie Bradley ほか（Cognizant AI Labs ほか）| ACM TELO 2024

1 どんなもの？

親個体のテキストを並べた few-shot プロンプトを LLM に続けさせ、出力を子とする交叉演算子 LMX を提案。ビット列・数式・文・画像生成プロンプト・Python コードの 5 領域で、専用演算子なしに進化を回せた。

2 先行研究と比べてどこがすごい？

従来の交叉・変異は表現ごとに手設計が必要で、ELM は指示つきの 1 親変異だった。LMX は指示なしで複数の親の共通パターンを文脈内学習に推定させ、EDA のように親の分布から子を標本化する。

3 技術や手法のキモはどこ？

LMX(x1..xk)=φ(LLM(φ[x1..xk]))（φ：親の連結、φ：出力の分解）。親が増えるほど出力分布が UMDA 型 EDA の分布に近づき（Fig. 12）、親の並べ順で子の分布を偏らせられる（Fig. 13）。

4 どうやって有効だと検証した？

Pythia 70M ～ 6.9B で大きいモデルほど有効・新規な子が増加（Fig. 2b）。記号回帰（banana）で SRBench の Pareto 前線上（Fig. 7）。画像プロンプト進化で 1 点交叉とゼロショット生成を上回った（Fig. 10）。

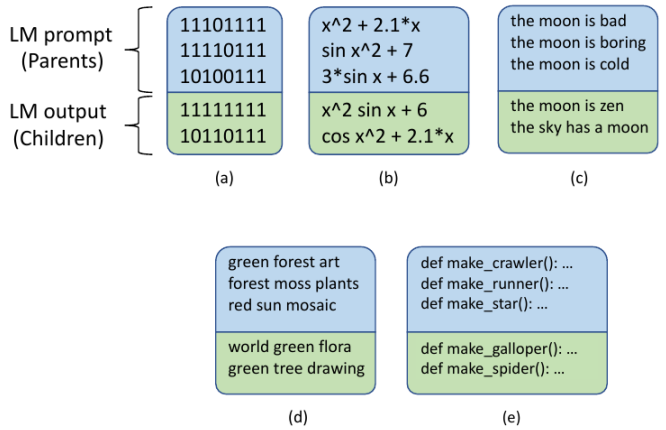
5 議論はある？

著者：無効な出力、文脈長の上限、LLM の不透明さが限界。

所感：「親の集合＝プロンプト」は、後の AlphaEvolve 系のインスピレーション文脈や MAP-Elites からの親抽出の原型。結果は小型モデルでの概念実証にとどまる。

6 次に読むべき論文は？

- ELM (2022)（既存：swarm-intelligence/ga-hybrid）
- Promptbreeder (2023)（本資料）
- QDAIF (Bradley+ 2023)（未調査）



出典：LMX Fig. 1（親を並べたプロンプトから子を生成する 5 領域の例。2 段に再配置）

書誌情報

発表： ACM TELO 2024
リンク： https://arxiv.org/abs/2302.12170
系譜： 原典（← ELM）
調査日： 2026-10-24
確認範囲： 全文（問題提起・手法・実験・結果・考察）

OMNI: Open-endedness via Models of human Notions of Interestingness

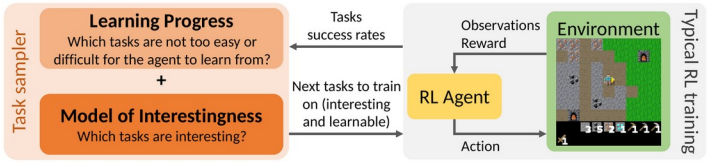
Jenny Zhang, Joel Lehman, Kenneth Stanley, Jeff Clune（UBC / Vector Institute ほか）| ICLR 2024

1 どんなもの？

基盤モデルを「面白さのモデル（MoI）」とし、学習進捗（LP）で選んだ課題のうち面白いものに絞る自動カリキュラム OMNI を提案。Crafter・BabyAI・AI2-THOR で一様抽出と LP 単独を上回った。

2 先行研究と比べてどこがすごい？

LP 型カリキュラムは「学べるが退屈な課題」（数を変えただけの課題など）に気を取られる。新奇性などの手書き指標は Goodhart の法則で病的な解を生む。OMNI は人間の興味の判断を基盤モデルから借りる。



出典：OMNI Fig. 1（学習進捗と面白さのモデルを組み合わせた課題サンプラー）

3 技術や手法のキモはどこ？

LP（成功率の 2 重 EMA の差）で重みを付け、GPT-3/4 が退屈と判定した課題の重みを 0.001 倍にする。無限の課題空間では GPT-4 が次の課題と、その成否を判定するコードを同時に生成する。

4 どうやって有効だと検証した？

Crafter（面白い 15 ＋退屈 90 ＋極難 1023 課題）で習得課題数は一様 4 ／ LP 55 ／ OMNI 82、平均成功率 0.03 ／ 0.42 ／ 0.56（Fig. 3）。BabyAI 1 ／ 4 ／ 8（Fig. 4）、AI2-THOR 0 ／ 2 ／ 13（Fig. 5）。

5 議論はある？

著者：MoI も最適化の対象になれば崩れるため、人の評価で更新する OEHF を提案。

所感：面白さの判定を LLM に任せる発想が OMNI-EPIC・DGM・AI Scientist に受け継がれた。退屈な課題は人工的に作った設定である点は割り引くべき。

6 次に読むべき論文は？

- OMNI-EPIC (2024)（本資料）
- POET (Wang+ 2019)（未調査）
- Kanitscheider+ 2021 学習進捗カリキュラム（未調査）

書誌情報

発表： ICLR 2024
リンク： https://arxiv.org/abs/2306.01711
系譜： 原典
調査日： 2026-10-24
確認範囲： 全文（問題提起・手法・実験・結果・考察）

Promptbreeder: Self-Referential Self-Improvement Via Prompt Evolution

Chrisantha Fernando, Dylan Banarse, Henryk Michalewski, Simon Osindero, Tim Rocktäschel（Google DeepMind）| ICML 2024

1 どんなもの？

タスクプロンプトと、それを書き換える変異プロンプトを同時に進化させる自己参照的なプロンプト進化 Promptbreeder を提案。PaLM 2-L で GSM8K 83.9%（ゼロショット）など、CoT・Plan-and-Solve・OPRO を上回った。

2 先行研究と比べてどこがすごい？

APE は反復しても 3 回ほどで改善が頭打ちになり、OPRO・EvoPrompt は変異の指示文が固定。Promptbreeder は変異プロンプトも LLM で変異させ（超変異）、多様性の維持で頭打ちを避ける。

3 技術や手法のキモはどこ？

P′=LLM(M+P)、M′=LLM(H+M)。二値トーナメント GA（集団 50）に 9 種の変異（ゼロ次生成、EDA・系譜ベース、超変異、Lamarck 型、交叉）を一様に適用。EDA 変異では BERT 類似度 0.95 超を除外する。

4 どうやって有効だと検証した？

Table 1：GSM8K 83.9（OPRO 80.2）、MultiArith 99.7、AQuA 62.2 など。ETHOS 80%→89%。改善を生んだ割合はゼロ次超変異 42%、系譜変異 26%（Table 8）。自己参照の演算子を外すとほぼ全データで低下（Fig. 4）。

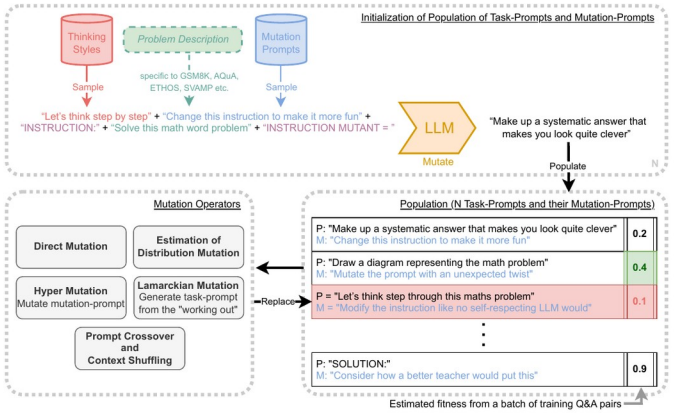
5 議論はある？

著者：プロンプトの使い方（段数・構造）は固定で、内容しか適応しない。

所感：アブレーションでは初期化の多様化の寄与が最大で、超変異そのものの効果は限定的に見える。DGM・Hyperagents の「改善手順も改善する」発想の前身。

6 次に読むべき論文は？

- LMX (2023)（本資料）
- OPRO (Yang+ 2023)（未調査）
- Darwin Gödel Machine (2025)（本資料）



出典：Promptbreeder Fig. 1（初期化・変異演算子・集団の全体像）

書誌情報

発表： ICML 2024
リンク： https://arxiv.org/abs/2309.16797
系譜： 発展（← LMX）
調査日： 2026-10-24
確認範囲： 全文（問題提起・手法・実験・結果・考察）

OMNI-EPIC: Open-endedness via Models of human Notions of Interestingness with Environments Programmed in Code

Maxence Faldor, Jenny Zhang, Antoine Cully, Jeff Clune（Imperial College London / UBC）| ICLR 2025

1 どんなもの？

LLM が「学習可能で面白い」次の課題を自然言語で提案し、その環境と報酬関数を Python コードで生成する OMNI-EPIC を提案。PyBullet 上で課題アーカイブを広げ続け、RL エージェントに学習させた。

2 先行研究と比べてどこがすごい？

POET や OMNI は環境のパラメータ空間（障害物の種類・大きさ等）が手設計で狭い。OMNI-EPIC は世界・報酬・終了条件をコードで書かせ、原理上は任意の課題を作れる方向（Darwin Completeness）へ広げた。

3 技術や手法のキモはどこ？

成功・失敗課題のアーカイブから類似課題を検索して文脈に入れ（踏み石）、課題生成→環境コード生成→事後の面白さ判定（類似課題と比べて新規か）→ DreamerV3 で学習→成功判定、を繰り返す。

4 どうやって有効だと検証した？

学習を省いた長期実行（200 反復、各 3 回）で、アーカイブなし・面白さなしより埋めたセル数が有意に多い（$p<0.05$, Fig. 4）。RL 付き短期実行 5 回でも新指標 ANNECS-OMNI が両対照を上回った。

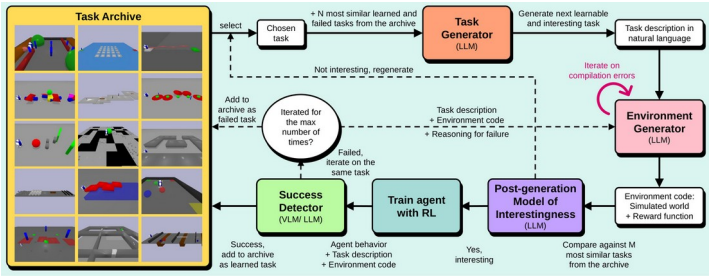
5 議論はある？

著者：シミュレータが 1 つで Darwin Complete ではなく、課題ごとの専門エージェントの汎化も未検証。

所感：アーカイブ除去の効果を定量化した点が本テーマの基準点。ただし多様性は埋め込み PCA のセル数で、実行数も少ない。

6 次に読むべき論文は？

- OMNI (2023)（本資料）
- POET / Enhanced POET (Wang+ 2019/2020)（未調査）
- Darwin Gödel Machine (2025)（本資料）



出典：OMNI-EPIC Fig. 1（課題アーカイブ・課題生成・環境生成・面白さ判定・成功判定のループ）

書誌情報

発表： ICLR 2025
リンク： https://arxiv.org/abs/2405.15568
系譜： 発展（← OMNI）
調査日： 2026-10-24
確認範囲： 全文（問題提起・手法・実験・結果・考察）

Darwin Godel Machine: Open-Ended Evolution of Self-Improving Agents

Jenny Zhang, Shengran Hu, Cong Lu, Robert Lange, Jeff Clune（UBC / Vector Institute / Sakana AI）| ICLR 2026

1 どんなもの？

コーディングエージェントが自分のコードを書き換え、子孫をすべてアーカイブに残してそこから親を選び続ける DGM を提案。80 反復で SWE-bench Verified 20.0%→50.0%、Polyglot（全体）14.2%→30.7%。

2 先行研究と比べてどこがすごい？

Gödel Machine は改善の証明が要り実現できず、ADAS はメタエージェントが固定、SICA は最良版だけを登る。DGM は証明を評価に置き換え、自己改変も課題もコーディングなので改善が自己改善能力に直結する。

3 技術や手法のキモはどこ？

親の選択確率 ∝ sigmoid(λ(α−0.5)) · 1/(1+n)（α：性能、n：機能する子の数）。高性能で子の少ない個体を優先しつつ全個体に非ゼロ確率を残す（App. C.2）。評価は 10→60→200 課題の段階制。

4 どうやって有効だと検証した？

Table 1（SWE-bench / Polyglot）：DGM 50.0/38.0、アーカイブなし 23.0/14.0、自己改善なし 39.0/28.0、貪欲（常に最良が親）39.7/30.0。最良系譜は性能が下がった個体を 2 回経由（Fig. 3）。

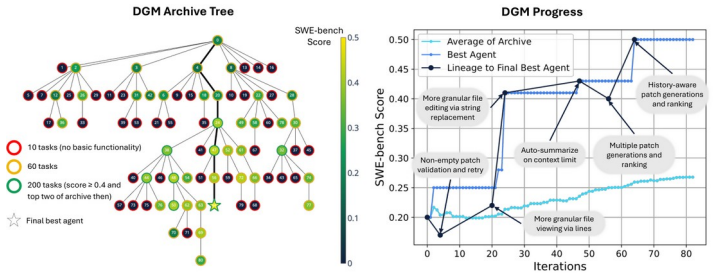
5 議論はある？

著者：1 実行に約 2 週間・約 2.2 万ドル。親選択とアーカイブは固定で自己改変できない。検出用トークンを消す目的ハッキングも観察（App. H）。

所感：アーカイブと非貪欲な親選択の寄与を同条件で比べた貴重な例だが、各条件 1 実行。

6 次に読むべき論文は？

- HGM (2025)（本資料）
- Hyperagents (2026)（本資料）
- ADAS (Hu+ 2024)（未調査）
- SICA (Robeyns+ 2025)（未調査）



出典：DGM Fig. 3（SWE-bench でのアーカイブ木と、最良エージェントに至る系譜の進捗）

書誌情報

発表： ICLR 2026
リンク： https://arxiv.org/abs/2505.22954
系譜： 発展（← OMNI-EPIC）
調査日： 2026-10-24
確認範囲： 全文（問題提起・手法・実験・結果・考察）

ShinkaEvolve: Towards Open-Ended And Sample-Efficient Program Evolution

Robert Tjarko Lange, Yuki Imajuku, Edoardo Cetin（Sakana AI）| ICLR 2026

1 どんなもの？

LLM を変異演算子とする島モデルのプログラム進化に、性能と子の数による親選択、新奇性による棄却、UCB1 による LLM 選択を加えたオープンソース枠組み。26 円詰めで 150 評価未満で AlphaEvolve の解を上回った。

2 先行研究と比べてどこがすごい？

AlphaEvolve などは数千回の評価を要し、多くが非公開。ShinkaEvolve は DGM 由来の親選択と、似たプログラムを評価前に捨てる仕組みで標本効率を上げ、Apache 2.0 で公開した。

3 技術や手法のキモはどこ？

親選択 $p \propto \sigma(\lambda(F-\text{median } F)) \cdot 1/(1+N)$。変異は diff・全面書き換え・交叉。島内の既存プログラムとの埋め込み類似度が 0.95 を超えたら LLM に新規性を判定させ、新しくなければ棄却する。

4 どうやって有効だと検証した？

AIME 足場は 7 呼び出しの構成を発見し、別年度・別モデルに転移（Fig. 6）。ALE-Bench LITE で平均約 2.3% 改善（Fig. 7）。円詰めのアブレーションで、重み付き親選択＞山登り＞ Best-of-N、埋め込み棄却＞棄却なし（Fig. 9）。

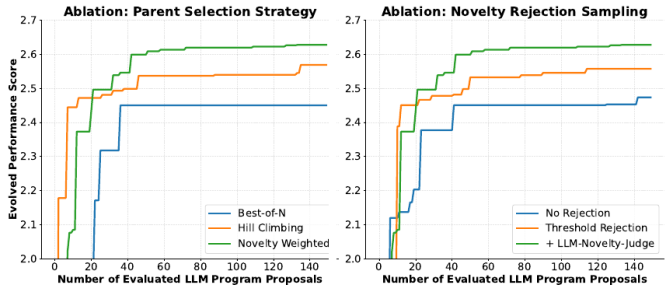
5 議論はある？

著者：探索と活用の配分は固定設定で、目的関数は人が定義する必要がある。

所感：アブレーションは円詰め 1 課題・各 1 本の曲線で、ばらつきが示されていない。LLM による新奇性判定の上乗せは小さいと著者も認める。

6 次に読むべき論文は？

- AlphaEvolve (2025)（既存：swarm-intelligence/metabbo）
- AdaEvolve (Cemri+ 2026)（未調査）
- No Universal Harness (2026)（本資料）



出典：ShinkaEvolve Fig. 9（円詰めでの親選択と新奇性棄却のアブレーション。3 枚中 2 枚を抜粋）

書誌情報

発表： ICLR 2026
リンク： https://arxiv.org/abs/2509.19349
系譜： 最新（← AlphaEvolve / DGM）
調査日： 2026-10-24
確認範囲： 全文（問題提起・手法・実験・結果・考察）

Huxley-Gödel Machine: Human-Level Coding Agent Development by an Approximation of the Optimal Self-Improving Machine

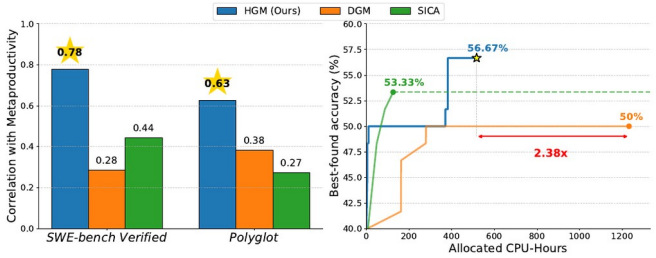
Wenyi Wang, Piotr Piękos, Li Nanbo ほか（KAUST）| ICLR 2026

1 どんなもの？

自己改善の木探索で、親の目先の性能ではなく子孫全体（クレード）の成績から自己改善の見込み CMP を推定して展開先を選ぶ HGM を提案。DGM・SICA を上回り、CPU 時間は DGM の 1/2.38。

2 先行研究と比べてどこがすごい？

DGM・SICA は性能の高いエージェントほど良い子を生むと仮定するが、実際の相関は弱い（Metaproductivity–Performance Mismatch）。HGM はクレード単位の統計で将来性を測り、展開と評価を分けて非同期化した。



出典：HGM Fig. 1（左：選択基準と将来の自己改善の相関、右：CPU 時間あたりの最良精度）

3 技術や手法のキモはどこ？

CMP(a) ＝クレード内の成功数 ÷ 評価数。Beta 分布の Thompson サンプリングで展開先を選び、評価と展開の切替は N^α≥|T| の規則（UCB-Air 型）で決める。真の CMP があれば Gödel Machine を模倣できる（定理 1）。

4 どうやって有効だと検証した？

経験的 CMP との加重相関は HGM 0.778 ／ DGM 0.285 ／ SICA 0.444（SWE-Verified-60, Table 1）。800 評価で最良 56.7%（DGM 53.3、SICA 50.0）、Polyglot 30.5%（27.1、25.4）（Table 2）。

5 議論はある？

著者：理論は最終エージェントのみを目的とし、評価が反復可能という仮定に依存。

所感：親選択の信号の選び方が結果を左右することを DGM 系で直接示した。各手法 1 実行で分散は不明。DGM の「子の少なさ」に当たる新奇性項は持たない。

6 次に読むべき論文は？

- Darwin Gödel Machine (2025)（本資料）
- Gödel Machine (Schmidhuber 2003)（未調査）
- HGM-Dual (Paul+ 2026)（未調査）

書誌情報

発表： ICLR 2026
リンク： https://arxiv.org/abs/2510.21614
系譜： 最新（← DGM）
調査日： 2026-10-24
確認範囲： 全文（問題提起・手法・実験・結果・考察）

Hyperagents

Jenny Zhang, Bingchen Zhao, Wannan Yang ほか（UBC / Meta ほか）| arXiv 2026

1 どんなもの？

課題を解くタスクエージェントと、それを書き換えるメタエージェントを 1 つの編集可能なプログラムにまとめ、改善手順も進化させる DGM-H を提案。論文査読・報酬設計・数学採点でも自己改善が続いた。

2 先行研究と比べてどこがすごい？

DGM は自己改善の指示を作る部分が手作りで固定され、課題能力と自己改変能力が一致するコーディングでしか「改善の改善」が成り立たない。DGM-H はメタ部分も編集対象にして、この一致の仮定を外した。

3 技術や手法のキモはどこ？

DGM のアーカイブと親選択（性能に比例、子の数に反比例）はそのまま使い、子は過去の評価とリポジトリを読んで任意の部分を書き換える。改善能力は imp@k（固定メタで k 個生成したときの最大改善）で測る。

4 どうやって有効だと検証した？

5 実行中央値で査読 0.0→0.710（静的基準 0.630）、報酬設計 0.060→0.372。自己改善なし 0.0/0.213、アーカイブなし 0.0/0.116、元の DGM 0.0/0.0（Fig. 2）。転移 hyperagent の imp@50 は 0.630、DGM 由来は 0.0（Fig. 3）。

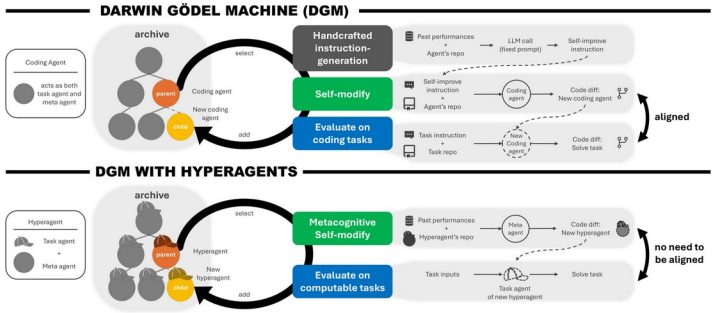
5 議論はある？

著者：課題分布と外側ループ（親選択・評価）は固定で、完全な自己参照ではない。

所感：アーカイブなしの崩れ方が DGM より大きく、領域を越えるほど踏み石の価値が上がることを示唆。発見された性能追跡や永続メモリは人の実験ノートに近い。

6 次に読むべき論文は？

- Darwin Gödel Machine (2025)（本資料）
- ADAS (Hu+ 2024)（未調査）
- OMNI-EPIC (2024)（本資料）



出典：Hyperagents Fig. 1（DGM と DGM-H の比較。メタエージェント自体が編集対象になる）

書誌情報

発表： arXiv プレプリント 2026
リンク： https://arxiv.org/abs/2603.19461
系譜： 最新（← DGM）
調査日： 2026-10-24
確認範囲： 全文（問題提起・手法・実験・結果・考察）

Towards End-to-End Automation of AI Research

Yutaro Yamada, Robert Tjarko Lange, Cong Lu ほか（Sakana AI ほか）| Nature 2026

1 どんなもの？

アイデア生成・新規性確認・実験・作図・執筆・自動査読までを 1 つにした The AI Scientist の統合版（テンプレート型の v1 と木探索型の v2）。生成論文 1 本が ICLR 2025 ワークショップの査読で平均 6.33 を得た。

2 先行研究と比べてどこがすごい？

従来は仮説生成・文献レビュー・実験コード生成など工程ごとの自動化にとどまっていた。本論は研究の全工程を通し、自動査読器を人間の査読結果と照合して、系の改良を大規模に評価できるようにした。

3 技術や手法のキモはどこ？

アイデアは LLM を変異演算子として育てる MAP-Elites 型アーカイブで作り、Semantic Scholar で既存研究に似たものを捨てる。テンプレート不要型は実験を 4 段階（予備→ハイパラ→本実験→アブレーション）の木探索で進める。

4 どうやって有効だと検証した？

自動査読器の balanced accuracy は 0.69（2017–24）、カットオフ後の 2025 年も 0.66 で人間間の一致（0.66）と同等（Table 1）。論文の質はモデルの公開時期（$p<0.00001$, Fig. 1B）と木探索のノード数（Fig. 2C）とともに上昇。

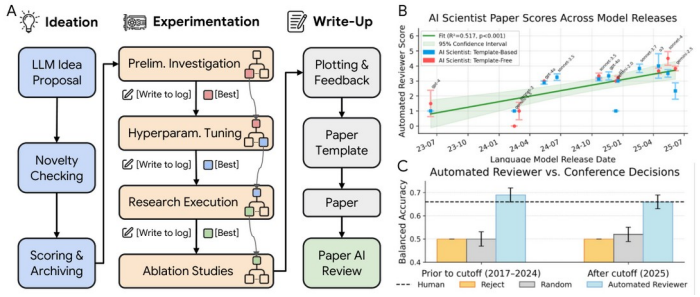
5 議論はある？

著者：本会議水準には届かず、浅いアイデア・実装誤り・引用の幻覚が残る。査読負荷の増大など倫理面の懸念も大きい。

所感：投稿 3 本は人手で選別しており、完全自動の採択率ではない。アーカイブ型アイデア生成の寄与は切り分けられていない。

6 次に読むべき論文は？

- The AI Scientist v1 (Lu+ 2024)（未調査）
- The AI Scientist-v2 (Yamada+ 2025)（未調査）
- Hyperagents (2026)（本資料）



出典：AI Scientist Fig. 1（A 全体の流れ、B モデル公開時期と論文スコア、C 自動査読器の精度）

書誌情報

発表： Nature 2026
リンク： https://arxiv.org/abs/2606.15497
系譜： 最新（← AI Scientist v1/v2）
調査日： 2026-10-24
確認範囲： 全文（問題提起・手法・実験・結果・考察）

Automated Discovery Has No Universally Superior Harness

Akshat Gupta, Jermaine Lei, Alexander Lu, Gopala Anumanchipalli, Leshem Choshen（UC Berkeley / MIT）| arXiv 2026

1 どんなもの？

LLM 駆動の発見系のハーネスを部品（Top-K アーカイブ、ε 探索、MAP-Elites、島、UCT/PUCT など）に分解し、30 構成×12 のモデル・問題組を 310 万ロールアウトで比較。どの固定ハーネスも一貫しては勝たないと示した。

2 先行研究と比べてどこがすごい？

OpenEvolve や TTT-Discover は複数の設計を束ねた複合レシピで、高価なため数回の試行で比べられてきた。本論は貪欲な逐次 Best-of-N を基準に部品を 1 つずつ足し、100 回（または 30 回）の基準実行を帰無分布として検定した。

3 技術や手法のキモはどこ？

5 回実行の最大値を、基準実行の best-of-5 のブートストラップ分布と比べる。12 組中 7 組以上で勝つ確率 $\hat{P}maj$ を全体指標にし、置換検定と Holm 補正で判定。部分実行の成績で枝刈りして予算を移す適応配分も試した。

4 どうやって有効だと検証した？

最良の K=1・ε=20% でも $\hat{P}maj=0.914$、Holm 補正後 $p=0.678$ で有意でない。OpenEvolve 完全版は $\hat{P}maj=0.033$ で最下位（Fig. 5a）。Top-K を大きくするだけでは改善なし（Fig. 2）。適応配分で平均 84.35→85.75%（Table 1）。

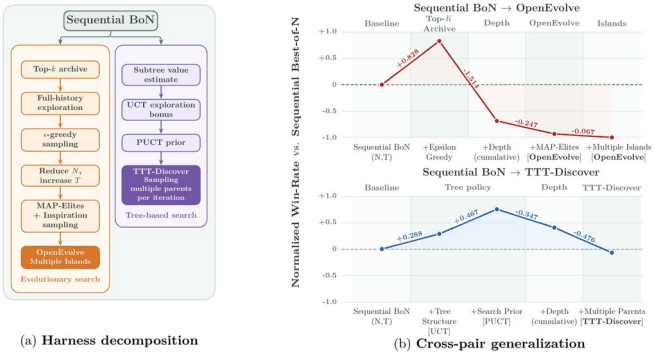
5 議論はある？

著者：ハーネスは問題とモデルに依存するハイパーパラメータとして扱うべき。

所感：対象は数学 3 問と 3B ～ 120B の公開モデルで、自己改善エージェントや課題生成は未検証。各論文の「アーカイブが効く」は条件付きの知見として読むべき。

6 次に読むべき論文は？

- Simple Baselines are Competitive with Code Evolution (Gideoni+ 2026)（未調査）
- TTT-Discover (Yuksekgonul+ 2026)（未調査）
- ShinkaEvolve (2025)（本資料）



(a) Harness decomposition　(b) Cross-pair generalization

出典：No Universal Harness Fig. 1（a 部品分解、b 部品を足したときの基準比勝率の推移）

書誌情報

発表： arXiv プレプリント 2026
リンク： https://arxiv.org/abs/2607.18235
系譜： 最新（← OpenEvolve / TTT-Discover）
調査日： 2026-10-24
確認範囲： 全文（問題提起・手法・実験・結果・考察）