群知能 | 先行研究調査 (2026-10-23)

MetaBBO と LLM によるアルゴリズム自動設計

最適化アルゴリズムの設計そのものを自動化・学習する流れを追う。①自動構成: ParamILS→irace-evo 。②学習型最適化器 (MetaBBO) : L2O→LES→MetaBox-v2 。③LLM による生成: FunSearch→ReEvo→AlphaEvolve 。2026 年は両者が合流 (HADA) し、生成物の新規性の検証 (BehaveSim) が課題になっている。

#	年	論文	発表	系譜
1	2009	ParamILS (Hutter+ 2009)	JAIR 2009	原典
2	2017	L2O w/o GD (Chen+ 2017)	ICML 2017	原典
3	2023	LES (Lange+ 2023)	ICLR 2023	発展
4	2024	FunSearch (Romera-Paredes+ 2024)	Nature 2024	原典
5	2024	ReEvo (Ye+ 2024)	NeurIPS 2024	発展
6	2025	AlphaEvolve (Novikov+ 2025)	arXiv プレプリント 2025	最新
7	2025	MetaBox-v2 (Ma+ 2025)	NeurIPS 2025	最新
8	2025	irace-evo (Chacón Sartori & Blum 2025)	arXiv プレプリント 2025	最新
9	2026	BehaveSim (Zhang & Lu 2026)	ICLR 2026	最新
10	2026	HADA (Yu+ 2026)	arXiv プレプリント 2026	最新

ParamILS: An Automatic Algorithm Configuration Framework

Frank Hutter, Holger H. Hoos, Kevin Leyton-Brown, Thomas Stützle（University of British Columbia）| JAIR 36, 2009

1 どんなもの?

アルゴリズムのパラメータ設定（カテゴリ値を含む多数のパラメータ）を、問題インスタンス集合上の性能で自動探索する反復局所探索 ParamILS と、無駄な試行を打ち切る adaptive capping を提案。CPLEX の既定設定を最大で一桁以上高速化した。

2 先行研究と比べてどこがすごい?

手作業の調整は数週間かかり、手法比較の公平性も損なう。F-Race・CALIBRA・SPO は数値パラメータ限定か、候補の全列挙が必要だった。ParamILS は条件付き・カテゴリ値を含む 10^37 通り規模の空間を扱い、部品からの自動設計を可能にした。

3 技術や手法のキモはどこ?

設定空間上で「1 パラメータだけ変える」近傍を持つ ILS（摂動・局所探索・受理）。FocusedILS は良い設定ほど評価インスタンス数を増やして支配関係で比較し、極限で最適設定に収束する。adaptive capping は現行最良を超えた時点で実行を打ち切る。

4 どうやって有効だと検証した?

SAT（SAPS, SPEAR）と CPLEX の 5 シナリオで既定設定の PAR（未解決は打切り時間 ×10）を大幅改善（SAPS-SWGCP で 20.41→0.32 秒、Table 3）。CPLEX の実問題 5 種（Table 9）では Regions200 で 72→10.5 秒、MIK で平均 23 倍速。

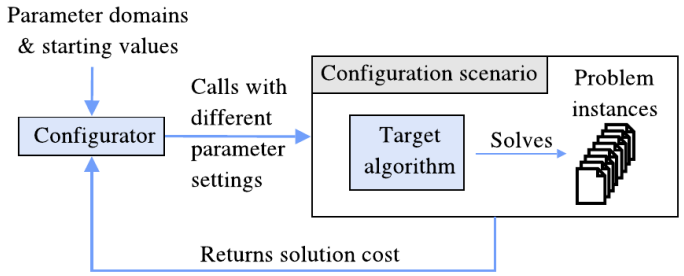
5 議論はある?

著者:訓練インスタンスが少なく不均質だと汎化しない。打切り時間が短すぎると、CPLEX-QP のように長時間設定で劣化する。

所感:群知能のパラメータ・部品選択を自動化する「設計の自動化」の原点。後継の irace・SMAC を経て METAFOR へ直結する。

6 次に読むべき論文は?

- irace (López-Ibáñez+ 2016)（未調査:本文取得不可）
- METAFOR (2025)（既存: ga-hybrid）
- irace-evo (2025)（本資料）



出典: ParamILS (Hutter+ 2009) Fig. 1（構成器が対象アルゴリズムを様々な設定で問題インスタンスに適用し、コストを受け取って次の設定を決める）

書誌情報

発表: JAIR 2009
リンク: https://arxiv.org/abs/1401.3492
系譜: 原典
調査日: 2026-10-23
確認範囲: 全文（問題提起・手法・実験・結果・考察）

Learning to Learn without Gradient Descent by Gradient Descent

Yutian Chen, Matthew W. Hoffman, Sergio Gómez Colmenarejo ほか (DeepMind) | ICML 2017

1 どんなもの?

GP からサンプルした合成関数上で、RNN (LSTM/DNC) そのものをブラックボックス最適化器として勾配降下で学習した。学習済みの最適化器は BO パッケージと同等の性能を保ちつつ提案計算が 10^2 ～ 10^4 倍速く、未知の関数群へ転移した。

2 先行研究と比べてどこがすごい?

ベイズ最適化 (Spearmint, SMAC, TPE) は獲得関数の最適化と GP 推論に重い計算を要する。先行の L2L (Andrychowicz+ 2016) は勾配を使う最適化器の学習だった。本研究は、勾配を使わない探索則そのものをデータから学習する。

3 技術や手法のキモはどこ?

h_t, x_t = RNN_θ (h_{t−1}, x_{t−1}, y_{t−1}) で次の問い合わせ点を出す。訓練時だけ f の勾配を使い、軌跡全体の損失 (Σf、期待改善 EI、観測改善 OI) を BPTT で最小化する。並列評価のため、完了フラグを入力に加えた版も作った。

4 どうやって有効だと検証した?

GP 関数 (1 ～ 9 次元) では 6 次元以上で Spearmint を上回った (Fig. 3)。Branin・Hartmann6 等では高次元ほど速く収束し、100 回の提案にかかる時間は DNC が 0.1 秒、Spearmint が 1239 秒 (Table 1)。HPOLib と CIFAR-100 の ResNet 調整でも同等 (Fig. 7)。

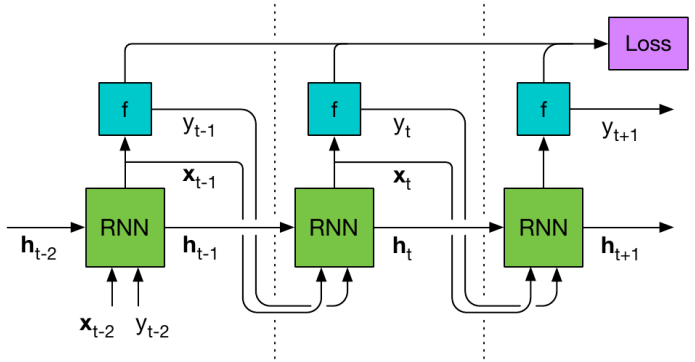
5 議論はある?

著者:訓練時の地平を超える長い最適化は苦手で、入力次元ごとにモデルを学習し直す必要がある。

所感: MetaBBO-SL 系 (RNN-Opt) の原典。ただし MetaBox-v2 の BBOB 評価では最下位級で、汎化の主張は限られた条件の下でのもの。

6 次に読むべき論文は?

- LES (Lange+ 2023) (本資料)
- Learning to learn by GD by GD (Andrychowicz+ 2016) (未調査)
- GLEET (Ma+ 2024) (既存: deep-learning-fusion)



出典: L2O w/o GD (Chen+ 2017) Fig. 1 (RNN 最適化器を複数ステップ展開した計算グラフ。損失を RNN パラメータで微分して学習する)

書誌情報

発表: ICML 2017
リンク: https://arxiv.org/abs/1611.03824
系譜: 原典
調査日: 2026-10-23
確認範囲: 全文 (問題提起・手法・実験・結果・考察)

Discovering Evolution Strategies via Meta-Black-Box Optimization

Robert Tjarko Lange, Tom Schaul, Yutian Chen ほか(Technical University Berlin / DeepMind)| ICLR 2023

1 どんなもの?

ES の更新則(組換え重みと学習率)を自己注意で表し、その重みを CMA-ES で外側から最適化する「 MetaBBO 」を提案した(用語の初出)。BBOB の低次元関数だけで学習した LES が、数千次元の Brax 制御や MNIST の神経進化で既存の ES を上回った。

2 先行研究と比べてどこがすごい?

手設計の ES は更新則が固定で柔軟性がない。先行の学習型 BBO (Chen+ 2017 など)は RNN で解ベクトルを処理するため、個体数や次元が固定され、狭い領域でしか使えなかった。LES は個体の順序に不変な注意機構により、個体数・次元・地平の変化に汎化する。

3 技術や手法のキモはどこ?

各個体の適応度の z スコア・中心化順位・改善フラグをトークンとし、w = softmax(softmax(QK^T/√D_K)V) を組換え重みにして探索分布の平均と標準偏差を更新する。外側ループはタスクを抽出し、正規化した適応度でメタ ES を更新する(パラメータ 500 未満)。

4 どうやって有効だと検証した?

Brax 8 タスクで OpenES・SNES・Sep-CMA・PGPE・ASEBO を上回った(Fig. 1)。小予算では 7 タスク中 5 で最良(Fig. 3)。学習した更新則を逆解析した単純な DES も同等の性能を示し(Fig. 5)、LES 自身で自分を学習させる自己参照的メタ進化も成功した(Fig. 6)。

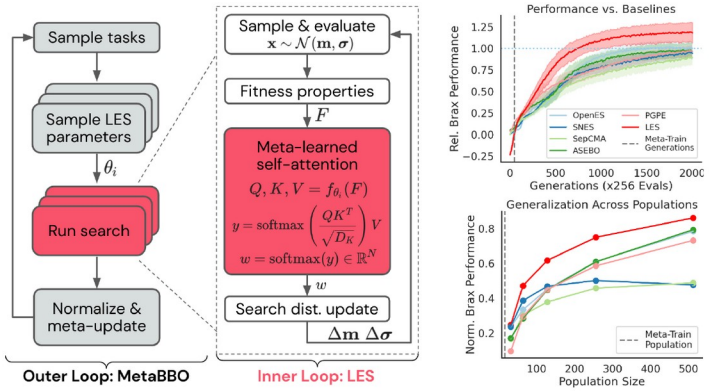
5 議論はある?

著者:対角共分散に限られ非分離問題に弱い。学習率モジュールが長い地平に汎化しにくく、注意機構は個体数の 2 乗で計算量が増える。

所感: MetaBox-v2 では BBOB-10D で 19 位と振るわず、汎化の評価は課題設定に依存する。群知能の位置更新則にも同じ枠組みを使える。

6 次に読むべき論文は?

- Discovering Attention-Based GA via MetaBBO (Lange+ 2023) (未調査)
- MetaBox-v2 (Ma+ 2025) (本資料)
- Evolution Transformer (Lange+ 2024) (未調査)



出典: LES (Lange+ 2023) Fig. 1 (左:外側ループの MetaBBO 、中:自己注意で組換え重みを出す LES 、右: Brax 制御での性能と個体数への汎化)

書誌情報

発表: ICLR 2023
リンク: https://arxiv.org/abs/2211.11260
系譜: 発展(← L2O w/o GD (Chen+ 2017))
調査日: 2026-10-23
確認範囲: 全文(問題提起・手法・実験・結果・考察)

Mathematical discoveries from program search with large language models

Bernardino Romera-Paredes, Mohammadamin Barekatain, Alexander Novikov ほか (Google DeepMind) | Nature 625, 2024

1 どんなもの?

固定した事前学習 LLM と自動評価器を組み合わせ、解そのものではなく「解を作るプログラム」を進化させる FunSearch を提案。cap set 問題で 8 次元の 512-cap を発見し、容量の下界を 2.2180 から 2.2202 へ更新した。ビンパッキングでも新しいヒューリスティクスを得た。

2 先行研究と比べてどこがすごい?

LLM 単体は作話 (confabulation) しやすく、既知の結果を超えにくい。ELM など LLM× 進化の先行研究は合成課題が中心だった。FunSearch は評価器で誤りを除き、未解決の数学問題で既知の最良を更新して、学習データの再現でない発見であることを示した。

3 技術や手法のキモはどこ?

骨格プログラムのうち、優先度関数だけを進化させる。島モデルの集団から高得点のプログラム k=2 個を版番号付きでプロンプトに並べ (best-shot prompting)、次の版を書かせる。島内はスコアの署名でクラスタ化し、短いプログラムを優先して選ぶ。

4 どうやって有効だと検証した?

Codey (PaLM 2 系) で約 10^6 回サンプルした。オンライン・ビンパッキングでは OR1 ～ 4 と Weibull の全データで best fit より超過ビン率が低く、Weibull 100k では 3.79%→0.03% (Table 1)。n=8 の cap set は 140 回の実行のうち 4 回だけ成功した (Methods)。

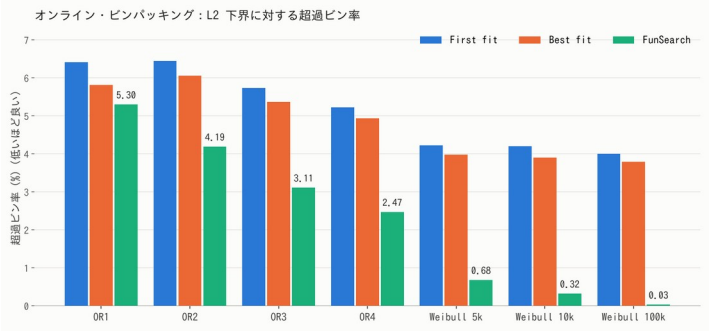
5 議論はある?

著者:効率的な評価器、段階的なスコア、進化させる部分を切り出せる骨格の 3 条件が必要で、定理の証明などは対象外。

所感:「アルゴリズムを生成する」LLM 研究の起点。10^6 回という膨大な評価と骨格設計への依存は、後続研究の主な論点になった。

6 次に読むべき論文は?

- ELM (Lehman+ 2022) (既存: ga-hybrid)
- EoH (Liu+ 2024) (既存: ga-hybrid)
- AlphaEvolve (Novikov+ 2025) (本資料)



出典: FunSearch Table 1 の数値を調査者が作図(オンライン・ビンパッキングの超過ビン率)

書誌情報

発表: Nature 2024
リンク: https://doi.org/10.1038/s41586-023-06924-6
系譜: 原典
調査日: 2026-10-23
確認範囲: 全文(問題提起・手法・実験・結果・考察)

ReEvo: Large Language Models as Hyper-Heuristics with Reflective Evolution

Haoran Ye, Jiarui Wang, Zhiguang Cao ほか (Peking University) | NeurIPS 2024

1 どんなもの?

LLM でヒューリスティクスを生成する枠組みを「 Language Hyper-Heuristics 」と位置づけ、親 2 つの比較に基づく短期の反省と、蓄積する長期の反省を進化に組み込んだ ReEvo を提案。ACO のヒューリスティック値、GLS の罰則、GA の演算子などを自動設計した。

2 先行研究と比べてどこがすごい?

従来のハイパーヒューリスティクスは人が決めた探索空間に縛られる。FunSearch・EoH はサンプル効率が悪く、問題の中身を伏せた設定(ブラックボックス)では推論も弱い。ReEvo は反省を「言語の勾配」として使い、100 回程度の評価で強いヒューリスティクスを得る。

3 技術や手法のキモはどこ?

個体はコード片。①ランダム選択 ②反省 LLM が 2 つの親の優劣を比べて短期の反省を書く ③生成 LLM による交叉 ④反省を要約して長期の反省を更新 ⑤長期の反省を使うエリート変異、の 5 段階を繰り返す。ヒューリスティクスの評価は 100 回まで。

4 どうやって有効だと検証した?

ACO では 5 種の COP すべてで人手設計を上回り、3 種では DeepACO も上回った(Fig. 2)。KGLS-ReEvo は TSP200 で gap 0.216% (Table 1)。POMO の TSP1000 では gap を 52%→29% に改善(Table 3)。反省により景観の相関長が 0.28→1.28 と滑らかになった(Table 4)。

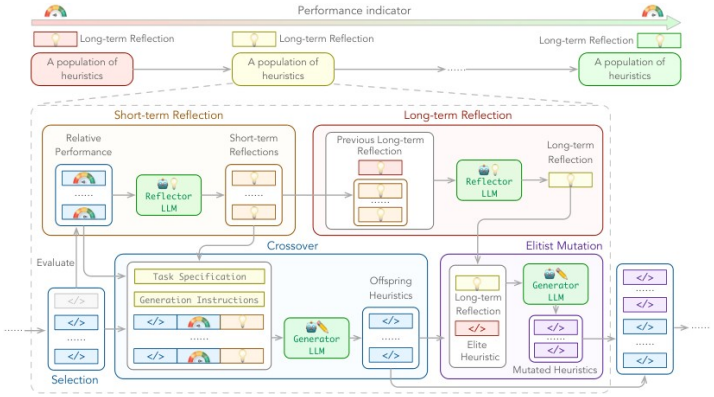
5 議論はある?

著者:評価回数 100 回までの結果で、回数を増やすと手法間の差は縮む。弱いオープン LLM では反省の効果が有意にならない。

所感: ACO のヒューリスティック値を LLM で設計した点で群知能に直結する。ただし優位性の多くは「評価回数が少ない」前提の下での話。

6 次に読むべき論文は?

- EoH (Liu+ 2024) (既存: ga-hybrid)
- Understanding the Importance of Evolutionary Search (Zhang+ 2024) (参照のみ)
- DeepACO (Ye+ 2023) (既存: deep-learning-fusion)



出典: ReEvo (Ye+ 2024) Fig. 1(a) (選択・短期の反省・交叉・長期の反省・エリート変異からなる 1 世代の流れ)

書誌情報

発表: NeurIPS 2024
リンク: https://arxiv.org/abs/2402.01145
系譜: 発展 (← FunSearch / EoH)
調査日: 2026-10-23
確認範囲: 全文 (問題提起・手法・実験・結果・考察)

AlphaEvolve: A coding agent for scientific and algorithmic discovery

Alexander Novikov, Ngân Vũ, Marvin Eisenberger ほか (Google DeepMind) | arXiv ホワイトペーパー 2025

1 どんなもの?

最先端 LLM (Gemini 2.0 Flash/Pro) の集合と進化的データベースで、複数関数・数百行のコード全体を差分で進化させるコーディングエージェント。4×4 の複素行列の積を 48 回の乗算で計算する方法を見つけ、Strassen 以来 56 年ぶりに改善した。

2 先行研究と比べてどこがすごい?

FunSearch は単一の Python 関数 (10 ～ 20 行) しか進化できず、評価は 20 分以内、単一指標で 10^6 回のサンプルを要した。AlphaEvolve はファイル全体・任意の言語・複数指標・長時間の並列評価に対応し、数千回のサンプルで済む。

3 技術や手法のキモはどこ?

EVOLVE-BLOCK で指定した部分を、LLM が SEARCH/REPLACE 形式の差分で書き換える。プロンプトには過去の解・評価結果・文献を入れ、メタプロンプトも共進化させる。データベースは MAP-Elites と島モデルの組合せで、評価は難易度の段階を踏む。

4 どうやって有効だと検証した?

行列積の 14 ケースで最良記録を更新 (Table 2)。50 以上の数学問題のうち 75% で既知最良に一致、20% で更新 (11 次元のキス数 593 など)。Google のスケジューラで計算資源の 0.7% を回収し、Gemini のカーネルを 23% 高速化。要素を外すと性能が落ちた (Fig. 8)。

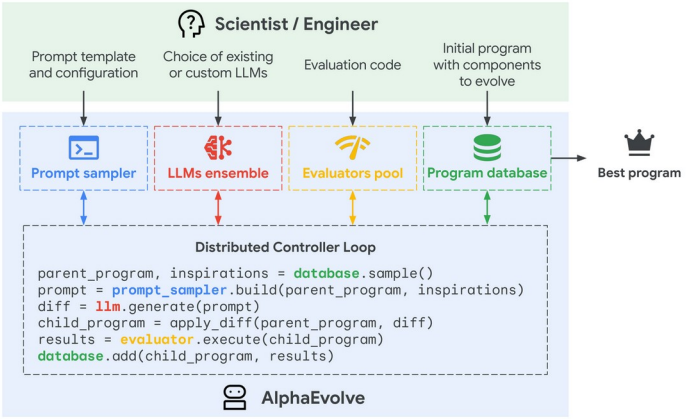
5 議論はある?

著者:自動評価器を作れる問題に限られ、実験を要する自然科学には適用しにくい。

所感:群知能の観点では「探索アルゴリズム自体を進化させる」使い方が肝。ただしホワイトペーパーであり、計算コスト・失敗率・再現性の情報は乏しい。

6 次に読むべき論文は?

- FunSearch (Romera-Paredes+ 2024) (本資料)
- OpenEvolve / ShinkaEvolve (2025) (未調査)
- LEVI (2026) (未調査)



出典: AlphaEvolve (Novikov+ 2025) Fig. 2 (プロンプト生成・LLM 集合・評価器・プログラム DB が分散ループで回る)

書誌情報

発表: arXiv プレプリント 2025
リンク: https://arxiv.org/abs/2506.13131
系譜: 最新 (← FunSearch (2024))
調査日: 2026-10-23
確認範囲: 全文 (問題提起・手法・実験・結果・考察)

MetaBox-v2: A Unified Benchmark Platform for Meta-Black-Box Optimization

Zeyuan Ma, Yue-Jiao Gong, Hongshu Guo ほか (South China University of Technology) | NeurIPS 2025

1 どんなもの?

MetaBBO のベンチマーク基盤 MetaBox (2023) を改訂した。RL・SL・NE・ICL の 4 系統の手法 23 種と、単目的・多目的・多峰・多タスクの 18 問題群 (1900 以上のインスタンス) を統一 API で扱い、並列化で学習を最大 10 倍、評価を 40 倍以上速くした。

2 先行研究と比べてどこがすごい?

初代 MetaBox は単目的・RL 系の 8 手法に限られ、他の学習方式や問題種別の急増に追いつけなかった。COCO・EvoX・PyPop7 などは二層のメタ学習を前提としていない。MetaBox-v2 は学習効率や問題の変化への頑健さまで多面的に評価できる。

3 技術や手法のキモはどこ?

メタ方策 π_θ が状態 s_t から低層の最適化器の設計 ω_t を出し、$J(\theta) = E_p[\Sigma\ r_t]$ を最大化する二層構造を統一テンプレートにした。指標として学習効率 (性能 / 学習時間) と、分布外での性能の変化を表す Anti-NFL を新設した。

4 どうやって有効だと検証した?

BBOB-10D の 8 関数で学習し 16 関数でテスト (Table 3)。上位は LDE・DEDDQN・RLDAS で、GLEET 6 位、PSO 12 位、LES 19 位、OPRO 20 位。分布外 (タンパク質・UAV・HPO-B) では従来の DE・SHADE が頑健で、多くの学習型手法は劣化した (Fig. 6)。

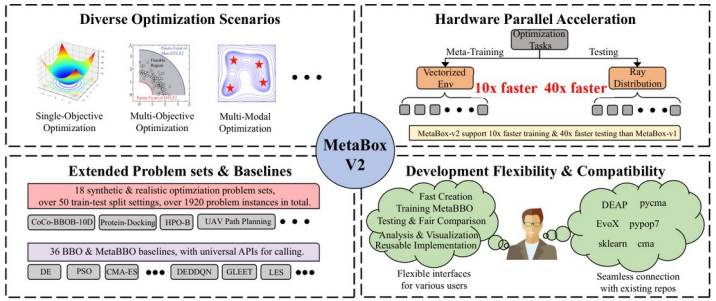
5 議論はある?

著者:既存研究は狭い評価で MetaBBO を過大評価しており、分布外での過学習が残っている。

所感: PSO 系の学習型手法 (RLPSO・NRLPSO) は下位に沈んだ。本文の「DEDDQN が平均 1 位」という記述は表の順位 (LDE が 1 位) と食い違い、要確認。

6 次に読むべき論文は?

- MetaBox (Ma+ 2023) (参照のみ)
- Toward Automated Algorithm Design: MetaBBO Survey (Ma+ 2024) (参照のみ)
- GLEET (Ma+ 2024) (既存: deep-learning-fusion)



出典: MetaBox-v2 (Ma+ 2025) Fig. 1 (多様な最適化シナリオ・並列化・問題群と手法の拡充・外部ライブラリとの互換性)

書誌情報

発表: NeurIPS 2025
リンク: https://arxiv.org/abs/2505.17745
系譜: 最新 (← LES / GLEET)
調査日: 2026-10-23
確認範囲: 全文 (問題提起・手法・実験・結果・考察)

irace-evo: Automatic Algorithm Configuration Extended With LLM-Based Code Evolution

Camilo Chacón Sartori, Christian Blum（ IIIA-CSIC / ICN2 ）| arXiv プレプリント 2025

1 どんなもの?

反復レース型の自動構成ツール irace を拡張し、パラメータと同時に LLM でコードの 1 関数を進化させる irace-evo を提案。可変サイズのビンパッキング（ VSBPP ）の最良手法 CMSA で、配置ヒューリスティクスの改良版を 10 回の実行すべてで得た。費用は計 2 ユーロ未満。

2 先行研究と比べてどこがすごい?

irace・SMAC・ParamILS はパラメータ値は調整するが、コード自体は変えない。EoH・LLaMEA 系は Python 限定で、毎回コード全体を送るためトークン費用が高い。irace-evo は C++ にも対応し、パラメータとコード版の組を F-Race で同時に競わせる。

3 技術や手法のキモはどこ?

構成を「パラメータ θ とコード版 A の組 (θ, A) 」に拡張した。新しいコード版は常に元のコードから生成し（ Always-From-Original ）、誤りの蓄積を防ぐ。文脈は初回だけ全文を渡して以後は縮約し、反復が進むと変更の強度を std から aggressive へ上げる。

4 どうやって有効だと検証した?

Claude Haiku 3.5 、実験予算 300 回、1 実行 150 秒。150 インスタンス（ B1 ～ B3 ）で元の CMSA との勝率を比較（ Table 1 ）。凸費用の B3 （ n=2000 ）では勝率 86 ～ 97% で有意。既知最良も多数更新した（ Table 2 ）が、小規模インスタンスでは差がない。

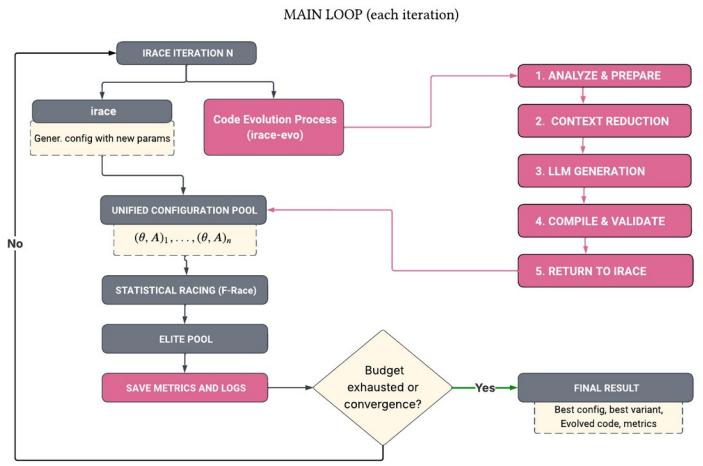
5 議論はある?

著者:変更できるのは 1 関数だけで、関数の切り出し方が性能を左右する。

所感:既知最良の更新幅は 356235→356212 程度とわずかで、対象も CMSA 1 手法のみ。自動構成の統計的な枠組みに LLM を組み込む設計は、群知能の部品設計にも使える。

6 次に読むべき論文は?

- ParamILS (Hutter+ 2009)（本資料）
- LLaMEA-HPO (van Stein+ 2025)（未調査）
- METAFOR (2025)（既存: ga-hybrid ）



出典: irace-evo (2025) Fig. 1（ irace の各反復にコード進化を差し込み、(θ, A) の組を F-Race で選別する流れ）

書誌情報

発表: arXiv プレプリント 2025
リンク: https://arxiv.org/abs/2511.14794
系譜:最新（← ParamILS / irace ）
調査日: 2026-10-23
確認範囲:全文（問題提起・手法・実験・結果・考察）

Rethinking Code Similarity for Automated Algorithm Design with LLMs

Rui Zhang, Zhichao Lu（City University of Hong Kong）| ICLR 2026

1 どんなもの?

LLM が生成したアルゴリズム同士の類似度を、コードの字面ではなく実行時の中間解の系列（PSTraj）を DTW で比べて測る BehaveSim を提案。これを FunSearch・EoH の多様性管理に使うと、3 課題すべてで性能が向上した。

2 先行研究と比べてどこがすごい?

BLEU・AST・CodeBLEU・埋め込み・実行結果・実行トレースに基づく既存の類似度は、argmin と argmax の違いのように挙動が全く異なるコードを「ほぼ同じ」とし、同じ探索の再帰版と反復版を「別物」とする。これでは真の新規性を測れない。

3 技術や手法のキモはどこ?

BehaveSim(A1, A2) = E_I E_s[1 − DTW(T1, T2)/min(|T1|, |T2|)] 。中間解の距離は順列なら編集距離、連続値ならユークリッド距離で正規化する。FunSearch では島への割り当てに、EoH では最良解との類似度を第 2 目的として使う。

4 どうやって有効だと検証した?

4 種類の対データ（Table 2）で、既存の指標は同じ挙動の別実装（Type-3）を 0.42 ～ 0.91 と判定したが、BehaveSim は 1.00 と判定した。GPT-5-nano を使った TSP で gap は FunSearch 25.2%→17.4% 、EoH 18.9%→16.6% に改善（Table 3）。

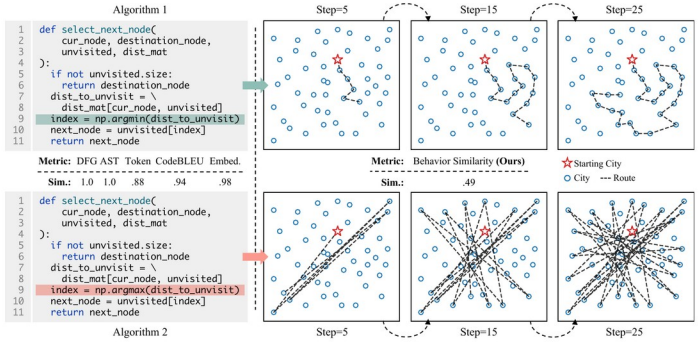
5 議論はある?

著者:計算量など、挙動以外の新規性の観点は今後の課題。

所感:比喩ベースのメタヒューリスティクスの「新規性」問題を、生成アルゴリズムで定量化する道具になる。PSO と DE など集団型手法同士の比較にも使えそうだが、確率的な手法の扱いには工夫が要る。

6 次に読むべき論文は?

- Equivalence framework (Fister+ 2026)（既存: foundations）
- Behaviour Space Analysis of LLM-driven Meta-heuristic Discovery (2025)（参照のみ）
- Fitness Landscape of LLM-AAS (Liu+ 2025)（参照のみ）



出典: BehaveSim (Zhang & Lu 2026) Fig. 2（argmin と argmax だけが違う 2 つの TSP 構築法。既存の指標は類似度 0.88 ～ 1.0 、BehaveSim は 0.49）

書誌情報

発表: ICLR 2026
リンク: https://arxiv.org/abs/2603.02787
系譜: 最新（← FunSearch / EoH）
調査日: 2026-10-23
確認範囲: 全文（問題提起・手法・実験・結果・考察）

Hyper Algorithm Design Agent: Evolving Learnable Optimizer from Zero

Zipei Yu, Yue-Jiao Gong, Zeyuan Ma, Yuncheng Jiang, Zhiguang Cao (South China University of Technology) | arXiv プレプリント 2026

1 どんなもの?

MetaBBO そのもの(メタ方策・低層の最適化器・学習手順)の設計をコーディング作業とみなし、タスク用とハイパー用の 2 つの LLM エージェントで再帰的に改良する HADA を提案。DE を DQN で制御する単純な初期版から、GLEET を上回る MetaBBO を自動で得た。

2 先行研究と比べてどこがすごい?

MetaBBO では低層の最適化器・状態特徴・方策網を人が設計しており、設計者の偏りが性能の上限を決めている。LLaMEA 等は単一の最適化器のコード生成に留まる。HADA は学習型最適化器の全体を、開放的(open-ended)な自己改良で設計する。

3 技術や手法のキモはどこ?

ハイパーエージェントがタスクエージェントのプロンプトと自分自身を書き換え、タスクエージェントが MetaBBO のプロジェクトを編集する。結果は木構造の進化履歴に保存し、性能と子の数から親を選ぶ。スコアは初期値から最適値への到達度で [0, 1] に正規化する。

4 どうやって有効だと検証した?

BBOB 20D の未学習関数で平均 0.967 (GLEET 0.894 、CMA-ES 0.834) (Table 2)。10D・40D・UAV へのゼロショットでも最良だが差は小さい(UAV で 0.798 対 0.767 、Fig. 2)。制約付き・多目的にも転移(Fig. 4)。初期を PSO にすると 0.942 (Table 4)。

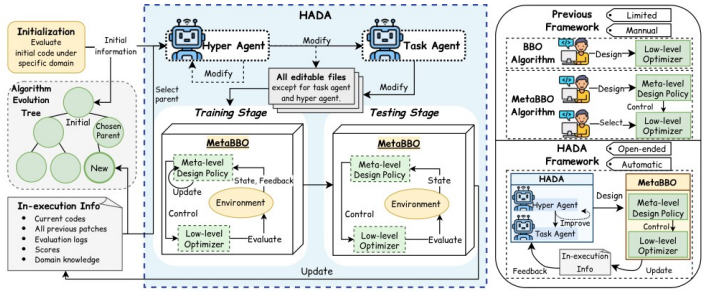
5 議論はある?

著者:探索方針は単純なヒューリスティクスで、組合せ最適化は今後の課題。

所感:「 121.7% 向上」は最下位の CMA-ES を基準にした相対値で、誇張気味。評価は同じ BBOB 関数群の分割で、進化中の評価も 5 回実行のみ。過学習の検証はまだ不十分。

6 次に読むべき論文は?

- READY (Huang+ 2026) (参照のみ)
- LLaMEA (van Stein & Bäck 2024) (既存: ga-hybrid)
- Darwin Gödel Machine (2025) (未調査)



出典: HADA (Yu+ 2026) Fig. 1 (ハイパー/タスクエージェントが MetaBBO のコードを編集・評価し、進化木に記録する流れ)

書誌情報

発表: arXiv プレプリント 2026
リンク: https://arxiv.org/abs/2609.35328
系譜: 最新(← MetaBox-v2 / AlphaEvolve)
調査日: 2026-10-23
確認範囲: 全文(問題提起・手法・実験・結果・考察)