Spiking Transformer ・大規模化

SNN を Transformer/LLM 規模へ拡張する系譜。深い残差 SNN（ SEW-ResNet ）を足場に Spikformer がスパイク自己注意を導入し、Spike-driven Transformer v1→v3 が加算のみの計算と大規模化を追求。

言語側は SpikeGPT（ RWKV ）・SpikingSSM から、SpikeLLM 、SpikingBrain 1.0/2.0（線形・疎注意＋整数→スパイク符号化）へ。2026 年にはスケーリング則の検証も始まった。

#	年	論文	発表	系譜
1	2021	SEW-ResNet (Fang+ 2021)	NeurIPS 2021	原典
2	2022	Spikformer (Zhou+ 2022)	ICLR 2023	原典
3	2023	SpikeGPT (Zhu+ 2023)	TMLR 2024	原典
4	2023	Spike-driven Transformer (Yao+ 2023)	NeurIPS 2023	発展
5	2024	Meta-SpikeFormer / SDT V2 (Yao+ 2024)	ICLR 2024	発展
6	2024	SpikeLLM (Xing+ 2024)	ICLR 2025	発展
7	2024	SpikingSSMs (Shen+ 2024)	AAAI 2025	発展
8	2024	E-SpikeFormer / SDT V3 (Yao+ 2024)	IEEE TPAMI 2025	最新
9	2025	SpikingBrain (Pan+ 2025)	arXiv プレプリント 2025	最新
10	2026	SpikingBrain2.0 (Pan+ 2026)	arXiv プレプリント 2026	最新
11	2026	Spiking LM Scaling Laws (Saunders+ 2026)	NeurIPS 2026 WS（ AXIOM ）	最新

Deep Residual Learning in Spiking Neural Networks

Wei Fang, Zhaofei Yu, Yanqi Chen ほか（北京大学）| NeurIPS 2021

1 どんなもの？

Spiking ResNet の残差ブロックを、スパイク同士を要素ごとの関数 g（ADD/AND/IAND）で結ぶ SEW ブロックに置き換え、直接学習で 100 層超（SEW-ResNet-152）の SNN を初めて実現。深くするほど精度が上がることを示した。

2 先行研究と比べてどこがすごい？

従来の Spiking ResNet（tdBN など）は ReLU を SN に置き換えただけで、LIF 等では恒等写像が作れず勾配消失 / 爆発が起き、深くすると劣化（152 層で ImageNet 10.03%）。SEW は任意のニューロンモデルで恒等写像を実現する。

3 技術や手法のキモはどこ？

残差を SN の後で合流：O[t]=g(SN(F(S[t])), S[t])。最後の BN を 0 初期化すれば A≡0 となり ADD/IAND は恒等写像に、ブロック間の勾配は定数 1 に保たれる（Eq. 11）。ただし ADD では出力が整数スパイクになる。

4 どうやって有効だと検証した？

ImageNet（T=4, IF）で SEW-ResNet-18/34/50/101/152 = 63.18/67.04/67.78/68.76/69.26%、同構造の Spiking ResNet は 152 層で 10.03%（Table 2）。DVS Gesture 97.92%（0.13M, T=16, Table 5）、CIFAR10-DVS 74.4%（Table 6）。

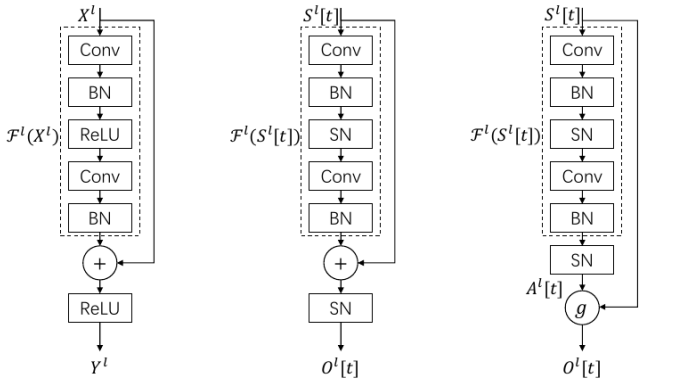
5 議論はある？

著者：AND は深層で発火が消える silence 問題があり IAND で緩和、精度は ADD が最良（Table 4）。ANN2SNN に精度で劣るが T は 64～87 倍少ない。

所感：ADD の整数出力は“スパイク駆動”を崩し、後に SDT が膜電位ショートカットで批判する論点となった。

6 次に読むべき論文は？

- Spikformer (2022)（本資料）
- MS-ResNet: Advancing SNNs towards Deep Residual Learning (2021)（未調査）
- Spike-driven Transformer (2023)（本資料）



出典：SEW-ResNet Fig. 1（ResNet・Spiking ResNet・SEW の残差ブロック比較）

書誌情報

発表： NeurIPS 2021
リンク： https://arxiv.org/abs/2102.04159
系譜： 原典
調査日： 2026-10-23
確認範囲： 全文（問題提起・手法・実験・結果・考察）

Spikformer: When Spiking Neural Network Meets Transformer

Zhaokun Zhou, Yuesheng Zhu, Chao He ほか（北京大学・鵬城実験室）| ICLR 2023

1 どんなもの？

Q・K・V をスパイク（0/1）化し softmax を除いた Spiking Self Attention（SSA）を提案し、初の直接学習 Spiking Transformer「Spikformer」を構築。ImageNet で 74.81%（66.3M, T=4）と当時の直接学習 SNN 最高を達成した。

2 先行研究と比べてどこがすごい？

SNN は ResNet 型（SEW-ResNet-152: 69.26%）止まりで、既存の“Spiking Transformer”は ANN の自己注意をそのまま使い、浮動小数の積と softmax が SNN の加算主体の計算規則に反していた。SSA は乗算を避けて注意を実現。

3 技術や手法のキモはどこ？

Q,K,V=SN(BN(XW)) で 2 値化し SSA=SN($QK^TV \cdot s$)。注意マップが非負なので softmax 不要で、積は AND と加算に退化する。softmax がないため K^TV を先に計算すれば $O(Nd^2)$ にできる。パッチ化は畳み込み SPS、LN の代わりに BN。

4 どうやって有効だと検証した？

ImageNet：Spikformer-8-384 が 16.81M で 70.24%（SEW-ResNet-152 60.19M の 69.26% を上回る）、8-768 で 74.81%（Table 2）。CIFAR10/100 95.51/78.21%、DVS128 98.3%、CIFAR10-DVS 80.9%（Table 3, 4）。SSA は演算量を大幅削減（Table 1）。

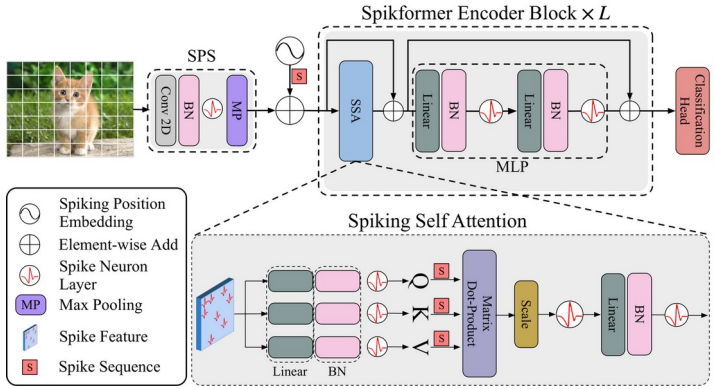
5 議論はある？

著者：同構造の ANN-ViT とは 7.42% 差だが推定エネルギーは 1/3.31。I/ReLU 型注意は値が大きく収束しない（Table 5）。

所感：残差は SEW 型の整数加算、スケール s は乗算で、完全なスパイク駆動ではない。エネルギーも理論推定のみ。

6 次に読むべき論文は？

- Spike-driven Transformer (2023)（本資料）
- Spikformer V2 (2024)（未調査）
- SpikeBERT (2023)（未調査）
- QKFormer (2024)（未調査）



出典：Spikformer Fig. 2（SPS・エンコーダブロック・SSA の全体構成）

書誌情報

発表： ICLR 2023
リンク： https://arxiv.org/abs/2209.15425
系譜： 原典（← SEW-ResNet）
調査日： 2026-10-23
確認範囲： 全文（問題提起・手法・実験・結果・考察）

SpikeGPT: Generative Pre-trained Language Model with Spiking Neural Networks

Rui-Jie Zhu, Qihang Zhao, Guoqi Li, Jason K. Eshraghian（UC Santa Cruz ほか）| TMLR 2024

1 どんなもの？

RWKV を土台に、2 値スパイク活性で言語生成を行う初の SNN 言語モデル SpikeGPT（46M/216M）を構築。系列次元を SNN の時間次元に重ね、線形計算量で自己回帰学習し、GPT-2 級に迫る生成性能を示した。

2 先行研究と比べてどこがすごい？

Spikformer など既存のスパイキング Transformer は画像分類のみで、追加の時間次元が計算量を増やし、系列全体を並列に見る自己注意は再帰的な SNN と相性が悪かった。言語生成に成功した SNN は存在しなかった。

3 技術や手法のキモはどこ？

自己注意を Spiking RWKV に置換:減衰ベクトル W_d, W_f と状態 A[t], B[t] により要素積だけでトークンを混合し、出力を LIF でスパイク化。FFN は GLU 変種の SRFFN、入力は Binary Embedding、残差は SEW 型。

4 どうやって有効だと検証した？

Enwik8：46M（T=3072）で test BPC 1.262（Linear Transformer 1.207、Transformer 1.137、Table 2）。WikiText-2 PPL 18.01（GPT-2 medium 22.76）、WikiText-103 39.75（GPT-2 small 29.41、Table 3）。演算は推定 32.2 倍削減（Table 1）。

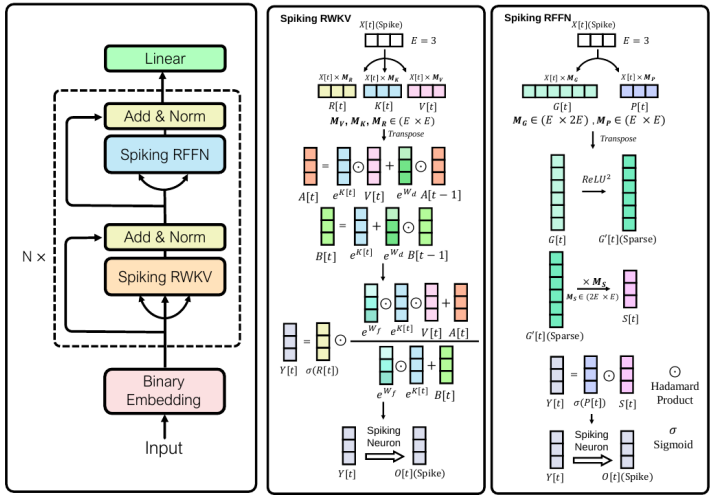
5 議論はある？

著者: WikiText-103 では GPT-2 に劣り過学習傾向。216M→430M→1.2B で損失が下がりスケールの兆候（Fig. 3）。

所感:要素積や ReLU² は非 2 値で、ハード前提は楽観的。スケール検証も 0.9B トークンの学習損失のみ。

6 次に読むべき論文は？

- SpikingSSMs (2024)（本資料）
- Compute-Optimal Scaling Laws for Spiking LMs (2026)（本資料）
- SpikingBERT (2023)（未調査）



出典: SpikeGPT Fig. 1（ブロック構成と Spiking RWKV / Spiking RFFN）

書誌情報

発表: TMLR 2024
リンク: https://arxiv.org/abs/2302.13939
系譜:原典（← SEW-ResNet）
調査日: 2026-10-23
確認範囲:全文（問題提起・手法・実験・結果・考察）

Spike-driven Transformer

Man Yao, Jiakui Hu, Zhaokun Zhou ほか（中国科学院自動化研究所）| NeurIPS 2023

1 どんなもの？

自己注意を含む全演算を「マスクと疎な加算」だけで行う Spike-driven Transformer を提案。Spike-Driven Self-Attention（SDSA）と膜電位ショートカットにより、ImageNet 77.1%（66M, 288px 推論）を達成した。

2 先行研究と比べてどこがすごい？

Spikformer 等は SN を挿入した“ハイブリッド計算”で、QK^TV が大きな整数を生みスケール乗算が要り、SEW 残差も整数スパイクを出すためチップ上で加算だけにならない。SDT は全層で 2 値スパイク通信を保証する。

3 技術や手法のキモはどこ？

SDSA=SN(SUM_c(Q_S⊗K_S))⊗V_S：アダマール積（＝マスク）と列和、SN で注意を作る。トークン・チャネルの両方に線形な線形注意の一種で、加算は約 0.02ND 回。残差は SN 前の膜電位同士で結ぶ（MS ショートカット）。

4 どうやって有効だと検証した？

ImageNet：8-384 で 72.28%（Spikformer 70.24%）、8-768 で 76.32%、288px 推論で 77.07%、推定 6.09mJ（Spikformer 21.47mJ）（Table 3）。SDSA は VSA 比で最大 87.2 倍低エネルギー（Table 4）。DVS128 99.3%（Table 5）。

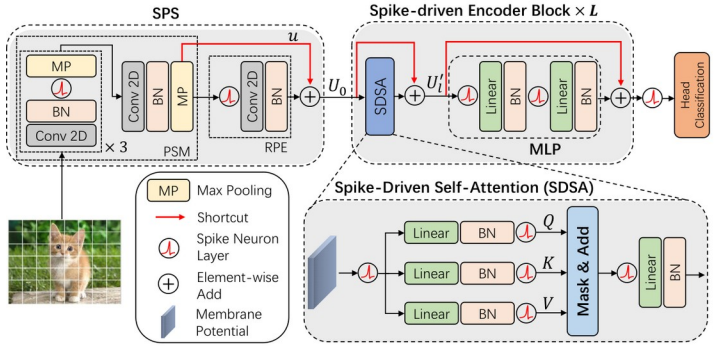
5 議論はある？

著者：SDSA 単独では CIFAR で微減（-0.03/-0.34%）し、MS ショートカットが精度を押し上げる（Table 6）。ANN-ViT 比 9.3 倍省エネ。

所感：2 値の“ハード注意”でチャネルを捨てるため表現力の天井が懸念。エネルギーは理論値。

6 次に読むべき論文は？

- Spike-driven Transformer V2 (2024)（本資料）
- MS-ResNet (2021)（未調査）
- QKFormer (2024)（未調査）



出典：Spike-driven Transformer Fig. 2（SPS・膜電位ショートカット・SDSA）

書誌情報

発表： NeurIPS 2023
リンク： https://arxiv.org/abs/2307.01694
系譜： 発展（← Spikformer）
調査日： 2026-10-23
確認範囲： 全文（問題提起・手法・実験・結果・考察）

Spike-driven Transformer V2: Meta Spiking Neural Network Architecture Inspiring the Design of Next-generation Neuromorphic Chips

Man Yao, Jiakui Hu, Tianxiang Hu ほか（中国科学院自動化研究所）| ICLR 2024

1 どんなもの？

MetaFormer の考え方を SNN に移し、Conv 型と Transformer 型の SNN ブロックを組み合わせた汎用骨格 Meta-SpikeFormer を提案。直接学習 SNN で初めて ImageNet 80.0%（55M）に到達し、検出・セグメンテーションも 1 つの骨格で扱った。

2 先行研究と比べてどこがすごい？

SDT は加算のみを実現したが Conv 型 SNN（MS-ResNet 75.3%）に対する明確な優位がなく、Transformer 型 SNN 向けのチップも存在しない。既存の SNN 骨格は分類以外のタスクへの汎用性を示せていなかった。

3 技術や手法のキモはどこ？

前 2 段を SepConv＋ChannelConv の Conv 型ブロック、後 2 段をピラミッド構造の Transformer 型ブロックに。SDSA-3=SN_s((Q_S K_S^T)V_S) はスケール s を閾値に吸収して乗算を排除。Q,K,V は RepConv で生成、残差は MS。

4 どうやって有効だと検証した？

ImageNet：55.4M で 79.7%（蒸留で T=4 80.0%、T=1 79.1%、Table 1）。COCO mAP@0.5 51.2%（Table 3）、ADE20K mIoU 35.3%（Table 4）、HAR-DVS 47.5%。全 Conv 化 -2.9%、全 Transformer 化 -3.7%、SEW 残差 -1.9%（Table 5）。

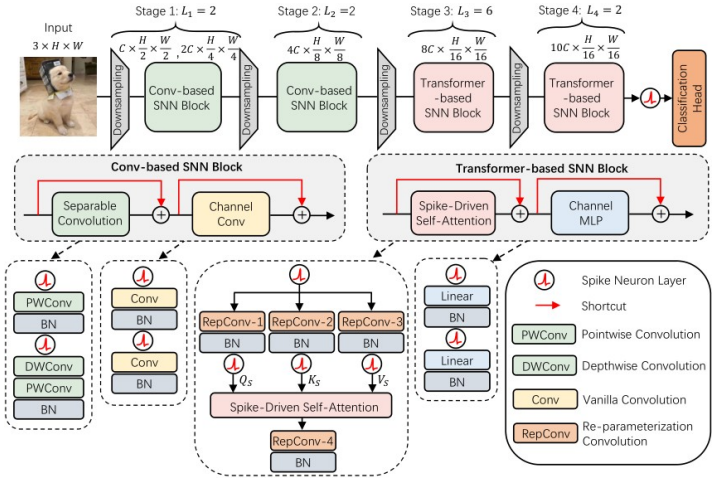
5 議論はある？

著者：Conv＋ViT 構成、SDSA、メタ構造が次世代ニューロモルフィックチップ設計の指針になると主張。

所感：精度の代償に推定電力が 52.4mJ と SDT（6.1mJ）より大幅増。RepConv が電力の約 6 割を占めると後に V3 が指摘。

6 次に読むべき論文は？

- Scaling Spike-driven Transformer (E-SpikeFormer, 2024)（本資料）
- MetaFormer / CAFormer (2022)（未調査）
- QKFormer (2024)（未調査）



出典：Spike-driven Transformer V2 Fig. 2（Meta-SpikeFormer の 4 段構成とブロック詳細）

書誌情報

発表: ICLR 2024
リンク: https://arxiv.org/abs/2404.03663
系譜: 発展（← Spike-driven Transformer）
調査日: 2026-10-23
確認範囲: 全文（問題提起・手法・実験・結果・考察）

SpikeLLM: Scaling up Spiking Neural Network to Large Language Models via Saliency-based Spiking

Xingrun Xing, Boyan Gao, Zheng Liu ほか（中国科学院自動化研究所・BAAI）| ICLR 2025

1 どんなもの？

7 ～ 70B の LLaMA にスパイク機構を導入した初の“スパイキング LLM”。複数ステップを低ビット量子化にまとめる GIF ニューロンと、重要チャネルにだけ多ステップ発火を割り当てる OBSpiking で、同等演算量の量子化 LLM を上回った。

2 先行研究と比べてどこがすごい？

SNN 言語モデルは SpikeGPT・SpikeLM 等 1B 未満に留まり、発火率符号化は T 段階の表現に T ステップを要し非効率、BPTT や ANN-SNN 変換も LLM 規模では非現実的。量子化 LLM は外れ値・重要チャネルで誤差が大きい。

3 技術や手法のキモはどこ？

GIF は L ステップを 1 ステップ $\log_2 L$ ビットに統合し、符号長を T から $(T/L)\cdot\log_2 L$ に圧縮。OBSpiking は活性に 1 次（$X \circ W^T W X$）、重みに 2 次（Hessian）の saliency を用い、上位チャネルだけ T′ ステップで符号化する。

4 どうやって有効だと検証した？

OmniQuant 系 W4A4：LLaMA-1-7B で常識推論平均 49.93→52.48%、WikiText2 PPL 11.01% 減（Table 1, 3）。LLaMA-2-70B W2A16 で 53.31→60.38%。QuaRot 併用でも +1.0 ～ 1.2%（Table 4）。三値 GIF の全加算版は PB-LLM 超え（Table 6）。

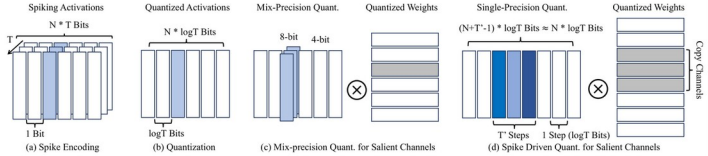
5 議論はある？

著者：ANN LLM との性能差が主な限界で、校正は 128 サンプルのみ（7B で 3.5 GPU 時間）。継続事前学習で改善し得る。

所感：実体は“量子化の一般化”で時間ダイナミクスはほぼ使わない。1 ビット展開すると演算は GEMM 版より増える（Table 5）。

6 次に読むべき論文は？

- SpikingBrain (2025)（本資料）
- SpikeLM (2024)（未調査）
- Spike-driven Large Language Model (SDLLM, 2026)（未調査）



出典：SpikeLLM Fig. 1（スパイク符号化・量子化・混合精度・spike-driven 量子化の比較）

書誌情報

発表： ICLR 2025
リンク： https://arxiv.org/abs/2407.04752
系譜： 発展（← SpikeGPT）
調査日： 2026-10-23
確認範囲： 全文（問題提起・手法・実験・結果・考察）

SpikingSSMs: Learning Long Sequences with Sparse and Parallel Spiking State Space Models

Shuaijie Shen, Chao Wang, Renzhuo Huang ほか（南方科技大学・ Huawei ACS Lab ）| AAAI 2025

1 どんなもの？

S4D 型の状態空間モデルの出力に LIF ニューロンを載せた SpikingSSM を提案。リセットを含む LIF の発火を小さな代理ネットワーク（ SDN ）で並列予測し、長系列で最大 100 倍の学習高速化と約 90% のスパース性を両立した。

2 先行研究と比べてどこがすごい？

SNN は時間ダイナミクスを持つのに長系列タスクではほぼ使われず、リセット付き LIF は逐次計算で並列学習できない。PSN はリセット除去で発火が増え、Binary S4D や S6 系 SNN はダイナミクス軽視や精度低下が課題だった。

3 技術や手法のキモはどこ？

y_t=Ch_t を LIF の入力電流とし u′_t=τu_{t−1}+y_t を閾値処理（樹状突起 h・細胞体 y の 2 階層）。SDN（1D-CNN, 200 パラメータ未満）が入力からスパイク列を予測し、膜電位を並列計算。閾値は入力スケールとして学習。

4 どうやって有効だと検証した？

学習速度: L=8K で BPTT 比 101.2 倍（ Table 1 ）。LRA 平均 84.33%（ S4D-Lin 85.52% ）、Path-X 94.82%、発火率約 0.1（ Table 3 ）。WikiText-103 で PPL 33.94（ 75M ）と SpikeGPT 39.75（ 213M ）を上回る（ Table 4 ）。

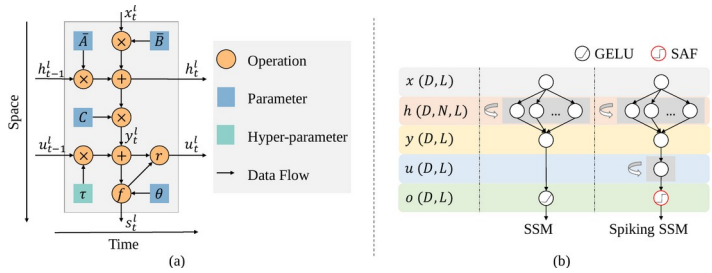
5 議論はある？

著者:事前学習した SDN の帰納バイアスが有効（同時学習の SDN-S は 81.52% と劣る、Table 5 ）。

所感: SSM 内部の状態更新は浮動小数のままで、スパイク化は層出力のみ。言語モデルは Transformer（ PPL 20.51 ）とまだ差が大きい。

6 次に読むべき論文は？

- P-SpikeSSM (2024)（未調査）
- SpikingBrain (2025)（本資料）
- NeuronSpark (2026)（未調査）



出典: SpikingSSMs Fig. 1（ (a) 1 層の計算グラフ、(b) SSM と Spiking SSM の比較）

書誌情報

発表: AAAI 2025
リンク: https://arxiv.org/abs/2408.14909
系譜: 発展（← SpikeGPT ）
調査日: 2026-10-23
確認範囲: 全文（問題提起・手法・実験・結果・考察）

Scaling Spike-driven Transformer with Efficient Spike Firing Approximation Training

Man Yao, Xuerui Qiu, Tianxiang Hu ほか（中国科学院自動化研究所）| IEEE TPAMI 2025

1 どんなもの？

2 値発火そのものを性能・スケーリングの欠陥と捉え、学習は整数活性・推論はスパイク列に展開する Spike Firing Approximation（SFA）を提案。効率化した E-SpikeFormer と MIM 事前学習で 173M・ImageNet 86.2% まで SNN を拡大した。

2 先行研究と比べてどこがすごい？

Meta-SpikeFormer は 55M・80.0% で推定 52.4mJ と重く、多時刻ステップ直接学習はメモリ O(L×T) で大規模化を阻む。さらに単純に大型化すると性能が劣化した。ANN2SNN は推論ステップが長い。

3 技術や手法のキモはどこ？

学習: S_D=round(clip(U,0,D)) の整数活性を 1 ステップで学習。推論: IF・ソフトリセット（V_th=1）で D ステップのスパイク列に等価展開（Prop. 1）。RepConv を Linear＋SpikeSepConv に替え、MIM 用に Spike Sparse Conv を導入。

4 どうやって有効だと検証した？

ImageNet：10M で 78.5%（3.0mJ）、19M で 79.8%（5.9mJ, DeiT-S 並）、83M で 84.0%、173M で 86.2%（384px）（Table 1）。10M ベースライン比 +7.2%、学習 5.3 倍速、推論 3.7 倍省エネ（Table 5）。COCO 58.8%、ADE20K 41.4%。

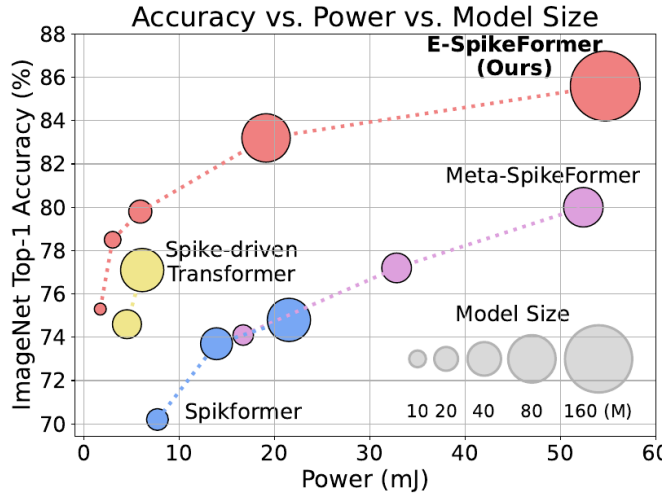
5 議論はある？

著者: 2 値発火のままでは MIM を使っても大型化で劣化し有効ランクも低下（Fig. 10）。SFA は非同期チップ向きだが D が大きいと帯域超過の恐れ。

所感:“整数で学びスパイクで推論”は SpikingBrain に引き継がれる転換点。

6 次に読むべき論文は？

- SpikingBrain (2025)（本資料）
- Spikformer V2 (2024)（未調査）
- Speck: 非同期センシング・計算ニューロモルフィックチップ (2024)（未調査）



出典: E-SpikeFormer Fig. 1（ImageNet 精度・推定電力・モデルサイズの比較）

書誌情報

発表: IEEE TPAMI 2025
リンク: https://arxiv.org/abs/2411.16061
系譜: 最新（← Meta-SpikeFormer / SDT V2）
調査日: 2026-10-23
確認範囲: 全文（問題提起・手法・実験・結果・考察）

SpikingBrain: Spiking Brain-inspired Large Models

Yuqi Pan, Yupeng Feng, Jinghao Zhuang ほか（中国科学院自動化研究所・MetaX）| arXiv プレプリント 2025

1 どんなもの？

Qwen2.5-7B から変換した線形 SpikingBrain-7B と、ハイブリッド線形 MoE の 76B（A12B）を約 150B トークンの継続学習で構築。適応閾値スパイク符号化で活性スパース率 69.15%、4M トークンで TTFT 100 倍超の高速化を報告。

2 先行研究と比べてどこがすごい？

Transformer LLM は学習が系列長の 2 乗、推論メモリが線形に増える。SpikeLLM 等は既存 LLM の量子化的スパイク化で構造は非効率のまま、ゼロからの学習は 10T トークン級で非現実的。非 NVIDIA（MetaX）での大規模学習も未検証。

3 技術や手法のキモはどこ？

注意を線形注意（GLA）＋SWA（7B は層間交互、76B は層内並列＋一部 FA）に変換し、FFN は upcycling で MoE 化。活性は V_th=mean|x|/k の適応閾値で整数カウントにし、推論時に 2 値・3 値・ビット単位のスパイク列へ展開。

4 どうやって有効だと検証した？

7B：MMLU 65.84（Qwen2.5-7B 74.21、Llama3.1-8B 65.74）、76B：MMLU 73.58、CMMLU 78.83（Table 1, 2）。W8＋スパイクで平均約 2% 低下（Table 3）。1M トークンで TTFT 26.5 倍、MetaX で MFU 23.4%、推定 MAC エネルギー FP16 比 97.7% 減。

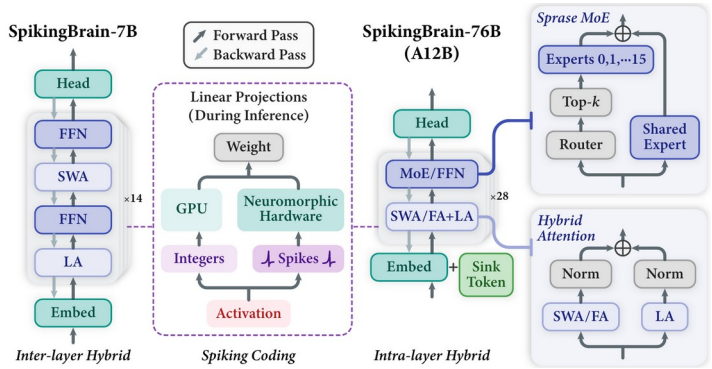
5 議論はある？

著者：線形注意は想起に弱く、短文連結での長文学習は効果が限定的。エネルギーは理想的な非同期 HW を仮定した推定（App. C.2）。

所感：“スパイク”は推論時に展開する整数量子化に近く、効率の大半は線形注意由来。SNN の定義が拡張されている。

6 次に読むべき論文は？

- SpikingBrain2.0 (2026)（本資料）
- Gated Linear Attention (2024)（未調査）
- SpikeLLM (2024)（本資料）



出典：SpikingBrain Fig. 3（7B 層間ハイブリッド・スパイク符号化・76B 層内ハイブリッド MoE）

書誌情報

発表： arXiv プレプリント 2025
リンク： https://arxiv.org/abs/2509.05276
系譜： 最新（← E-SpikeFormer / SpikeLLM）
調査日： 2026-10-23
確認範囲： 全文（問題提起・手法・実験・結果・考察）

SpikingBrain2.0: Brain-Inspired Foundation Models for Efficient Long-Context and Cross-Platform Inference

Yuqi Pan, Jinghao Zhuang, Yupeng Feng ほか（中国科学院自動化研究所）| arXiv プレプリント 2026

1 どんなもの？

Qwen3-4B から変換した 5B のハイブリッドスパイキング基盤モデル（言語・視覚言語）。疎なソフトマックス注意 MoBA と疎な線形注意 SSE を 1:3 で混ぜる DSSA を導入し、7k A100 時間未満で元モデル性能の 95% 超を回復した。

2 先行研究と比べてどこがすごい？

SpikingBrain1.0 は 7B（線形）の長文能力が不足し、76B は FA 層が多く効率が伸びず、継続学習 150B トークンも重かった。DSSA と蒸留中心の Transformer→Hybrid 変換で、性能・効率・学習コストの両立を狙う。

3 技術や手法のキモはどこ？

36 層中、感度分析で選んだ 9 層を MoBA、26 層を SSE-GDN＋小窓 SWA（dropout 0.5）、最終層だけ FA。変換は層出力 MSE＋logit 蒸留（3B トークン）→ 512k 長文化（11B）→ SFT。活性は INT8-Spiking か FP8 で符号化。

4 どうやって有効だと検証した？

事前学習版の平均 66.31（Qwen3-4B 69.58、Table 5）。4M トークンで TTFT 10.13 倍（Table 9）、vLLM で 10M トークン提供（Qwen3 は 4M 超で OOM、Table 11）。INT8-Spiking は -0.69%・スパース率 64.31%、28nm 合成で面積 70.6%・電力 46.5% 減（Table 14）。

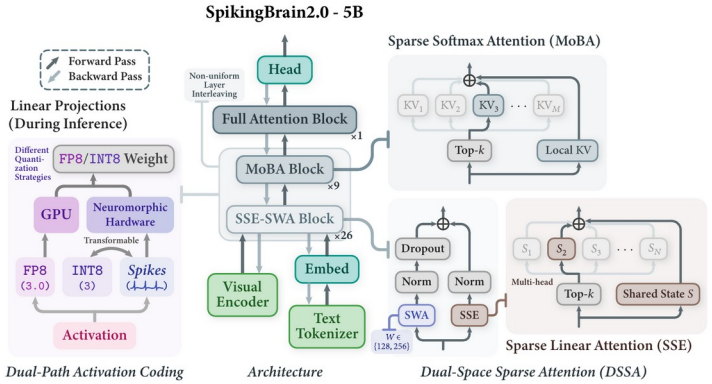
5 議論はある？

著者：CPT ウォームアップが必須、蒸留は SFT より CPT で有効、変換後の長文学習が必要。AIME や VLM で基盤モデルとの差が残る。

所感：SNN 要素は活性符号化に限られ、ほぼ“効率的ハイブリッド LLM”。電力が回路合成ベースになった点は前進。

6 次に読むべき論文は？

- MoBA: Mixture of Block Attention (2025)（未調査）
- Sparse State Expansion (SSE, 2025)（未調査）
- SpikingBrain (2025)（本資料）



出典：SpikingBrain2.0 Fig. 1（二経路活性符号化・DSSA・全体構成）

書誌情報

発表： arXiv プレプリント 2026
リンク： https://arxiv.org/abs/2604.22575
系譜： 最新（← SpikingBrain）
調査日： 2026-10-23
確認範囲： 全文（問題提起・手法・実験・結果・考察）

Compute-Optimal Scaling Laws for Spiking Language Models

Dan Saunders, Benjamin Ren, Catherine He（Luma AI・X School）| NeurIPS 2026 Workshop (AXIOM)

1 どんなもの？

SpikeGPT 系（RWKV 骨格）のスパイキング言語モデルで初めて Chinchilla 型 IsoFLOP スケーリング則を測定。計算最適なパラメータ数は N_opt∝C^0.56 と密な Transformer（0.50）に近く、スパイク化の損失コストは計算量とともに縮むと示した。

2 先行研究と比べてどこがすごい？

SpikeGPT は計算最適域よりはるかに小さい学習量で評価され、SpikeLLM 等は既存 LLM の事後スパイク化。スパイキング LM をゼロから学習する際の N と D の配分、スパース化による精度コストは未解明だった。

3 技術や手法のキモはどこ？

幅 384 ～ 1536 のモデルを 3×10^{17} ～ 10^{19} FLOPs の 4 段で FineWeb-EDU 学習し、各段の放物線頂点から (N_opt, D_opt) を推定。同条件で非スパイク RWKV と Transformer も学習し、損失差を“骨格コスト”と“スパイクコスト”に分解した。

4 どうやって有効だと検証した？

総パラメータ基準で α=0.556（Approach 3 で 0.595）、非埋め込み基準では 0.748（Table 1）。10^{20} FLOPs（2.44B）への外挿予測 2.74 に対し実測 2.76。骨格コストは約 0.16 nats で一定、スパイクコストは 0.338→0.225 nats に減少（Table 2, Fig. 2）。

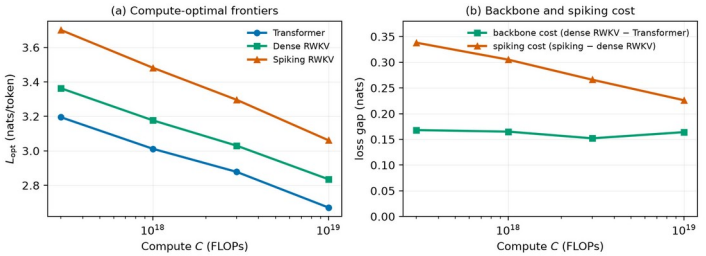
5 議論はある？

著者：規模は 10^{19} FLOPs まで（Chinchilla の 10^{21} ～ 10^{24} より小）、データは 1 種、ベースラインは 1 シード。発火率は規模でなく学習進度で決まり約 0.36 に飽和。

所感：4 ページの WS 論文だが“スパイク化の税は規模で薄まる”定量的根拠は貴重。

6 次に読むべき論文は？

- SpikeGPT (2023)（本資料）
- Training Compute-Optimal LLMs (Chinchilla, 2022)（未調査）
- Scaling Laws for Linear Complexity LMs (2024)（未調査）



出典：Spiking LM Scaling Laws Fig. 2（計算最適損失と、骨格コスト・スパイクコストの推移）

書誌情報

発表： NeurIPS 2026 WS（AXIOM）
リンク： https://arxiv.org/abs/2610.15146
系譜： 最新（← SpikeGPT）
調査日： 2026-10-23
確認範囲： 全文（問題提起・手法・実験・結果・考察）