確率的·多峰な未来を扱う潜在世界モデル

決定論的な予測器は多峰な未来を平均化してしまう。SV2P・SVG の確率的潜在変数を原典に、DreamerV2 の離散潜在、VQM・IRIS の離散トークン、NWM の潜在拡散へと発展した。

2026 年には非生成型の JEPA 系にも拡散(JEDI)・flow matching (FlowWM)・有限個の分岐(Branch-JEPA)が入り、生成された確率の較正を問う評価(CaliBench)も現れた。

#	年	論文	発表	系譜
1	2017	SV2P (Babaeizadeh+ 2017)	ICLR 2018	原典
2	2018	SVG (Denton & Fergus 2018)	ICML 2018	発展
3	2021	DreamerV2 (Hafner+ 2021)	ICLR 2021	発展
4	2021	VQM (Ozair+ 2021)	ICML 2021	発展
5	2023	IRIS (Micheli+ 2023)	ICLR 2023	発展
6	2025	NWM (Bar+ 2025)	CVPR 2025	発展
7	2026	JEDI (Lim+ 2026)	arXiv プレプリント 2026	最新
8	2026	FlowWM (Porcher+ 2026)	arXiv プレプリント 2026	最新
9	2026	Branch-JEPA (Song+ 2026)	arXiv プレプリント 2026	最新
10	2026	CaliBench (Sadeghi+ 2026)	TMLR 2026	最新

Stochastic Variational Video Prediction

Mohammad Babaeizadeh, Chelsea Finn, Dumitru Erhan, Roy H. Campbell, Sergey Levine（UIUC / UC Berkeley / Google Brain）| ICLR 2018

1 どんなもの？

動画予測に潜在変数 z を導入し、z をサンプルし直すたびに異なるもっともらしい未来を出す SV2P を提案。実世界の動画（BAIR ロボット押し、Human3.6M）で、複数フレーム先まで確率的に予測できた初の潜在変数モデルだと主張する。

2 先行研究と比べてどこがすごい？

Finn+ (2016) の CDNA など決定論的な予測器は MSE で学ぶため、可能な未来の平均を出して画像がぼやける。GAN はモード崩壊、自己回帰でピクセルを生成する VPN は 1 秒分の生成に 1 分以上かかる。SV2P は変分推論で、速く多様な予測を得る。

3 技術や手法のキモはどこ？

推論ネット q(z|x0:T) は未来のフレームまで見て z を推定し、ELBO ＝再構成誤差＋ KL(q‖N(0,I)) で学ぶ。素朴に学習すると z が無視されるため、①決定論部だけ ② KL なし ③ KL を徐々に増やす、の 3 段階で学習する。

4 どうやって有効だと検証した？

図形がランダムな方向に動くトイデータで、決定論モデルは 8 方向の平均（にじんだ像）を出すが、SV2P は個々の方向を出す（Fig. 1）。100 サンプル中最良の PSNR/SSIM で CDNA と VPN を上回り（Fig. 6）、人検出の確信度も高い（Fig. 7）。

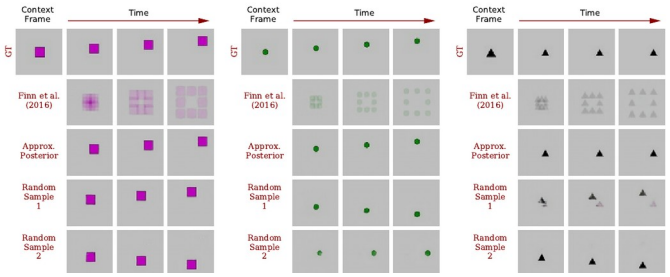
5 議論はある？

著者：事後分布が重なるため、サンプルが複数の未来の平均になる場合が残る。

所感：「平均化」の問題を初めて実データで示した。ただ評価は best-of-100 で、分布がどれだけ合っているかは測れていない。この評価の弱さは CaliBench まで続く。

6 次に読むべき論文は？

- SVG (2018)（本資料）
- PlaNet (2019)（既存：latent-planning）
- SimPLe (Kaiser+ 2019)（未調査）



出典：SV2P Fig. 1（決定論モデル（2 行目）は平均を出し、SV2P はサンプルごとに異なる方向へ動かす）

書誌情報

発表： ICLR 2018
リンク： https://arxiv.org/abs/1710.11252
系譜： 原典
調査日： 2026-10-24
確認範囲： 全文（問題提起・手法・実験・結果・考察）

Stochastic Video Generation with a Learned Prior

Emily Denton, Rob Fergus（New York University / Facebook AI Research）| ICML 2018

1 どんなもの？

決定論的なフレーム予測器に、時刻ごとの確率的潜在変数 z_t を加えた SVG を提案。z_t の事前分布も過去フレームから学ぶ（SVG-LP）。不確実な時点（壁への衝突など）でだけ分散が大きくなり、鮮明で多様な予測を出せる。

2 先行研究と比べてどこがすごい？

SV2P は動画全体から 1 つの事後分布を推定するため、3 段階の学習が必要だった。SVG は時刻ごとの事後分布 q(z_t|x1:t) を再帰的に推定し、1 つの損失で end-to-end に学べる。生成画像も SV2P より鮮明になった。

3 技術や手法のキモはどこ？

損失は再構成誤差＋ β·KL(q(z_t|x1:t) ‖ p_φ(z_t|x1:t−1))。学習した事前分布 p_φ が「次の時刻がどれだけ不確実か」を予測する。β が小さすぎると z が答えを写し、大きすぎると z が無視される。

4 どうやって有効だと検証した？

壁で跳ね返る方向がランダムな Stochastic Moving MNIST で、生成した速度の分布が真の分布に一致した（Fig. 5）。事前分布の σ は衝突の時刻に立ち上がる（Fig. 6）。KTH・BAIR でも決定論版や SV2P を SSIM で上回る（Fig. 7, 8）。

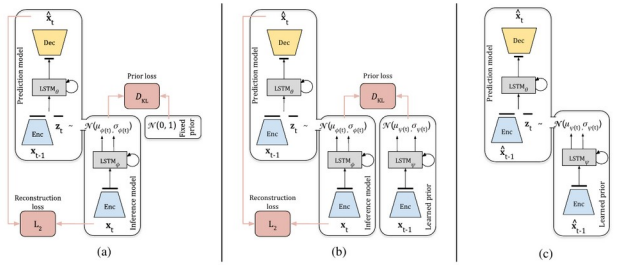
5 議論はある？

著者：PSNR はぼやけた予測を好むため、後半の時刻では SV2P の PSNR がわずかに高い。

所感：「決定論部＋時刻ごとの学習事前分布」は RSSM の原型で、PlaNet・Dreamer の確率的状態にそのまま引き継がれた。

6 次に読むべき論文は？

- PlaNet (2019)（既存：latent-planning）
- DreamerV2 (2021)（本資料）
- VRNN (Chung+ 2015)（未調査）



出典：SVG Fig. 2（(a) 固定事前分布での学習 (b) 学習事前分布での学習 (c) 学習事前分布からの生成）

書誌情報

発表： ICML 2018
リンク： https://arxiv.org/abs/1802.07687
系譜： 発展（← SV2P）
調査日： 2026-10-24
確認範囲： 全文（問題提起・手法・実験・結果・考察）

Mastering Atari with Discrete World Models

Danijar Hafner, Timothy Lillicrap, Mohammad Norouzi, Jimmy Ba（Google Research / DeepMind / University of Toronto）| ICLR 2021

1 どんなもの？

RSSM の確率的状態を、ガウス分布から「32 クラスのカテゴリカル変数 32 個」に替え、KL バランシングを加えた DreamerV2 を提案。世界モデル内の想像だけで方策を学ぶエージェントとして、初めて Atari 55 ゲームで人間並みの性能に達した。

2 先行研究と比べてどこがすごい？

PlaNet・DreamerV1 の RSSM はガウス潜在で、Atari では方策学習に足る精度が出なかった。SimPLe は画素の予測モデルで 36 ゲームのみ、MuZero は計算量が膨大で非公開。DreamerV2 は単一 GPU で Rainbow・IQN を超えた。

3 技術や手法のキモはどこ？

z_t を one-hot 32 個で表し、straight-through 勾配で学ぶ。KL バランシングでは KL 損失の重みを事前側（遷移予測器）に 0.8、事後側に 0.2 と配分する。表現を未熟な事前分布へ寄せる前に、事前分布を事後分布へ近づけるためである。

4 どうやって有効だと検証した？

Atari 55 ゲーム・200M ステップで gamer median 2.15（IQN 1.29、Rainbow 1.47）（Table 1）。アブレーションで離散潜在を外すと gamer mean は 11.33→3.71、clipped record mean は 0.25→0.19 に下がり、42 ゲームでカテゴリカルが勝つ（Table 2）。

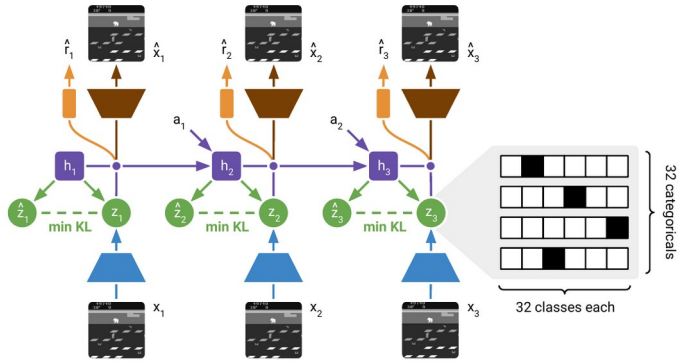
5 議論はある？

著者：理由は不明としつつ、「ガウス事前分布は事後分布の混合に合わせられず、多峰な変化を予測しにくい」などの仮説を挙げる。

所感：離散化が効く理由が多峰性なのか最適化の容易さなのかは、今も切り分けられていない。

6 次に読むべき論文は？

- PlaNet (2019)（既存：latent-planning）
- IRIS (2023)（本資料）
- DreamerV3 (2023)（未調査）



出典：DreamerV2 Fig. 2（RSSM の確率的状態を 32×32 のカテゴリカル変数で表す）

書誌情報

発表： ICLR 2021
リンク： https://arxiv.org/abs/2010.02193
系譜： 発展（← PlaNet（既存））
調査日： 2026-10-24
確認範囲： 全文（問題提起・手法・実験・結果・考察）

Vector Quantized Models for Planning

Sherjil Ozair, Yazhe Li, Ali Razavi, Ioannis Antonoglou, Aäron van den Oord, Oriol Vinyals（DeepMind / Mila）| ICML 2021

1 どんなもの？

行動の結果のばらつきを VQ-VAE の離散符号 k で表し、MCTS で「エージェントの行動」と「環境の応答（符号）」の両方を枝分かれさせて計画する VQM を提案。決定論的な環境を前提とする MuZero を、確率的・部分観測の環境へ広げた。

2 先行研究と比べてどこがすごい？

MuZero は決定論的で完全観測の環境を前提とし、相手の手を観測できない「1 人チェス」では性能が急落する。連続潜在の確率モデル（PlaNet など）は CEM のような手法でしか計画できない。離散符号なら既存の MCTS の技術をそのまま使える。

3 技術や手法のキモはどこ？

状態 VQ-VAE が「過去から予測できない次状態の情報」を符号 k にし、自己回帰の遷移モデルが行動の方策 π と符号の分布 τ を出す。探索木に偶然ノードを置き、符号を argmax[$\hat{Q}$+P(k|s)U] で選ぶ（$\hat{Q}=0$ なら中立、−Q なら敵対）。

4 どうやって有効だと検証した？

人間の棋譜によるオフライン学習の 1 人チェスで、Stockfish Lv.15 への勝率は 1 人用 MuZero が約 1%、VQHybrid（敵対）は約 26% で、2 人用 MuZero の約 30% に迫る（Fig. 4 の読み取り）。DeepMind Lab の長期予測でも LSTM と連続 VAE を上回る（Fig. 8）。

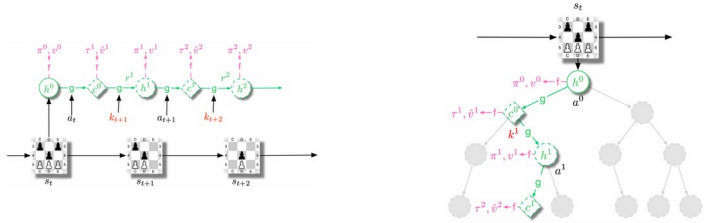
5 議論はある？

著者：中立の偶然ノードでは、探索を増やしても強くならない（Fig. 6）。

所感：「世界の不確実性を離散化して探索木に入れる」発想は Stochastic MuZero に直結する。ただし符号の数を決める基準は経験的である。

6 次に読むべき論文は？

- Stochastic MuZero (2022)（未調査・本文未確認）
- IRIS (2023)（本資料）
- MuZero (2020)（未調査）



出典：VQM Fig. 3(b)(c)（行動と離散符号を交互に予測する遷移モデル（左）と、両方で枝分かれする MCTS（右））

書誌情報

発表： ICML 2021
リンク： https://arxiv.org/abs/2106.04615
系譜： 発展（← MuZero）
調査日： 2026-10-24
確認範囲： 全文（問題提起・手法・実験・結果・考察）

Transformers are Sample-Efficient World Models

Vincent Micheli, Eloi Alonso, François Fleuret（University of Geneva）| ICLR 2023

1 どんなもの？

画像を離散オートエンコーダで 16 トークンに変え、GPT 型 Transformer でトークン列を自己回帰生成する世界モデル IRIS を提案。Atari 100k で平均人間正規化スコア 1.046 を記録し、先読み探索を使わない手法として当時の最高となった。

2 先行研究と比べてどこがすごい？

DreamerV2 は 200M フレームの設定で作られ、少データ（100k ステップ＝約 2 時間）向けではない。SimPLe は画素を予測し、SPR は表現学習のみ。IRIS は世界モデルを「画像トークンの言語モデル」とみなし、Transformer の系列モデリング力を使う。

3 技術や手法のキモはどこ？

VQ 型の符号化器 E（語彙 512、1 フレーム 16 トークン）と Transformer G からなる。G はトークン単位の自己回帰で $p(\hat{z}_{t+1} | z \le t, a \le t)$ を交差エントロピーで学ぶ。カテゴリカル分布を逐次サンプリングするので、多峰な未来をそのまま表せる。

4 どうやって有効だと検証した？

Atari 100k の 26 ゲームで平均 1.046、IQM 0.501、人間超え 10 ゲーム（SPR 比 +70%、+49%、+67%）（Table 1, Fig. 5）。KungFuMaster では同じ初期フレームから、敵の種類と数が異なる未来を生成した（Fig. 2）。

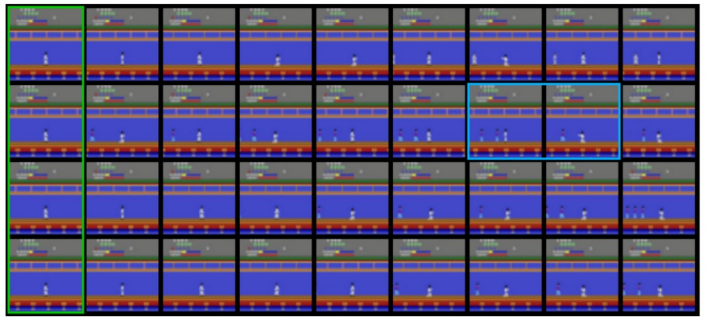
5 議論はある？

著者：低確率の事象で解放される新しいレベル（Frostbite）は再現できない。16 トークンでは細部が消える。

所感：多峰性は表せるが計算が重い（8 GPU で 1 ゲームあたり約 3.5 日）。その後 Δ-IRIS・STORM・DIAMOND が効率化を進めた。

6 次に読むべき論文は？

- Δ-IRIS (2024)（未調査）
- STORM (2023)（未調査）
- JEDI (2026)（本資料）



出典：IRIS Fig. 2（同じ初期フレーム（緑枠）から想像した 4 本の軌道。現れる敵の種類と数が異なる）

書誌情報

発表： ICLR 2023
リンク： https://arxiv.org/abs/2209.00588
系譜： 発展（← VQM / DreamerV2）
調査日： 2026-10-24
確認範囲： 全文（問題提起・手法・実験・結果・考察）

Navigation World Models

Amir Bar, Gaoyue Zhou, Danny Tran, Trevor Darrell, Yann LeCun（FAIR at Meta / NYU / UC Berkeley）| CVPR 2025

1 どんなもの？

Stable Diffusion の VAE 潜在空間で、過去のフレームと移動行動から次の潜在を拡散で生成する 1B パラメータの Navigation World Model (NWM) を提案。生成した未来とゴール画像の類似度で軌道を評価し、CEM による計画や他方策の候補選びに使う。

2 先行研究と比べてどこがすごい？

DIAMOND・GameNGen は単一ゲームで画素拡散を学ぶ。NoMaD などの航行方策は、学習後に制約を加えられない。NWM は複数のロボットと人の動画で 1 つのモデルを学び、計画時に「最初は左右だけに動く」などの制約を加えられる。

3 技術や手法のキモはどこ？

CDiT ブロックでは、ノイズを加えた目標フレームのトークンだけで自己注意し、過去フレームとは交差注意する。計算量が文脈長に線形になり、同等以上の性能で DiT の約 1/4 の FLOPs 。行動と時間シフト k は AdaLN で条件づけ、計画では 3 サンプルの LPIPS を平均する。

4 どうやって有効だと検証した？

RECON で 2 秒先の軌道計画の ATE 1.13（NoMaD 1.93、GNM 1.87）、RPE 0.35（Table 2）。NoMaD の候補 32 本を NWM で選ぶと ATE 1.78 に改善。16 秒の生成で予測精度と FVD が DIAMOND より良い（Fig. 4, 6）。

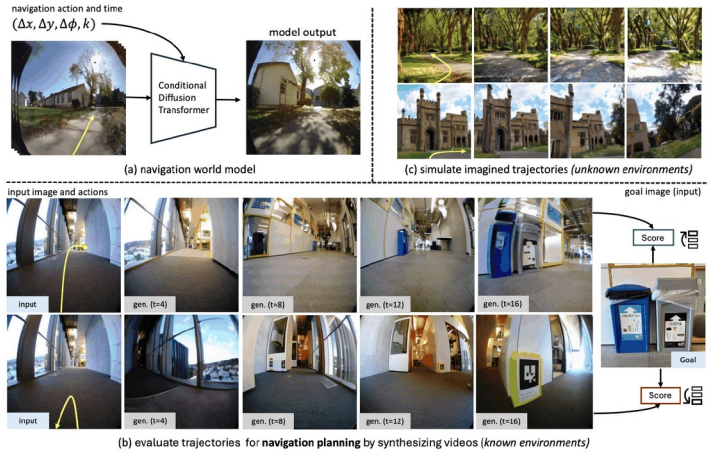
5 議論はある？

著者：未知の環境では学習データに似た画面へ徐々に戻る「モード崩壊」が起き、歩行者の動きもうまく再現できない。

所感：生成型の世界モデルを計画に使った例だが、確率性は評価の平均に使うだけで、分岐する未来を明示的には扱っていない。

6 次に読むべき論文は？

- DIAMOND (2024)（未調査）
- DINO-WM (2024)（既存：jepa）
- FlowWM (2026)（本資料）



出典：NWM Fig. 1（(a) CDiT による世界モデル (b) 生成した軌道をゴールとの類似度で評価 (c) 未知環境での想像）

書誌情報

発表： CVPR 2025
リンク： https://arxiv.org/abs/2412.03572
系譜： 発展（← DIAMOND）
調査日： 2026-10-24
確認範囲： 全文（問題提起・手法・実験・結果・考察）

JEDI: Joint Embedding Diffusion World Model for Online Model-Based Reinforcement Learning

Jing Yu Lim, Rushi Shah, Zarif Ikram, Samson Yu ほか (National University of Singapore) | arXiv プレプリント 2026

1 どんなもの？

JEPA 型の予測的な潜在を、拡散のノイズ除去損失だけで end-to-end に学ぶ、初のオンライン潜在拡散世界モデル JEDI を提案。再構成も事前学習エンコーダも使わずに Atari 100k で DIAMOND に並び、学習時間を 98→38 時間に縮めた。

2 先行研究と比べてどこがすごい？

画素拡散の DIAMOND は強いが重い。潜在拡散の Horizon Imagination は別途学習した潜在を使い、性能で劣る。JEPA は決定論的な予測が中心だった。JEDI は拡散による多峰な予測と、JEPA の予測的な表現学習を 1 つの損失で両立させる。

3 技術や手法のキモはどこ？

符号化器が観測を 16×8×8 の潜在 z^0 にし、EDM 型の denoiser が過去 4 ステップの潜在と行動を条件に次の潜在を復元する（目標側は stop-gradient ）。JEPA の KL 損失もノイズ除去損失も、情報ボトルネック型に分解できることを示す。

4 どうやって有効だと検証した？

Atari 100k (26 ゲーム ×5 シード）で IQM 0.688 (DIAMOND 0.641)、平均 HNS 1.450 (同 1.459) (Table 5)。VRAM 43% 減、サンプリング 3 倍速 (Fig. 8)。フレームスキップを確率的にした Atari 3 ゲームで DreamerV3 を上回る (Fig. 7)。

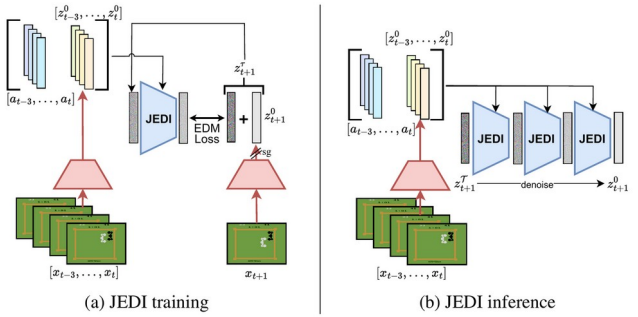
5 議論はある？

著者：DMC や高解像度の環境は未検証。性能は tanh クランプや denoiser のバッチサイズに敏感。

所感：ゲームごとに 2 つのバッチサイズの良い方を採っており、比較はやや有利。確率性の効果は 3 ゲームでしか確かめていない。

6 次に読むべき論文は？

- DIAMOND (2024)（未調査）
- Dreamer-CDP (2026)（既存：jepa ）
- Branch-JEPA (2026)（本資料）



(a) JEDI training　(b) JEDI inference

出典：JEDI Fig. 1 ((a) 学習：次の潜在にノイズを加えて復元し、エンコーダも更新 (b) 推論：ノイズから次の潜在を生成）

書誌情報

発表： arXiv プレプリント 2026
リンク： https://arxiv.org/abs/2605.13013
系譜： 最新（← DIAMOND / JEPA ）
調査日： 2026-10-24
確認範囲： 全文（問題提起・手法・実験・結果・考察）

Flow Matching in Feature Space for Stochastic World Modeling

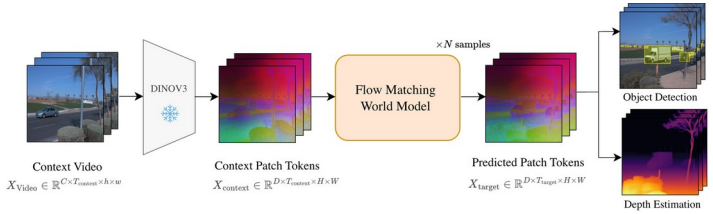
François Porcher, Nicolas Carion, Karteek Alahari, Shizhe Chen（FAIR at Meta / Inria）| arXiv プレプリント 2026

1 どんなもの？

凍結した DINOv3 の高次元パッチ特徴の空間で、直接 flow matching を行う確率的世界モデル FlowWM を提案。Waymo から作った将来知覚ベンチマークで、決定論的な予測器と VAE 潜在の生成モデルの両方を、物体検出と深度推定で上回った。

2 先行研究と比べてどこがすごい？

DINO-WM など特徴空間の予測器は決定論的で、多峰な未来を「どの未来でもない平均」に潰す（付録 A で証明）。動画生成型は低次元の VAE 潜在で意味情報が乏しい。Walker+ (2025) の特徴空間の拡散は、高次元で性能が伸びなかった。



出典：FlowWM Fig. 1（凍結 DINOv3 の特徴上で未来を N 本サンプルし、検出・深度推定で評価）

3 技術や手法のキモはどこ？

幅広の射影ヘッド（1024 次元＞特徴 384 次元）と、ノイズ側に寄せた時刻シフトが鍵。1 ステップ射影 $\tilde{x}_1 = x_\tau + (1-\tau)u_\theta$ で ODE を積分せずに終点を近似し、時間差分の一致損失と検出器の損失をかける。

4 どうやって有効だと検証した？

跳ね返り方向が確率的な図形環境で F1 誤差 4.31（DINO-WM 17.8、Walker+ 14.4）（Table 1）。Waymo で APL(3) 20.9（DINO-WM 14.5、WAN2.2 VAE 17.5）、深度 RMSE 0.078（Table 2）。予測が長いほど決定論型との差が広がる（Fig. 6）。

5 議論はある？

著者：行動条件づけと計画への利用は今後の課題。性能は凍結エンコーダに縛られる。

所感：評価は best-of-N が中心で、確率の正しさ（較正）は測っていない。end-to-end 化は JEDI が別の道で試みている。

6 次に読むべき論文は？

- DINO-WM (2024)（既存：jepa）
- Frozen Forecasting (Walker+ 2025)（未調査）
- CaliBench (2026)（本資料）

書誌情報

発表： arXiv プレプリント 2026
リンク： https://arxiv.org/abs/2606.29059
系譜： 最新（← DINO-WM（既存））
調査日： 2026-10-24
確認範囲： 全文（問題提起・手法・実験・結果・考察）

Branch-JEPA: Finite-Support Predictive Distributions for JEPA World Models

Zhi Song, Ximing Xing, Zhenchao Tang, Hanbo Huang ほか（City University of Hong Kong / Tencent）| arXiv プレプリント 2026

1 どんなもの？

JEPA の予測器が 1 つの潜在しか返さない点を、重みつきの K 個の潜在後続状態（有限サポートの分布）に置き換える Branch-JEPA を提案。Argoverse 2 の軌道予測で、出力側だけで分岐させる場合より有効なモード数を 10.3% 増やした。

2 先行研究と比べてどこがすごい？

二乗誤差の点予測は条件付き平均にしかならず、損失を変えても点は点のまま（point-valued support bottleneck）。MDN や複数ヘッドでは、重複や希少な未来の無視が起きる。生成で解く JEDI と違い、1 回の推論で列挙できる集合を返す。

3 技術や手法のキモはどこ？

K 個の予測器と、文脈だけを見るルーター π_k からなる。学習は「最も近い枝だけ更新する特化」か、エネルギースコア $\Sigma \pi_k d(X_k,T) - \frac{1}{2}\Sigma \pi_k \pi_l d(X_k,X_l)$ で集合全体を採点する方式。後者は K 点分布による最適近似を母集団の目標とする。

4 どうやって有効だと検証した？

AV2 公式検証（5 シード）で、全集合学習のエネルギースコアは 2.077。特化より 6.5% 良く、MDN（2.383）にも勝つ（Table 1）。点予測の JEPA は 2.843（Table 2）。OGBench では検証済み経路の存在率 19.2%（MDN 3.9%）（Table 3）。

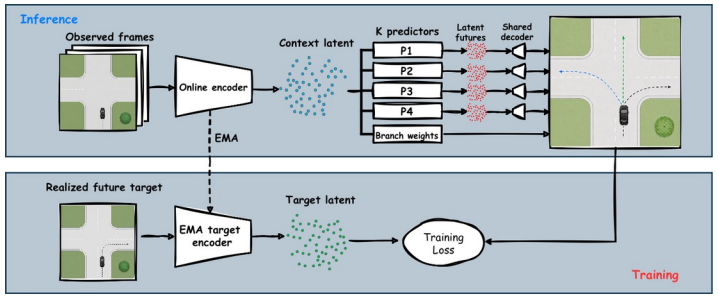
5 議論はある？

著者：予測分布の表し方が主題で、予測性能の SOTA や閉ループ制御は対象外。

所感：K が分岐数の上限を決めてしまう。計画で枝をどう使うかは未検証。評価手順を事前に固定するなど、統計の扱いは丁寧で参考になる。

6 次に読むべき論文は？

- MDN-VJEPA (2026)（未調査）
- UWM-JEPA (2026)（未調査）
- LeWM (2026)（既存：jepa）



出典：Branch-JEPA Fig. 1（K 個の予測器が重みつきの潜在後続状態を出し、共有デコーダで個別に復号）

書誌情報

発表： arXiv プレプリント 2026
リンク： https://arxiv.org/abs/2607.05238
系譜： 最新（← JEPA 世界モデル）
調査日： 2026-10-24
確認範囲： 全文（問題提起・手法・実験・結果・考察）

CaliBench: Are the Stochastic Dynamics of Video World Models Physically Calibrated?

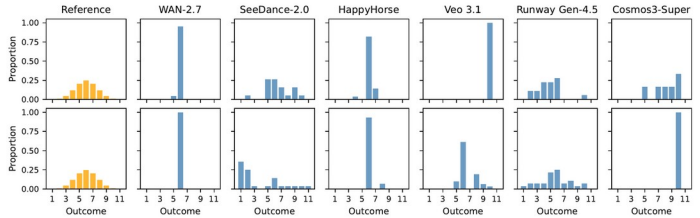
Jonathan Sadeghi, Jenny Seidenschwarz, Jesse Allardice, Sirish Srinivasan, Benjamin Graham, Jeffrey Hawke（Odyssey）| TMLR 2026

1 どんなもの？

ゴルトンボード・サイコロ・ルーレットなど、結果の分布が解析的に分かる 9 場面で動画世界モデルに 32 回ずつ生成させ、結果の分布が正しいか（較正）を測るベンチマーク CaliBench を提案。主要 6 モデルのほとんどが有意に較正から外れていた。

2 先行研究と比べてどこがすごい？

VBench・PhysicsIQ などは 1 本ごとのもっともらしさを測り、FVD はデータセット全体の特徴分布を粗く比べるだけである。CaliBench は離散で解釈できる結果空間を使い、既知の参照分布との距離を直接測る。



出典：CaliBench Fig. 4（ゴルトンボードの結果分布。橙：真の二項分布、青：各モデル。上段：写真、下段：イラスト）

3 技術や手法のキモはどこ？

性能を「採点可能率 ρ」（結果を読み取れる生成の割合）と「全変動距離 TV」に分ける。結果は VLM（Gemini 3.1 Pro）の 3 回多数決で抽出し（人手との一致 93.8%）、モンテカルロ χ^2 検定と、ノイズの下限で正規化した mnTV で集約する。

4 どうやって有効だと検証した？

6 モデル（WAN-2.7、Veo 3.1、Cosmos3-Super など）で、多重比較の補正後も 44 セル中 28 セルが有意に較正外れ（Table 3）。最良の SeeDance-2.0 でも mnTV 0.39（理想は ≈ 0）（Table 2）。ゴルトンボードでは中央の箱に集中する（Fig. 4）。

5 議論はある？

著者：失敗の主因は確率質量の過集中。CFG を弱めると改善するが、採点可能率が下がる。N=32 では大きなずれしか検出できない。

所感：生成型でも「多様に見える」ことと「正しい確率で出す」ことは別だと示した。潜在世界モデルにも同じ検査が要る。

6 次に読むべき論文は？

- PAWBench (2026)（未調査）
- C3 (Mei+ 2025)（未調査）
- Hallucination in WMs (2026)（既存：foundation-world-model）

書誌情報

発表： TMLR 2026
リンク： https://arxiv.org/abs/2608.16829
系譜： 最新（← 生成型の動画世界モデル）
調査日： 2026-10-24
確認範囲： 全文（問題提起・手法・実験・結果・考察）