学習手法

SNN の学習法の系譜。STDP 等の局所則と ANN-SNN 変換を出発点に、2018 年の SuperSpike/SLAYER でサロゲート勾配 BPTT が確立。
以後、局所・オンライン化（ e-prop, OTTT ）、厳密勾配（ EventProp ）、低遅延変換（ QCFS ）、理論付け（ Gygax & Zenke ）を経て、
2026 年は BPTT の並列化（ FidLIF ）とエッジでの「推論しながら学習」（ BSD ）へ。

#	年	論文	発表	系譜
1	2015	STDP-MNIST (Diehl+ 2015)	Front. Comput. Neurosci. 2015	原典
2	2017	ANN→SNN 変換 (Rueckauer+ 2017)	Front. Neurosci. 2017	原典
3	2018	SuperSpike (Zenke+ 2018)	Neural Computation 2018	原典
4	2018	SLAYER (Shrestha+ 2018)	NeurIPS 2018	原典
5	2019	SG 解説 (Neftci+ 2019)	IEEE SPM 2019	発展
6	2020	e-prop (Bellec+ 2020)	Nat. Commun. 2020	発展
7	2021	EventProp (Wunderlich+ 2021)	Sci. Rep. 2021	発展
8	2022	QCFS (Bu+ 2022)	ICLR 2022	発展
9	2022	OTTT (Xiao+ 2022)	NeurIPS 2022	発展
10	2024	SG 理論 (Gygax+ 2024)	Neural Computation 2025	最新
11	2026	BSD-Edge (Zhang+ 2026)	arXiv プレプリント 2026	最新
12	2026	FidLIF (He+ 2026)	arXiv プレプリント 2026	最新

Unsupervised learning of digit recognition using spike-timing-dependent plasticity

Peter U. Diehl, Matthew Cook（ETH Zurich / Univ. of Zurich, INI）| Frontiers in Computational Neuroscience 2015

1 どんなもの？

教師信号もラベルも使わず、STDP・側抑制・適応閾値だけで学習する 2 層 SNN を提案。MNIST で 95.0%（興奮性 6400 個）を達成し、当時の教師なし SNN の最高精度を示した。生物学的に妥当な局所学習則の代表的な基準点。

2 先行研究と比べてどこがすごい？

当時の高精度 SNN は、ANN を逆伝播で学習して SNN へ変換するか、各ニューロンに正解を与える教師付き STDP が主流だった。本研究はコンダクタンス型シナプス・指数型 STDP 窓など生物寄りの部品のみで、教師なしの Querlioz+ 2013（93.5%）を上回った。

3 技術や手法のキモはどこ？

ポアソン入力→興奮性層を STDP で学習し、興奮性→抑制性の 1 対 1 結合と抑制性→他の全興奮性の結合でソフト WTA を作る。発火するほど閾値が上がる恒常性で各ニューロンに競合の機会を与える。学習後に最大応答クラスでラベル付けし平均発火率で分類。

4 どうやって有効だと検証した？

MNIST：興奮性 100/400/1600/6400 個で 82.9/87.0/91.9/95.0%（Fig. 2B）。4 種の STDP 則（べき則・指数重み依存・pre-post・triplet）でほぼ同性能。100 万サンプル提示後も性能低下なし（Fig. 2C）。1 数字あたり約 17 スパイク。

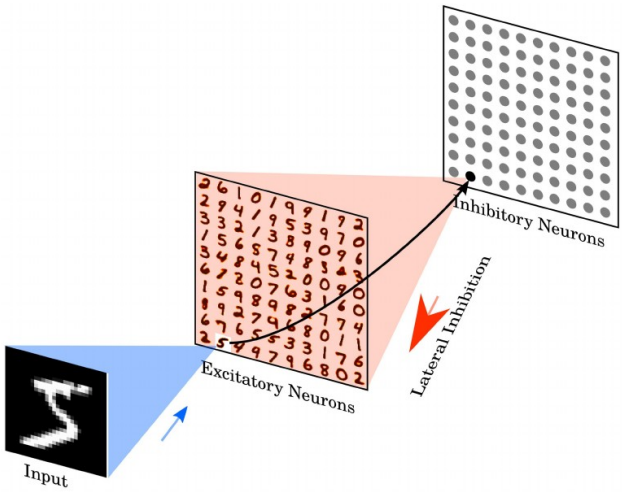
5 議論はある？

著者：勾配法の変換 SNN（99.1%）には届かず、受容野の局所化や多層化に改善余地。

所感：本質は k-means 的な競合学習で、層を積んでも伸びにくい。勾配ベース手法との性能差の根源だが、教師なし局所則の比較基準として今も参照される。

6 次に読むべき論文は？

- Bi & Poo (1998) STDP の実験的発見（本文未確認）
- SuperSpike (2018)（本資料）
- e-prop (2020)（本資料）



出典：STDP-MNIST (Diehl+ 2015) Fig. 1（ネットワーク構成）

書誌情報

発表： Front. Comput. Neurosci. 2015
リンク：
https://doi.org/10.3389/fncom.2015.00099
系譜：原典（← STDP (Bi & Poo 1998)）
調査日： 2026-10-23
確認範囲：全文（問題提起・手法・実験・結果・考察）

Conversion of Continuous-Valued Deep Networks to Efficient Event-Driven Networks for Image Classification

Bodo Rueckauer, Iulia-Alexandra Lungu, Yuhuang Hu ほか（Univ. of Zurich / ETH Zurich, INI）| Frontiers in Neuroscience 2017

1 どんなもの？

学習済み CNN の ReLU 活性を IF ニューロンの発火率に対応させる ANN-SNN 変換を理論化し、max-pooling・softmax・BN・バイアスのスパイク版を導入。VGG-16 と Inception-V3 を初めて SNN 化し、CIFAR-10 で誤差 11.18%（ANN 11.13%）とほぼ無損失。

2 先行研究と比べてどこがすごい？

Cao+ 2015、Diehl+ 2015 の変換はバイアス無し・平均プーリング限定で、深い CNN では近似誤差が蓄積していた。本研究は発火率と ANN 活性の誤差を解析的に導出し、reset-to-zero で閾値超過分の電荷が捨てられることが劣化原因だと特定した。

3 技術や手法のキモはどこ？

膜電位から閾値分だけ引く reset by subtraction で、発火率は ANN 活性の不偏な近似になる（誤差項は時間とともに消える）。重み正規化は最大値でなく活性分布の 99.9 パーセンタイルで行い外れ値に頑健化。入力はポアソンでなくアナログ電流で与える。

4 どうやって有効だと検証した？

CIFAR-10 の寄与分析（Fig. 2）：素朴な変換で誤差 83.50%→max 正規化 40.18→ 減算リセット 20.50→ アナログ入力 16.40→99.9% 正規化 12.18%（ANN 12.14%）。MNIST 0.56%。ImageNet Inception-V3 で top-1 誤差 25.40%（ANN 23.88%）（Table 1）。

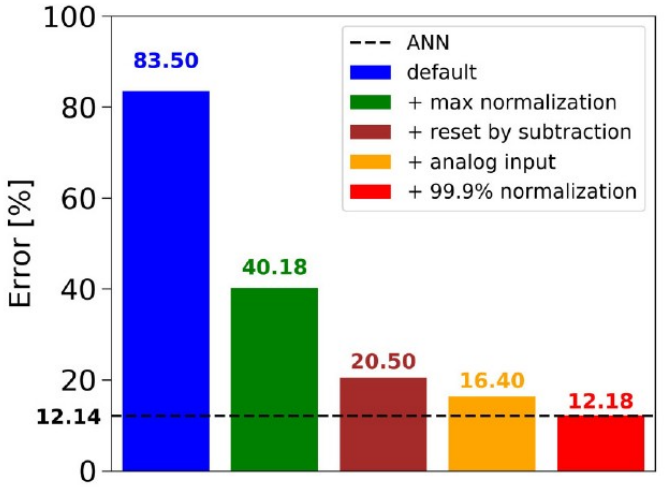
5 議論はある？

著者：VGG-16 は ImageNet で誤差 36.11→50.39% と劣化。深いほど誤差が伝播し長い推論時間が要り、大規模網では演算削減が得られない。

所感：変換系の「時間ステップが多い」問題の出発点。後の QCFS はここを ANN 側の量子化学習で解く。

6 次に読むべき論文は？

- Diehl+ (2015) 重み正規化による変換（本文未確認）
- QCFS (Bu+ 2022)（本資料）
- Sengupta+ (2019) Going deeper in SNNs（未調査）



出典：ANN→SNN 変換（Rueckauer+ 2017）Fig. 2（各工夫の CIFAR-10 誤差への寄与）

書誌情報

発表： Front. Neurosci. 2017
リンク： https://doi.org/10.3389/fnins.2017.00682
系譜： 原典（← Cao+ 2015 / Diehl+ 2015）
調査日： 2026-10-23
確認範囲： 全文（問題提起・手法・実験・結果・考察）

SuperSpike: Supervised learning in multi-layer spiking neural networks

Friedemann Zenke, Surya Ganguli（Stanford Univ. / Univ. of Oxford）| Neural Computation 2018

1 どんなもの？

決定論的 LIF ニューロンの多層 SNN を時空間スパイクパターン変換課題で学習するサロゲート勾配法 SuperSpike を導出。スパイクの微分を膜電位の滑らかな関数（fast sigmoid の導関数）で置き換え、電圧依存の三因子学習則として定式化した。

2 先行研究と比べてどこがすごい？

SpikeProp 系はスパイク時刻で微分するため無発火状態から学習できず、確率的手法（Pfister+ 2006, Gardner+ 2015）はノイズ注入で収束が遅い。Bohte 2011 は閾値下で勾配が消える。SuperSpike はノイズなしで、隠れ層が完全に沈黙した初期状態からも学習できる。

3 技術や手法のキモはどこ？

$\partial S/\partial w$ を $\sigma'(U)\cdot\partial U/\partial w$ に置換（$\sigma'=(1+|\beta(U-\vartheta)|)^{-2}$）。リセット項を無視すると更新は「誤差 × α ∗[σ'(U)·(ε ∗S_pre)]」の三因子則となり、適格度トレースで時間方向の信用割当を RTRL 的にオンラインで行う。隠れ層には対称 / ランダム / 一様の誤差フィードバック。

4 どうやって有効だと検証した？

Auryn 上で 0.1ms 刻みの LIF 網。単一ニューロンは沈黙状態から 500 試行で目標スパイク列を習得（Fig. 1）。隠れ層必須の時間 XOR をランダム / 対称 FB で完全に解く（Fig. 4）。100 出力・3.5 秒の複雑パターンでは対称 FB が明確に優位、ランダム FB は隠れ層なし以下（Fig. 6b）。

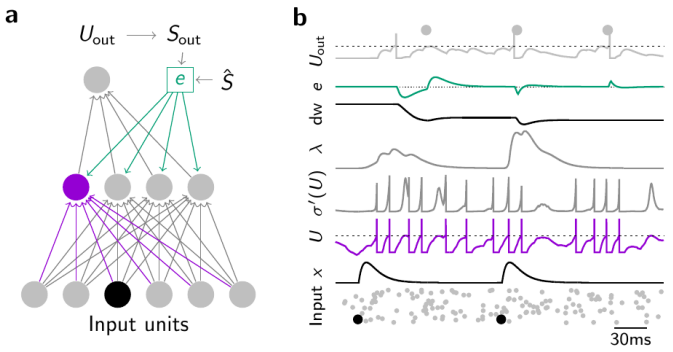
5 議論はある？

著者：シナプスごとの適格度で O(n²) の計算量。複雑な課題では単一のグローバル信号でなく高次元の誤差フィードバックが必要。

所感：評価は小規模な合成課題中心でベンチマーク精度はない。だが「サロゲート微分」と三因子則という解釈が以後の系譜の起点。

6 次に読むべき論文は？

- SLAYER (2018)（本資料）
- Neftci+ (2019) サロゲート勾配の解説（本資料）
- e-prop (2020)（本資料）



出典：SuperSpike (Zenke+ 2018) Fig. 2（学習則の模式図と各量の時間変化）

書誌情報

発表： Neural Computation 2018
リンク： https://arxiv.org/abs/1705.11146
系譜： 原典
調査日： 2026-10-23
確認範囲： 全文（問題提起・手法・実験・結果・考察）

SLAYER: Spike Layer Error Reassignment in Time

Sumit Bam Shrestha, Garrick Orchard（Temasek Laboratories, National Univ. of Singapore）| NeurIPS 2018

1 どんなもの？

SRM ニューロンの多層 SNN で、誤差を層方向だけでなく時間方向にも再配分する逆伝播法 SLAYER を提案。シナプス重みに加え軸索遅延も学習でき、CUDA 実装を公開。NMNIST 99.20%、DVS Gesture 93.64% など当時の SNN 最高精度を達成した。

2 先行研究と比べてどこがすごい？

SpikeProp 系は発火時刻でのみ微分し「死んだニューロン」問題を抱え、Lee+ 2016 や Zenke+ 2018 など時刻単位の手法は過去入力の影響（時間依存性）を無視していた。SLAYER はスパイク応答カーネルを通じた時間的な信用割当を明示的に扱う。

3 技術や手法のキモはどこ？

スパイク関数の微分を「状態が変化する確率密度」とみなし、エスケープ率 $\rho(t)=\alpha^{-1}\exp(-\beta|u-\vartheta|)$ を期待値として用いる。誤差は $\delta=\rho\cdot(\varepsilon_d \star e)$ の時間相関で過去へ割り当て、重み勾配 $\int \delta\cdot a^{T}dt$ と遅延勾配を計算。分類はスパイク数の目標で学習する。

4 どうやって有効だと検証した？

Table 1：MNIST 99.36%（変換 SNN 99.44% に迫る）、NMNIST 99.20%（Lee+ 98.66%）、DVS Gesture 93.64%（TrueNorth 91.77%、より少ない層数）、TIDIGITS 99.09%（SOM-SNN 97.6%）。いずれも 5 試行平均。

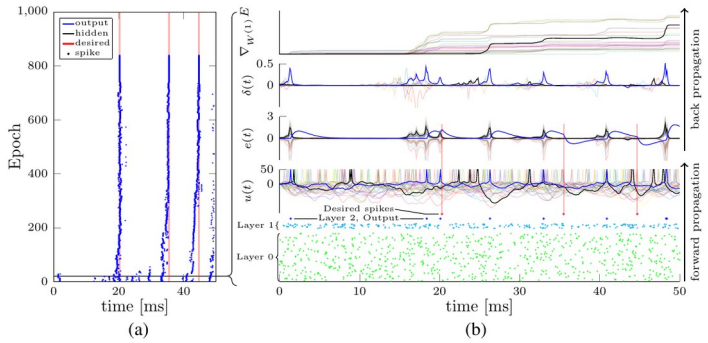
5 議論はある？

著者：扱えるデータは従来の深層学習より依然小さい。オフライン学習してチップへ展開する用途を想定。

所感：エスケープ率で微分を正当化する視点は、Gygax & Zenke 2024 の確率的解釈を先取り。DVS Gesture は先頭 1.5 秒のみ使用で比較には注意。

6 次に読むべき論文は？

- SuperSpike (2018)（本資料）
- STBP (Wu+ 2018)（未調査）
- OTTT (2022)（本資料）



出典：SLAYER (Shrestha+ 2018) Fig. 2（学習の推移と逆伝播信号のスナップショット）

書誌情報

発表： NeurIPS 2018
リンク： https://arxiv.org/abs/1810.08646
系譜： 原典
調査日： 2026-10-23
確認範囲： 全文（問題提起・手法・実験・結果・考察）

Surrogate Gradient Learning in Spiking Neural Networks

Emre O. Neftci, Hesham Mostafa, Friedemann Zenke（UC Irvine ほか。著者順は任意）| IEEE Signal Processing Magazine 2019

1 どんなもの？

SNN を「二値活性を持つ RNN 」として定式化し、学習の難しさ（不連続なスパイク非線形と BPTT のコスト）と解決策を整理したチュートリアル。サロゲート勾配（SG ）を体系化して命名し、以後の直接学習研究の共通言語を作った。

2 先行研究と比べてどこがすごい？

従来の SNN 学習は局所則・ANN 変換・平滑化モデル（ソフト閾値 / 確率 / レート / 単一スパイク時刻）に散在していた。本稿は「モデルは変えず勾配だけを代替する」SG を平滑化と区別し、SuperSpike・SLAYER・Bellec+ 2018 等を統一的に位置づけた。

3 技術や手法のキモはどこ？

離散時間 LIF を $I[n+1]=\alpha I[n]+WS[n]$ 、$U[n+1]=\beta U[n]+I[n]-S[n]$ と書き RNN に帰着（Fig. 2 ）。Θ' を区分線形・fast sigmoid ・指数などで置換すれば自動微分で BPTT できる。順方向法（適格度）、FA/DFA 、局所誤差（DCLL ）による局所化も整理。

4 どうやって有効だと検証した？

解説論文のため大規模な比較実験はない。2-2-2 網の補間経路上で、真の損失は勾配ゼロの平坦部を持つが SG は有限・連続な代替勾配を与えることを可視化（Fig. 4 ）。時間 XOR （Fig. 7 ）や DCLL の DVS Gesture 例を紹介。

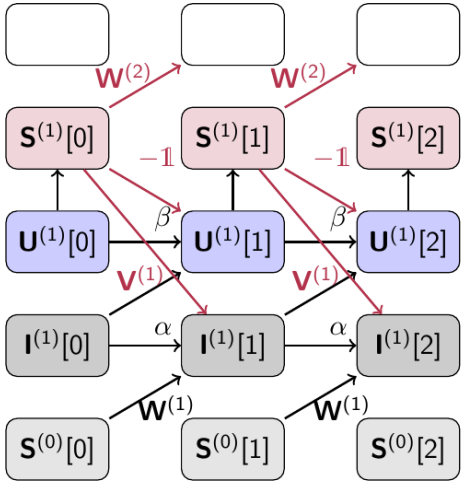
5 議論はある？

著者：SG 関数の体系的な比較は未了。SG が学習に持ち込むバイアスや、深い網での勾配消失が今後の課題。

所感：BPTT の $O(NT)$ メモリと順方向法の $O(N^3)$ を明示しており、後の OTTT 等のメモリ効率化研究の問題設定がここで既に示されている。

6 次に読むべき論文は？

- SuperSpike (2018)（本資料）
- DECOLLE (Kaiser+ 2020)（未調査）
- Gygax & Zenke (2024)（本資料）



出典：SG 解説（Neftci+ 2019) Fig. 2（離散時間 SNN の計算グラフ）

書誌情報

発表： IEEE SPM 2019
リンク： https://arxiv.org/abs/1901.09948
系譜： 発展（← SuperSpike / SLAYER ）
調査日： 2026-10-23
確認範囲： 全文（問題提起・手法・実験・結果・考察）

A solution to the learning dilemma for recurrent networks of spiking neurons

Guillaume Bellec, Franz Scherr, Anand Subramoney, Elias Hajek ほか（Graz Univ. of Technology）| Nature Communications 2020

1 どんなもの？

再帰型 SNN の勾配を「学習信号 × 適格度トレース」の時間和に厳密に分解し、後者を順方向に局所計算するオンライン学習則 e-prop を提案。適応閾値ニューロン（LSNN）と組み合わせ、TIMIT 音素認識や Atari の強化学習で BPTT に近い性能を示した。

2 先行研究と比べてどこがすごい？

再帰 SNN の勾配学習は BPTT しかなく、全状態の保存と時間逆向きの伝播を要するため脳でもチップでも実現困難（学習のジレンマ）だった。FORCE は非局所かつ読み出し層のみ、SuperSpike は再帰網を扱えない。e-prop は再帰結合込みで O(n²) に局所化した。

3 技術や手法のキモはどこ？

dE/dW_ji = Σ_t L_j^t·e_ji^t 。適格度 e_ji^t は誤差に依存せずシナプスで前向きに再帰計算できる（近似なし）。学習信号は現在の出力誤差を重み B_jk で配る L_j^t=Σ_k B_jk(y_k−y*_k) で近似。適応閾値の遅い成分が長時間の信用割当を担う。

4 どうやって有効だと検証した？

TIMIT（Fig. 2c）：フレーム誤差 e-prop 34.6% / BPTT 32.9%（グローバル信号のみ約 52%）、系列誤差 26.4% / 24.7% 。遅延 1 秒超の手掛かり蓄積課題を LSNN で解き、適応なし LIF 網は BPTT でも解けない（Fig. 3）。報酬型 e-prop で Pong 等を単一エージェント学習。

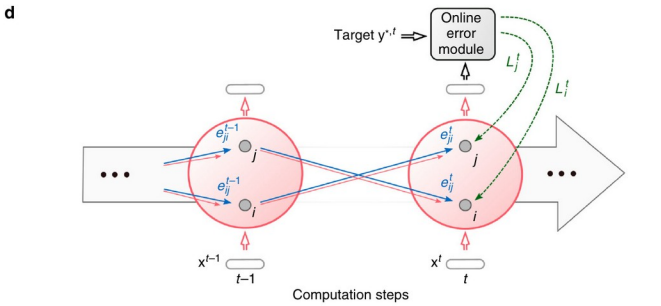
5 議論はある？

著者：BPTT より学習が遅い。自ニューロンの遅い変数を通る経路が塞がる構成では対称 e-prop は失敗し、深い FF 網では Broadcast Alignment 同様の限界が予想される。

所感：Loihi 等でのオンチップ学習の標準候補になった。学習信号の設計が性能の鍵。

6 次に読むべき論文は？

- SuperSpike (2018)（本資料）
- OTTT (2022)（本資料）
- Bellec+ (2018) LSNN（未調査）



出典：e-prop (Bellec+ 2020) Fig. 1d（適格度トレースとオンライン学習信号）

書誌情報

発表： Nat. Commun. 2020
リンク：
https://doi.org/10.1038/s41467-020-17236-y
系譜：発展（← SuperSpike）
調査日： 2026-10-23
確認範囲：全文（問題提起・手法・実験・結果・考察）

Event-based backpropagation can compute exact gradients for spiking neural networks

Timo C. Wunderlich, Christian Pehle（Heidelberg Univ.）| Scientific Reports 2021

1 どんなもの？

連続時間 LIF 網に随伴法と、スパイク時の状態不連続における偏微分のジャンプ条件を適用し、近似なしの厳密勾配を求める逆伝播 EventProp を導出。誤差はスパイク時刻でのみ逆伝播され、順・逆パスとも時空間的に疎な事象駆動計算になる。

2 先行研究と比べてどこがすごい？

SG は閾値関数を平滑化した近似勾配で、離散時間格子では全時刻の状態保存が必要。既存の厳密勾配（Göltz+, Comsa+ 等）は初回スパイク時刻の損失や特定カーネルに限られていた。EventProp は膜電位・スパイク時刻の任意の損失と再帰結合を扱える。

3 技術や手法のキモはどこ？

LIF 網をハイブリッド力学系とみなし、閾値到達条件に陰関数定理を使って∂ V/∂ w のジャンプを求め、随伴変数 λ_V, λ_I の逆時間方程式（随伴スパイク網）を構成。勾配は dL/dw_ji=−τ_syn Σ(λ_I)_j をi のスパイク時刻で和。メモリはスパイク数に比例。

4 どうやって有効だと検証した？

事象駆動シミュレータで 1 隠れ層網を学習。Yin-Yang（初回発火時刻損失）98.1±0.2%（Göltz+ 95.9%）、MNIST（電圧最大値損失、隠れ 350）97.6±0.1% で同規模の SNN 既報と同等（Table 3）。勾配は中心差分と相対誤差 <1e-7 で一致（Fig. 2）。

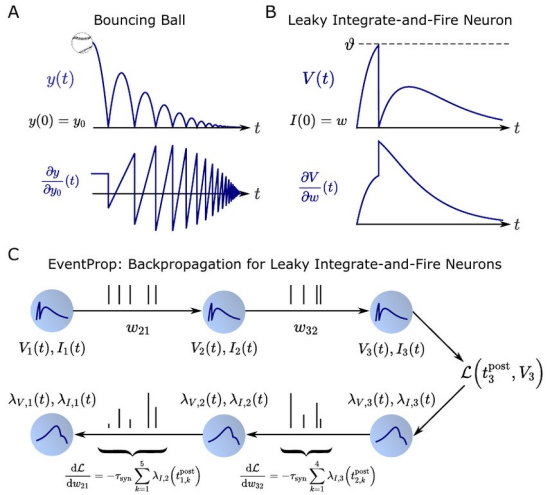
5 議論はある？

著者：スパイクの出現 / 消失点で勾配が発散し、厳密勾配はスパイクを新たに生む / 消す方向を知らない。SG は暗黙の正則化かもしれない。

所感：評価は浅い網のみ。厳密勾配と SG の関係という問いは、Gygax & Zenke 2024 や Eventax（2026）に引き継がれた。

6 次に読むべき論文は？

- SpikeProp (Bohte+ 2002)（本文未確認）
- Gygax & Zenke (2024)（本資料）
- Eventax (König+ 2026)（未調査）



出典：EventProp (Wunderlich+ 2021) Fig. 1（偏微分のジャンプと随伴網による逆伝播）

書誌情報

発表： Sci. Rep. 2021
リンク： https://arxiv.org/abs/2009.08378
系譜： 発展（← SpikeProp / SG）
調査日： 2026-10-23
確認範囲： 全文（問題提起・手法・実験・結果・考察）

Optimal ANN-SNN Conversion for High-accuracy and Ultra-low-latency Spiking Neural Networks

Tong Bu, Wei Fang, Jianhao Ding, PengLin Dai, Zhaofei Yu, Tiejun Huang（Peking Univ. ほか）| ICLR 2022

1 どんなもの?

ANN-SNN 変換の誤差をクリッピング・量子化・不均一性の 3 要因に分解し、ReLU を量子化 clip-floor-shift（QCFS）活性に置き換えて ANN を学習することで変換誤差の期待値をゼロにした。CIFAR-10 で 4 ステップ 93.96% の超低遅延を実現。

2 先行研究と比べてどこがすごい?

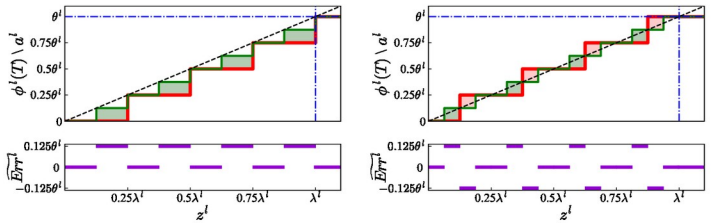
Rueckauer+ 2017 以降の変換（重み正規化・閾値調整・ソフトリセット等）は数十〜数百ステップを要し、短い推論時間では大きく劣化した（例: RMP は T=32 で 60.30%）。本研究は入力スパイクの時刻の偏りによる不均一性誤差を新たに指摘し、ANN 側の活性関数設計で対処した。

3 技術や手法のキモはどこ?

$\hat{a}=\lambda\cdot\mathrm{clip}(\lfloor zL/\lambda\rfloor/L+\phi, 0, 1)$。T=L かつ $\theta=\lambda$ なら推定変換誤差は 0（定理 1）、シフト $\phi=1/2$ なら T≠L でも誤差の期待値が 0（定理 2）。閾値 λ は学習可能で、床関数は STE で学習する。量子化段数 L は 4 か 8 を推奨。

4 どうやって有効だと検証した?

Table 2（CIFAR-10, VGG-16）: T=2 で 91.18%、T=4 で 93.96%、T=32 で 95.54%（ANN 95.52%）。SNNC-AP は T=32 で 93.71%。ImageNet ResNet-34 の T=32 で 69.37%（SNNC-AP 64.54%、RTS 0.09%）（Table 3）。



出典: QCFS (Bu+ 2022) Fig. 2b, 2c（L=4,T=8 での SNN 出力と ANN 活性:シフトなし／ $\phi=0.5$）

5 議論はある?

著者: L=T でも不均一性誤差は残り、T=1 での高性能な変換は難しい。

所感: ANN を量子化学習する時点で純粋な変換と直接学習の中間。LLM の変換（LAS 2025 等）を支える基盤になった一方、低 T 域では直接学習との差が縮まっている。

6 次に読むべき論文は?

- Rueckauer+ (2017)（本資料）
- SNNC-AP (Li+ 2021)（未調査）
- LAS (Chen+ 2025) LLM の無損失変換（未調査）

書誌情報

発表: ICLR 2022
リンク: https://arxiv.org/abs/2303.04347
系譜: 発展（← Rueckauer+ 2017）
調査日: 2026-10-23
確認範囲: 全文（問題提起・手法・実験・結果・考察）

Online Training Through Time for Spiking Neural Networks

Mingqing Xiao, Qingyan Meng, Zongpeng Zhang, Di He, Zhouchen Lin（ Peking Univ. ほか）| NeurIPS 2022

1 どんなもの？

SG 付き BPTT から時間依存を切り離し、前シナプス活動のトレースと各時刻の瞬時損失だけで勾配を計算する順方向オンライン学習 OTTT を提案。学習メモリが時刻数によらず一定で、ImageNet まで BPTT 同等以上の精度を得た。

2 先行研究と比べてどこがすごい？

SG-BPTT は時刻数に比例するメモリを要し、最適化の理論的保証もない。発火率表現に基づく手法は降下方向が明確だが高遅延。既存のオンライン法（ SuperSpike, e-prop, DECOLLE ）は大規模課題へ拡張できなかった。OTTT は両系統を接続した。

3 技術や手法のキモはどこ？

リセット経路の勾配を切ると時間依存は膜の減衰 λ のみとなり、$\nabla_W L = \Sigma_t g_u[t] \cdot \hat{a}[t]^T$、$\hat{a}[t] = \lambda \hat{a}[t-1] + s[t]$ と前向きに追跡できる。重み付き発火率表現の勾配との内積が正（降下方向）であることを証明。三因子ヘブ則の形。BN は sWS で代替。

4 どうやって有効だと検証した？

Table 1（ T=6 ）: CIFAR-10 93.52%（同設定 BPTT 92.78% ）、CIFAR-100 71.05%（ 69.06% ）、ImageNet 65.15%（ tdBN-BPTT 63.72% ）、CIFAR10-DVS 76.63% 。DVS-Gesture 96.88%（ BPTT と同等）。T=6 でもメモリ 2 ～ 3 倍削減（ Fig. 2 ）。

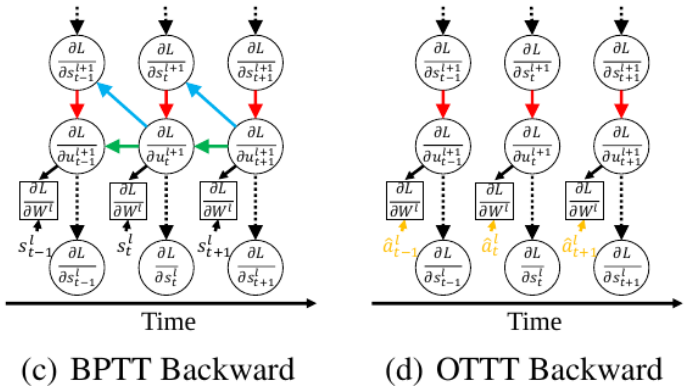
5 議論はある？

著者：時間方向の BN が使えず sWS で代替しており、最高性能には追加の正則化が要る。理論は収束する入力を仮定。

所感：真に時間的な課題での限界が気になる（ DVS-Gesture は同等止まり）。SLTT・NDOT 等、後続のメモリ効率化研究の基準点。

6 次に読むべき論文は？

- e-prop (2020)（本資料）
- SLTT (Meng+ 2023)（未調査）
- FidLIF (2026)（本資料）



(c) BPTT Backward　(d) OTTT Backward

出典：OTTT (Xiao+ 2022) Fig. 1c, 1d（ BPTT と OTTT の逆伝播の比較）

書誌情報

発表： NeurIPS 2022
リンク： https://arxiv.org/abs/2210.04195
系譜： 発展（← SG-BPTT / e-prop ）
調査日： 2026-10-23
確認範囲： 全文（問題提起・手法・実験・結果・考察）

Elucidating the theoretical underpinnings of surrogate gradient learning in spiking neural networks

Julia Gygax, Friedemann Zenke（ Friedrich Miescher Institute / Univ. of Basel ）| Neural Computation 2025（ arXiv 2024 ）

1 どんなもの？

経験的に成功してきたサロゲート勾配（ SG ）の理論的根拠を、確率的自動微分（ stochAD ）と結び付けて与えた。エスケープノイズを持つ確率的 SNN では SG が平滑化確率微分と一致し、代替微分はノイズ関数の導関数に合わせるべきと示した。

2 先行研究と比べてどこがすごい？

SG はヒューリスティックで、なぜ機能するか、どの代替関数を選ぶべきかが不明だった。平滑化確率モデルは単一ニューロンでは SG と一致するが多層では自動微分できない。本研究は stochAD（ Arya+ 2022 ）を初めて SNN に適用し、多層での関係を示した。

3 技術や手法のキモはどこ？

確率的ニューロン y~Ber(σ_β(u−θ)) では、選んだ順伝播経路に条件付けた各層の期待値 E[h_i|h_{i−1}] を微分する平滑化確率微分が、β_SG=β_N の SG と一致（ Fig. 3 ）。決定論的 SG はその点推定。一方 SG は保存場でなく、どの代理損失の勾配でもない。

4 どうやって有効だと検証した？

微分可能な MLP で SG と真の勾配の符号が逆転する例を構成（ Fig. 4, Table 1 ）、閉路積分が非ゼロ（ Fig. 5 ）。確率的 SNN も SG で学習でき、SHD の ConvSNN で検証 97.2%（決定論 94.7% ）、テスト 85.1%（ 84.3% ）（ Fig. 7 ）。

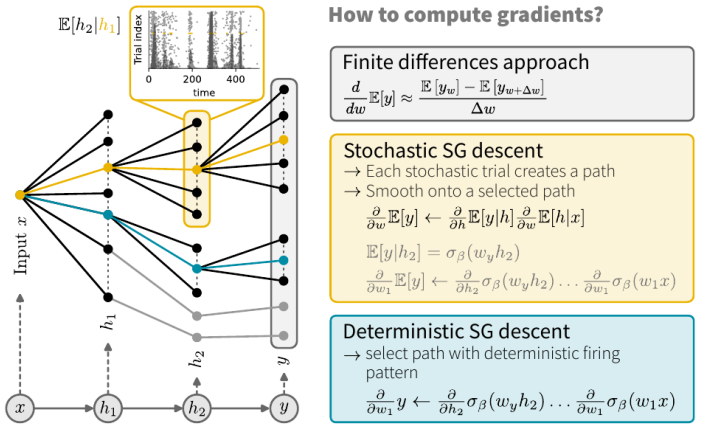
5 議論はある？

著者：SG は局所最小への収束を保証しない。どのエスケープノイズを使うかは未解決で、解析は主にパーセプトロン、課題も限定的。

所感：「 SG は勾配ではない」という結論は重い。確率的 SNN が汎化で同等以上という結果は、ノイズを正則化に使う方向を示唆する。

6 次に読むべき論文は？

- SuperSpike (2018)（本資料）
- Arya+ (2022) stochAD（未調査）
- EventProp (2021)（本資料）



出典：SG 理論（Gygax+ 2024) Fig. 3（確率的 SG ＝経路に条件付けた平滑化確率微分）

書誌情報

発表： Neural Computation 2025
リンク： https://arxiv.org/abs/2404.14964
系譜： 最新（← SuperSpike / Neftci+ 2019 ）
調査日： 2026-10-23
確認範囲： 全文（問題提起・手法・実験・結果・考察）

Learning While Inferring: Local and Parallel Learning for Edge SNNs across Sensing Modalities

Yanxun Zhang, Yifei Wang, Changze Lv, Jingwen Xu ほか（Fudan Univ. / Zhejiang Univ.）| arXiv 2026

1 どんなもの？

刺激駆動の順方向 SNN と、ラベルから入力を再構成する逆方向 SNN を中間表現の局所対照損失で揃える双方向スパイク蒸留（BSD）を、エッジの「推論しながら学習」原理として評価。5 モダリティ 25 課題で BP との差は平均 3.8pt 。

2 先行研究と比べてどこがすごい？

SG-BP は全層・全時刻に浮動小数点の誤差を逐次伝播し、更新中は推論を止める必要がある。OTTT や e-prop は時間方向を局所化したが層方向は大域 BP のまま。BSD は 2 経路の計算グラフを整列点まで分離し、層方向の誤差連鎖もなくした。

3 技術や手法のキモはどこ？

各段 i で順方向と逆方向の発火前活性を正規化（q, r）し、ReCo 損失 $(1-q^{\top}r)^2+\gamma\,\Sigma\max(0,q_n^{\top}r_m)^2$ で整列。勾配は段内に閉じ段ごとに並列更新。時系列では逆 RNN を時間逆向きに走らせ各時刻で整列する。配備時は順方向枝のみ。

4 どうやって有効だと検証した？

SOUL 25 課題（Table 1）：平均 BSD 81.12% vs BP 84.89% 。11 課題で差 3pt 以内、Widar3 等では大差。並列実行の推定学習時間は 0.72 倍、演算数ベースの学習エネルギーは 0.36 倍（Fig. 3）。CIFAR-100 FSCIL の最終セッション 42.18%（BP 44.62%）。

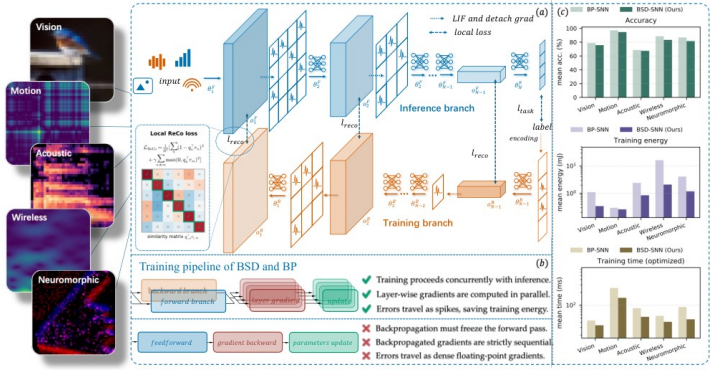
5 議論はある？

著者：効率は実機計測でなく演算数からの推定と理想並列の投影。小バッチの課題では対照項が効きにくい。

所感：段内では依然 SG を使うので「BP 不要」ではなく「大域 BP 不要」。逐次実行では BP より遅い点にも注意。

6 次に読むべき論文は？

- BSD (Lv+ 2025, ICLR 2026)（未調査）
- DECOLLE (Kaiser+ 2020)（未調査）
- e-prop (2020)（本資料）



出典：BSD-Edge (Zhang+ 2026) Fig. 1（順方向 / 逆方向の 2 経路と局所 ReCo 損失）

書誌情報

発表： arXiv プレプリント 2026
リンク： https://arxiv.org/abs/2610.03149
系譜： 最新（← BSD (ICLR 2026) / e-prop ）
調査日： 2026-10-23
確認範囲： 全文（問題提起・手法・実験・結果・考察）

FidLIF: Parallel Training of High-Fidelity Spiking Neurons with Exact BPTT

Kaixiang He, Yujie Wu（The Hong Kong Polytechnic Univ.）| arXiv 2026

1 どんなもの?

ハードリセット付き標準 LIF の膜電位軌道を Newton 法と結合スキャンで全時刻並列に復元し、逆伝播は 1 回の逆向きスキャンで BPTT と等価な勾配を得る並列学習法 FidLIF を提案。学習は並列、推論は同じニューロンを逐次実行できる。

2 先行研究と比べてどこがすごい?

PSN（Fang+ 2023）等はリセット除去や近似でダイナミクスを改変し、FPT（Feng+ 2025）は反復代入が遅く全反復を逆伝播するためメモリが反復数に比例する。多くは逐次推論もできない。FidLIF は LIF への忠実性・並列学習・逐次推論を両立した。

3 技術や手法のキモはどこ?

G(v)=v−P((1−s)⊙v+v_rest·s)−q=0 を、Heaviside をシグモイドで緩和して Newton 反復で解く。ヤコビアンが下二重対角なので各反復は O(log T) 深さの結合スキャン。収束軌道で陰関数微分すると随伴は逆スキャンで求まり、BPTT と一致する。

4 どうやって有効だと検証した?

膜電位 MAE は 5 反復で <1e-7、K=3 で勾配誤差 <1e-6、メモリは K によらずほぼ一定（Fig. 3, 4）。Table 1：Seq. CIFAR10 90.99%、Seq. CIFAR100 66.42%（MF-PSN 66.21%）、SHD 94.38%、CIFAR10-DVS 84.13%。並列 / 逐次実行の差は 0.5pt 以内（Table 2）。

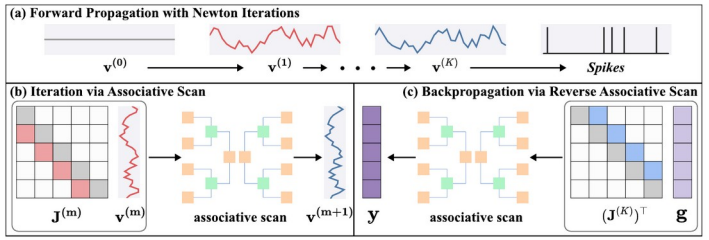
5 議論はある?

著者:明示的な限界節はなく、多層では並列 / 逐次の微差が層を通じて蓄積しうると述べる。

所感:入力依存パラメータを外すと 91.25→80.66% と大きく落ち（Table 4）、利得の多くは並列化でなく表現力由来に見える。SHD 等では既存最良に届かない。

6 次に読むべき論文は?

- PSN (Fang+ 2023)（未調査）
- FPT (Feng+ 2025)（未調査）
- OTTT (2022)（本資料）



出典：FidLIF (He+ 2026) Fig. 1（Newton 反復と結合スキャンによる並列順伝播・逆伝播）

書誌情報

発表: arXiv プレプリント 2026
リンク: https://arxiv.org/abs/2610.16924
系譜: 最新（← SG-BPTT / PSN）
調査日: 2026-10-23
確認範囲: 全文（問題提起・手法・実験・結果・考察）