ハイパーネットワークの基礎と重み生成

別のネットワークの重みを生成するハイパーネットワークの系譜。fast weights (1992) と動的フィルタ (2016) を源流に HyperNetworks が体系化し、SMASH・GHN-2 で未知構造の重み予測、Functa で INR 重みのデータ化へ発展。
2024 ～ 26 年は「注意機構＝ハイパーネット」の理論視点、基盤モデル型・汎用型の生成器、表現力の鋭い理論解析が進む。

#	年	論文	発表	系譜
1	2016	DFN (De Brabandere+ 2016)	NIPS 2016	原典
2	2016	HyperNetworks (Ha+ 2016)	ICLR 2017	原典
3	2017	SMASH (Brock+ 2017)	ICLR 2018	発展
4	2020	Hyperfan 初期化 (Chang+ 2020)	ICLR 2020	発展
5	2021	FWP (Schlag+ 2021)	ICML 2021	発展
6	2021	GHN-2 (Knyazev+ 2021)	NeurIPS 2021	発展
7	2022	Functa (Dupont+ 2022)	ICML 2022	発展
8	2024	Attention as a Hypernetwork (Schug+ 2024)	ICLR 2025 (Oral)	最新
9	2025	FM ハイパーネット (Gu & Yeung-Levy 2025)	ICLR 2025	最新
10	2026	UHN (Zhou 2026)	arXiv プレプリント 2026	最新
11	2026	アフィン潜在パラメータ化の近似率 (Zhang 2026)	arXiv プレプリント 2026	最新

Dynamic Filter Networks

Bert De Brabandere, Xu Jia, Tinne Tuytelaars, Luc Van Gool（KU Leuven）| NIPS 2016

1 どんなもの?

入力に応じて畳み込みフィルタそのものを生成する Dynamic Filter Network を提案。フィルタ生成ネットワークと動的フィルタ層からなり、Moving MNIST の動画予測で Conv-LSTM の約 1/12 のパラメータ（637K）で当時の最良を上回った。

2 先行研究と比べてどこがすごい?

従来の CNN は学習後のフィルタが全サンプル共通で、動画ごとに異なる動きを同じ演算で処理していた。Spatial Transformer は大域的・パラメトリックな幾何変換に限られる。DFN はサンプルごと・位置ごとの局所フィルタを生成し、幾何と輝度の変化を扱う。

3 技術や手法のキモはどこ?

入力 A からフィルタ生成ネットワークが θ を出し、入力 B に適用: $G(i,j)=F_\theta(I_B(i,j))$。全位置共通の動的畳み込みと、位置ごとに別フィルタを使う dynamic local filtering の 2 形態。softmax で疎なフィルタに制約すると画素の移動を表せる。

4 どうやって有効だと検証した?

Moving MNIST（10 フレームから 10 フレーム予測）で BCE 285.2（Conv-LSTM 367.1、FC-LSTM 341.2、Table 1）。高速道路動画・ステレオ予測でも動作し、生成フィルタを可視化するとラベルなしで光学フロー・視差に相当する地図が得られた（Fig. 7）。

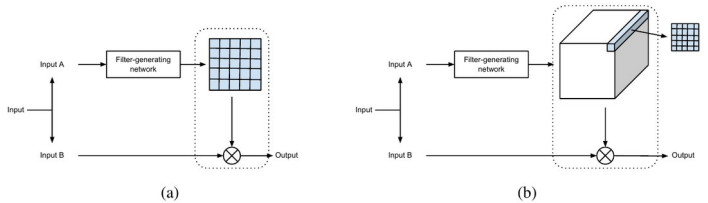
5 議論はある?

著者:予測は時間とともにぼやける。画素単位損失と不確実性の組合せが原因で、サンプリング型手法は今後の課題。

所感:「入力条件付きの重み生成」をハイパーネットと独立に示した源流で、CondConv・Dynamic Convolution につながる。分類など大規模課題では未検証。

6 次に読むべき論文は?

- HyperNetworks (2016)（本資料）
- CondConv (2019)（未調査）
- Dynamic Convolution (2020)（未調査）



出典: DFN Fig. 2（(a) 動的畳み込み、(b) 位置ごとに別フィルタを生成する動的局所フィルタ）

書誌情報

発表: NIPS 2016
リンク: https://arxiv.org/abs/1605.09673
系譜: 原典
調査日: 2026-10-27
確認範囲: 全文（問題提起・手法・実験・結果・考察）

HyperNetworks

David Ha, Andrew Dai, Quoc V. Le（Google Brain）| ICLR 2017

1 どんなもの?

小さなネットワーク(ハイパーネットワーク)が主ネットワークの重みを生成する枠組みを命名・体系化。CNN 向けの静的版と RNN 向けの動的版(HyperLSTM)を示し、文字言語モデルや機械翻訳で LSTM を上回った。

2 先行研究と比べてどこがすごい?

HyperNEAT や Compressed Weight Search など進化計算による重み生成は小規模にとどまり、Schmidhuber の fast weights も RNN 版は思考実験だった。本論文は勾配法で end-to-end に学習し、深い CNN と長い RNN に適用できることを示した。

3 技術や手法のキモはどこ?

静的版は層埋め込み z_j から 2 層線形ネットで K_j=g(z_j) を生成し、層間の「緩い重み共有」を実現。動的版は小さな HyperRNN が時刻ごとに埋め込みを出し、主 RNN の重み行列の各行を d(z) でスケールする(メモリ効率版)。

4 どうやって有効だと検証した?

CIFAR-10 で WRN 40-2 の誤差 5.66%(2.2M)に対し Hyper 版 7.23%(0.15M)(Table 2)。PTB 文字 LM 1.250 bpc(LN-LSTM 1.267、Table 3)、enwik8 1.340(Table 4)、WMT'14 En→Fr で BLEU 40.03(GNMT の LSTM 38.95、Table 6)。

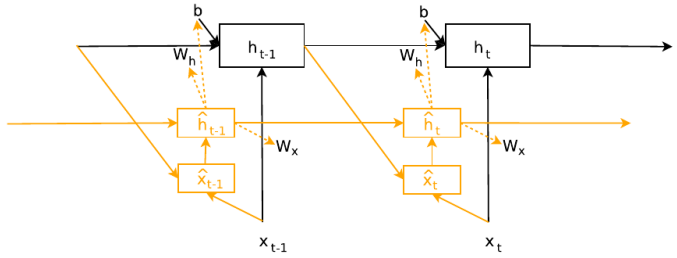
5 議論はある?

著者:静的版は全層に共通性を強いるため精度が約 1.25 〜 1.5% 落ちる。HyperLSTM の重み変化は単語の切れ目で離散的に起きる。

所感:「圧縮」と「入力依存の重み」の 2 動機が混在し、後続は後者へ進んだ。初期化の議論はない。

6 次に読むべき論文は?

- Fast Weights (Schmidhuber 1992)(本文未確認)
- SMASH (2017)(本資料)
- Hyperfan 初期化 (2020)(本資料)
- HyperNEAT (2009)(genetic-algorithm/neat で並行調査)



出典: HyperNetworks Fig. 3(HyperRNN:橙の小さな RNN が主 RNN の重みを時刻ごとに生成)

書誌情報

発表: ICLR 2017
リンク: https://arxiv.org/abs/1609.09106
系譜: 原典(← Fast Weights (Schmidhuber 1992))
調査日: 2026-10-27
確認範囲: 全文(問題提起・手法・実験・結果・考察)

SMASH: One-Shot Model Architecture Search through HyperNetworks

Andrew Brock, Theodore Lim, J.M. Ritchie, Nick Weston（Heriot-Watt University）| ICLR 2018

1 どんなもの?

アーキテクチャの符号を入力に重みを生成する HyperNet を 1 回だけ学習し、生成重みでの検証誤差で候補を順位付けする One-Shot NAS「SMASH」を提案。1 回の学習で多数の構造を評価し、CIFAR-100 で誤差 20.6% の構造を得た。

2 先行研究と比べてどこがすごい?

強化学習による NAS は 1 万回超のフル学習を要し、進化法も膨大な計算を使う。ランダム重みで評価する手法は深いネットに拡張しにくい。SMASH は「生成重みでの相対性能が最終性能と相関する」と仮定し、評価コストを 1 回の学習に償却した。

3 技術や手法のキモはどこ?

ネットを「メモリバンクへの読み書き」として表し、ResNet・DenseNet・FractalNet を包含する探索空間を構成。読み書きパターンや演算を 2 値テンソル c に符号化し、全畳み込み HyperNet が W=H(c) を出す。毎ステップ構造をサンプルして学習。

4 どうやって有効だと検証した?

CIFAR-100 の 50 構造で SMASH 誤差と真の誤差が相関（Fig. 4）。HyperNet を小さくすると相関は崩れる（Fig. 5a）。SMASHv2 は C10 4.03%・C100 20.60%（16M、Table 1）で Large-Scale Evolution や MetaQNN を上回るが NAS-RL（3.84%）には届かない。

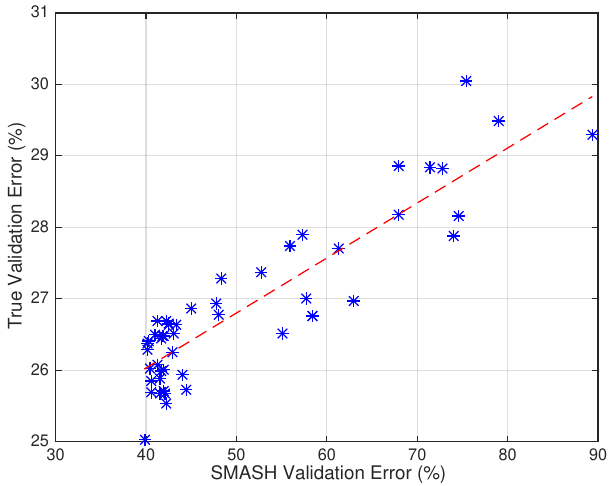
5 議論はある?

著者:相関の検証は計算コストのため 1 データ点にすぎず一般性は保証されない。生成重みが担う容量が小さいと相関が消える。

所感:「重み予測の質が構造評価の質を決める」という課題を残し GHN の動機となった。BN 統計を生成できない制約も後継へ引き継がれる。

6 次に読むべき論文は?

- Graph HyperNetworks (2019)（参照のみ）
- GHN-2 (2021)（本資料）
- DARTS (2019)（未調査）



出典: SMASH Fig. 4（CIFAR-100 の 50 構造:生成重みでの検証誤差と真の誤差の相関）

書誌情報

発表: ICLR 2018
リンク: https://arxiv.org/abs/1708.05344
系譜: 発展（← HyperNetworks）
調査日: 2026-10-27
確認範囲: 全文（問題提起・手法・実験・結果・考察）

Principled Weight Initialization for Hypernetworks

Oscar Chang, Lampros Flokas, Hod Lipson（Columbia University）| ICLR 2020

1 どんなもの?

Xavier・Kaiming 初期化をハイパーネットにそのまま使うと主ネットの重みのスケールが狂うことを示し、分散解析に基づく hyperfan-in / hyperfan-out 初期化を導出。Adam に頼らず SGD だけで安定に学習できるようにした。

2 先行研究と比べてどこがすごい?

実践者は Adam のスケール不変性に頼り、「小さい乱数」や出力層を 1/10 に縮めるなど場当たり的な初期化を使っていた。古典的初期化は層間の活性を保つが、ハイパーネットは「活性→重み」の変換も担うため主ネットの活性が深さに対し指数的に爆発・消失する。

3 技術や手法のキモはどこ?

線形出力層 H の分散を、生成される主ネットの重みが fan-in 初期化と同じ分散になるよう設定: $\mathrm{Var}(H)=1/(d_j\, d_k\, \mathrm{Var}(e))$。バイアスも生成する場合は分散を半分ずつ配分し、逆伝播側（fan-out）で対称性が崩れる点も扱う。

4 どうやって有効だと検証した?

MNIST の 5 層 MLP で Xavier では初期から活性が爆発（Fig. 1）。CIFAR-10（All-CNN）で Kaiming fan-in は全く学習せず、fan-out は約 270 エポック後に遅れて学習開始、hyperfan は即座に学習（Fig. 5）。継続学習・ImageNet の Bayesian NN でも初期損失が小さい。

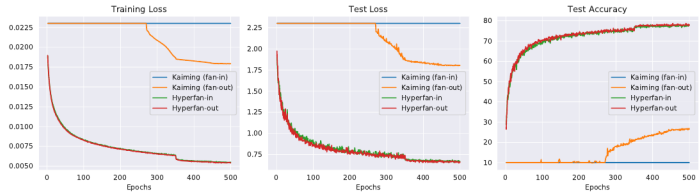
5 議論はある?

著者:残差接続は扱えない。BN があれば fan-out 版でも同等だが、ハイパーネットはパラメータが多くバッチを大きくできない。

所感:結果は曲線のみ。入力スケール依存（MIP 2023）や構造ごとの正規化（GHN-2）へ議論が続く。

6 次に読むべき論文は?

- MIP (Ortiz+ 2023)（参照のみ）
- GHN-2 (2021)（本資料）
- HyperNetworks (2016)（本資料）



出典: Hyperfan 初期化 Fig. 5（CIFAR-10：Kaiming 初期化は学習が進まず、hyperfan は即座に収束）

書誌情報

発表: ICLR 2020
リンク: https://arxiv.org/abs/2312.08399
系譜: 発展（← HyperNetworks）
調査日: 2026-10-27
確認範囲: 全文（問題提起・手法・実験・結果・考察）

Linear Transformers Are Secretly Fast Weight Programmers

Imanol Schlag, Kazuki Irie, Jürgen Schmidhuber（IDSIA）| ICML 2021

1 どんなもの?

線形化した自己注意が、1990 年代の Fast Weight Programmer（遅いネットがキーと値の外積で速い重みを書き換える）と形式的に等価であることを示した。この視点から記憶容量の限界を導き、デルタ則型の更新則と新カーネル DPFP を提案。

2 先行研究と比べてどこがすごい?

線形 Transformer や Performer は softmax の近似として設計され、記憶としての性質は分析されていなかった。FWP として見ると有限サイズ行列への加算書き込みであり、系列長がキー次元 d_dot を超えると想起が干渉する（過容量）。

3 技術や手法のキモはどこ?

速い重み $W_i=W_{i-1}+v_i \otimes \phi(k_i)$、出力 $y_i=W_i \phi(q_i)$ が線形注意そのもの。改良版は現在の値 $\bar{v}=W \phi(k)$ を読み出し、学習される書き込み強度 β で $W \mathrel{+}= \beta(v-\bar{v}) \otimes \phi(k)$ と誤差修正する（Delta Network）。

4 どうやって有効だと検証した?

連想想起課題で線形注意は約 60 キー（d=64）から誤差が出て容量の理論と一致（Fig. 2）。WikiText-103 で Linear Transformer の PPL 38.3→35.5（small）、33.0→31.5（medium）（Table 2）。WMT14 En-De で DPFP は小さな d_dot で Performer を上回る（Table 1）。

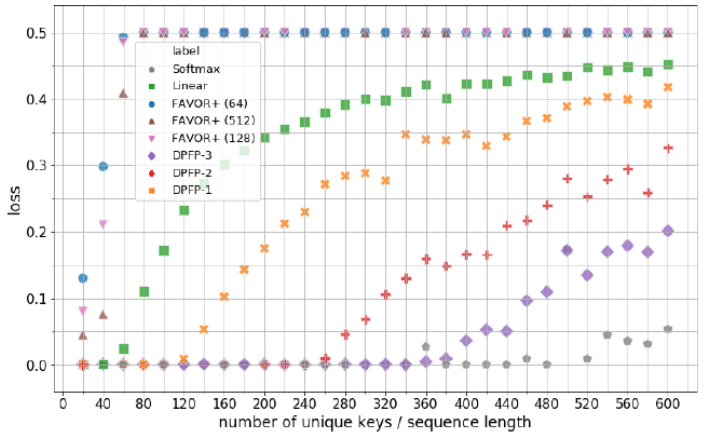
5 議論はある?

著者: Delta Net は文脈を切らずに学習しても破綻しないが、大きな状態の Transformer-XL には及ばない。

所感:注意を「入力ごとに重みを生成するハイパーネット」とみなす視点の起点で、DeltaNet 系線形 RNN の源流。

6 次に読むべき論文は?

- Fast Weights (Schmidhuber 1992)（本文未確認）
- Attention as a Hypernetwork (2024)（本資料）
- FWP と線形 Transformer の総説 (Irie & Gershman 2025)（未調査）



出典: FWP Fig. 2（キー数を増やすと線形注意は d_dot 付近から想起誤差が増大）

書誌情報

発表: ICML 2021
リンク: https://arxiv.org/abs/2102.11174
系譜: 発展（← Fast Weights (Schmidhuber 1992)）
調査日: 2026-10-27
確認範囲: 全文（問題提起・手法・実験・結果・考察）

Parameter Prediction for Unseen Deep Architectures

Boris Knyazev, Michal Drozdzal, Graham W. Taylor, Adriana Romero-Soriano (University of Guelph / Facebook AI Research) | NeurIPS 2021

1 どんなもの?

計算グラフを GNN で読み、未知のアーキテクチャの全パラメータを 1 回の順伝播で予測する GHN-2 を提案。100 万構造のデータセット DeepNets-1M を構築し、ResNet-50 の全 2400 万パラメータを 1 秒未満で予測して CIFAR-10 で約 60% を得た。

2 先行研究と比べてどこがすごい?

GHN (Zhang+ 2019)や SMASH は NAS の順位付けが目的で、予測重みそのものの性能は低い。メタ学習の多くは単一構造に縛られる。本論文は多様な構造への汎化と使える重みを目標に、GHN-1 の失敗要因(重みのスケール、長距離伝播、勾配ノイズ)を特定した。

3 技術や手法のキモはどこ?

演算をノードとする DAG に GatedGNN を順・逆伝播順で適用し、デコーダで各ノードの重みを出す。改良は (1) fan-in 型の微分可能なパラメータ正規化、(2) 最短路距離で重み付けした仮想エッジ、(3) 1 バッチに 8 構造を入れるメタバッチ。

4 どうやって有効だと検証した?

CIFAR-10 の未知構造で平均 66.9% ・最高 77.1% (GHN-1 51.4% 、SGD 5 エポック 69.2% 、Table 3)。ImageNet top-5 平均 27.2% ・最高 48.3% (Table 4)。予測重みを初期値にすると 100-shot CIFAR-10 で He 初期化より 8 〜 15pt 高い(Table 6)。

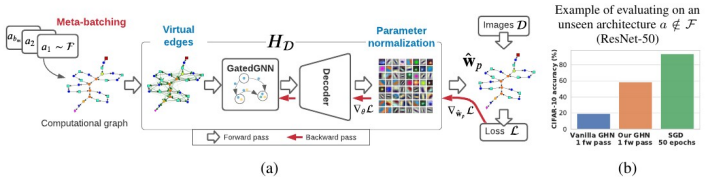
5 議論はある?

著者:予測重みの精度は SGD での学習には遠く、直接の実用には足りない。BN の移動統計は予測できない。

所感:重み生成を「学習の償却」として正面から扱った転換点。ImageNet での差は大きく、初期化用途(GHN-3 、LoGAH)へ軸足が移った理由がよく分かる。

6 次に読むべき論文は?

- GHN-3 (2023) (参照のみ)
- LoGAH (2024) (参照のみ)
- UHN (2026) (本資料)



出典: GHN-2 Fig. 1 ((a) GHN-2 の構成と 3 つの改良、(b) 未知の ResNet-50 での CIFAR-10 精度)

書誌情報

発表: NeurIPS 2021
リンク: https://arxiv.org/abs/2110.13100
系譜:発展(← SMASH / GHN (Zhang+ 2019))
調査日: 2026-10-27
確認範囲:全文(問題提起・手法・実験・結果・考察)

From data to functa: Your data point is a function and you can treat it like one

Emilien Dupont, Hyunjik Kim, S. M. Ali Eslami, Danilo Rezende, Dan Rosenbaum (University of Oxford / DeepMind) | ICML 2022

1 どんなもの?

画像・3D 形状・NeRF シーン・球面上の気温場を陰関数表現 (INR) で表し、その関数自体を「 functa 」として生成・推論・分類の入力にする枠組みを提案。256 次元程度の変調ベクトルで多様なモダリティを統一的に扱った。

2 先行研究と比べてどこがすごい?

INR は解像度に依存しないが、1 データずつ最適化すると遅く (NeRF は 1 シーン 1GPU 日)、パラメータも大きく下流で使いにくい。GAN 型の GASP は不安定で NeRF に使えない。本論文は共有ベースネット+低次元変調への分解とメタ学習で解決した。

3 技術や手法のキモはどこ?

SIREN の各層にシフト変調を加え、それを潜在ベクトルからの線形写像 (=線形ハイパーネット) で生成。内側ループで変調だけを 3 ステップ勾配更新し、外側で共有重みを学ぶ CAVIA 型メタ学習で、データセットを変調の集合に変換する。

4 どうやって有効だと検証した?

3 ステップで ShapeNet 椅子のボクセル精度 99.1 ～ 99.5%、CelebA-HQ 64^2 で PSNR 25.6 ～ 30.7dB (256 ～ 1024 次元、Table 1)。変調上の DDPM で CelebA FID 40.4、SRN Cars の NeRF 生成 FID 80.3 (π-GAN 36.7)。ShapeNet 10 クラス分類は MLP 93.6% (3D CNN 93.3%、Table 2)。

5 議論はある?

著者:変調は空間構造を失い MLP しか使えない。MAML 由来のメモリ消費と不安定さ、少数ステップの制約による再構成精度の上限がある。

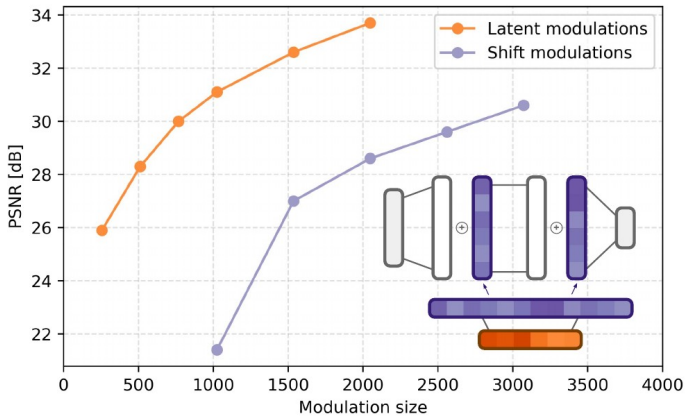
所感:重みを「データ表現」とみなす発想の起点。生成品質は π-GAN に劣り、利点は統一性と計算効率にある。

6 次に読むべき論文は?

・Trans-INR (2022) (参照のみ)

・Spatial Functa (2023) (未調査)

・重みの生成モデル (同分野 weight-space-learning で扱う)



出典: Functa Fig. 3 (変調次元と再構成 PSNR。右下は潜在ベクトル→シフト変調→ SIREN の構成)

書誌情報

発表: ICML 2022

リンク: https://arxiv.org/abs/2201.12204

系譜: 発展 (← SIREN / CAVIA)

調査日: 2026-10-27

確認範囲: 全文 (問題提起・手法・実験・結果・考察)

Attention as a Hypernetwork

Simon Schug, Seijin Kobayashi, Yassir Akram, João Sacramento, Razvan Pascanu（ETH Zürich）| ICLR 2025

1 どんなもの?

マルチヘッド注意を「ヘッド方向の注意スコアを潜在コードとし、キー・クエリ対ごとの線形 value ネットを生成する線形ハイパーネット」として再定式化。この潜在コードが未知の課題の組合せで再利用され、組成的汎化を支えることを示した。

2 先行研究と比べてどこがすごい?

Schlag+ 2021 の FWP 視点はキー方向の外積和で速い重みを作るもので、ヘッドの役割は説明しない。複数ヘッドは訓練の安定化のためとも言われ、組成的汎化の機構は不明だった。本論文はヘッド方向の低次元コードに着目した。

3 技術や手法のキモはどこ?

MHA_q(X)=Σ_k(Σ_h a_{h,q,k} W_h^out W_h^value) x_k と書き換え、括弧内がコード a で重み付けた線形ハイパーネット。value ネットに ReLU を入れヘッド方向に RMS 正規化する HYLA を、追加パラメータなしで提案。

4 どうやって有効だと検証した?

ファジィ論理関数の文脈内学習で、未知の項の組合せへの汎化は HYLA が softmax・線形注意より劣化が小さい（Fig. 2C）。記号版レーヴン行列 SRAVEN では規模とデータの増加で OOD 正解率約 80% に達し、1 ヘッドでは低下（Fig. 4, 5C）。

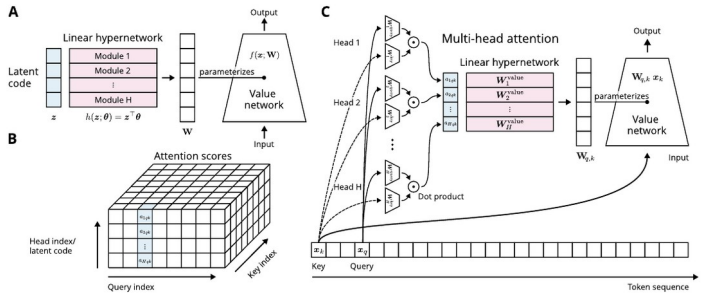
5 議論はある?

著者:スクラッチ学習の小規模モデルに限った分析で、大規模事前学習モデルに同様の構造化コードがあるかは未検証。

所感: Transformer が内部にハイパーネットを持つという視座は強力。主結果は図のみで数値表が少なく、効果量の比較はしにくい。

6 次に読むべき論文は?

- FWP (Schlag+ 2021)（本資料）
- Hypernetworks とモジュール解の発見 (Schug+ 2024)（未調査）
- HyperTransformer (2022)（同分野 task-adaptation で扱う）



出典: Attention as a Hypernetwork Fig. 1（A 線形ハイパーネット、B ヘッド方向の潜在コード、C MHA の書き換え）

書誌情報

発表: ICLR 2025（Oral）
リンク: https://arxiv.org/abs/2406.05816
系譜: 最新（← FWP (Schlag+ 2021)）
調査日: 2026-10-27
確認範囲: 全文（問題提起・手法・実験・結果・考察）

Foundation Models Secretly Understand Neural Network Weights: Enhancing Hypernetwork Architectures with Foundation Models

Jeffrey Gu, Serena Yeung-Levy (Stanford University) | ICLR 2025

1 どんなもの?

Transformer 型ハイパーネット (Trans-INR) のエンコーダを DINOv2・CLIP などの事前学習済み基盤モデルに置き換えると、INR の重み生成の性能・未知クラス汎化・データ効率が上がることを体系的に示した。凍結して重みトークンだけ学習しても同等以上。

2 先行研究と比べてどこがすごい?

汎化可能な INR の最良手法 (Trans-INR 、PONP 、IPC) はいずれもエンコーダをゼロから学習していた。出力が「重み」という画像タスクと異質なモダリティのため、基盤モデルの利用は検討されてこなかった。

3 技術や手法のキモはどこ?

画像パッチトークンと学習可能な重みトークンを基盤モデルに通し、重みトークンの出力を層ごとの線形ヘッドで写像して共有ベースパラメータに要素積、L2 正規化して INR の重みとする。プロンプトチューニングでは基盤モデルを凍結。

4 どうやって有効だと検証した?

ShapeNet 3 カテゴリ同時学習の新視点合成で PSNR 20.86→22.10 (DINOv2 、Table 1)。MAE だけは改善せず。凍結 DINO (学習 100K パラメータ) で 21.04 とスクラッチ 87M の 20.86 を上回る (Table 3)。PONP・IPC でも改善 (Table 4)、大きいモデルほど良い (Fig. 3)。

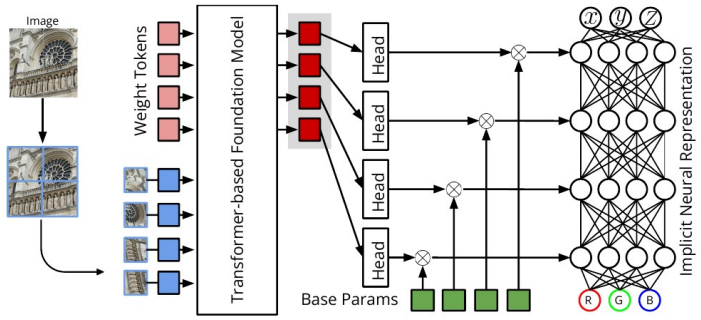
5 議論はある?

著者:全体のファインチューンは基盤モデル特徴の汎化性を一部損なう (未知クラスは凍結が PSNR 最良、Table 2)。

所感:音声 (LibriSpeech) では PSNR 24.431→24.434 と誤差程度で、効果はモダリティ依存。単一視点の NVS のみの評価である点にも注意。

6 次に読むべき論文は?

- Trans-INR (2022) (参照のみ)
- Functa (2022) (本資料)
- CryoHype (2026) (参照のみ)



出典: FM ハイパーネット Fig. 1 (基盤モデル+重みトークン→線形ヘッド × ベースパラメータで INR の重みを生成)

書誌情報

発表: ICLR 2025
リンク: https://arxiv.org/abs/2503.00838
系譜: 最新 (← Trans-INR (Chen & Wang 2022) / Functa)
調査日: 2026-10-27
確認範囲: 全文 (問題提起・手法・実験・結果・考察)

Universal Hypernetworks for Arbitrary Models

Xuanfeng Zhou（独立研究者）| arXiv プレプリント 2026

1 どんなもの?

パラメータの位置・アーキテクチャ・タスクを表す決定的な記述子から各スカラー重みを予測する、構造固定の生成器 Universal Hypernetwork（UHN）を提案。1 つの UHN で画像・グラフ・テキスト・数式回帰のモデルを生成し直接学習に迫った。

2 先行研究と比べてどこがすごい?

従来のハイパーネットは出力次元や層・チャンクごとの学習埋め込みが目標構造に結び付き、構造を変えると再設計が要る。GHN 系も最大構造に合わせた出力やマスクが必要。UHN は目標側の特異性をすべて入力記述子に移した。

3 技術や手法のキモはどこ?

w_i=H_θ(v_i, s_g, {s_ℓ}, t)。添字記述子 v_i をガウス Fourier 特徴で符号化して残差 MLP で処理し、層記述子は 1 層 Transformer で集約して加算。生成重みの平均・分散を目標値に合わせる初期化段階を設け、再帰生成も安定させる。

4 どうやって有効だと検証した?

CIFAR-10 CNN-20 で 89.93%（直接学習 89.99%）、AG News 90.99%（91.86%）、Cora GCN 79.5%（81.7%）（Table 1）。CNN を深さ 20→56 にしても UHN は 612K パラメータで固定（Table 2）。3 段の再帰生成でも MNIST 97.4%（Table 5）。

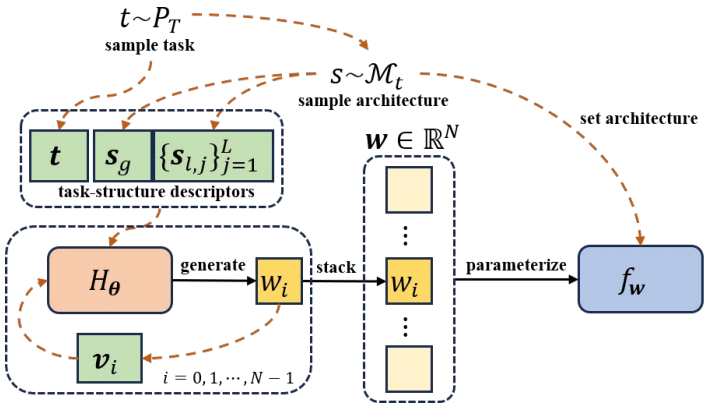
5 議論はある?

著者:直接学習に常に並ぶわけではなく、BN 統計は生成できず学習コストも増える。初期化段階なしでは再帰生成が発散しうる。

所感: UHN（612K）が生成対象（3 万〜38 万）より大きい例が多く、圧縮ではない。単著・小規模で追試が要る。

6 次に読むべき論文は?

- GHN-2 (2021)（本資料）
- HyperNetworks (2016)（本資料）
- Chunked hypernetworks (von Oswald+ 2020)（同分野 task-adaptation で扱う）



出典: UHN Fig. 2（タスク・構造記述子と添字記述子 v_i から各重み w_i を生成）

書誌情報

発表: arXiv プレプリント 2026
リンク: https://arxiv.org/abs/2604.02215
系譜: 最新（← GHN-2 / HyperNetworks）
調査日: 2026-10-27
確認範囲: 全文（問題提起・手法・実験・結果・考察）

Sharp Approximation Rates for Neural Networks with Affine Latent Parameterizations

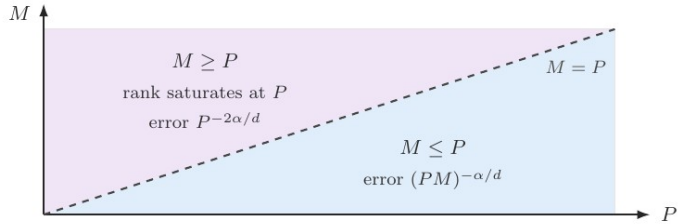
Shijun Zhang (Hong Kong Polytechnic University) | arXiv プレプリント 2026

1 どんなもの?

共有の生成器で M 次元の潜在 ξ から全 P 個のパラメータを作るモデルの表現力を、生成器がアフィンの場合に解析。α-Hölder 関数の最悪誤差が [P·min{M,P}]^(−α/d) で上下から一致することを証明した。

2 先行研究と比べてどこがすごい?

ハイパーネット・部分空間学習・LoRA 類は「タスク依存の情報量 M 」と「共有デコーダの規模 P 」を区別せず語られてきた。既存の近似理論は全パラメータが目標依存の場合か、デコーダ規模を数えない場合のどちらかに偏っていた。



出典:アフィン潜在パラメータ化 Fig. 2 (M と P の 2 つの領域での最適誤差率)

3 技術や手法のキモはどこ?

θ_f=Aξ_f+a (A, a は目標クラス全体で固定)。上界は幅が d のみに依存する ReLU ネットで、潜在座標に 2 進列を詰めて逐次復号する構成。下界は A の階数で実効変数を減らした擬次元評価と Hölder バンプのパッキング。

4 どうやって有効だと検証した?

実験はなく定理で示す。Theorem 3.1 (上界)と 3.3 (下界)から、M≤P では (PM)^(−α/d) 、M≥P では P^(−2α/d) に飽和 (Fig. 2)。M を 4 以上で固定しても、デコーダ規模 P を増やせば誤差は P^(−α/d) で 0 に向かう(Remark 3.4)。

5 議論はある?

著者:構成は厳密な実数演算と不連続な符号化に依存し、有限精度・安定性・最適化は対象外。非線形生成器への拡張が課題。

所感:「低次元コードで足りる」理由を与えるが、ビット長を数えると M·b の情報制約が効くため、実際のハイパーネットの説明としては上限的な結果。

6 次に読むべき論文は?

- On the Modularity of Hypernetworks (2020) (参照のみ)
- On Infinite-Width Hypernetworks (2020) (未調査)
- Intrinsic Dimension (Li+ 2018) (未調査)

書誌情報

発表: arXiv プレプリント 2026
リンク: https://arxiv.org/abs/2608.31157
系譜:最新(← On the Modularity of Hypernetworks (Galanti & Wolf 2020))
調査日: 2026-10-27
確認範囲:全文(問題提起・手法・実験・結果・考察)