重み空間の学習と拡散によるパラメータ生成

学習済みの重みそのものをデータとして扱う系譜。重みから精度を当てる Unterthiner+ 2020 、チェックポイントを生成する G.pt 、置換対称性に等変な DWSNets を原典に、GMN・p-diff・SANE が規模と汎用性を広げた。

2025 〜 2026 年は RPG の大規模生成と、Zeng+ による「生成重みは記憶にすぎない」という検証が焦点。等変フローマッチングや LM 向け GMT がこれに応えようとしている。

#	年	論文	発表	系譜
1	2020	Accuracy from Weights (Unterthiner+ 2020)	arXiv プレプリント 2020	原典
2	2022	G.pt (Peebles+ 2022)	arXiv プレプリント 2022	原典
3	2023	DWSNets (Navon+ 2023)	ICML 2023	原典
4	2024	GMN (Lim+ 2024)	ICLR 2024	発展
5	2024	p-diff (Wang+ 2024)	arXiv プレプリント 2024	発展
6	2024	SANE (Schürholt+ 2024)	ICML 2024	発展
7	2025	RPG (Wang+ 2025)	NeurIPS 2025	最新
8	2025	Weight Memorization (Zeng+ 2025)	CVPR 2026	最新
9	2026	PEFM (Piven+ 2026)	arXiv プレプリント 2026	最新
10	2026	GMT (Wolanowsky+ 2026)	arXiv プレプリント 2026	最新

Predicting Neural Network Accuracy from Weights

Thomas Unterthiner, Daniel Keysers, Sylvain Gelly ほか(Google Research, Brain Team)| arXiv プレプリント 2020

1 どんなもの?

入力データを一切使わずに、学習済み CNN の重みだけからテスト精度を予測できることを示した。4 データセットで学習した 12 万個の CNN (Small CNN Zoo)を公開し、層ごとの重み統計量を GBM に入れるだけで $R^2>0.98$ を達成した。

2 先行研究と比べてどこがすごい?

Jiang+ 2019・Yak+ 2019 の汎化予測は、データを通した中間層マージンが必要で、計算が重い。同一ハイパラでシードだけ違うモデルが学習・評価に分かれると情報が漏れる問題も指摘した。本研究は重みだけを使い、1 設定 1 シードで漏れを防いだ。

3 技術や手法のキモはどこ?

固定アーキテクチャ(4970 パラメータ)の CNN を、ハイパラをランダムに変えて 3 万個ずつ学習する。予測器 $\hat{F}: W \to [0,1]$ を MSE で学習し、入力は生の重み、層ごとの平均・分散・分位点 (56 次元)、ノルムを比較した。

4 どうやって有効だと検証した?

CIFAR10-GS で層統計+ GBM が $R^2=0.984$ 。生の全重みは 0.970 、ハイパラだけでは 0.934 (Table 1, 2)。別データセットへの転移でも Kendall $\tau \geq 0.6$ (Table 3)。小 CNN で学習した予測器が ResNet32 の順位を $\tau=0.28 \sim 0.62$ で当てた (Table 4)。

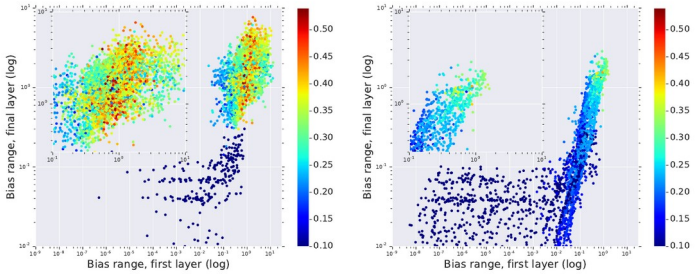
5 議論はある?

著者:予測が人間に解釈できる規則に落ちるかは未解明。順序不変性を組み込む Deep Sets 系の帰納バイアスが今後の課題。

所感:置換・スケール不変性を手作り統計量で迂回した出発点。後続の DWSNets・GMN はここを構造で解く。

6 次に読むべき論文は?

- Hyper-Representations (Schürholt+ 2021)(未調査)
- DWSNets (Navon+ 2023)(本資料)
- GMN (Lim+ 2024)(本資料)



出典: Accuracy from Weights Fig. 3 (初層・最終層のバイアス幅で CIFAR10-GS の CNN を散布。色は精度。左 Adam/RMSProp 、右 SGD)

書誌情報

発表: arXiv プレプリント 2020
リンク: https://arxiv.org/abs/2002.11448
系譜: 原典
調査日: 2026-10-27
確認範囲: 全文(問題提起・手法・実験・結果・考察)

Learning to Learn with Generative Models of Neural Network Checkpoints

William Peebles, Ilija Radosavovic, Tim Brooks, Alexei A. Efros, Jitendra Malik (UC Berkeley) | arXiv プレプリント 2022

1 どんなもの?

10 万回以上の学習で得た 2300 万チェックポイントで、条件付き拡散 Transformer「G.pt」を学習した。初期重みと目標損失(誤差・リターン)を与えると、未知の初期値からでも 1 回の更新で目標を満たすパラメータを出す。

2 先行研究と比べてどこがすごい?

学習型オプティマイザ(Andrychowicz+ 2016)や MAML は展開最適化や強化学習に頼るため、訓練が不安定で、目的関数が微分可能である必要もあった。G.pt は過去のチェックポイントを使った通常の生成モデル学習なので、誤差率のような非微分指標にも条件付けできる。

3 技術や手法のキモはどこ?

同じ学習の中から開始 θ と未来の θ^* を選び、$L = E\| \theta^* - G(\theta^*_j, \theta, \ell^*, \ell, j)\|^2$ で未来パラメータを直接予測する。層ごとのトークン化、GPT-2 型 Transformer、入力 θ への全体残差で構成し、置換拡張でデータを水増しする。

4 どうやって有効だと検証した?

MNIST・CIFAR-10・Cartpole で、1 ステップ後の性能が AdamW・SGD など 5 種の 1 ステップ更新を上回った(Fig. 3)。2M ～ 858M パラメータのモデルでスケールを調べ、60M 未満は汎化しなかった(Fig. 7)。中間チェックポイントを除くと損失が 0.2→0.32 に悪化した。

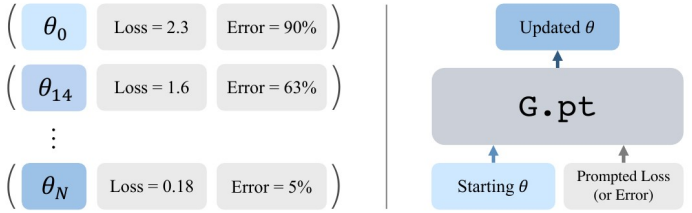
5 議論はある?

著者: CIFAR-10 で未学習気味であること、訓練データの範囲外の損失へ外挿できないこと、単一アーキ・単一タスクに限ることを限界に挙げる。

所感:置換拡張なしでは過学習するという記述は、後の記憶問題(Zeng+ 2025)の予兆と読める。

6 次に読むべき論文は?

- p-diff (Wang+ 2024) (本資料)
- HyperDiffusion (Erkoç+ 2023) (未調査)
- Weight Memorization (Zeng+ 2025) (本資料)



Pre-training dataset of neural network checkpoints　　A generative model of checkpoints

出典: G.pt Fig. 1 (左:損失・誤差付きチェックポイントのデータセット、右:開始 θ と目標損失から更新後 θ を出す生成モデル)

書誌情報

発表: arXiv プレプリント 2022
リンク: https://arxiv.org/abs/2209.12892
系譜: 原典
調査日: 2026-10-27
確認範囲: 全文(問題提起・手法・実験・結果・考察)

Equivariant Architectures for Learning in Deep Weight Spaces

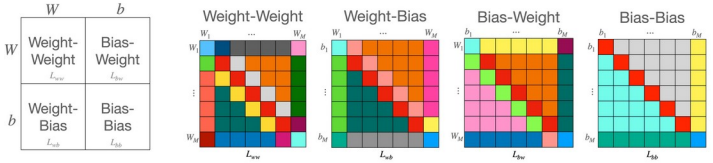
Aviv Navon, Aviv Shamsian, Idan Achituve, Ethan Fetaya, Gal Chechik, Haggai Maron (Bar-Ilan University, NVIDIA) | ICML 2023

1 どんなもの?

MLP の重みを入力とし、隠れニューロンの置換対称性に等変な層を積み重ねるネットワーク「 DWSNets 」を提案した。重み空間上の線形等変層をすべて特徴付けたうえで、INR の分類や分類器のドメイン適応で既存手法を大きく上回った。

2 先行研究と比べてどこがすごい?

従来は重みを平坦化して MLP や Transformer (Schürholt+ 2021)に入れていたため、同じ関数を表す置換違いの重みを別物として扱っていた。置換拡張や Git Re-Basin による整列でも補いきれない。対称性を構造で組み込んだ初の原理的なアーキテクチャである。



出典: DWSNets Fig. 2 (重み・バイアス間の等変線形写像のブロック構造。色ごとに異なる層タイプ)

3 技術や手法のキモはどこ?

重み空間 V=⊕(W_m⊕B_m) と群 G=S_d1×⋯×S_dM−1 の作用を定める。等変線形層を W→W 、W→B 、B→W 、B→B のブロック行列に分け、各ブロックがプーリング・ブロードキャスト・全結合の組合せで書けることを証明した(Theorem 5.1)。

4 どうやって有効だと検証した?

MNIST INR 分類で 85.7% (MLP+ 整列 59.0% 、Transformer 26.6% 、Table 1)。正弦波 INR の自己教師あり表現で MSE 1.39 (INR2Vec 3.86 、Table 2)。CIFAR-10→ 破損版の適応で 71.4% (適応なし 60.9% 、Table 3)。

5 議論はある?

著者:層構造が特定の MLP に固定され、初期化が難しく学習が不安定なタスクがある。実装も複雑。

所感:スケール対称性や異種アーキテクチャは扱えない。同時期の NFN (Zhou+ 2023)と並び、等変メタネットの出発点である。

6 次に読むべき論文は?

- NFN (Zhou+ 2023) (未調査)
- GMN (Lim+ 2024) (本資料)
- Equivariant Deep Weight Space Alignment (Navon+ 2024) (未調査)

書誌情報

発表: ICML 2023
リンク: https://arxiv.org/abs/2301.12780
系譜: 原典
調査日: 2026-10-27
確認範囲: 全文(問題提起・手法・実験・結果・考察)

Graph Metanetworks for Processing Diverse Neural Architectures

Derek Lim, Haggai Maron, Marc T. Law, Jonathan Lorraine, James Lucas（MIT CSAIL, NVIDIA）| ICLR 2024

1 どんなもの?

入力ネットワークを「パラメータ=辺」のグラフに変換し、GNN で処理する Graph Metanetworks（GMN）を提案した。正規化・残差・畳み込み・多頭注意を含む多様なアーキテクチャを 1 つのメタネットで扱い、精度予測などで既存手法を上回った。

2 先行研究と比べてどこがすごい?

DWSNets・NFN は MLP や単純な CNN ごとに等変層を手設計する必要があった。正規化層・残差接続・注意機構や、層数・幅の異なる入力は扱えなかった。GMN はグラフの自己同型を対称性とみなすので、GNN を使えば等変性が自動的に得られる。

3 技術や手法のキモはどこ?

計算グラフの代わりに、各パラメータが 1 本の辺に対応する「パラメータグラフ」を層ごとの部分グラフで組み立てる。バイアスはバイアスノードからの辺、畳み込みは空間位置付きの多重辺で表す。neural DAG 自己同型への等変性と、DWSNets 以上の表現力を証明した。

4 どうやって有効だと検証した?

CIFAR-10 分類器約 3 万個（CNN・ResNet・ViT 等）の精度予測で、多様アーキの OOD 設定は R^2=0.768（DMC −0.134、Table 1）。INR 編集 Contrast で MSE 0.0197（NFT 0.0200、Table 2）。自己教師あり表現で MSE 1.13（DWSNets 1.39、Table 3）。

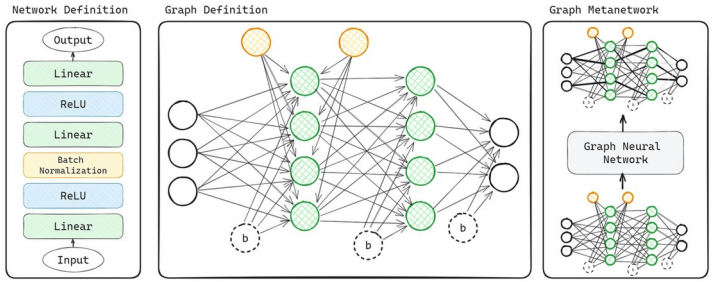
5 議論はある?

著者:数十億パラメータ規模は未検証で、グラフ設計規則も未形式化。スケール対称性は扱わない。

所感:重み空間学習を任意アーキテクチャに開いた転換点。PEFM・GMT の土台になった。

6 次に読むべき論文は?

- Neural Graphs (Kofinas+ 2024)（未調査）
- Scale Equivariant GMN (Kalogeropoulos+ 2024)（未調査）
- GMT (Wolanowsky+ 2026)（本資料）



出典: GMN Fig. 1（ネットワーク定義 → パラメータグラフ（バイアス・BN ノード付き）→ GNN による処理）

書誌情報

発表: ICLR 2024
リンク: https://arxiv.org/abs/2312.04501
系譜: 発展（← DWSNets (Navon+ 2023)）
調査日: 2026-10-27
確認範囲: 全文（問題提起・手法・実験・結果・考察）

Neural Network Diffusion

Kai Wang, Dongwen Tang, Boya Zeng ほか (National University of Singapore) | arXiv プレプリント 2024

1 どんなもの?

パラメータ用の自己符号化器と潜在拡散モデルを組み合わせた p-diff を提案した。ノイズから高性能なパラメータ(主に最終 BN 層、小型モデルは全体)を生成し、7 データセット・6 アーキテクチャで元モデルと同等以上の精度を報告した。

2 先行研究と比べてどこがすごい?

G.pt は生成モデルが元のチェックポイントより低い性能にとどまり、Hyper-Representations は解析が中心だった。p-diff は「元モデル以上の性能」と「記憶ではない新規性」を同時に主張し、拡散による重み生成ブームの起点となった。

3 技術や手法のキモはどこ?

収束後のモデルを 300 ステップ追加学習し、毎ステップ保存した部分パラメータを 1D 畳み込みの自己符号化器で潜在化する。入力と潜在にノイズ拡張($\sigma_v=0.001$, $\sigma_z=0.1$)を加え、潜在上で DDPM を学習する。新規性は誤予測集合の IoU で測る。

4 どうやって有効だと検証した?

ResNet-18/CIFAR-100 で元 77.4%・平均重み 77.7%・p-diff 77.9%、ImageNet で 69.5→70.4% (Table 1)。全パラメータ生成(24K ～ 81K)でも同等(Table 2)。生成モデルの最大類似度はノイズ付加より低く、精度は高い(Fig. 4)。

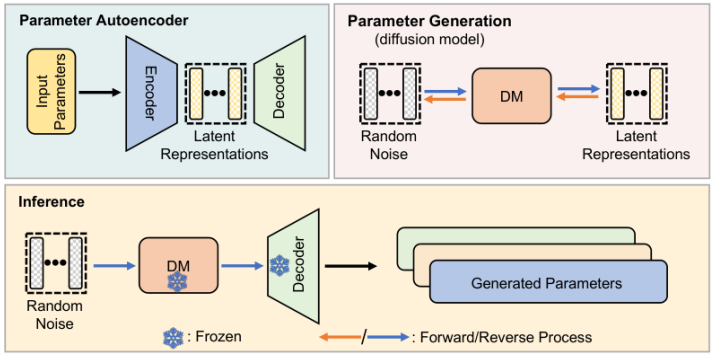
5 議論はある?

著者:大規模モデル全体の生成ではメモリが制約になり、構造設計と性能の安定性にも課題が残る。

所感:訓練データが単一学習の連続チェックポイントで、多様性が極めて小さい。Zeng+ 2025 はこれを「補間にすぎない」と反証した。

6 次に読むべき論文は?

- D2NWG (Soro+ 2024) (未調査)
- RPG (Wang+ 2025) (本資料)
- Weight Memorization (Zeng+ 2025) (本資料)



出典: p-diff Fig. 2 (パラメータ自己符号化器・潜在拡散の学習と、ノイズ→ DM→ デコーダによる生成)

書誌情報

発表: arXiv プレプリント 2024
リンク: https://arxiv.org/abs/2402.13144
系譜: 発展 (← G.pt (Peebles+ 2022))
調査日: 2026-10-27
確認範囲: 全文(問題提起・手法・実験・結果・考察)

Towards Scalable and Versatile Weight Space Learning

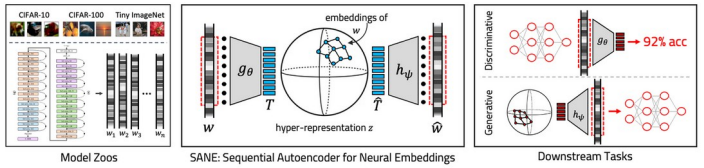
Konstantin Schürholt, Michael W. Mahoney, Damian Borth（ University of St.Gallen, ICSI/UC Berkeley ）| ICML 2024

1 どんなもの?

重みをトークン列として部分窓ごとに符号化する逐次自己符号化器「 SANE 」を提案した。1 つの表現で性能予測（識別）とモデル生成（生成）の両方をこなし、ResNet-18（約 1200 万パラメータ）規模の model zoo に初めて適用した。

2 先行研究と比べてどこがすごい?

Hyper-Representations（ Schürholt+ 2021, 2022 ）は全重みを一度に符号化するため小さなモデルしか扱えず、識別用と生成用を別々に学習する必要があった。アーキテクチャも固定だった。SANE は窓単位の学習で、メモリ使用量をモデルサイズから切り離した。



出典: SANE Fig. 2（ model zoo の重みを逐次化 → 窓単位の自己符号化器で hyper-representation を学習 → 識別・生成タスク）

3 技術や手法のキモはどこ?

重みを出力チャネルごとに行スライスし、固定長トークン化して 3 次元位置 [n, l, k] を付ける。部分窓で再構成損失＋対照損失を学習する。生成時は少数のプロンプトモデルの埋め込みに KDE を当ててサンプルし、上位を選ぶか反復で絞り込む。

4 どうやって有効だと検証した?

ResNet-18 zoo で層統計量並みの R^2 の精度予測（ Table 2 ）。サンプルした ResNet-18 は微調整なしで CIFAR-10 68.1%（スクラッチ約 10% 、Table 4 ）。小 CNN では従来の Hyper-Rep 比で初期化時に約 20% 向上（ Table 3 ）。ResNet-34 への転移も示した。

5 議論はある?

著者:事前学習は単一アーキの zoo のみで、生成には良いプロンプト例が必要。実験はビジョンに限られる。

所感:重みを Git Re-Basin で参照モデルに整列してから学習しており、対称性は前処理で消している。Zeng+ 2025 の記憶検証の対象にもなった系譜である。

6 次に読むべき論文は?

- Hyper-Representations as Generative Models (Schürholt+ 2022)（未調査）
- Model Zoos (Schürholt+ 2022)（未調査）
- Learning Model Representations from Model Hubs (Falk+ 2025)（未調査）

書誌情報

発表: ICML 2024

リンク: https://arxiv.org/abs/2406.09997

系譜:発展（← Accuracy from Weights (Unterthiner+ 2020) ）

調査日: 2026-10-27

確認範囲:全文（問題提起・手法・実験・結果・考察）

Recurrent Diffusion for Large-Scale Parameter Generation

Kai Wang, Dongwen Tang, Wangbo Zhao, Konstantin Schürholt, Zhangyang Wang, Yang You（National University of Singapore）| NeurIPS 2025

1 どんなもの?

パラメータをトークン化し、再帰モデル（Mamba）が出すプロトタイプで 1D 拡散を条件付ける RPG を提案した。ConvNeXt-L（約 2 億パラメータ）の全重みを単一 GPU で約 1.3 分で生成し、ImageNet・COCO・LLaMA-7B 用 DoRA で元モデル並みの性能を得た。

2 先行研究と比べてどこがすごい?

G.pt や p-diff は部分パラメータか数万パラメータ規模にとどまり、主流モデルとは 10^3 倍以上の差があった。D2NWG のように分割して生成すると、層間の相関が失われる。ViT 2 つの層を半分ずつ交換すると精度が崩れる実験で、相関モデリングの必要性を示した。

3 技術や手法のキモはどこ?

層ごとに正規化した重みを固定長トークンに切り、2D 位置埋め込みと one-hot の「置換状態」S を付ける。再帰モデルでプロトタイプ P を作り、$L = E\| \varepsilon - \varepsilon_\theta(K_t, t, P)\|^2$ でトークンを拡散生成する。

4 どうやって有効だと検証した?

ImageNet で ViT-B 84.4→ 生成 84.6%、ConvNeXt-L 85.8→85.8%（Table 1）。推論メモリは約 20GB（Table 7）。CIFAR-10 の二値タスク 1022 種のうち未学習 20 種のうち表示された 10 種で、元 96.7 ～ 98.9% に対し生成 92.9 ～ 96.6%（Table 9）。

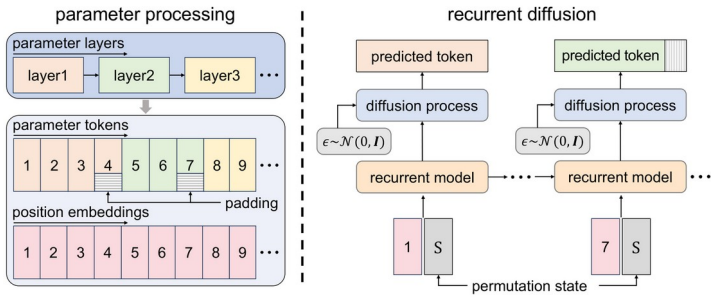
5 議論はある?

著者:新しいアーキテクチャの生成はできず、単一タスク内の関係しかモデル化していない。

所感:訓練データは 1 モデルの微調整チェックポイント 50 個で、置換状態で各チェックポイントを指定する設計は「再現」に近い。未知タスク実験が汎化の唯一の根拠である。

6 次に読むべき論文は?

- ORAL (Khan+ 2025)（未調査）
- Weight Memorization (Zeng+ 2025)（本資料）
- DeepWeightFlow (Gupta+ 2026)（未調査）



出典: RPG Fig. 2（左:層分割・トークン化・位置埋め込み、右:置換状態付き再帰モデル → 拡散でトークンを生成）

書誌情報

発表: NeurIPS 2025
リンク: https://arxiv.org/abs/2501.11587
系譜: 最新（← p-diff (Wang+ 2024)）
調査日: 2026-10-27
確認範囲: 全文（問題提起・手法・実験・結果・考察）

Generative Modeling of Weights: Generalization or Memorization?

Boya Zeng, Yida Yin, Zhiqiu Xu, Zhuang Liu（Princeton University）| CVPR 2026

1 どんなもの?

Hyper-Representations・G.pt・HyperDiffusion・p-diff の 4 手法を検証し、生成された重みは訓練チェックポイントの複製か、せいぜい単純な補間にすぎないことを示した。ノイズ付加や平均化という自明なベースラインにも勝てない。

2 先行研究と比べてどこがすごい?

先行研究は生成モデルの精度だけで評価し、「新規な重み」を主張していた（p-diff など）。本研究は最近傍の訓練重みとの距離、決定境界、誤り IoU を並べ、ノイズ付加ベースラインと同じ新規性の水準で比べる評価手順を確立した。

3 技術や手法のキモはどこ?

生成重みごとに最近傍の訓練重みを L2 距離で探す（置換拡張をした手法は全置換を列挙）。重み値、決定境界・3D 形状、精度対最大類似度のトレードオフで比較する。さらにデータ量・モデル容量・対称性拡張を操作し、記憶の原因を切り分けた。

4 どうやって有効だと検証した?

HyperDiffusion の生成重みの 94.4% は訓練重みとの距離が 10 未満で、訓練重み同士は 50 超（Fig. 4）。p-diff は重み平均・ガウス近似と区別できない（Fig. 8）。G.pt はデータを 10 倍の 2040 万にすると記憶が減った（距離 2.25→2.78、Fig. 9）。

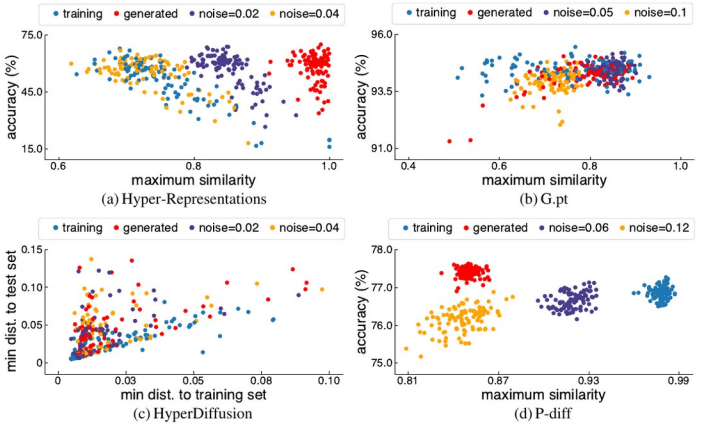
5 議論はある?

著者:原因はデータ不足・過剰な容量・構造的事前知識の不足。置換拡張だけでは HyperDiffusion が学習できず、対称性を構造で組み込む必要がある。

所感:重み生成の評価基準を変えた転換点の論文。以後の論文は記憶の否定を示す義務を負った。

6 次に読むべき論文は?

- HyperDiffusion (Erkoç+ 2023)（未調査）
- PEFM (Piven+ 2026)（本資料）
- NNiT (Kim+ 2026)（未調査）



出典: Weight Memorization Fig. 6（4 手法の精度と最大類似度。赤が生成、紫・橙がノイズ付加。p-diff 以外はノイズ付加に勝てない）

書誌情報

発表: CVPR 2026
リンク: https://arxiv.org/abs/2506.07998
系譜: 最新（← p-diff (Wang+ 2024)）
調査日: 2026-10-27
確認範囲: 全文（問題提起・手法・実験・結果・考察）

Permutation-Equivariant Flow Matching for Alignment-Free Neural Weight Generation

Arkadi Piven, Yam Eitan, Guy Bar-Shalom ほか(Technion, TU Munich, NVIDIA)| arXiv プレプリント 2026

1 どんなもの?

フローマッチングの速度場を置換等変な Graph Meta Network で表し、独立に学習された最大 10 万個のネットワークから、整列なしで重みを生成した。精度・機能類似度・重み類似度の同時分布が訓練集団に近く、記憶ではない生成の証拠を示した。

2 先行研究と比べてどこがすごい?

p-diff・RPG は単一学習のチェックポイントを集め(事前整列)、SANE・DeepWeightFlow は Git Re-Basin で事後整列していた。どちらも独立学習モデルの集団には適用しにくく、Zeng+ 2025 の記憶批判にも答えていない。PEFM は対称性を構造に組み込み、両方を解消した。

3 技術や手法のキモはどこ?

初期分布と学習手続きが置換不変なら、学習済み重み分布も置換不変になり、最適な FM 速度場は等変になることを示した。そこで v_θ(G, w_t, t, c) を GMN (AdaLN で時刻・タスク条件)で表す。等変なので整列しても目的関数は変わらない。

4 どうやって有効だと検証した?

MNIST・CIFAR-10 で、精度・最大誤り IoU・重みコサイン類似度を合わせた JWS が 0.91/0.92 。ベースラインは最大 0.59/0.64 (Table 1)。20 タブラー課題・16 アーキの混合集団で平均精度 82.2% (参照 83.2%)。未知の幅 0.5 倍で 79.0% を得た(Fig. 6)。

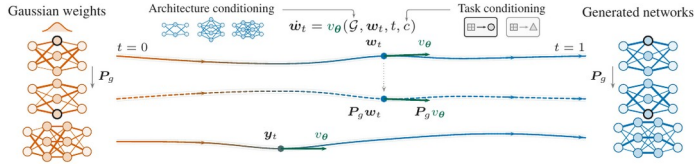
5 議論はある?

著者:対象は小規模ネットワークのみで、密なグラフ表現は大規模化でメモリを食う。条件はタスク ID で、未知タスクの生成は評価していない。

所感:記憶批判に正面から応えた評価設計が要点。基盤モデル規模で同じ主張が成り立つかは未知数。

6 次に読むべき論文は?

- DeepWeightFlow (Gupta+ 2026) (未調査)
- Geometric Flow Models over Neural Network Weights (Erdogan 2025) (未調査)
- Weight Memorization (Zeng+ 2025) (本資料)



出典: PEFM Fig. 2 (アーキ G・タスク c で条件付けた共有速度場。置換 P_g は軌道と速度を同じく置換し、機能が等価なネットワークを生む)

書誌情報

発表: arXiv プレプリント 2026
リンク: https://arxiv.org/abs/2609.32833
系譜: 最新(← GMN (Lim+ 2024))
調査日: 2026-10-27
確認範囲: 全文(問題提起・手法・実験・結果・考察)

Graph Metanetworks for Transformer Based Language Models

Yonathan Wolanowsky, Guy Bar-Shalom, Fabrizio Frasca, Haggai Maron（Technion）| arXiv プレプリント 2026

1 どんなもの?

decoder-only 言語モデル全体の重み空間対称性群を定式化した。その群とグラフ同型が一致するグラフ構成「GMT」を提案し、学習コーパス比率の予測や微調整の検出（どの重みが変わったか）で既存メタネットを上回った。

2 先行研究と比べてどこがすごい?

GMN・Neural Graphs は注意層の GL 対称性を無視し、ヘッド構造も正しく符号化していなかった。Tran+ の NFN-T は GL 対称性を扱えるが、単一アーキに固定されている。埋め込み・語彙置換まで含めた言語モデル全体の扱いは、これまでなかった。

3 技術や手法のキモはどこ?

群は FF ニューロン置換・残差流置換・ヘッドごとの GL(d_k)×GL(d_v)・ヘッド置換・語彙置換の積。GMT-GL は $W_q W_k^T$ と $W_v W_O$ を辺に載せ、パラメータを持たない結合辺とヘッドノードで置換を連動させる。軽量版の GMT-P も用意した。

4 どうやって有効だと検証した?

9 万〜15 万パラメータの LM 集団でのコーパス比率予測で、KL は GMT-GL 0.124（GMN 0.170、MLP 0.264、Table 2）。4000 個の LoRA 微調整検出で AUC 0.956（GMN 0.936、Table 4）。重み単位の検出は Macro-F1 0.952（GMN 0.904、Table 5）。

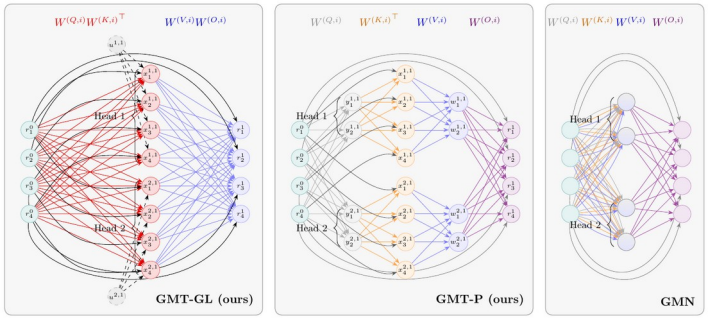
5 議論はある?

著者:スケール・符号対称性は未対応で、実験は数百万パラメータまで。タスクは監査用途の小規模な代理問題。

所感:重み空間学習を LLM 監査（来歴・改変検出）へ向ける動き。実用 LLM 規模への拡張と、生成側への応用が次の課題である。

6 次に読むべき論文は?

- Equivariant NFN for Transformers (Tran+ 2024)（未調査）
- Learning on LoRAs (Putterman+ 2024)（未調査）
- Interfaces and Modules (Kozyra & Bronstein 2026)（未調査）



出典: GMT Fig. 1（2 ヘッド注意層のグラフ構成。左 GMT-GL、中 GMT-P、右 従来の GMN）

書誌情報

発表: arXiv プレプリント 2026
リンク: https://arxiv.org/abs/2610.18471
系譜: 最新（← GMN (Lim+ 2024)）
調査日: 2026-10-27
確認範囲: 全文（問題提起・手法・実験・結果・考察）